

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC MÁY TÍNH

LÊ HỒNG HIỂN

LUẬN VĂN THẠC SĨ

GIẢI PHÁP KẾT HỢP ONTOLOGY VÀ
MÔ HÌNH NGÔN NGỮ LỚN ĐỂ THIẾT
KẾ HỆ THỐNG TƯ VẤN KIẾN THỨC
VỀ QUY ĐỊNH ĐÀO TẠO SAU ĐẠI HỌC

INTEGRATING ONTOLOGY AND
LARGE LANGUAGE MODELS TO
DESIGN AN ADVISORY SYSTEM FOR
POSTGRADUATE EDUCATION
REGULATIONS

THẠC SĨ NGÀNH KHOA HỌC MÁY TÍNH

TP. HỒ CHÍ MINH, NĂM 2026

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC MÁY TÍNH

LÊ HỒNG HIỂN - 210101006

LUẬN VĂN THẠC SĨ

GIẢI PHÁP KẾT HỢP ONTOLOGY VÀ
MÔ HÌNH NGÔN NGỮ LỚN ĐỂ THIẾT
KẾ HỆ THỐNG TƯ VẤN KIẾN THỨC
VỀ QUY ĐỊNH ĐÀO TẠO SAU ĐẠI HỌC

INTEGRATING ONTOLOGY AND
LARGE LANGUAGE MODELS TO
DESIGN AN ADVISORY SYSTEM FOR
POSTGRADUATE EDUCATION
REGULATIONS

THẠC SĨ NGÀNH KHOA HỌC MÁY TÍNH

GIẢNG VIÊN HƯỚNG DẪN
PGS. TS. NGUYỄN ĐÌNH HIỂN
TS. NGÔ QUỐC HÙNG

TP. HỒ CHÍ MINH, NĂM 2026

Thông tin hội đồng chấm luận văn thạc sĩ

Hội đồng chấm luận văn thạc sĩ, thành lập theo Quyết định số.../QĐ-ĐHCNTT ngày ... tháng ... năm 2026 của Hiệu trưởng Trường Đại học Công nghệ Thông tin.

- | | |
|--------|-------------|
| 1. ... | Chủ tịch |
| 2. ... | Phản biện 1 |
| 3. ... | Phản biện 2 |
| 4. ... | Ủy viên |
| 5. ... | Thư ký |

Lời cam đoan

Tôi xin cam đoan đây là công trình nghiên cứu của riêng tôi, được thực hiện dưới sự hướng dẫn khoa học của PGS. TS. Nguyễn Đình Hiến và TS. Ngô Quốc Hưng. Các số liệu, kết quả nêu trong luận văn là trung thực và chưa từng được ai công bố trong bất kỳ công trình nào khác.

Tôi xin chịu trách nhiệm về nghiên cứu của mình.

Thành phố Hồ Chí Minh, ngày 04 tháng 05 năm 2026

Người thực hiện

Lê Hồng Hiến

Lời cảm ơn

Xin chân thành cảm ơn quý thầy cô trong trường Đại học Công Nghệ Thông Tin, ĐHQG-HCM đã tận tình dạy bảo cho em nhiều kiến thức bổ ích trong suốt thời gian học tập tại trường, cũng như tạo điều kiện cho em thực hiện đề tài này. Kính chúc quý thầy cô luôn dồi dào sức khỏe và thành công trong cuộc sống.

Đặc biệt, em xin bày tỏ lòng biết ơn chân thành đến PGS. TS. Nguyễn Đình Hiến, người thầy đã tận tâm, nhiệt tình hướng dẫn và chỉ bảo cho em trong suốt quá trình thực hiện đề tài. Em cũng xin gửi lời cảm ơn đến TS. Ngô Quốc Hưng (University College Dublin), người đồng hướng dẫn đã hỗ trợ về mặt học thuật quốc tế và đóng góp nhiều góp ý về phương pháp nghiên cứu.

Tôi cũng xin gửi lời cảm ơn đến ThS. Đặng Việt Dũng đã hỗ trợ và giúp đỡ tôi trong quá trình nghiên cứu.

Tôi cũng không quên gửi lời cảm ơn đến tác giả của các báo cáo nghiên cứu khoa học mà tôi đã tham khảo và tìm hiểu cho đề tài.

Luận văn đã hoàn thành với một số kết quả nhất định tuy nhiên vẫn không tránh khỏi thiếu sót. Kính mong sự cảm thông và đóng góp ý kiến từ quý thầy cô và các bạn.

Một lần nữa tôi xin chân thành cảm ơn!

Thành phố Hồ Chí Minh, ngày 04 tháng 05 năm 2026

Người thực hiện

Lê Hồng Hiến

Mục lục

Thông tin hội đồng chấm luận văn thạc sĩ	i
Lời cam đoan	iii
Lời cảm ơn	v
Mục lục	vi
Danh sách hình vẽ	x
Danh sách bảng	xi
Danh mục thuật ngữ tiếng Anh	xiii
1 Tổng quan	1
1.1 Giới thiệu đề tài	1
1.1.1 Bối cảnh và động lực nghiên cứu	1
1.1.2 Hiện trạng các hệ thống chatbot giáo dục tại Việt Nam	2
1.1.3 Thách thức trong truy xuất thông tin văn bản quy phạm	2
1.2 Mục tiêu và phạm vi nghiên cứu	3
1.2.1 Mục tiêu nghiên cứu	3
1.2.2 Đối tượng	3
1.2.3 Phạm vi nghiên cứu	4
1.3 Bố cục luận văn	5
2 Cơ sở lý thuyết và các công trình liên quan	7

2.1	Các phương pháp truy xuất thông tin	7
2.1.1	Các phương pháp cơ bản	7
2.1.2	Đồ thị tri thức và Ontology	12
2.2	Các phương pháp truy vấn kiến thức pháp lý	13
2.2.1	Ontology và biểu diễn tri thức pháp lý	14
2.2.2	Mô hình ngôn ngữ và NLP cho văn bản pháp lý	15
2.2.3	Truy xuất tăng cường sinh (RAG)	17
2.2.4	Truy xuất dựa trên đồ thị tri thức	19
2.2.5	Hỏi đáp pháp lý tự động	20
3	Thu thập kiến thức và thiết kế giải thuật	23
3.1	Giới thiệu về hệ thống quy chế đào tạo thạc sĩ	23
3.1.1	Tổng quan hệ thống quy chế đào tạo sau đại học tại Việt Nam .	23
3.1.2	Cấu trúc văn bản quy phạm	24
3.1.3	Các quy chế trong phạm vi nghiên cứu	25
3.2	Thu thập dữ liệu	30
3.2.1	Quy trình thu thập và số hóa	30
3.2.2	Các khái niệm chính trong quy chế đào tạo	31
3.2.3	Các mối quan hệ giữa các khái niệm	32
3.2.4	Phân loại chủ đề	33
3.2.5	Nguồn thu thập và phương pháp xây dựng bộ câu hỏi kiểm thử	34
3.2.6	Phân loại câu hỏi theo độ phức tạp	35
3.2.7	Thống kê và phân tích bộ câu hỏi	36
3.3	Tiền xử lý dữ liệu	37
3.3.1	Chuẩn hóa văn bản	37
3.3.2	Xử lý cấu trúc phân cấp	39
3.3.3	Chuẩn bị dữ liệu cho truy xuất	40
3.4	Tổng quan kiến trúc hệ thống	42
3.4.1	Pha ngoại tuyến	42
3.4.2	Pha trực tuyến	47
3.5	Kiến trúc truy xuất 3-Tier KG-RAG	47
3.5.1	Phân tích truy vấn	48
3.5.2	Pipeline truy xuất ba tầng	51

4	Thiết kế hệ thống và thử nghiệm	61
4.1	Kiến trúc hệ thống	61
4.1.1	Yêu cầu hệ thống	61
4.1.2	Kiến trúc triển khai	62
4.2	Kết quả thử nghiệm	65
4.2.1	Thử nghiệm với Quy định đào tạo trường	65
4.2.2	Thử nghiệm với các văn bản luật của VN	72
4.3	Ứng dụng minh họa	78
4.3.1	Kiến trúc ứng dụng	78
4.3.2	Phương pháp sinh câu trả lời IRAC	79
4.3.3	Các tính năng chính	80
4.3.4	Ví dụ minh họa tiêu biểu	81
5	Kết luận và hướng phát triển	87
5.1	Kết quả đề tài	87
5.2	Hạn chế	88
5.3	Hướng phát triển	89
A	Danh sách quy chế đào tạo	91
A.1	QĐ 270/QĐ-ĐHCNTT: Quy chế đào tạo trình độ thạc sĩ của UIT	91
A.2	QĐ 160/QĐ-ĐHQG: Quy chế đào tạo ThS ĐHQG-HCM (khóa 2021)	92
A.3	QĐ 1393/QĐ-ĐHQG: Quy chế đào tạo ThS ĐHQG-HCM (khóa 2022+)	92
A.4	QĐ 218/QĐ-ĐHQG: Sửa đổi bổ sung quy định GVHD	92
A.5	QĐ 851/QĐ-ĐHCNTT: Quy định liên chính học thuật	93
B	Bộ câu hỏi kiểm thử mẫu	95
B.1	Câu hỏi miền quy định đào tạo	95
B.2	Câu hỏi miền pháp luật	95
C	Mẫu quan hệ đồ thị tri thức	99
C.1	Quan hệ REFERENCES (Tham chiếu)	99
C.2	Quan hệ REQUIRES (Yêu cầu)	100
C.3	Thống kê loại quan hệ	100
D	Prompt LLM sử dụng trong hệ thống	103

D.1	Trích xuất thực thể và quan hệ (Pha ngoại tuyến)	103
D.2	Sinh tóm tắt chương (Pha ngoại tuyến)	103
D.3	Sinh tóm tắt điều khoản (Pha ngoại tuyến)	103
D.4	Bước 2: Chọn chương (Pha trực tuyến)	106
D.5	Bước 3: Chọn điều khoản (Pha trực tuyến)	106
D.6	Sinh câu trả lời theo phương pháp IRAC (Pha trực tuyến)	106

Tài liệu tham khảo	109
---------------------------	------------

Danh sách hình vẽ

Hình 3.1	Cấu trúc Document Tree của QĐ 270/QĐ-ĐHCNTT	26
Hình 3.2	Đồ thị con KG chủ đề “bảo vệ luận văn thạc sĩ”	34
Hình 3.3	Kiến trúc hệ thống truy xuất ba tầng	43
Hình 3.4	Quy trình xây dựng tri thức ngoại tuyến	46
Hình 3.5	Pipeline phân tích truy vấn	48
Hình 3.6	Minh họa quá trình duyệt cây ba bước	53
Hình 3.7	Kiến trúc Tầng 2 – truy xuất ngữ nghĩa hai cấp	57
Hình 3.8	Minh họa luồng xử lý end-to-end qua 3 tầng	59
Hình 4.1	Kiến trúc triển khai hệ thống	63
Hình 4.2	Màn hình chào mừng	81
Hình 4.3	Trạng thái truy xuất đang xử lý	81
Hình 4.4	Câu trả lời IRAC với panel nguồn	82
Hình 4.5	Panel trích dẫn nguồn	82
Hình 4.6	Lộ trình truy xuất 3 bước	83

Danh sách bảng

Bảng 2.1	So sánh các công trình liên quan với luận văn	22
Bảng 3.1	Danh sách các quy chế đào tạo trong phạm vi nghiên cứu	26
Bảng 3.2	So sánh điểm khác biệt chính giữa QĐ 160 và QĐ 1393	28
Bảng 3.3	Thống kê kết quả số hóa và phân tích cấu trúc	31
Bảng 3.4	Phân loại chủ đề trong quy chế đào tạo thạc sĩ	35
Bảng 3.5	Thống kê bộ câu hỏi kiểm thử miền quy định đào tạo	37
Bảng 3.6	Ví dụ câu hỏi mẫu từ bộ kiểm thử	38
Bảng 3.7	Thống kê dữ liệu sau tiền xử lý	42
Bảng 3.8	Quy tắc đặt định danh nút trong Document Forest	44
Bảng 3.9	Thống kê Knowledge Graph	45
Bảng 3.10	Sáu loại ý định truy vấn và mẫu nhận diện	49
Bảng 3.11	Phân nhóm từ điển viết tắt (49 mục)	50
Bảng 3.12	Ví dụ phân tích truy vấn trên ba câu hỏi mẫu	51
Bảng 4.1	Công nghệ sử dụng trong hệ thống	63
Bảng 4.2	Kết quả trên miền quy định đào tạo (130 câu hỏi)	68
Bảng 4.3	Kết quả chi tiết trên miền quy định đào tạo (130 câu hỏi)	69
Bảng 4.4	Hit@10 (%) theo nhóm chủ đề trên miền quy định đào tạo	70
Bảng 4.5	Thống kê kho tài liệu miền pháp luật	72
Bảng 4.6	Tỷ lệ Hit (%) trên miền pháp luật (400 câu hỏi)	74
Bảng 4.7	Hit@10 (%) theo miền trên ba lĩnh vực	75
Bảng 4.8	So sánh prompt IRAC giữa miền pháp luật và miền đào tạo	80
Bảng 4.9	So sánh top-5 kết quả truy xuất giữa các hệ thống – Ví dụ 1	83
Bảng 4.10	So sánh top-5 kết quả truy xuất giữa các hệ thống – Ví dụ 2	84
Bảng 4.11	So sánh top-5 kết quả truy xuất giữa các hệ thống – Ví dụ 3	84

Bảng B.1	Câu hỏi mẫu miễn quy định đào tạo (trích 10/130 câu)	96
Bảng B.2	Câu hỏi mẫu miễn pháp luật (trích 10/400 câu)	97
Bảng C.1	Mẫu quan hệ REFERENCES trong KG	99
Bảng C.2	Mẫu quan hệ REQUIRES trong KG	100
Bảng C.3	Top 10 loại quan hệ trong đồ thị tri thức	101
Bảng D.1	Prompt trích xuất thực thể và quan hệ	104
Bảng D.2	Prompt sinh tóm tắt chương	105
Bảng D.3	Prompt sinh tóm tắt điều khoản	105
Bảng D.4	Prompt chọn chương (Bước 2)	106
Bảng D.5	Prompt chọn điều khoản (Bước 3)	107
Bảng D.6	Prompt sinh câu trả lời IRAC – Lĩnh vực pháp luật	107
Bảng D.7	Prompt sinh câu trả lời IRAC – Lĩnh vực đào tạo	108

Danh mục thuật ngữ tiếng Anh

Tiếng Anh	Tiếng Việt
Knowledge Graph	Đồ thị tri thức
Ontology	Bản thể học
Retrieval-Augmented Generation	Retrieval-Augmented Generation (RAG)
Large Language Model	Mô hình ngôn ngữ lớn
Tree Traversal	Duyệt cây
Semantic Retrieval	Truy xuất ngữ nghĩa
Reciprocal Rank Fusion	Reciprocal Rank Fusion (RRF)
Personalized PageRank	PageRank cá nhân hóa
Document Forest	Rừng cây tài liệu
Cross-reference	Tham chiếu chéo
Embedding	Biểu diễn nhúng
Hallucination	Ảo giác
Query Intent	Ý định truy vấn
Hit Rate	Tỷ lệ trúng
Mean Reciprocal Rank	Hạng nghịch đảo trung bình
Summary Tree	Cây tóm tắt
Document Tree	Cây tài liệu
Multi-hop Reasoning	Suy luận đa bước
Knowledge Graph Expansion	Mở rộng đồ thị tri thức

Chương 1

Tổng quan

Chương này trình bày tổng quan về đề tài nghiên cứu, bao gồm giới thiệu bối cảnh và động lực nghiên cứu, mục tiêu và phạm vi nghiên cứu, cũng như bố cục của luận văn.

1.1 Giới thiệu đề tài

1.1.1 Bối cảnh và động lực nghiên cứu

Tại các trường đại học ở Việt Nam, nhiều phòng ban chức năng đã được thành lập để hỗ trợ sinh viên trong học tập, rèn luyện và giải quyết các thủ tục hành chính. Tuy nhiên, do thông tin bị phân tán giữa nhiều phòng ban và các quy định thường khó hiểu, sinh viên gặp nhiều trở ngại trong việc tra cứu, tiếp cận và nắm bắt đầy đủ các quy định đào tạo, nhất là đối với những quy chế mới hoặc có tính chất phức tạp. Sinh viên thường phải liên hệ với nhiều nơi khác nhau cho từng vấn đề, dẫn đến mất thời gian, chờ đợi kéo dài và đôi khi không nhận được thông tin chính xác, kịp thời.

Ngoài ra, các nhu cầu tư vấn về học tập, nghiên cứu khoa học, lựa chọn ngành nghề, điều kiện tốt nghiệp cũng ngày càng đa dạng, trong khi nguồn lực cán bộ tư vấn còn hạn chế. Việc giải thích các quy định đào tạo phức tạp thường đòi hỏi sự tương tác trực tiếp, gây áp lực lớn cho đội ngũ cán bộ và không đáp ứng được nhu cầu hỗ trợ 24/7. Do đó, việc xây dựng một hệ thống tư vấn tự động, thông minh sẽ giúp giảm tải cho cán bộ, tiết kiệm chi phí vận hành, đồng thời nâng cao trải nghiệm và sự hài lòng của sinh viên.

1.1.2 Hiện trạng các hệ thống chatbot giáo dục tại Việt Nam

Gần đây, nhiều trường đại học tại Việt Nam đã tiên phong ứng dụng trí tuệ nhân tạo vào các hệ thống hỗ trợ sinh viên:

- **Chatbot UEB** (Đại học Kinh tế Quốc dân): triển khai dựa trên nền tảng ChatGPT, giúp sinh viên tra cứu thông tin và giải đáp thắc mắc mọi lúc, mọi nơi.
- **UEH AI Chatbot** (Đại học Kinh tế TP.HCM): hỗ trợ tư vấn tuyển sinh, hướng nghiệp cho phụ huynh và học sinh.
- **HUNRE AI Chatbot** (Đại học Tài nguyên và Môi trường Hà Nội): góp phần nâng cao chất lượng phục vụ sinh viên và tối ưu hóa quy trình quản lý đào tạo.

Các ứng dụng chatbot này chủ yếu dựa trên mô hình ngôn ngữ lớn (LLM), đã được triển khai rộng rãi và bước đầu mang lại nhiều tiện ích cho sinh viên. Tuy nhiên, hiện vẫn còn thiếu các nghiên cứu đánh giá định lượng về mức độ chính xác và hiệu quả thực sự của các hệ thống này. Bên cạnh đó, các LLM hiện nay vẫn gặp nhiều hạn chế trong việc xử lý các câu hỏi phức tạp đòi hỏi suy luận logic sâu. Đặc biệt, hiện tượng “ảo giác” (hallucination), tức khi mô hình tạo ra câu trả lời không chính xác hoặc không sát với thực tế, vẫn là một rào cản lớn, có thể dẫn đến việc cung cấp thông tin sai lệch với hậu quả nghiêm trọng đối với sinh viên.

1.1.3 Thách thức trong truy xuất thông tin văn bản quy phạm

Các văn bản quy chế đào tạo tại Việt Nam có cấu trúc phân cấp phức tạp: một quy chế tổ chức nội dung theo các cấp Chương, Điều, Khoản và Điểm, mỗi cấp mang phạm vi quy định riêng biệt. Ngoài ra, các văn bản còn chứa nhiều tham chiếu chéo (cross-reference): để trả lời câu hỏi “*Học viên cao học cần đáp ứng điều kiện gì để được bảo vệ luận văn?*” cần kết nối Điều 24 (điều kiện bảo vệ) trong QĐ 270 của UIT với Điều 25 (yêu cầu ngoại ngữ) trong QĐ 1393 của ĐHQG-HCM, vốn là hai văn bản khác nhau ở hai tầng quản lý.

Tiếng Việt còn tạo thêm thách thức qua sự đa nghĩa thanh điệu, các viết tắt chuyên ngành (GVHD, ThS, NCS, ĐHQG) và hệ thống phân cấp văn bản quy phạm đa tầng (Bộ GD&ĐT, ĐHQG-HCM, trường thành viên). Các phương pháp truy xuất thông tin truyền thống dựa trên vector similarity [28] hiệu quả trong nhiều lĩnh vực [7] nhưng không đủ

cho văn bản quy phạm có cấu trúc: embedding mở đi ý nghĩa chính xác của thuật ngữ chuyên ngành (*semantic gap*), truy xuất phẳng bỏ qua cấu trúc phân cấp tài liệu, và tìm kiếm dày đặc không thể kết nối các tham chiếu chéo giữa các quy chế. Các thách thức tương tự cũng xuất hiện trong lĩnh vực pháp luật Việt Nam, nơi hệ thống được mở rộng đánh giá (Chương 4).

1.2 Mục tiêu và phạm vi nghiên cứu

1.2.1 Mục tiêu nghiên cứu

Luận văn này nghiên cứu và giải quyết các vấn đề sau:

1. **Xây dựng Knowledge Graph và Ontology cho văn bản quy phạm:** Xây dựng pipeline trích xuất tri thức bán tự động sử dụng LLM để trích xuất thực thể và quan hệ từ văn bản quy phạm, kết hợp tinh chỉnh bởi chuyên gia (*expert-in-the-loop*) để tạo KG. Từ KG đã xây dựng, suy luận (*infer*) ontology chuyên biệt theo chuẩn OWL, xác định hệ thống phân cấp các loại thực thể (chủ thể, điều kiện, thời hạn, mức phạt, ...) và quan hệ (*references, requires, depends_on, ...*), phục vụ cho cơ chế Concept Matching trong truy xuất ngữ nghĩa.
2. **Đề xuất kiến trúc truy xuất 3-Tier KG-RAG:** Thiết kế kiến trúc truy xuất ba tầng kết hợp duyệt cây cấu trúc hướng dẫn bởi LLM (Tầng 1), truy xuất ngữ nghĩa hai cấp dựa trên KG và embedding (Tầng 2), và hợp nhất Reciprocal Rank Fusion với mở rộng Knowledge Graph (Tầng 3). Kiến trúc này tận dụng đồng thời cấu trúc phân cấp của văn bản quy phạm, quan hệ ngữ nghĩa trong đồ thị tri thức và tín hiệu tương đồng vector để truy xuất chính xác các điều khoản liên quan.
3. **Xây dựng bộ đánh giá và so sánh định lượng:** Thiết kế các bộ benchmark tiếng Việt gồm các câu hỏi phức tạp yêu cầu suy luận đa bước, tham chiếu chéo giữa các văn bản. Đánh giá hệ thống bằng các chỉ số Hit@k và MRR, so sánh với các phương pháp tiên tiến (PageIndex, RAPTOR, LightRAG).

1.2.2 Đối tượng

Đề tài này nghiên cứu việc tổ chức và truy xuất thông tin từ các văn bản quy phạm có cấu trúc phân cấp để xây dựng một hệ thống hỏi đáp tự động dựa trên đồ thị tri thức

1.2. Mục tiêu và phạm vi nghiên cứu

và mô hình ngôn ngữ lớn. Hệ thống hướng đến đối tượng là học viên cao học, sinh viên sau đại học tại UIT và các trường thuộc ĐHQG-HCM có nhu cầu tra cứu các quy định đào tạo, cũng như cán bộ phòng đào tạo cần hỗ trợ giải đáp thắc mắc cho học viên. Hệ thống cũng có thể mở rộng ra cho người dùng có nhu cầu muốn tra cứu thông tin pháp luật.

1.2.3 Phạm vi nghiên cứu

Phạm vi nghiên cứu bao gồm hai miền ứng dụng: miền quy định đào tạo và miền pháp luật Việt Nam.

Miền quy định đào tạo. Hệ thống được kiểm thử trên 5 bộ quy chế, quy định đào tạo thạc sĩ:

1. Quy chế đào tạo trình độ thạc sĩ của UIT số 270/QĐ-ĐHCNTT ngày 25/04/2022.
2. Quy chế đào tạo trình độ thạc sĩ cho khóa 2021 số 160/QĐ-ĐHQG ngày 24/03/2017 của ĐHQG-HCM.
3. Quy chế đào tạo trình độ thạc sĩ cho khóa từ năm 2022 số 1393/QĐ-ĐHQG ngày 03/11/2021 của ĐHQG-HCM.
4. Quy chế sửa đổi bổ sung số 218/QĐ-ĐHQG ngày 15/03/2024 của ĐHQG-HCM.
5. Quy định về liên chính học thuật số 851/QĐ-ĐHCNTT ngày 14/08/2024 của UIT.

Miền pháp luật Việt Nam. Để chứng minh tính tổng quát của phương pháp, hệ thống được đánh giá bổ sung trên 13 văn bản pháp luật thuộc hai lĩnh vực: luật doanh nghiệp và luật giao thông. Lĩnh vực luật doanh nghiệp bao gồm Luật Doanh nghiệp 2020 (số 59/2020/QH14) cùng các nghị định hướng dẫn thi hành, quy định về thành lập, tổ chức, quản lý, giải thể doanh nghiệp, quyền và nghĩa vụ của các loại hình doanh nghiệp (TNHH, cổ phần, hợp danh). Lĩnh vực luật giao thông bao gồm Nghị định 168/2024/NĐ-CP về xử phạt vi phạm hành chính trong lĩnh vực giao thông đường bộ và các văn bản liên quan, quy định mức phạt cho các hành vi vi phạm cụ thể (vượt đèn đỏ, nồng độ cồn, không giấy phép lái xe). Corpus pháp luật gồm tổng cộng 672 điều khoản, lớn hơn đáng kể so với miền đào tạo (109 điều), cho phép đánh giá khả năng mở rộng của hệ thống. Bộ kiểm thử miền pháp luật gồm 400 câu hỏi do chuyên gia gán nhãn, bao gồm các tình

huống single-hop, multi-hop, và reasoning phức tạp yêu cầu kết hợp thông tin từ nhiều điều khoản thuộc các văn bản khác nhau.

1.3 Bố cục luận văn

Phần còn lại của luận văn được tổ chức như sau:

- **Chương 2: Cơ sở lý thuyết và các công trình liên quan:** trình bày các phương pháp truy xuất thông tin (truy xuất thưa, truy xuất dày đặc, đồ thị tri thức, ontology, Retrieval-Augmented Generation) và khảo sát các phương pháp truy vấn kiến thức pháp lý liên quan.
- **Chương 3: Thu thập kiến thức và thiết kế giải thuật:** trình bày tổng quan hệ thống quy chế đào tạo thạc sĩ, quy trình thu thập và tổ chức kiến thức từ văn bản quy phạm, xây dựng bộ câu hỏi kiểm thử; tiếp đó trình bày chi tiết kiến trúc 3-Tier KG-RAG bao gồm phân tích truy vấn, duyệt cây cấu trúc, truy xuất ngữ nghĩa hai cấp và hợp nhất RRF với mở rộng Knowledge Graph.
- **Chương 4: Thiết kế hệ thống và thử nghiệm:** trình bày kiến trúc triển khai, kết quả thử nghiệm trên hai miền (quy định đào tạo và pháp luật Việt Nam), và ứng dụng chatbot minh họa.
- **Chương 5: Kết luận và hướng phát triển:** tổng kết các kết quả đạt được, thảo luận hạn chế và đề xuất hướng phát triển tương lai.

Chương 2

Cơ sở lý thuyết và các công trình liên quan

Chương này trình bày các nền tảng lý thuyết được sử dụng trong luận văn và tổng hợp các công trình liên quan. Phần 2.1 giới thiệu các phương pháp truy xuất thông tin, từ phương pháp cơ bản đến đồ thị tri thức. Phần 2.2 khảo sát các công trình nghiên cứu liên quan và xác định vị trí đóng góp của luận văn.

2.1 Các phương pháp truy xuất thông tin

Phần này trình bày các phương pháp truy xuất thông tin được sử dụng trong luận văn, bao gồm các phương pháp cơ bản (truy xuất thưa, truy xuất dày đặc, xếp hạng và hợp nhất) và các phương pháp dựa trên đồ thị tri thức.

2.1.1 Các phương pháp cơ bản

Truy xuất thông tin (Information Retrieval – IR) là bài toán tìm kiếm các tài liệu liên quan từ một kho dữ liệu lớn dựa trên truy vấn của người dùng [18]. Một hệ thống IR nhận đầu vào là truy vấn q và kho tài liệu $\mathcal{D} = \{d_1, d_2, \dots, d_N\}$, trả về danh sách xếp hạng các tài liệu theo mức độ liên quan giảm dần. Các phương pháp truy xuất được chia thành hai nhóm chính: truy xuất thưa (sparse retrieval) dựa trên so khớp thuật ngữ, và truy xuất dày đặc (dense retrieval) dựa trên biểu diễn ngữ nghĩa.

2.1. Các phương pháp truy xuất thông tin

Chỉ mục ngược. Chỉ mục ngược (inverted index) là cấu trúc dữ liệu nền tảng cho truy xuất văn bản. Với mỗi thuật ngữ t trong từ vựng, chỉ mục lưu danh sách các tài liệu chứa t cùng thông tin hỗ trợ như tần suất xuất hiện và vị trí. Khi nhận truy vấn, hệ thống tra cứu chỉ mục cho từng thuật ngữ trong truy vấn, giao các danh sách tài liệu, rồi tính điểm xếp hạng. Cấu trúc này cho phép truy xuất trong thời gian gần tuyến tính theo kích thước kết quả, thay vì quét toàn bộ kho tài liệu.

BM25 và TF-IDF. BM25 (Best Matching 25) [29] là hàm xếp hạng dựa trên mô hình xác suất, kết hợp tần suất thuật ngữ (TF), tần suất tài liệu ngược (IDF) với chuẩn hóa độ dài tài liệu và bão hòa tần suất. BM25 cải tiến từ TF-IDF [18] — phương pháp biểu diễn tài liệu bằng vector trọng số thuật ngữ — bằng cách xử lý hiệu quả hơn sự chênh lệch độ dài giữa các tài liệu. Cả hai phương pháp đều thuộc nhóm truy xuất thưa (sparse retrieval): nhanh, dễ giải thích, và hiệu quả khi thuật ngữ trong truy vấn trùng khớp với tài liệu. Tuy nhiên, truy xuất thưa thất bại trước bài toán bất khớp từ vựng (vocabulary mismatch) [28]: người dùng hỏi “*mở công ty cần gì*” trong khi văn bản quy định dùng thuật ngữ “*đăng ký thành lập doanh nghiệp*”. Hạn chế này thúc đẩy sự phát triển của truy xuất dày đặc và truy xuất lai.

Các chỉ số đánh giá truy xuất. Luận văn sử dụng hai chỉ số đánh giá chính [18]:

Hit@ k (Top- k Hit Rate) đo tỷ lệ truy vấn mà ít nhất một tài liệu liên quan xuất hiện trong k kết quả hàng đầu:

$$\text{Hit}@k = \frac{1}{|Q|} \sum_{q \in Q} \mathbf{1}[\exists a \in R_q : \text{rank}(a) \leq k] \quad (2.1)$$

trong đó Q là tập truy vấn, R_q là tập tài liệu liên quan của truy vấn q , và $\mathbf{1}[\cdot]$ là hàm chỉ báo. Hit@10 được chọn làm chỉ số chính vì trong pipeline RAG, mô hình ngôn ngữ lớn đóng vai trò lọc bổ sung trên ngữ cảnh đã truy xuất; chỉ cần một điều khoản đúng trong 10 ứng viên là đủ để sinh câu trả lời chính xác.

MRR (Mean Reciprocal Rank) trung bình hạng nghịch đảo của tài liệu liên quan đầu tiên:

$$\text{MRR} = \frac{1}{|Q|} \sum_{q \in Q} \frac{1}{\min_{a \in R_q} \text{rank}(a)} \quad (2.2)$$

2.1. Các phương pháp truy xuất thông tin

MRR bổ sung cho Hit@ k bằng cách thưởng cho việc đặt tài liệu liên quan ở vị trí cao hơn, giúp giảm nhiễu mà mô hình ngôn ngữ phải lọc.

Embedding câu. Truy xuất thưa dựa trên so khớp thuật ngữ không nắm bắt được tương đồng ngữ nghĩa giữa các cách diễn đạt khác nhau của cùng một khái niệm. Truy xuất dày đặc (dense retrieval) giải quyết vấn đề này bằng cách biểu diễn cả truy vấn và tài liệu dưới dạng vector trong không gian liên tục, nơi khoảng cách vector phản ánh mức độ tương đồng ngữ nghĩa.

Sentence-BERT (SBERT) [28] mở rộng kiến trúc BERT bằng mạng Siamese để tính embedding cấp câu một cách độc lập. Mỗi câu s được mã hóa thành vector $\mathbf{v}_s \in \mathbb{R}^d$ (với $d = 384$ trong mô hình đa ngôn ngữ paraphrase-multilingual-MiniLM-L12-v2 mà luận văn sử dụng). Mức độ tương đồng giữa hai câu s_1 và s_2 được tính bằng cosine similarity:

$$\text{sim}(s_1, s_2) = \frac{\mathbf{v}_{s_1} \cdot \mathbf{v}_{s_2}}{\|\mathbf{v}_{s_1}\| \cdot \|\mathbf{v}_{s_2}\|} \quad (2.3)$$

Ưu điểm chính của SBERT so với BERT gốc: câu hỏi và tài liệu được mã hóa *độc lập*, cho phép tính trước embedding của toàn bộ kho tài liệu và truy xuất bằng tìm kiếm vector thay vì so khớp từng cặp. SBERT giảm thời gian tìm kiếm từ 65 giờ (so khớp cặp với BERT) xuống khoảng 5 giây cho 10.000 câu.

Tìm kiếm vector với FAISS. FAISS (Facebook AI Similarity Search) là thư viện tìm kiếm vector cho phép truy xuất các vector gần nhất từ tập dữ liệu lớn. Luận văn sử dụng FAISS để xây dựng chỉ mục vector cho các embedding điều khoản, hỗ trợ tìm kiếm tương đồng ngữ nghĩa tại Tầng 2 của pipeline truy xuất. Với kho tài liệu gồm N điều khoản, FAISS cho phép tìm k điều khoản gần nhất trong thời gian gần hằng số thông qua các cấu trúc chỉ mục tối ưu (flat index, IVF, HNSW).

Truy xuất lai. Truy xuất thưa giỏi so khớp thuật ngữ chính xác nhưng bỏ sót tương đồng ngữ nghĩa; truy xuất dày đặc nắm bắt ngữ nghĩa nhưng có thể bỏ qua tín hiệu từ vựng quan trọng [7]. Truy xuất lai (hybrid retrieval) kết hợp cả hai bằng cách chạy song song BM25 và tìm kiếm vector, sau đó hợp nhất kết quả thông qua phương pháp như Reciprocal Rank Fusion (RRF). Cách tiếp cận này đã trở thành chuẩn công nghiệp cho các hệ thống RAG [7], và là nền tảng mà kiến trúc 3-Tier KG-RAG của luận văn mở

2.1. Các phương pháp truy xuất thông tin

rộng: thay vì chỉ kết hợp hai nguồn tín hiệu (thưa và dày đặc), luận văn hợp nhất ba tầng truy xuất gồm duyệt cây cấu trúc, tìm kiếm ngữ nghĩa hai cấp, và mở rộng đồ thị tri thức.

Xếp hạng lại. Trong kiến trúc truy xuất hai giai đoạn (two-stage retrieval), giai đoạn đầu dùng phương pháp nhanh (BM25 hoặc bi-encoder) để lọc N ứng viên từ kho tài liệu lớn; giai đoạn hai dùng cross-encoder — mô hình xử lý đồng thời cặp (truy vấn, tài liệu) — để xếp hạng lại chính xác hơn [25]. Cross-encoder đạt độ chính xác cao hơn bi-encoder nhưng có chi phí tính toán $O(N)$ theo số ứng viên, nên chỉ áp dụng trên tập nhỏ đã lọc. Các nghiên cứu cho thấy reranking cải thiện 33–40% độ chính xác với chỉ 120ms chi phí bổ sung. Luận văn không sử dụng cross-encoder generic mà thay thế bằng cơ chế chuyên biệt miền: KG expansion tại Tầng 3 đóng vai trò “xếp hạng lại dựa trên tri thức” — bổ sung các điều khoản liên quan thông qua quan hệ trong đồ thị tri thức thay vì chỉ dựa trên tương đồng ngữ nghĩa bề mặt.

Truy xuất tăng cường bởi LLM. Sự phát triển của các mô hình ngôn ngữ lớn (LLM) đã mở ra paradigm mới trong truy xuất thông tin: sử dụng LLM không chỉ để sinh câu trả lời mà còn để cải thiện chính quá trình truy xuất [35]. HyDE (Hypothetical Document Embeddings) [8] tạo tài liệu giả định từ truy vấn rồi dùng embedding của tài liệu đó để tìm kiếm, giúp thu hẹp khoảng cách ngữ nghĩa giữa truy vấn ngắn và tài liệu dài. Step-Back Prompting trừu tượng hóa truy vấn cụ thể thành câu hỏi tổng quát hơn để mở rộng phạm vi truy xuất. Các hệ thống Agentic RAG [1] cho phép LLM tự đánh giá và điều chỉnh chiến lược truy xuất qua nhiều vòng lặp. Tầng 1 của luận văn thuộc paradigm này: sử dụng LLM để phân tích truy vấn và điều hướng trên cấu trúc phân cấp của văn bản quy phạm (duyệt cây chương–điều), thay vì tìm kiếm trực tiếp trên toàn bộ kho tài liệu.

Personalized PageRank. PageRank [9] là thuật toán xếp hạng nút trên đồ thị, ban đầu được thiết kế để đo tầm quan trọng của trang web dựa trên cấu trúc liên kết. Personalized PageRank (PPR) [11, 13] mở rộng PageRank bằng cách thiên lệch (bias) phân phối xác suất về một tập nút nguồn cụ thể, cho phép đo tầm quan trọng *tương đối so với* nút nguồn thay vì tầm quan trọng toàn cục.

PPR được tính theo công thức lặp:

2.1. Các phương pháp truy xuất thông tin

$$\text{PPR}(v) = (1 - \alpha) \sum_{u \in N(v)} \frac{w(u, v) \cdot \text{PPR}(u)}{d^+(u)} + \alpha \cdot p(v) \quad (2.4)$$

trong đó:

- $\alpha \in (0, 1)$ là xác suất dịch chuyển tức thời (teleport probability), kiểm soát tỷ lệ giữa duyệt đồ thị và quay về nút nguồn;
- $N(v)$ là tập nút kề có cạnh hướng đến v ;
- $w(u, v)$ là trọng số cạnh từ u đến v ;
- $d^+(u) = \sum_{v' \in N^+(u)} w(u, v')$ là tổng trọng số cạnh đi ra từ u ;
- $p(v)$ là vector cá nhân hóa (personalization vector), phân phối xác suất trên các nút nguồn.

Trực giác: PPR mô phỏng bước đi ngẫu nhiên (random walk) trên đồ thị, trong đó tại mỗi bước, người đi hoặc theo một cạnh ngẫu nhiên (xác suất $1 - \alpha$) hoặc nhảy về nút nguồn (xác suất α). Sau khi hội tụ, các nút có giá trị PPR cao là những nút “gần” với nút nguồn theo cấu trúc đồ thị. Thuật toán hội tụ khi $\max_v |\text{PPR}^{(t)}(v) - \text{PPR}^{(t-1)}(v)| < \varepsilon$ (luận văn sử dụng $\alpha = 0,15$, $\varepsilon = 10^{-6}$, tối đa 50 vòng lặp).

Trong luận văn, PPR được áp dụng trên đồ thị tri thức pháp lý tại Tầng 2 của pipeline truy xuất. Vector cá nhân hóa $p(v)$ được khởi tạo từ các thực thể khớp với truy vấn (seed entities), và trọng số cạnh $w(u, v)$ được điều chỉnh theo ý định truy vấn (intent-aware): các cạnh dẫn đến thực thể liên quan đến ý định nhận trọng số 1,0, các cạnh khác nhận 0,5. Cơ chế này cho phép PPR ưu tiên các đường suy luận phù hợp với loại câu hỏi.

Reciprocal Rank Fusion. Reciprocal Rank Fusion (RRF) [3] là phương pháp kết hợp nhiều danh sách xếp hạng thành một danh sách duy nhất. RRF không yêu cầu điểm số thô (raw score) từ các hệ thống thành phần, chỉ cần thứ hạng, giúp kết hợp được các hệ thống có thang điểm khác nhau. Điểm RRF của tài liệu d được tính:

$$\text{RRF}(d) = \sum_{s=1}^S w_s \cdot \frac{1}{k + \text{rank}_s(d)} \quad (2.5)$$

2.1. Các phương pháp truy xuất thông tin

trong đó S là số danh sách nguồn, w_s là trọng số của nguồn thứ s , $\text{rank}_s(d)$ là thứ hạng của d trong nguồn s (bắt đầu từ 1), và k là hằng số điều hòa (thường $k = 60$) giúp giảm ảnh hưởng quá mức của các tài liệu xếp hạng rất cao.

RRF phù hợp cho bài toán của luận văn vì ba tầng truy xuất sử dụng các phương pháp khác nhau (duyet cây, embedding, đồ thị) với thang điểm không tương thích. RRF cho phép kết hợp chúng chỉ dựa trên thứ hạng, tận dụng thế mạnh bổ trợ của từng tầng.

2.1.2 Đồ thị tri thức và Ontology

Đồ thị tri thức. Đồ thị tri thức (Knowledge Graph – KG) là cấu trúc dữ liệu biểu diễn tri thức dưới dạng đồ thị có hướng, trong đó các nút biểu diễn thực thể và các cạnh biểu diễn quan hệ giữa chúng. Mỗi đơn vị tri thức được biểu diễn bằng một bộ ba (triple):

$$(h, r, t) \in \mathcal{E} \times \mathcal{R} \times \mathcal{E} \quad (2.6)$$

trong đó h (head) là thực thể nguồn, r (relation) là quan hệ, t (tail) là thực thể đích, $\mathcal{E}$ là tập thực thể và $\mathcal{R}$ là tập loại quan hệ. Ví dụ, bộ ba (*Điều 24, requires, ngoại ngữ B1*) biểu diễn rằng Điều 24 yêu cầu trình độ ngoại ngữ B1.

Trong ngữ cảnh luận văn, KG được xây dựng từ văn bản quy phạm với hai vai trò: biểu diễn các quan hệ ngữ nghĩa giữa điều khoản (tham chiếu, phụ thuộc, điều kiện) phục vụ suy luận đa bước, và cung cấp thông tin thực thể cho truy xuất ngữ nghĩa tại Tầng 2.

Ontology và OWL. Ontology là mô hình hình thức định nghĩa các khái niệm (concept), thuộc tính (property), và quan hệ (relation) trong một miền tri thức cụ thể. Ontology cung cấp lược đồ (schema) cho đồ thị tri thức, xác định các loại thực thể hợp lệ và các loại quan hệ giữa chúng.

OWL (Web Ontology Language) là ngôn ngữ chuẩn W3C cho biểu diễn ontology, hỗ trợ phân cấp lớp (class hierarchy), ràng buộc thuộc tính (property restrictions), và suy luận logic. Luận văn sử dụng OWL để định nghĩa ontology miền với 14 loại thực thể (Action, Legal Term, Organization, Penalty, Condition, v.v.) tổ chức theo phân cấp 4 cấp, kèm ảnh xạ nhãn tiếng Việt. Ontology miền phục vụ hai mục đích: hướng dẫn quá trình trích xuất thực thể từ văn bản (đảm bảo tính nhất quán về loại), và cung cấp thông tin loại thực thể cho cơ chế Concept Matching tại Tầng 2.

2.2. Các phương pháp truy vấn kiến thức pháp lý

Document Forest. Các văn bản quy phạm Việt Nam có cấu trúc phân cấp nghiêm ngặt: Văn bản $\rightarrow$ Chương $\rightarrow$ Mục $\rightarrow$ Điều $\rightarrow$ Khoản $\rightarrow$ Điểm. Mỗi tài liệu được mô hình hóa dưới dạng cây có gốc (rooted tree), và toàn bộ kho tài liệu gồm m văn bản tạo thành Document Forest $\mathcal{F} = \{T_1, T_2, \dots, T_m\}$, được bổ sung các cạnh tham chiếu chéo liên kết các điều khoản giữa các cây. Cấu trúc Document Forest cho phép duyệt cây top-down (từ văn bản xuống điều khoản) và mở rộng ngang (cross-reference) giữa các văn bản.

Retrieval-Augmented Generation. Retrieval-Augmented Generation (RAG) [17] là kiến trúc kết hợp bộ truy xuất (retriever) với mô hình ngôn ngữ lớn (LLM) để sinh câu trả lời có căn cứ từ tài liệu nguồn. Pipeline RAG cơ bản gồm ba bước:

1. **Truy xuất (Retrieve):** Cho truy vấn q , bộ truy xuất tìm k tài liệu liên quan nhất $\{d_1, \dots, d_k\}$ từ kho dữ liệu.
2. **Tăng cường (Augment):** Các tài liệu được ghép vào prompt cùng truy vấn, tạo thành ngữ cảnh cho LLM.
3. **Sinh (Generate):** LLM sinh câu trả lời dựa trên ngữ cảnh đã truy xuất, giảm thiểu hiện tượng ảo giác (hallucination) bằng cách neo (ground) nội dung vào tài liệu cụ thể.

RAG giải quyết hai hạn chế chính của LLM đơn thuần: kiến thức bị đóng băng tại thời điểm huấn luyện (knowledge cutoff), và xu hướng sinh thông tin sai khi thiếu ngữ cảnh (hallucination). Trong miền pháp lý, RAG đặc biệt quan trọng vì câu trả lời phải trích dẫn được điều khoản cụ thể và phản ánh đúng quy định hiện hành.

Tuy nhiên, chất lượng câu trả lời của RAG phụ thuộc trực tiếp vào chất lượng truy xuất. Nếu bộ truy xuất không tìm được điều khoản đúng, LLM hoặc bỏ sót thông tin quan trọng hoặc sinh nội dung không chính xác dựa trên điều khoản không liên quan. Đây là động lực thiết kế pipeline truy xuất ba tầng trong luận văn: kết hợp nhiều phương pháp truy xuất bổ trợ để tăng khả năng tìm được điều khoản liên quan.

2.2 Các phương pháp truy vấn kiến thức pháp lý

Bài toán thu thập, biểu diễn, và truy xuất kiến thức pháp lý là một lĩnh vực nghiên cứu có lịch sử lâu dài trong trí tuệ nhân tạo và luật học tính toán (computational law). Phần

2.2. Các phương pháp truy vấn kiến thức pháp lý

này trình bày năm hướng nghiên cứu chính liên quan đến luận văn: ontology pháp lý, mô hình ngôn ngữ cho văn bản pháp lý, truy xuất tăng cường sinh (Retrieval-Augmented Generation), truy xuất dựa trên đồ thị tri thức, và hỏi đáp pháp lý tự động.

2.2.1 Ontology và biểu diễn tri thức pháp lý

Sartor và cộng sự [31] trình bày một tuyển tập các phương pháp xây dựng ontology pháp lý, phân biệt ba tầng: *ontology trên* (upper ontology) định nghĩa các khái niệm trừu tượng như quy tắc (norm), chủ thể (agent), hành vi (action); *ontology miền* (domain ontology) đặc tả cho từng lĩnh vực pháp luật cụ thể; và *ontology ứng dụng* (application ontology) phục vụ tác vụ riêng biệt. Các tác giả nhấn mạnh rằng ontology pháp lý là nền tảng thiết yếu cho việc xử lý, truy xuất, và suy luận tự động trên thông tin pháp lý trong bối cảnh Semantic Web. Mô hình ba tầng này được xác nhận là tối ưu cho việc biểu diễn tri thức pháp lý trong các bối cảnh khác nhau, từ suy luận logic đến truy xuất tài liệu. Luận văn áp dụng mô hình phân tầng này, trong đó ontology miền cho quy chế đào tạo được tự động sinh bởi LLM (14 loại thực thể) kết hợp tinh chỉnh thủ công.

Nguyen T. và cộng sự [24] đề xuất Legal-Onto, mô hình hai lớp cho biểu diễn tri thức văn bản pháp luật: lớp ontology định nghĩa các khái niệm và quan hệ trong văn bản pháp luật, còn lớp Knowledge Graph hiện thực hóa ontology phục vụ truy xuất thông minh. Mô hình được thiết kế cho văn bản pháp luật Việt Nam, tập trung vào cấu trúc phân cấp (chương, mục, điều, khoản) và các quan hệ giữa các điều khoản. Cách tiếp cận hai lớp này cho phép tách biệt rõ ràng giữa định nghĩa khái niệm (conceptual layer) và triển khai kỹ thuật (implementation layer), tạo điều kiện cho việc tái sử dụng ontology qua nhiều ứng dụng khác nhau. Luận văn kế thừa ý tưởng tích hợp ontology–Knowledge Graph từ Legal-Onto, nhưng mở rộng bằng việc bổ sung quan hệ ngữ nghĩa (synonym, related, prerequisite) bên cạnh quan hệ cấu trúc.

Do N. V. và cộng sự [5] đề xuất Rela-model, khung biểu diễn tri thức dựa trên ontology cho hệ thống chuyên gia, bao gồm ba thành phần: khái niệm (concept), quan hệ (relation), và quy tắc (rule). Mô hình sử dụng ngôn ngữ đặc tả hình thức để mô tả cấu trúc tri thức miền, hỗ trợ suy luận dựa trên quy tắc trên dữ liệu có cấu trúc. Điểm mạnh của Rela-model là khả năng biểu diễn các luật suy luận phức tạp và các ràng buộc (constraints) trên dữ liệu, điều này đặc biệt hữu ích cho miền pháp lý nơi các quy tắc và điều kiện là trung tâm. Luận văn tham khảo cách tiếp cận quan hệ hóa (relation-based) của Rela-model khi thiết kế lược đồ quan hệ cho Knowledge Graph pháp lý.

2.2. Các phương pháp truy vấn kiến thức pháp lý

Ngo H. và cộng sự [20] đề xuất phương pháp ontology Knowledge Map cho việc xây dựng Linked Data cho các ứng dụng pháp lý tiếng Việt. Nghiên cứu này xử lý kho dữ liệu lớn gồm khoảng 325.000 tài liệu pháp lý, đề xuất Legal-Onto model kết hợp ontology làm lớp khái niệm (conceptual layer) và Knowledge Graph làm lớp triển khai (implementation layer). Một đóng góp quan trọng của công trình này là cách tiếp cận hệ thống để trích xuất ontology từ một khối lượng lớn tài liệu pháp lý không có cấu trúc, sử dụng kỹ thuật xử lý ngôn ngữ tự nhiên để tự động nhận diện khái niệm và quan hệ. Phương pháp này trực tiếp hỗ trợ bài toán của luận văn về việc tự động sinh ontology miễn cho quy chế đào tạo từ tài liệu gốc.

Pham V. và cộng sự [26] đề xuất cách tiếp cận tri thức được tích hợp (knowledge-infused) cho truy xuất thông tin pháp lý trong lĩnh vực luật lao động tiếng Việt. Nghiên cứu sử dụng tập dữ liệu gồm 300.000 tài liệu được phân loại thành 20 loại tài liệu pháp lý và 27 lĩnh vực pháp lý, xây dựng bộ câu hỏi–trả lời (Q&A dataset) riêng cho lĩnh vực luật lao động và tích hợp ontology pháp lý vào quy trình truy xuất. Kết quả cho thấy việc tích hợp tri thức ontology cải thiện đáng kể hiệu suất truy xuất so với các phương pháp không sử dụng tri thức, chứng minh hiệu quả của việc kết hợp Knowledge Graph và ontology cho truy xuất tài liệu pháp lý tiếng Việt – một kết quả mà luận văn tận dụng cho miễn quy chế đào tạo.

Pham V. và cộng sự [27] đề xuất phương pháp Knowledge Graph dựa trên ontology cho hệ thống truy xuất thông tin pháp lý tự động, nhấn mạnh tích hợp sâu giữa ontology làm lớp khái niệm và Knowledge Graph làm lớp triển khai. Phương pháp được thiết kế để xử lý các vấn đề chính trong miễn pháp lý: tự động trích xuất thông tin từ tài liệu không có cấu trúc, suy luận trên các quan hệ phức tạp giữa các khái niệm pháp lý, và trả lời các truy vấn yêu cầu suy luận đa bước. Công trình chứng minh rằng Knowledge Graph kết hợp với ontology pháp lý cải thiện độ chính xác truy xuất so với các phương pháp truyền thống, cung cấp nền tảng lý thuyết cho thiết kế Tầng 3 của luận văn nơi Knowledge Graph kết hợp suy luận đồ thị được sử dụng để mở rộng kết quả truy xuất.

2.2.2 Mô hình ngôn ngữ và NLP cho văn bản pháp lý

Devlin và cộng sự [4] giới thiệu BERT (Bidirectional Encoder Representations from Transformers), kiến trúc mô hình ngôn ngữ tiền huấn luyện hai chiều đạt kết quả vượt trội trên 11 tác vụ NLP. BERT trở thành nền tảng cho hầu hết các mô hình ngôn ngữ chuyên biệt miễn sau này, bao gồm cả miễn pháp lý.

2.2. Các phương pháp truy vấn kiến thức pháp lý

Chalkidis và cộng sự [2] giới thiệu LEGAL-BERT, mô hình ngôn ngữ được tiền huấn luyện trên kho văn bản pháp lý tiếng Anh (bao gồm luật của EU, UK, và Mỹ). Thông qua tìm kiếm siêu tham số mở rộng, nghiên cứu chứng minh rằng các hướng dẫn tinh chỉnh (fine-tuning) từ NLP đa dụng không tổng quát hóa tốt cho miền pháp lý – mô hình chuyên biệt miền vượt trội so với mô hình đa ngữ (XLM-R) và BERT tổng quát trên các tác vụ phân loại văn bản pháp luật và rà soát hợp đồng.

Zhong và cộng sự [34] tổng hợp hệ thống các ứng dụng NLP trong lĩnh vực pháp luật, phân loại thành năm nhóm tác vụ chính: phân loại văn bản pháp lý, nhận dạng thực thể, trích xuất thông tin, tóm tắt văn bản, và hỏi đáp pháp lý. Nghiên cứu chỉ ra rằng miền pháp lý đặt ra các thách thức đặc thù: thuật ngữ chuyên ngành, nhạy cảm ngữ cảnh cao, và sự thay đổi thường xuyên của quy định.

Đối với tiếng Việt, Nguyen D. Q. và Nguyen A. T. [22] phát triển PhoBERT, mô hình ngôn ngữ tiền huấn luyện đơn ngữ cho tiếng Việt gồm hai phiên bản (PhoBERT_{base} và PhoBERT_{large}), được huấn luyện trên kho ngữ liệu tiếng Việt lớn. PhoBERT vượt trội so với mô hình đa ngôn ngữ XLM-R trên các tác vụ gán nhãn từ loại, phân tích cú pháp phụ thuộc, nhận dạng thực thể, và suy luận ngôn ngữ tự nhiên – khẳng định rằng mô hình đơn ngữ là thiết yếu cho các ngôn ngữ có hình thái phong phú. Vu T. và cộng sự [32] phát triển VnCoreNLP, bộ công cụ NLP mã nguồn mở cho tiếng Việt, tích hợp phân đoạn từ (word segmentation), gán nhãn từ loại (POS tagging), nhận dạng thực thể (NER), và phân tích cú pháp phụ thuộc (dependency parsing), đạt kết quả tiên tiến nhất (state-of-the-art) trên các tập dữ liệu chuẩn tiếng Việt tại thời điểm công bố.

Tuy nhiên, các công cụ NLP tiếng Việt nêu trên chưa được tối ưu cho văn bản pháp lý, đặc biệt trong việc nhận diện viết tắt chuyên ngành (ThS, NCS, GVHD), thuật ngữ pháp lý, và cấu trúc tham chiếu (“theo Điều X Khoản Y”). Luận văn bổ sung bước tiền xử lý chuyên biệt gồm mở rộng viết tắt (49 mục), ánh xạ đồng nghĩa (18 cặp), và trích xuất thực thể giống (seed entity extraction) trước khi truy xuất.

Reimers và Gurevych [28] đề xuất Sentence-BERT (SBERT), phương pháp tính embedding cấp câu dựa trên mạng Siamese BERT. Mặc dù BERT gốc đạt hiệu suất tốt nhất trên các tác vụ so khớp cặp câu (semantic textual similarity), mô hình này yêu cầu cả hai câu phải được đưa vào mạng cùng lúc, dẫn đến chi phí tính toán khổng lồ: việc tìm cặp câu giống nhất từ 10.000 câu yêu cầu khoảng 50 triệu phép suy luận (65 giờ). Sentence-BERT sử dụng cấu trúc mạng Siamese và Triplet để tính embedding câu một cách độc lập, cho phép so sánh bằng cosine-similarity trên các vector embedding,

2.2. Các phương pháp truy vấn kiến thức pháp lý

giảm thời gian tìm kiếm xuống còn khoảng 5 giây trong khi vẫn duy trì độ chính xác tương đương. Sentence-BERT đã trở thành phương pháp chuẩn (de facto standard) cho tính toán embedding câu trong hệ thống truy xuất vector hiện đại. Luận văn sử dụng Sentence-BERT tại Tầng 2 của pipeline truy xuất để tính embedding cho các điều khoản và câu hỏi người dùng, cho phép truy xuất nhanh chóng các điều khoản liên quan dựa trên tương đồng ngữ nghĩa.

2.2.3 Truy xuất tăng cường sinh (RAG)

Lewis và cộng sự [17] đề xuất kiến trúc RAG (Retrieval-Augmented Generation), kết hợp bộ truy xuất (retriever) dựa trên bộ mã hóa kép (dual-encoder) với bộ sinh (generator) seq2seq tiền huấn luyện, huấn luyện đầu-cuối (end-to-end) thông qua tìm kiếm tích nội tối đa (MIPS). RAG vượt trội so với mô hình seq2seq thuần trên các tác vụ đòi hỏi kiến thức (knowledge-intensive) như hỏi đáp miền mở (open-domain QA), xác minh sự kiện (fact verification), nhờ việc neo (grounding) quá trình sinh vào các tài liệu nguồn cụ thể. Sự kết hợp giữa bộ truy xuất và bộ sinh cho phép mô hình tiếp cận thông tin cập nhật từ kho tài liệu bên ngoài mà không cần huấn luyện lại toàn bộ các thông số mô hình. Kiến trúc RAG trở thành nền tảng cho hệ thống hỏi đáp có căn cứ – đặc biệt quan trọng trong miền pháp lý nơi câu trả lời phải trích dẫn được nguồn.

Karpukhin và cộng sự [14] giới thiệu DPR (Dense Passage Retrieval), sử dụng bộ mã hóa kép huấn luyện với hàm mất mát tương phản (contrastive loss) trên các cặp câu hỏi–đoạn văn. DPR vượt trội BM25 từ 9–19% độ chính xác truy xuất cấp đoạn văn, chứng minh rằng biểu diễn dày đặc (dense representation) nắm bắt tương đồng ngữ nghĩa tốt hơn phương pháp thưa (sparse). Phương pháp dual-encoder của DPR cho phép mã hóa độc lập câu hỏi và tài liệu, tạo điều kiện thuận lợi cho truy xuất nhanh bằng tính toán vector tương đồng. Luận văn sử dụng cách tiếp cận embedding dày đặc tương tự tại Tầng 2 của pipeline truy xuất.

Fan và cộng sự [7] khảo sát hệ thống các kiến trúc RAG kết hợp LLM, phân loại theo ba chiều: kiến trúc (retriever-reader, retriever-generator), chiến lược huấn luyện (huấn luyện retriever, generator, hoặc đồng thời), và ứng dụng (tăng tính chính xác, cập nhật kiến thức, tác vụ chuyên biệt miền). Nghiên cứu xác nhận rằng RAG chuyên biệt miền vượt trội so với RAG đa dụng, với các hệ thống miền cụ thể đạt được độ chính xác cao hơn 10–20% so với mô hình đa dụng trên các tác vụ hẹp, củng cố lựa chọn của luận văn về việc thiết kế pipeline truy xuất riêng cho miền quy chế đào tạo.

2.2. Các phương pháp truy vấn kiến thức pháp lý

Gao và cộng sự [8] đề xuất HyDE (Hypothetical Document Expansion), cách tiếp cận zero-shot cho truy xuất dày đặc không cần nhân liên quan. Thay vì truy xuất trực tiếp từ truy vấn người dùng, HyDE sử dụng LLM để tạo ra tài liệu giả thuyết (hypothetical document) có thể trả lời truy vấn, sau đó mã hóa tài liệu này bằng encoder không giám sát và sử dụng dense bottleneck để lọc bỏ ảo giác, chỉ giữ lại các tài liệu thực tế có vector tương đồng cao. HyDE đạt kết quả tương đương hoặc vượt trội DPR trên các bộ dữ liệu QA mở và xác minh sự kiện, đồng thời mở rộng được sang các ngôn ngữ không phải tiếng Anh.

Sarathi và cộng sự [30] đề xuất RAPTOR (Recursive Abstractive Processing for Tree-Organized Retrieval), giải quyết hạn chế của RAG truyền thống khi xử lý các tài liệu dài. RAPTOR xây dựng cây phân cấp bằng cách đệ quy nhúng, phân cụm, và tóm tắt các khối văn bản từ dưới lên trên, tạo ra các mức tóm tắt khác nhau từ chi tiết cụ thể đến tổng quát hóa toàn bộ tài liệu. Tại thời điểm suy luận, hệ thống truy xuất từ các mức cây khác nhau phù hợp với yêu cầu câu hỏi, tích hợp thông tin ở nhiều mức độ trừu tượng. Trên bộ dữ liệu QuALITY yêu cầu suy luận phức tạp đa bước, RAPTOR cải thiện kết quả 20% tuyệt đối khi kết hợp với GPT-4. RAPTOR được sử dụng làm baseline đánh giá trong Chương 4; so sánh cho thấy pipeline 3 tầng của luận văn vượt trội RAPTOR nhờ kết hợp duyệt cây theo hướng dẫn LLM, truy xuất ngữ nghĩa hai cấp, và mở rộng qua Knowledge Graph thay vì chỉ sử dụng cây phân cấp tóm tắt.

Asai và cộng sự [1] đề xuất Self-RAG, khung cho phép mô hình ngôn ngữ tự động quyết định khi nào cần truy xuất và đánh giá chất lượng tài liệu được truy xuất. Khác với RAG truyền thống luôn truy xuất một số lượng cố định tài liệu, Self-RAG huấn luyện mô hình truy xuất linh hoạt: có thể truy xuất nhiều lần trong quá trình sinh hoặc bỏ qua truy xuất hoàn toàn, sử dụng các reflection tokens để đánh giá cả tài liệu truy xuất lẫn nội dung sinh ra. Self-RAG (7B và 13B tham số) vượt trội ChatGPT và Llama2-chat trên các tác vụ hỏi đáp miền mở, suy luận, và xác minh sự kiện, đồng thời cải thiện tính xác thực (factuality) và độ chính xác trích dẫn. Cách tiếp cận phản xạ (self-reflection) của Self-RAG có ảnh hưởng đến thiết kế Tầng 1 của luận văn, nơi LLM được sử dụng để duyệt cây quy định một cách thông minh.

Zhang và Tang [33] giới thiệu PageIndex, khung RAG không sử dụng vector database (vectorless RAG) dựa trên suy luận LLM. Thay vì dựa vào vector similarity search, PageIndex xây dựng chỉ mục cấu trúc cây từ tài liệu và cho phép LLM thực hiện suy luận trên cấu trúc đó, mô phỏng cách chuyên gia con người điều hướng tài liệu phức

2.2. Các phương pháp truy vấn kiến thức pháp lý

tập. PageIndex không yêu cầu chia nhỏ tài liệu (chunking) mà tổ chức chúng vào các phần tự nhiên, cải thiện khả năng truy vết (explainability). Trên bộ dữ liệu tài chính FinanceBench, PageIndex đạt 98,7% độ chính xác. PageIndex cũng được sử dụng làm baseline trong Chương 4; so sánh cho thấy pipeline 3 tầng của luận văn vượt trội PageIndex khoảng 7–13 điểm phần trăm trên Hit@10, nhờ kết hợp truy xuất đa phương pháp: duyệt cây, embedding dày đặc, và mở rộng Knowledge Graph.

2.2.4 Truy xuất dựa trên đồ thị tri thức

Edge và cộng sự [6] đề xuất GraphRAG, phương pháp tiên tiến giải quyết hạn chế của RAG truyền thống trên các câu hỏi đòi hỏi tổng hợp toàn cục (global sensemaking queries) như “các chủ đề chính là gì?”. GraphRAG sử dụng LLM để trích xuất đồ thị tri thức thực thể từ tài liệu, sau đó sinh trước các bản tóm tắt cộng đồng (community summaries) cho từng cụm thực thể dựa trên cấu trúc phân cấp, rồi tổng hợp câu trả lời từ các bản tóm tắt này thay vì trực tiếp từ văn bản. Phương pháp cải thiện đáng kể tính toàn diện và đa dạng của câu trả lời so với RAG truyền thống, đồng thời cho phép mở rộng đến tập dữ liệu lớn (1 triệu token) nhờ cấu trúc cộng đồng phân cấp. GraphRAG đã được triển khai trong các ứng dụng quản lý tri thức tại Microsoft, chứng minh khả năng ứng dụng thực tế.

Guo và cộng sự [10] đề xuất LightRAG, khung truy xuất tối ưu hơn bằng cách tích hợp cấu trúc đồ thị trực tiếp vào quá trình đánh chỉ mục (indexing). LightRAG sử dụng hệ thống truy xuất hai cấp giúp khám phá thông tin ở cả mức thấp (low-level) cho các thực thể cụ thể và quan hệ chi tiết, và mức cao (high-level) cho các chủ đề tổng quát và cộng đồng thực thể, đồng thời tích hợp cấu trúc đồ thị với biểu diễn vector để truy xuất hiệu quả các thực thể liên quan và mối quan hệ giữa chúng. LightRAG vượt trội so với NaiveRAG, RQ-RAG, HyDE, và chính GraphRAG trên bốn miền ứng dụng, bao gồm rõ ràng **miền pháp lý**. Cơ chế truy xuất hai cấp độ của LightRAG có ảnh hưởng trực tiếp đến thiết kế Tầng 2 của luận văn (xem Chương 3), nơi truy xuất cấp thực thể (low-level) và cấp chủ đề (high-level) được tích hợp.

Mavromatis và Karypis [19] đề xuất GNN-RAG, sử dụng mạng nơ-ron đồ thị (Graph Neural Network) để trích xuất các đường lý luận (reasoning paths) có độ dài ngắn nhất trên đồ thị tri thức, kết nối trực tiếp từ thực thể được đề cập trong câu hỏi đến các ứng viên câu trả lời. Sau khi trích xuất, các đường lý luận được chuyển đổi thành dạng văn bản tự nhiên để LLM có thể suy luận dựa trên bối cảnh. GNN-RAG đạt kết quả tiên tiến

2.2. Các phương pháp truy vấn kiến thức pháp lý

trên các tập dữ liệu KGQA công khai WebQSP và CWQ, vượt phương pháp truy xuất bằng LLM từ 8,9–15,5% F1 trên các câu hỏi đa bước (multi-hop), đồng thời chỉ sử dụng khoảng 1/9 số token so với phương pháp ngữ cảnh dài (long-context). Ý tưởng trích xuất đường lý luận trên đồ thị tương đồng với cơ chế mở rộng KG tại Tầng 3 của luận văn, nơi PPR (Personalized PageRank) được dùng để tìm các thực thể liên quan qua suy luận đa bước.

Cấu trúc các phương pháp truy xuất dựa trên đồ thị xây dựng trên nền tảng lý thuyết của các thuật toán xếp hạng trên đồ thị, đặc biệt là các biến thể của PageRank. Haveliwala [11] giới thiệu Topic-Sensitive PageRank, phương pháp tính toán nhiều vector PageRank độc lập, mỗi vector được thiên lệch theo một chủ đề cụ thể, cho phép xếp hạng các nút đồ thị dựa trên tầm quan trọng so với chủ đề đó. Jeh và Widom [13] mở rộng công trình này bằng phương pháp tính toán vector PageRank cá nhân hóa theo tập hợp các trang được người dùng quan tâm, giải quyết bài toán tính toán hiệu quả mà không cần thực hiện lặp lại đầy đủ cho từng cá nhân hóa. Gleich [9] thực hiện khảo sát toàn diện về ứng dụng PageRank ngoài lĩnh vực tìm kiếm web, chứng minh rằng toán học PageRank là tổng quát và áp dụng được trên bất kỳ đồ thị hoặc mạng nào. Các công trình nền tảng này cung cấp cơ sở lý thuyết cho việc áp dụng PPR trong cơ chế mở rộng tri thức tại Tầng 3 của luận văn.

2.2.5 Hỏi đáp pháp lý tự động

Lai và cộng sự [15] thực hiện khảo sát toàn diện và hệ thống về ứng dụng của các mô hình ngôn ngữ lớn trong lĩnh vực pháp luật, với tiêu chí đánh giá 11 bộ benchmark năng lực pháp lý (CaseLaw, DISC-Law-Eval, KBL, LAiW, LawBench, LBOX OPEN, Legal-Bench, LexEval, LexGLUE, SimuCourt, SMILED) và 4 bộ benchmark tác vụ chuyên biệt. Nghiên cứu chỉ ra rằng LLM cho thấy tiềm năng lớn trong ba lĩnh vực chính: tư vấn pháp lý, hỗ trợ quyết định cho thẩm phán, và phân tích tài liệu pháp luật. Tuy nhiên, các mô hình đối mặt ba thách thức: dữ liệu huấn luyện pháp lý còn hạn chế so với dữ liệu chung; vấn đề đạo đức và trách nhiệm pháp lý khi sử dụng AI trong quyết định pháp lý; và ảo giác (hallucination) – hiện tượng mô hình phát sinh thông tin sai khi thiếu ngữ cảnh chính xác. Kết luận này củng cố lựa chọn kiến trúc RAG của luận văn: LLM cần bước truy xuất rõ ràng từ tài liệu gốc để đảm bảo câu trả lời có căn cứ pháp lý và giảm thiểu rủi ro ảo giác.

Ngo Q. H. và cộng sự [21] phát triển AimeLaw, hệ thống hỏi đáp pháp lý tiếng Việt

2.2. Các phương pháp truy vấn kiến thức pháp lý

tham gia cuộc thi Automated Legal Question Answering Competition (ALQAC) 2021. Hệ thống kết hợp ba thành phần chính: truy xuất từ điển (BM25), mô hình BERT tiền huấn luyện trên tập dữ liệu lớn, và tăng cường dữ liệu nhận biết miền pháp lý (domain-aware data augmentation) – kỹ thuật tạo mẫu huấn luyện nhân tạo dựa trên kiến thức miền. Hệ thống đạt kết quả nổi bật: suy luận văn bản pháp lý (legal textual entailment) 69,89% chính xác (giải nhất), truy xuất văn bản pháp lý 80,61% F2 (giải nhì), hỏi đáp pháp lý 64,77% chính xác (giải nhì). Kết quả cho thấy tích hợp tri thức miền pháp lý cải thiện đáng kể hiệu suất so với mô hình mở-ron thuần – một quan sát phù hợp với cách tiếp cận Knowledge Graph của luận văn.

Nguyen H. và cộng sự [23] phát triển hệ thống tìm kiếm thông minh cho việc khớp hồ sơ công việc và truy vấn luật lao động Việt Nam. Hệ thống sử dụng phương pháp dựa trên ontology để giải quyết hai bài toán: khớp kỹ năng công việc giữa hồ sơ ứng viên và mô tả công việc, đồng thời tìm kiếm các quy định pháp luật lao động liên quan. Nhóm tác giả xây dựng hai ontology riêng biệt – một ontology kỹ năng và một ontology pháp luật lao động – tích hợp vào cùng một cơ sở tri thức. Hệ thống đạt kết quả tốt nhất trên các truy vấn về bảo hiểm thất nghiệp (độ chính xác trên 70%), chứng minh hiệu quả của phương pháp biểu diễn tri thức dựa trên ontology cho các lĩnh vực pháp lý Việt Nam.

Ho X. và cộng sự [12] trình bày phương pháp xây dựng tập dữ liệu hỏi đáp đa bước (multi-hop QA dataset) gọi là 2WikiMultiHopQA, kết hợp dữ liệu có cấu trúc (từ Wikidata) và dữ liệu phi cấu trúc (văn bản Wikipedia). Đặc điểm nổi bật là mỗi câu hỏi đi kèm thông tin bằng chứng (evidence) chứa đường suy luận (reasoning path) rõ ràng, cho phép đánh giá không chỉ độ chính xác câu trả lời mà còn chất lượng quá trình suy luận. Phương pháp này đặc biệt liên quan đến luận văn vì các câu hỏi về quy chế đào tạo thường yêu cầu suy luận đa bước: cần kết hợp thông tin từ nhiều điều khoản, từ nhiều tầng quy chế (ĐHQG-HCM và UIT), hoặc từ các quy định liên quan để tạo thành câu trả lời hoàn chỉnh.

Tổng hợp và vị trí của luận văn. Bảng 2.1 so sánh các đặc trưng chính của luận văn với các công trình liên quan. Luận văn khác biệt ở ba điểm: sử dụng kiến trúc truy xuất 3 tầng (duyet cây + semantic + KG fusion) thay vì truy xuất đơn tầng; khai thác cấu trúc phân cấp đặc thù của văn bản quy phạm Việt Nam (6 cấp: văn bản → chương → mục → điều → khoản → điểm) thay vì coi tài liệu như tập hợp phẳng; và kết hợp Knowledge Graph với PPR để mở rộng kết quả truy xuất qua suy luận đa bước trên đồ thị quan hệ, thay vì chỉ dùng community summaries như GraphRAG hoặc dual-level retrieval như

2.2. Các phương pháp truy vấn kiến thức pháp lý

LightRAG.

Bảng 2.1: So sánh các công trình liên quan với luận văn

Công trình	KG	Đa tầng	Cấu trúc VB	Tiếng Việt
RAG [17]	–	–	–	–
DPR [14]	–	–	–	–
RAPTOR [30]	–	Cây	✓	–
Self-RAG [1]	–	–	–	–
PageIndex [33]	–	–	✓	–
GraphRAG [6]	✓	–	–	–
LightRAG [10]	✓	2 cấp	–	–
GNN-RAG [19]	✓	–	–	–
AimeLaw [21]	–	–	–	✓
Legal-Onto [24]	✓	–	✓	✓
Luận văn	✓	3 tầng	✓	✓

Chương 3

Thu thập kiến thức và thiết kế giải thuật

Chương này trình bày toàn bộ quy trình từ thu thập kiến thức miền đến thiết kế giải thuật truy xuất. Phần đầu (Mục 3.1–3.3) giới thiệu hệ thống quy chế đào tạo, thu thập dữ liệu (bao gồm cả bộ câu hỏi kiểm thử), và tiền xử lý dữ liệu. Phần sau (Mục 3.4–3.5) trình bày chi tiết kiến trúc giải thuật 3-Tier KG-RAG được đề xuất, bao gồm tổng quan kiến trúc hệ thống, phân tích truy vấn, và pipeline truy xuất ba tầng. Nội dung phần thiết kế giải thuật dựa trên bài báo khoa học đã nộp tại hội nghị SOMET 2026 [16].

3.1 Giới thiệu về hệ thống quy chế đào tạo thạc sĩ

3.1.1 Tổng quan hệ thống quy chế đào tạo sau đại học tại Việt Nam

Hệ thống giáo dục sau đại học tại Việt Nam được quản lý bởi nhiều tầng văn bản quy phạm pháp luật, từ cấp quốc gia đến cấp trường. Tại cấp quốc gia, Luật Giáo dục (Luật số 43/2019/QH14) và Luật Giáo dục Đại học (Luật số 08/2012/QH13, sửa đổi bổ sung bởi Luật số 34/2018/QH14) đặt ra khung pháp lý chung cho toàn bộ hệ thống giáo dục. Bộ Giáo dục và Đào tạo ban hành các quy chế đào tạo trình độ thạc sĩ, tiến sĩ áp dụng trên toàn quốc (Thông tư số 23/2021/TT-BGDĐT quy chế tuyển sinh và đào tạo trình độ thạc sĩ). Tại cấp cơ sở, các đại học quốc gia và trường đại học ban hành quy chế riêng phù hợp với đặc thù đào tạo, trong phạm vi quyền tự chủ được pháp luật cho phép.

3.1. Giới thiệu về hệ thống quy chế đào tạo thạc sĩ

Mô hình quản trị này tạo ra một hệ thống quy chế phân tầng (layered regulation system) với ba đặc điểm quan trọng ảnh hưởng đến bài toán truy xuất thông tin:

1. **Tính phân cấp (Hierarchical):** Văn bản cấp trên đặt ra nguyên tắc chung, văn bản cấp dưới cụ thể hóa và bổ sung. Khi xảy ra mâu thuẫn, văn bản cấp trên có hiệu lực cao hơn. Ví dụ: QĐ 1393 (ĐHQG-HCM) quy định thời gian đào tạo tối đa 4 năm, QĐ 270 (UIT) cụ thể hóa thêm điều kiện gia hạn.
2. **Tham chiếu chéo (Cross-reference):** Các điều khoản thường dẫn chiếu lẫn nhau, cả trong cùng văn bản (intra-document) và giữa các văn bản (inter-document). Ví dụ: Điều 24 QĐ 270 về điều kiện bảo vệ luận văn dẫn chiếu đến Điều 25 QĐ 1393 về yêu cầu ngoại ngữ đầu ra.
3. **Thay thế và kế thừa (Succession):** Văn bản mới có thể thay thế toàn bộ hoặc sửa đổi bổ sung văn bản cũ. Ví dụ: QĐ 1393 (2021) thay thế QĐ 160 (2017), nhưng học viên nhập học trước 2022 vẫn áp dụng QĐ 160 theo điều khoản chuyển tiếp.

Đối với UIT, một trường thành viên của ĐHQG-HCM, hệ thống quy chế đào tạo thạc sĩ bao gồm hai tầng chính:

- **Tầng ĐHQG-HCM:** Các quy chế khung do ĐHQG-HCM ban hành, áp dụng cho tất cả các trường thành viên (QĐ 160, QĐ 1393, QĐ 218).
- **Tầng trường:** Các quy chế, quy định cụ thể hóa do UIT ban hành (QĐ 270, QĐ 851), bổ sung và chi tiết hóa các quy định của ĐHQG-HCM.

Mô hình hai tầng này đặt ra thách thức cho bài toán hỏi đáp: khi học viên hỏi về một vấn đề cụ thể (ví dụ: “điều kiện bảo vệ luận văn”), hệ thống cần kết hợp thông tin từ cả hai tầng – quy định chung từ ĐHQG-HCM và quy định bổ sung từ UIT – để đưa ra câu trả lời đầy đủ. Đây là một trong những động lực chính cho kiến trúc truy xuất đa tầng được trình bày ở phần sau của chương (Mục 3.5).

3.1.2 Cấu trúc văn bản quy phạm

Các văn bản quy chế đào tạo tuân theo cấu trúc phân cấp chuẩn của văn bản quy phạm pháp luật Việt Nam, được quy định trong Luật Ban hành văn bản quy phạm pháp luật (Luật số 80/2015/QH13):

3.1. Giới thiệu về hệ thống quy chế đào tạo thạc sĩ

Văn bản → Chương → Mục → Điều → Khoản → Điểm

Mỗi cấp mang phạm vi pháp lý riêng biệt. Một Văn bản thường bao gồm nhiều Chương, mỗi Chương có thể chứa các Mục gom nhóm các Điều theo chủ đề. Mỗi Điều quy định về một vấn đề cụ thể và được chia thành các Khoản (đánh số 1, 2, 3...) và Điểm (đánh số a, b, c...). Trong thực tế, không phải văn bản nào cũng có đủ cả 6 cấp; ví dụ các quy chế đào tạo thường không có cấp Mục.

Cấu trúc phân cấp này có ý nghĩa quan trọng cho bài toán truy xuất:

- **Đơn vị trích dẫn (Citable unit):** Trong thực tiễn pháp lý và hành chính Việt Nam, đơn vị trích dẫn nhỏ nhất là Điểm hoặc Khoản (ví dụ: “theo Điểm a Khoản 1 Điều 24 QĐ 270”). Tuy nhiên, Điều là đơn vị trích dẫn phổ biến nhất vì mỗi Điều thường quy định trọn vẹn một vấn đề.
- **Ngữ cảnh phân cấp (Hierarchical context):** Để hiểu đúng một Điều, cần biết nó thuộc Chương nào (xác định chủ đề tổng quát) và văn bản nào (xác định phạm vi hiệu lực và cấp ban hành).
- **Tham chiếu nội bộ (Internal reference):** Nhiều Điều sử dụng cụm từ như “theo quy định tại Điều 5” hoặc “căn cứ Khoản 1 Điều 24” để dẫn chiếu đến nội dung ở vị trí khác trong cùng hoặc khác văn bản.

Hình 3.1 minh họa cấu trúc Document Tree của QĐ 270/QĐ-ĐHCNTT với các cấp phân cấp và tham chiếu chéo.


3.1.3 Các quy chế trong phạm vi nghiên cứu

Luận văn sử dụng 5 quy chế đào tạo được liệt kê trong Bảng 3.1, bao gồm tổng cộng 28 chương và 109 điều. Dưới đây trình bày chi tiết phạm vi, nội dung chính, và vai trò của từng quy chế trong hệ thống.

QĐ 270/QĐ-ĐHCNTT – Quy chế đào tạo trình độ thạc sĩ của UIT

QĐ 270 được ban hành ngày 25/04/2022, là quy chế đào tạo trình độ thạc sĩ chính của Trường Đại học Công nghệ Thông tin, gồm 8 chương và 35 điều. Đây là văn bản

3.1. Giới thiệu về hệ thống quy chế đào tạo thạc sĩ



Hình 3.1: Cấu trúc Document Tree của QĐ 270/QĐ-ĐHCNTT theo cấu trúc phân cấp 6 cấp: Văn bản → Chương → Mục → Điều → Khoản → Điểm (cấp Mục không áp dụng cho văn bản này). Mũi tên nét đứt đỏ thể hiện các tham chiếu chéo giữa các điều khoản và giữa các văn bản.

Bảng 3.1: Danh sách các quy chế đào tạo trong phạm vi nghiên cứu

STT	Tên quy chế	Số QĐ	Số chương	Số điều
1	Quy chế ĐT trình độ ThS của UIT	270/QĐ-ĐHCNTT	8	35
2	Quy chế ĐT trình độ ThS của ĐHQG-HCM (khóa 2021)	160/QĐ-ĐHQG	7	28
3	Quy chế ĐT trình độ ThS của ĐHQG-HCM (khóa 2022+)	1393/QĐ-ĐHQG	8	32
4	Quy chế sửa đổi bổ sung về GVHD	218/QĐ-ĐHQG	2	6
5	Quy định liên chính học thuật	851/QĐ-ĐHCNTT	3	8
Tổng cộng			28	109

3.1. Giới thiệu về hệ thống quy chế đào tạo thạc sĩ

được học viên cao học UIT tham chiếu nhiều nhất, quy định toàn bộ quy trình từ tuyển sinh đến tốt nghiệp.

- **Chương I** (Điều 1–4): Quy định chung – phạm vi áp dụng, đối tượng, mục tiêu đào tạo, hình thức đào tạo (tập trung, không tập trung).
- **Chương II** (Điều 5–7): Tuyển sinh – điều kiện dự tuyển, hồ sơ dự tuyển, hình thức xét tuyển.
- **Chương III** (Điều 8–12): Chương trình đào tạo – khung chương trình (60 tín chỉ cho định hướng nghiên cứu, 45 tín chỉ cho ứng dụng), các khối kiến thức, đăng ký môn học.
- **Chương IV** (Điều 13–17): Tổ chức đào tạo – thời gian đào tạo (1,5–4 năm), nghỉ phép, chuyển ngành, bảo lưu kết quả.
- **Chương V** (Điều 18–20): Đánh giá kết quả – thang điểm 0–10 (quy đổi A/B+/B/C+/C/D+/D/F), cảnh báo học vụ, buộc thôi học.
- **Chương VI** (Điều 21–28): Luận văn thạc sĩ – đề cương, giáo viên hướng dẫn, hội đồng xét duyệt đề cương, hội đồng chấm luận văn (5 thành viên), điều kiện bảo vệ, quy trình bảo vệ và chỉnh sửa sau bảo vệ.
- **Chương VII** (Điều 29–32): Tốt nghiệp – điều kiện tốt nghiệp ($GPA \geq 5,5$, luận văn đạt, ngoại ngữ đạt), công nhận tốt nghiệp, cấp bằng.
- **Chương VIII** (Điều 33–35): Điều khoản thi hành – hiệu lực, trách nhiệm thi hành, xử lý chuyển tiếp.

QĐ 160/QĐ-ĐHQG – Quy chế khung ĐHQG-HCM (khóa 2021)

QĐ 160 được ban hành ngày 24/03/2017, là quy chế khung của ĐHQG-HCM áp dụng cho các khóa đào tạo trước 2022, gồm 7 chương và 28 điều. Quy chế này đặt ra các nguyên tắc chung mà các trường thành viên phải tuân thủ khi xây dựng quy chế cấp trường:

- Thời gian đào tạo: tối đa 3 năm (ngắn hơn QĐ 1393).

3.1. Giới thiệu về hệ thống quy chế đào tạo thạc sĩ

- Yêu cầu ngoại ngữ: đạt trình độ B1 theo Khung tham chiếu châu Âu (CEFR) hoặc tương đương (TOEIC $\geq$ 450, IELTS $\geq$ 4,0).
- Số tín chỉ tối thiểu: 46 tín chỉ cho ThS nghiên cứu, 60 tín chỉ cho ThS ứng dụng.
- Chưa có quy định về bài báo khoa học bắt buộc.

QĐ 1393/QĐ-ĐHQG – Quy chế mới ĐHQG-HCM (khóa 2022+)

QĐ 1393 được ban hành ngày 03/11/2021, thay thế QĐ 160, áp dụng cho các khóa từ 2022 trở đi, gồm 8 chương và 32 điều. Quy chế mới có nhiều thay đổi quan trọng so với quy chế cũ. Bảng 3.2 so sánh chi tiết các điểm khác biệt chính giữa hai phiên bản.

Bảng 3.2: So sánh điểm khác biệt chính giữa QĐ 160 và QĐ 1393

Tiêu chí	QĐ 160 (2017)	QĐ 1393 (2021)
Thời gian DT tối đa	3 năm	4 năm
Ngoại ngữ đầu ra	B1 CEFR	B1 CEFR (giữ nguyên)
Bài báo khoa học	Không bắt buộc	Khuyến khích (tùy ngành)
Số tín chỉ ThS NC	≥ 46	≥ 60
Định hướng DT	NC và ứng dụng	NC, ứng dụng, và kết hợp
Điều khoản GVHD	Cơ bản	Chi tiết hơn (bổ sung bởi QĐ 218)
Luận văn	15–20 tín chỉ	15–20 tín chỉ (giữ nguyên)
Chuyển tiếp	–	HV khóa cũ áp dụng QĐ 160

Điểm đáng chú ý là điều khoản chuyển tiếp (Điều 32 QĐ 1393): học viên nhập học trước năm 2022 tiếp tục áp dụng QĐ 160, tạo ra tình huống hai quy chế cùng hiệu lực trong giai đoạn chuyển tiếp. Đây là một nguồn câu hỏi phổ biến từ học viên (“Tôi khóa 2021 thì áp dụng quy chế nào?”) và đặt ra yêu cầu cho hệ thống phải truy xuất đúng văn bản theo khóa học của người dùng.

3.1. Giới thiệu về hệ thống quy chế đào tạo thạc sĩ

QĐ 218/QĐ-ĐHQG – Sửa đổi bổ sung quy định GVHD

QĐ 218 được ban hành ngày 15/03/2024, sửa đổi và bổ sung một số điều về quy định giáo viên hướng dẫn trong quy chế đào tạo của ĐHQG-HCM, gồm 2 chương và 6 điều. Văn bản này quy định chi tiết:

- Tiêu chuẩn GVHD: phải có học vị tiến sĩ, có công bố khoa học quốc tế trong 5 năm gần nhất (ít nhất 1 bài ISI/Scopus).
- Số lượng hướng dẫn tối đa: mỗi GVHD hướng dẫn không quá 5 học viên ThS và 3 NCS cùng lúc (Điều 4).
- Trách nhiệm GVHD: theo dõi tiến độ, đánh giá định kỳ, ký xác nhận đề cương và luận văn.
- Đồng hướng dẫn: cho phép tối đa 2 người đồng hướng dẫn, ít nhất 1 người đáp ứng tiêu chuẩn chính.

QĐ 218 có mối quan hệ “sửa đổi bổ sung” (amend) với QĐ 1393: các điều khoản về GVHD trong QĐ 1393 được thay thế bởi nội dung tương ứng trong QĐ 218.

QĐ 851/QĐ-ĐHCNTT – Quy định liên chính học thuật

QĐ 851 được ban hành ngày 14/08/2024, là quy định về liên chính học thuật áp dụng cho học viên cao học UIT, gồm 3 chương và 8 điều:

- **Chương I** (Điều 1–3): Quy định chung – phạm vi áp dụng, định nghĩa đạo văn (plagiarism: sử dụng ý tưởng, dữ liệu, văn bản của người khác mà không trích dẫn nguồn), các hình thức vi phạm (tự đạo văn, đạo văn từ nguồn khác, gian lận dữ liệu, thuê viết).
- **Chương II** (Điều 4–6): Phát hiện và xử lý – quy trình phát hiện (kiểm tra Turnitin với ngưỡng trùng lặp $\leq 30\%$), hội đồng xác minh, các mức xử lý kỷ luật (cảnh cáo, hủy kết quả môn học, đình chỉ học tập, buộc thôi học).
- **Chương III** (Điều 7–8): Điều khoản thi hành – trách nhiệm của GVHD, khoa, và phòng đào tạo trong việc giám sát liên chính.

3.2 Thu thập dữ liệu

3.2.1 Quy trình thu thập và số hóa

Quá trình thu thập kiến thức từ các văn bản quy chế đào tạo được thực hiện qua bốn bước chính, từ thu thập văn bản gốc đến tạo các biểu diễn tri thức phục vụ truy xuất.

Bước 1: Thu thập văn bản gốc. Các quyết định được tải từ website chính thức của UIT (sdh.uit.edu.vn) và ĐHQG-HCM (vnuhcm.edu.vn). Tổng cộng 5 văn bản với 118 trang PDF, trong đó 4 văn bản ở dạng PDF scan (không có text layer) và 1 văn bản ở dạng PDF text. Các văn bản PDF scan được số hóa bằng LLM Vision OCR (Gemini Flash) với độ chính xác cao hơn OCR truyền thống nhờ khả năng hiểu ngữ cảnh và sửa lỗi tự động. Kết quả OCR được rà soát thủ công để đảm bảo tính chính xác, đặc biệt với các số hiệu điều khoản và tên riêng.

Bước 2: Phân tích cấu trúc. Sử dụng bộ phân tích cú pháp (parser) tùy chỉnh với regex nhận diện các dấu hiệu phân cấp tiếng Việt. Bộ regex bao gồm các mẫu:

- Chương: `Ch\ương\s+[IVXLC]+ (số La Mã)` hoặc `CHƯƠNG\s+\d+ (số Ả Rập)`
- Điều: `Đi\ều\s+\d+`
- Khoản: `^\d+\.` (số + dấu chấm đầu dòng)
- Điểm: `^[a-zđ]\)` (chữ cái + ngoặc đóng đầu dòng)

Parser xây dựng cây cấu trúc phân cấp bằng thuật toán đẩy–kéo (push–pop) trên stack: mỗi dấu hiệu mới ở cấp cao hơn đóng tất cả nút con đang mở, tạo nút mới và đẩy vào stack. Kết quả là một cây có gốc (rooted tree) cho mỗi văn bản, với metadata (số hiệu, ngày ban hành, cơ quan ban hành) gắn vào nút gốc.

Bước 3: Trích xuất tham chiếu chéo. Nhận diện các tham chiếu giữa các điều khoản bằng pattern matching trên các chuỗi trích dẫn. Các mẫu phổ biến bao gồm:

- Tham chiếu nội bộ: “theo quy định tại Điều 5”, “căn cứ Khoản 1 Điều 24”
- Tham chiếu ngoại bộ: “theo Điều 25 Quy chế đào tạo ĐHQG-HCM”
- Tham chiếu thay thế: “thay thế QĐ 160/QĐ-ĐHQG ngày 24/03/2017”

Mỗi tham chiếu được phân loại theo kiểu: THAM_CHIẾU (dẫn chiếu chung), SỬA_ĐỔI (amend), hoặc THAY_THẾ (replace). Tổng cộng phát hiện 168 tham chiếu chéo trong 5 văn bản, trong đó 134 tham chiếu nội bộ và 34 tham chiếu ngoại bộ.

Bước 4: Tạo tóm tắt. Sinh tóm tắt cho từng chương và điều bằng LLM (Claude 3.5 Haiku), tạo mô tả gồm tiêu đề và nhiều từ khóa đặc trưng phục vụ cho bước chọn nhánh trong Tầng 1 của pipeline truy xuất. Tổng cộng sinh 17 tóm tắt chương và 109 tóm tắt điều. Mỗi tóm tắt chương bao gồm: phạm vi điều khoản (ví dụ: “Điều 1–4”), chủ đề chính, và danh sách 5–10 từ khóa đặc trưng. Mỗi tóm tắt điều bao gồm: tiêu đề điều và 3–5 từ khóa nội dung chính.

Bảng 3.3 tóm tắt kết quả quá trình số hóa và phân tích cấu trúc.

Bảng 3.3: Thống kê kết quả số hóa và phân tích cấu trúc

Thành phần	Số lượng
Văn bản quy chế	5
Tổng số trang PDF	118
Chương	28
Điều khoản	109
Khoản	≈ 380
Điểm	≈ 520
Tham chiếu chéo nội bộ	134
Tham chiếu chéo ngoại bộ	34
Tóm tắt chương	17
Tóm tắt điều	109

3.2.2 Các khái niệm chính trong quy chế đào tạo

Qua phân tích nội dung 5 quy chế, các khái niệm chính (domain concepts) được xác định và phân loại theo ontology miền. Các khái niệm này đóng vai trò làm thực thể (entity) trong Knowledge Graph và giúp hệ thống hiểu mối quan hệ ngữ nghĩa giữa các điều khoản.

- **Chương trình đào tạo:** khung chương trình, môn học bắt buộc, môn học tự chọn, số tín chỉ tối thiểu (60 TC cho nghiên cứu, 45 TC cho ứng dụng), khối kiến thức

cơ sở ngành và chuyên ngành.

- **Tín chỉ và môn học:** định nghĩa tín chỉ (15 tiết lý thuyết hoặc 30 tiết thực hành), phân loại môn học (bắt buộc, tự chọn, bổ sung), điều kiện tiên quyết, quy trình đăng ký và hủy môn học.
- **Đánh giá kết quả học tập:** thang điểm 10 (0–10), thang điểm 4 (0–4), thang điểm chữ (A, B+, B, C+, C, D+, D, F), bảng quy đổi giữa các thang điểm. Ví dụ: 8,5–10 điểm = A = 4,0 điểm hệ 4 = Giỏi.
- **Thời hạn đào tạo:** thời gian chuẩn (1,5–2 năm), thời gian tối đa (4 năm theo QĐ 1393, 3 năm theo QĐ 160), quy trình gia hạn (đơn xin gia hạn → khoa xét → phòng đào tạo phê duyệt), bảo lưu kết quả học tập (tối đa 2 năm).
- **Luận văn thạc sĩ:** đề cương luận văn (nộp sau khi hoàn thành $\geq 70\%$ tín chỉ), hội đồng xét duyệt đề cương (3 thành viên), giáo viên hướng dẫn (tiêu chuẩn, số lượng tối đa), hội đồng bảo vệ luận văn (5 thành viên: chủ tịch, thư ký, 2 phản biện, ủy viên), quy trình bảo vệ (trình bày 20–30 phút, hỏi đáp 30–45 phút), kết quả bảo vệ (Đạt/Không đạt), chỉnh sửa sau bảo vệ (tối đa 3 tháng).
- **Điều kiện tốt nghiệp:** điểm trung bình tích lũy ($\geq 5,5$), yêu cầu ngoại ngữ (B1 CEFR hoặc tương đương), yêu cầu bài báo khoa học (tùy ngành), hoàn thành luận văn, không bị kỷ luật.
- **Liên chính học thuật:** định nghĩa đạo văn (5 hình thức: sao chép trực tiếp, diễn giải không trích nguồn, tự đạo văn, gian lận dữ liệu, thuê viết), mức xử lý kỷ luật (4 mức: cảnh cáo, hủy kết quả, đình chỉ, buộc thôi học), quy trình phát hiện (Turnitin $\leq 30\%$ trùng lặp).

3.2.3 Các mối quan hệ giữa các khái niệm

Các mối quan hệ quan trọng được xác định từ văn bản quy chế, phân thành hai nhóm: quan hệ cấu trúc (structural relations) phản ánh cách tổ chức văn bản, và quan hệ ngữ nghĩa (semantic relations) phản ánh mối liên hệ nội dung giữa các khái niệm.

Quan hệ cấu trúc:

- **Thuộc** (DieuKhoan $\rightarrow$ VanBan): Một điều khoản thuộc về một văn bản quy chế cụ thể. Ví dụ: Điều 24 *thuộc* QĐ 270.

- **Tham chiếu** (DieuKhoan → DieuKhoan): Một điều khoản dẫn chiếu đến điều khoản khác trong cùng hoặc khác văn bản. Ví dụ: Điều 24 QĐ 270 *tham chiếu* đến Điều 25 QĐ 1393 về yêu cầu ngoại ngữ.
- **Thay thế/Bổ sung** (VanBan → VanBan): Một văn bản thay thế hoặc bổ sung cho văn bản khác. Ví dụ: QĐ 1393 *thay thế* QĐ 160; QĐ 218 *bổ sung* QĐ 1393.

Quan hệ ngữ nghĩa:

- **Yêu cầu** (DieuKien → HanhDong): Một điều kiện phải được đáp ứng trước khi thực hiện một hành động. Ví dụ: “đạt ngoại ngữ B1” *yêu cầu trước* “bảo vệ luận văn”.
- **Tiên quyết** (MonHoc → MonHoc): Một môn học yêu cầu hoàn thành môn khác trước khi đăng ký. Ví dụ: “Luận văn ThS” *tiên quyết* “hoàn thành $\geq 70\%$ tín chỉ”.
- **Áp dụng cho** (QuyDinh → DoiTuong): Một quy định áp dụng cho đối tượng cụ thể. Ví dụ: QĐ 160 *áp dụng cho* “học viên khóa trước 2022”.

Hình 3.2 minh họa một đồ thị con trích xuất từ Knowledge Graph miền đào tạo, thể hiện các thực thể và quan hệ xung quanh chủ đề bảo vệ luận văn thạc sĩ. Các nút được phân loại theo ontology (Action, Condition, Organization, Person, Legal Reference) và các cạnh thể hiện các loại quan hệ (requires, leads_to, regulates, references).

3.2.4 Phân loại chủ đề

Bảng 3.4 trình bày các nhóm chủ đề chính được phân loại từ nội dung quy chế. Phân loại này phục vụ hai mục đích: tổ chức bộ câu hỏi kiểm thử theo chủ đề để đảm bảo độ bao phủ, và xây dựng nhóm miền (domain group) cho bước chọn tài liệu trong Tầng 1 của pipeline truy xuất.

Cần lưu ý rằng tổng số điều liên quan (84) nhỏ hơn tổng số điều (109) vì một số điều thuộc phần điều khoản chung (quy định phạm vi, đối tượng, hiệu lực) không nằm trong chủ đề chuyên biệt nào. Ngược lại, một số điều có thể liên quan đến nhiều chủ đề; ví dụ Điều 24 QĐ 270 (điều kiện bảo vệ luận văn) liên quan đến cả chủ đề “Luận văn” và “Điều kiện tốt nghiệp”.



Hình 3.2: Đồ thị con minh họa các thực thể và quan hệ xung quanh chủ đề “bảo vệ luận văn thạc sĩ”. Các nút được phân loại theo ontology (Action, Condition, Organization, Person, Legal Reference) và các cạnh thể hiện các loại quan hệ (requires, leads_to, regulates, references).

3.2.5 Nguồn thu thập và phương pháp xây dựng bộ câu hỏi kiểm thử

Tổng cộng 530 câu hỏi kiểm thử được thu thập từ hai nguồn: các nhóm tư vấn pháp lý trên Facebook (400 câu hỏi pháp luật) và các diễn đàn học viên UIT (130 câu hỏi quy định đào tạo). Các câu hỏi bao phủ nhiều mức độ phức tạp, từ tra cứu đơn điều khoản (“Vốn điều lệ tối thiểu công ty chứng khoán là bao nhiêu?”) đến các tình huống multi-hop đòi hỏi suy luận liên văn bản.

Mỗi câu hỏi được gán nhãn thủ công (manual annotation) bởi chuyên gia miền với 1–8 điều khoản liên quan (gold articles). Tiêu chí gán nhãn: một điều khoản được gán là “gold” nếu cần thiết để trả lời đầy đủ câu hỏi – tức là nếu thiếu điều khoản đó, câu trả lời sẽ không hoàn chỉnh hoặc thiếu căn cứ.

Cụ thể, 400 câu hỏi pháp luật thuộc hai lĩnh vực: luật doanh nghiệp (200 câu, Luật

Bảng 3.4: Phân loại chủ đề trong quy chế đào tạo thạc sĩ

STT	Chủ đề	Nội dung chính	Số điều liên quan
1	Quy trình đào tạo	Đăng ký môn học, lịch học, nghỉ phép, chuyển ngành	18
2	Điều kiện tốt nghiệp	Điểm TB, ngoại ngữ, bài báo, luận văn	12
3	Luận văn	Đề cương, GVHD, hội đồng, bảo vệ, chỉnh sửa	22
4	Đánh giá kết quả	Thang điểm, quy đổi, cảnh báo, buộc thôi học	10
5	Tuyển sinh	Điều kiện dự tuyển, hồ sơ, xét tuyển	8
6	Liên chính	Đạo văn, gian lận, xử lý vi phạm	8
7	Quy định GVHD	Tiêu chuẩn, số lượng, trách nhiệm	6
Tổng			84

Doanh nghiệp 2020 và các nghị định hướng dẫn) và luật giao thông (200 câu, Luật Trật tự, An toàn Giao thông Đường bộ 2024 và Nghị định 168/2024/NĐ-CP về xử phạt vi phạm hành chính). 130 câu hỏi đào tạo bao gồm các chủ đề thường gặp của học viên cao học: quy trình đào tạo, điều kiện tốt nghiệp, thủ tục bảo vệ luận văn, chuẩn ngoại ngữ đầu ra, đăng ký môn học, và học phí. Việc đánh giá trên cả ba miền nhằm chứng minh tính tổng quát của phương pháp.

3.2.6 Phân loại câu hỏi theo độ phức tạp

Phần này trình bày chi tiết phân loại bộ 130 câu hỏi miền quy định đào tạo theo ba mức độ phức tạp truy xuất, phản ánh số bước suy luận cần thiết để tìm đúng điều khoản. Bộ 400 câu hỏi miền pháp luật được thiết kế theo tiêu chí khác: toàn bộ đều thuộc dạng multi-hop yêu cầu suy luận đa bước, và sẽ được mô tả chi tiết trong Chương 4 cùng với kết quả thử nghiệm.

- **Single-hop (58 câu, 44,6%):** Câu hỏi chỉ cần tra cứu một điều khoản duy nhất,

thường có từ khóa trùng khớp trực tiếp với tiêu đề hoặc nội dung điều khoản. Ví dụ: “Thời gian đào tạo thạc sĩ tối đa là bao lâu?” → Điều 5 QĐ 270 (thời gian đào tạo).

- **Multi-hop (52 câu, 40,0%)**: Câu hỏi cần kết hợp thông tin từ nhiều điều khoản hoặc nhiều văn bản. Chia thành hai dạng phụ:
 - *Intra-document* (31 câu): Nhiều điều trong cùng văn bản. Ví dụ: “Quy trình bảo vệ luận văn từ A-Z?” cần Điều 22 (đề cương), Điều 23 (hội đồng), Điều 24 (điều kiện), Điều 25 (quy trình bảo vệ) QĐ 270.
 - *Cross-document* (21 câu): Kết hợp nhiều văn bản. Ví dụ: “Yêu cầu ngoại ngữ đầu ra cho học viên cao học?” cần Điều 29 QĐ 270 (điều kiện tốt nghiệp) và Điều 25 QĐ 1393 (chi tiết yêu cầu ngoại ngữ).
- **Reasoning (20 câu, 15,4%)**: Câu hỏi đòi hỏi suy luận logic dựa trên các quy định, thường là tình huống giả định yêu cầu áp dụng nhiều điều kiện. Ví dụ: “Học viên đã hết thời gian gia hạn nhưng chưa bảo vệ luận văn thì có thể làm gì?” cần suy luận từ Điều 17 (gia hạn) kết hợp Điều 20 (buộc thôi học) và Điều 16 (bảo lưu).

3.2.7 Thống kê và phân tích bộ câu hỏi

Bảng 3.5 trình bày phân bố câu hỏi theo chủ đề. Phân bố này phản ánh tần suất thực tế của các câu hỏi từ điển đàn: quy trình đào tạo và điều kiện tốt nghiệp là hai chủ đề được quan tâm nhiều nhất.

Phân tích cho thấy các chủ đề phức tạp (Luận văn, Điều kiện tốt nghiệp) có tỷ lệ câu hỏi multi-hop và reasoning cao hơn do bản chất liên kết nhiều điều khoản. Ngược lại, các chủ đề rõ ràng (Đánh giá kết quả, Tuyển sinh) có nhiều câu single-hop hơn.

Số gold articles trung bình mỗi câu hỏi là 3,0 (min: 1, max: 6, trung vị: 3). Phân bố: 3 câu có 1 gold article, 40 câu có 2 gold articles, 49 câu có 3 gold articles, 29 câu có 4 gold articles, 8 câu có 5 gold articles, và 1 câu có 6 gold articles. Phân bố nghiêng về phía đa điều khoản phản ánh đặc trưng tham chiếu chéo của hệ thống quy chế đào tạo, nơi hầu hết câu hỏi đòi hỏi kết hợp quy định từ nhiều điều khoản hoặc nhiều văn bản khác nhau.

3.3. Tiền xử lý dữ liệu

Bảng 3.5: Thống kê bộ câu hỏi kiểm thử miền quy định đào tạo

Chủ đề	Số câu	Tỷ lệ	Single	Multi	Reason
Quy trình đào tạo	28	21,5%	10	14	4
Điều kiện tốt nghiệp	25	19,2%	8	12	5
Luận văn	22	16,9%	8	10	4
Đánh giá kết quả	18	13,8%	12	4	2
Tuyển sinh	15	11,5%	9	4	2
Liên chính học thuật	12	9,2%	6	4	2
Quy định GVHD	10	7,7%	5	4	1
Tổng	130	100%	58	52	20

Bảng 3.6 trình bày 10 ví dụ câu hỏi mẫu từ bộ kiểm thử, bao phủ các mức độ phức tạp và chủ đề khác nhau.

Ký hiệu: S = Single-hop, M = Multi-hop, R = Reasoning.

Chi tiết kết quả đánh giá trên cả hai bộ dữ liệu (đào tạo và pháp luật) được trình bày trong Chương 4.

3.3 Tiền xử lý dữ liệu

Sau khi thu thập và số hóa các văn bản quy chế, dữ liệu thô cần trải qua một chuỗi bước tiền xử lý trước khi được đưa vào hệ thống truy xuất. Mục tiêu của giai đoạn này là đảm bảo chất lượng và nhất quán của dữ liệu, đồng thời chuyển đổi văn bản thành các biểu diễn số phục vụ cho truy xuất vector. Các bước tiền xử lý bao gồm chuẩn hóa văn bản, xử lý cấu trúc phân cấp, và chuẩn bị dữ liệu cho bước lập chỉ mục.

3.3.1 Chuẩn hóa văn bản

Văn bản pháp lý tiếng Việt thu thập từ nhiều nguồn khác nhau thường chứa nhiều vấn đề về định dạng và mã hóa cần được xử lý thống nhất. Bước đầu tiên là chuẩn hóa Unicode, đảm bảo rằng các ký tự tiếng Việt có dấu thanh điệu được biểu diễn nhất quán. Trong thực tế, cùng một ký tự như “ộ” có thể được mã hóa theo hai cách: một ký tự tổng hợp (precomposed, dạng NFC) hoặc ký tự cơ bản kết hợp với dấu kết hợp

Bảng 3.6: Ví dụ câu hỏi mẫu từ bộ kiểm thử

STT	Loại	Câu hỏi	Gold articles
1	S	Thời gian đào tạo thạc sĩ tối đa là bao lâu?	QĐ270: Đ.5
2	M	Điều kiện để được bảo vệ luận văn thạc sĩ?	QĐ270: Đ.24; QĐ1393: Đ.25
3	S	Điểm TB tích lũy tối thiểu để tốt nghiệp?	QĐ270: Đ.29
4	M	Yêu cầu ngoại ngữ đầu ra cho học viên cao học?	QĐ1393: Đ.25; QĐ270: Đ.29
5	S	Tiêu chuẩn để được làm GVHD luận văn ThS?	QĐ218: Đ.3
6	S	Thế nào là hành vi đạo văn trong luận văn?	QĐ851: Đ.3
7	S	Học viên bị cảnh báo học vụ khi nào?	QĐ270: Đ.18
8	R	HV khóa 2021 có được áp dụng quy chế mới không?	QĐ1393: Đ.32
9	M	Số tín chỉ tối thiểu cho ThS nghiên cứu?	QĐ270: Đ.8; QĐ1393: Đ.15
10	R	GVHD được hướng dẫn tối đa bao nhiêu HV?	QĐ218: Đ.4

(combining mark, dạng NFD), dẫn đến sự không nhất quán khi so khớp chuỗi và tính toán embedding. Hệ thống sử dụng chuẩn hóa NFD (Canonical Decomposition) để phân tách ký tự tiếng Việt thành ký tự cơ bản và dấu kết hợp, cho phép so sánh và khớp chuỗi ở mức ký tự cơ bản một cách nhất quán. Cách tiếp cận này đặc biệt hữu ích khi cần so khớp fuzzy giữa các chuỗi có dấu thanh điệu khác nhau hoặc thiếu dấu do lỗi OCR.

Tiếp theo là chuẩn hóa khoảng trắng và ký tự đặc biệt. Các văn bản PDF sau khi trích xuất text thường chứa nhiều khoảng trắng liên tiếp, ký tự tab, dấu cách không phân cách (non-breaking space, U+00A0), và ký tự xuống dòng thừa. Tất cả các biến thể khoảng trắng này được chuẩn hóa về dấu cách đơn (U+0020). Đối với các ký tự đặc biệt xuất hiện trong văn bản pháp lý như dấu gạch ngang dài (em dash —), dấu gạch ngang ngắn (en dash –), và các biến thể dấu ngoặc kép (“ và ” theo kiểu typography), chúng được ánh

xạ về dạng ASCII chuẩn tương ứng để tránh sự không nhất quán khi so khớp từ khóa.

Định dạng số trong văn bản quy chế cũng được chuẩn hóa. Các ngày tháng xuất hiện với nhiều dạng khác nhau (“25/04/2022”, “ngày 25 tháng 4 năm 2022”, “25-4-2022”) được chuẩn hóa về dạng “dd/mm/yyyy”. Số hiệu điều khoản như “Điều 24” hay “điều 24” được thống nhất viết hoa chữ “Điều” để hỗ trợ trích xuất tham chiếu chéo. Các giá trị số học liên quan đến điểm số, tín chỉ, và thời gian được giữ nguyên nhưng chuẩn hóa đơn vị (ví dụ: “1,5 năm” thay vì “một năm rưỡi”).

Một thách thức đặc thù khi xử lý văn bản từ PDF scan là các lỗi OCR, mặc dù đã sử dụng LLM Vision OCR với độ chính xác cao. Các lỗi phổ biến bao gồm dấu thanh điệu bị lệch vị trí (ví dụ: “quyết” thay vì “quyết”, “hôi” thay vì “hội”), chữ cái bị nhận nhầm do hình dạng tương tự (“l” và “1”, “O” và “0”), và khoảng cách giữa các ký tự bị mất (“đào tạo” thay vì “đào tạo”). Để xử lý các lỗi này, luận văn áp dụng danh sách thay thế (correction dictionary) được tổng hợp từ quá trình rà soát thủ công trên toàn bộ kết quả OCR. Danh sách bao gồm các cặp (chuỗi_lỗi, chuỗi_đúng) phổ biến nhất, ưu tiên các lỗi xuất hiện ở nhiều văn bản. Quá trình thay thế được thực hiện theo thứ tự độ dài giảm dần (longest-match-first) để tránh thay thế sai trong trường hợp một chuỗi lỗi là tiền tố của chuỗi lỗi khác.

3.3.2 Xử lý cấu trúc phân cấp

Sau khi chuẩn hóa văn bản thô, bước tiếp theo là chuyển đổi dòng văn bản liên tục thành cấu trúc phân cấp có tổ chức, phản ánh hệ thống 6 cấp của văn bản quy phạm pháp luật Việt Nam (Văn bản → Chương → Mục → Điều → Khoản → Điểm).

Việc phát hiện ranh giới câu (sentence boundary detection) trong văn bản pháp lý tiếng Việt đặt ra thách thức riêng so với văn bản thông thường. Viết tắt chuyên ngành như “ThS.”, “QĐ.”, “Đ.” (viết tắt của “Điều”), “Kh.” (“Khoản”) thường chứa dấu chấm nhưng không đánh dấu kết thúc câu. Tương tự, các điều khoản được đánh số như “1.” hay “a)” đứng đầu dòng không phải là ranh giới câu. Luận văn xây dựng danh sách viết tắt chuyên ngành pháp lý và hành chính (bao gồm các viết tắt tổ chức, loại hình doanh nghiệp, cơ quan nhà nước, và loại văn bản quy phạm) để loại trừ khỏi bộ phát hiện ranh giới câu, kết hợp với quy tắc ngữ cảnh: dấu chấm theo sau bởi chữ thường tiếp theo không được tính là kết thúc câu.

Phân đoạn đoạn văn (paragraph segmentation) tuân theo cấu trúc phân cấp cụ thể của từng văn bản. Bộ phân tích cú pháp (parser) nhận diện các dấu hiệu cấp độ qua pattern

matching với regex tiếng Việt, sau đó sử dụng thuật toán đẩy–kéo (push–pop stack) để xây dựng cây phân cấp. Điều quan trọng là không phải văn bản nào cũng sử dụng đủ 6 cấp; ví dụ QĐ 270 không có cấp Mục, và bộ phân tích phải xử lý cả trường hợp này mà không gây lỗi phân cấp.

Một số văn bản quy chế còn chứa bảng biểu và phụ lục. Ví dụ, QĐ 270 có bảng quy đổi điểm số (Phụ lục I) và biểu mẫu đơn xin bảo lưu kết quả (Phụ lục II). Các bảng biểu được trích xuất riêng và lưu trữ dưới dạng metadata gắn với nút văn bản tương ứng trong cây phân cấp. Nội dung bảng biểu không được đưa vào quá trình embedding vì định dạng dạng bảng thường không phù hợp với mô hình embedding văn bản, thay vào đó được cung cấp trực tiếp cho LLM khi cần thiết thông qua cơ chế tra cứu chính xác (exact lookup).

Trích xuất metadata từ tiêu đề và phần mở đầu văn bản bao gồm: số hiệu quyết định (ví dụ: “270/QĐ-ĐHCNTT”), ngày ban hành, cơ quan ban hành, và ngày có hiệu lực. Thông tin này được lưu trữ dưới dạng thuộc tính (attribute) của nút gốc trong Document Forest, phục vụ cho bộ lọc (filter) khi truy xuất theo văn bản hoặc theo thời gian hiệu lực.

Phát hiện và xử lý trùng lặp nội dung là một vấn đề thực tế khi làm việc với bộ văn bản quy chế có mối quan hệ kế thừa. QĐ 1393 kế thừa phần lớn nội dung từ QĐ 160, trong khi QĐ 218 sửa đổi bổ sung một số điều trong QĐ 1393. Để tránh việc cùng một thông tin pháp lý xuất hiện nhiều lần trong chỉ mục và gây nhiễu kết quả truy xuất, luận văn áp dụng bộ phát hiện trùng lặp dựa trên độ tương đồng chuỗi: mỗi điều khoản được chuẩn hóa về dạng canonical (loại bỏ dấu thanh điệu, viết thường, chuẩn hóa viết tắt) và so sánh bằng Jaro-Winkler similarity. Các điều khoản có độ tương đồng Jaro-Winkler $\geq 0,98$ được đánh dấu là trùng lặp tiềm năng và xử lý theo chính sách “giữ bản mới nhất” (keep-latest): trong bộ dữ liệu này, ưu tiên QĐ 1393 so với QĐ 160 và QĐ 218 so với QĐ 1393 cho các điều khoản tương ứng.

3.3.3 Chuẩn bị dữ liệu cho truy xuất

Sau khi văn bản đã được chuẩn hóa và phân cấu trúc, bước cuối cùng là chuyển đổi thành các biểu diễn phù hợp với hệ thống truy xuất. Giai đoạn này bao gồm ba công việc chính: xác định đơn vị truy xuất (retrieval unit), tính toán embedding vector, và xây dựng chỉ mục tìm kiếm.

Chiến lược phân đoạn theo điều (article-level chunking) được áp dụng: mỗi Điều trong văn bản quy chế trở thành một đơn vị truy xuất độc lập. Cách tiếp cận này ưu việt hơn phân đoạn theo kích thước cố định (fixed-size chunking) [18] theo nhiều phương diện. Thứ nhất, mỗi Điều trong văn bản pháp lý có ngữ nghĩa trọn vẹn và ranh giới pháp lý rõ ràng – đây là đơn vị trích dẫn trong thực tiễn hành chính và pháp lý Việt Nam. Thứ hai, phân đoạn theo điều bảo toàn ngữ cảnh đầy đủ của quy định: một Điều về “điều kiện bảo vệ luận văn” chứa tất cả các Khoản và Điểm liên quan, không bị cắt đứt giữa chừng như có thể xảy ra với fixed-size chunking. Thứ ba, kích thước của các Điều trong bộ dữ liệu này khá đồng đều (trung bình 180 token, min 45, max 520 token), phù hợp với giới hạn của mô hình embedding.

Mỗi đơn vị truy xuất được gán một định danh nút (node ID) theo sơ đồ phân cấp với tiền tố cho từng cấp: c cho chương (chapter), d cho điều (article), k cho khoản (clause), và chữ cái thường cho điểm (point). Cụ thể, định danh điều có dạng {doc_id}:d{số_điều}, trong đó doc_id là mã văn bản theo số hiệu quyết định (ví dụ: 270-QĐ-DHCNTT). Ví dụ đầy đủ: 270-QĐ-DHCNTT:d24 xác định duy nhất Điều 24 của QĐ 270/QĐ-DHCNTT. Đối với cấp thấp hơn, định danh được nối tiếp: 270-QĐ-DHCNTT:d24:k1 cho Khoản 1 của Điều 24, và 270-QĐ-DHCNTT:d24:k1:a cho Điểm a của Khoản 1 đó. Sơ đồ này cho phép cả truy xuất theo vị trí (vị trí trong cây Document Forest) lẫn tra cứu trực tiếp theo số hiệu điều khoản.

Việc tính toán embedding sử dụng mô hình paraphrase-multilingual-MiniLM-L12-v2 [28], một mô hình trong họ Sentence-BERT được huấn luyện đa ngôn ngữ trên 50 ngôn ngữ bao gồm tiếng Việt. Mô hình này được chọn vì ba lý do: hỗ trợ tiếng Việt tốt nhờ dữ liệu huấn luyện đa ngôn ngữ; kích thước compact (117 triệu tham số, 418 MB) phù hợp triển khai trên phần cứng hạn chế; và chiều embedding 384 tạo vector đủ biểu diễn mà không quá lớn ảnh hưởng đến hiệu suất tìm kiếm. Mỗi đơn vị truy xuất (một Điều) được biểu diễn bởi một vector embedding duy nhất tính từ toàn bộ nội dung điều đó, bao gồm tiêu đề và tất cả các khoản, điểm con.

Việc sinh tóm tắt cho từng chương và điều bằng LLM (Claude 3.5 Haiku) được thực hiện song song trong giai đoạn này, phục vụ cho Tầng 1 của pipeline truy xuất (đã trình bày chi tiết tại Mục 3.2.1). Tóm tắt không được dùng để thay thế nội dung gốc mà bổ sung thêm biểu diễn ngữ nghĩa ngắn gọn, giúp Tầng 1 xác định nhanh nhánh Document Forest cần duyệt.

Sau khi tính xong tất cả 109 embedding vector (một cho mỗi Điều trong 5 văn bản

3.4. Tổng quan kiến trúc hệ thống

quy chế), các vector này được lưu trữ để phục vụ truy xuất ngữ nghĩa tại Tầng 2 của pipeline. Việc tìm kiếm điều khoản tương đồng sử dụng cosine similarity trên các vector embedding, cho phép xếp hạng các điều khoản theo mức độ liên quan ngữ nghĩa đến truy vấn. Với tập dữ liệu nhỏ (109 vector, 384 chiều), phương pháp tìm kiếm vét cạn (exhaustive search) đảm bảo kết quả chính xác 100% mà không cần sử dụng chỉ mục xấp xỉ, đồng thời chi phí tính toán hoàn toàn chấp nhận được (dưới 1 ms cho mỗi truy vấn).

Riêng đối với chỉ mục chủ đề (theme index), hệ thống sử dụng FAISS (Facebook AI Similarity Search) với cấu hình IndexFlatIP kết hợp chuẩn hóa L2 (tương đương cosine similarity) để lưu trữ và tìm kiếm nhanh các vector embedding của chủ đề. Chỉ mục FAISS cho chủ đề được lưu trữ dưới dạng nhị phân trên đĩa, cho phép tải lại nhanh mà không cần tính toán lại embedding khi khởi động hệ thống.

Bảng 3.7 tóm tắt các số liệu thống kê của bộ dữ liệu sau khi hoàn tất quá trình tiền xử lý.

Bảng 3.7: Thống kê dữ liệu sau tiền xử lý

Thành phần	Số lượng/Giá trị
Tổng số điều khoản (retrieval units)	109
Chiều embedding	384
Mô hình embedding	MiniLM-L12-v2
Kích thước FAISS index	$\approx$ 167 KB
Số nút Document Forest	9.226
Tóm tắt chương	17
Tóm tắt điều	109

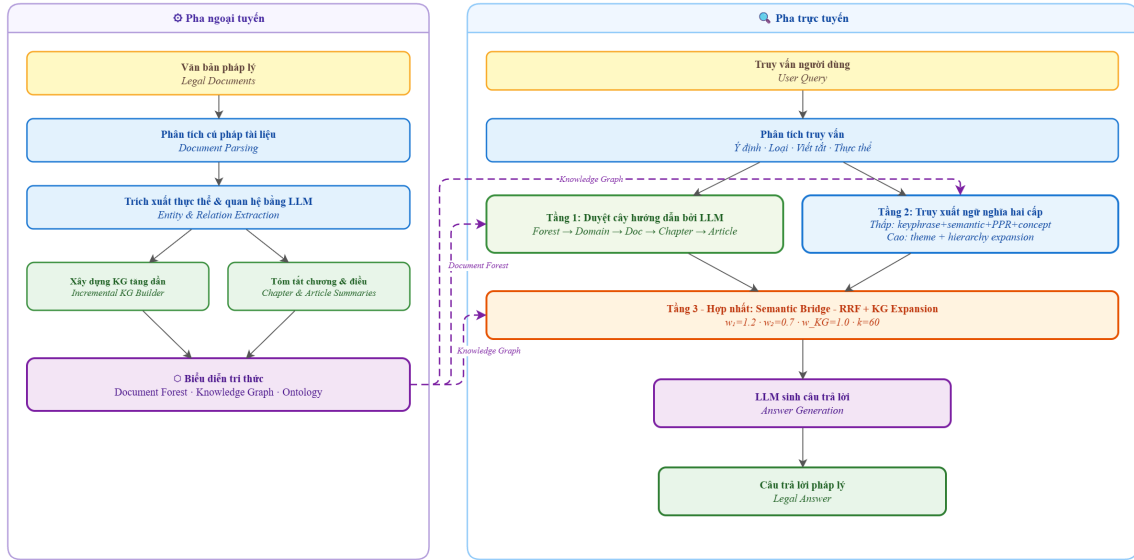
3.4 Tổng quan kiến trúc hệ thống

Kiến trúc hệ thống được chia thành hai pha: pha ngoại tuyến (offline phase) và pha trực tuyến (online phase), như minh họa trong Hình 3.3.

3.4.1 Pha ngoại tuyến

Pha ngoại tuyến xây dựng bốn bộ biểu diễn tri thức từ kho tài liệu thô, tuân theo phương pháp kỹ thuật tri thức [31]. Các biểu diễn này phục vụ cho từng tầng truy xuất

3.4. Tổng quan kiến trúc hệ thống



Hình 3.3: Kiến trúc hệ thống truy xuất ba tầng. Pha ngoại tuyến (trái): xây dựng mô hình tri thức từ văn bản quy phạm. Pha trực tuyến (phải): xử lý truy vấn qua Tầng 1 (duyet cây cấu trúc), Tầng 2 (truy xuất ngữ nghĩa hai cấp), và Tầng 3 (hợp nhất RRF với mở rộng KG).

khác nhau trong pha trực tuyến.

Document Forest. Mỗi văn bản quy phạm được phân tích thành cây có gốc theo cấu trúc phân cấp 6 cấp: Văn bản → Chương → Mục → Điều → Khoản → Điểm. Bộ phân tích cú pháp (parser) sử dụng regex nhận diện các dấu hiệu phân cấp tiếng Việt (“Chương I”, “Điều 5”, “Khoản 1”, “Điểm a”) để xây dựng cây cấu trúc. Mỗi nút trong cây lưu trữ: mã định danh (node_id), loại nút (node_type), tên, nội dung văn bản, và metadata (số hiệu, ngày ban hành, cơ quan ban hành).

Mỗi nút được gán một định danh hợp thành (composite ID) mã hóa vị trí trong cấu trúc phân cấp theo quy tắc {số_hiệu_văn_bản}:{tiền_tổ}{số}, các cấp phân cách bằng dấu hai chấm (:). Bảng 3.8 trình bày quy tắc đặt tiền tố cho từng cấp. Ví dụ, Điều 5 của Luật Doanh nghiệp 2020 có định danh 59-2020-QH14:d5, Chương 3 của Quy chế 1393 có định danh 1393-QD-DHQQ:c3. Sơ đồ này cho phép: tra cứu nút trong thời gian $O(1)$ qua bảng băm, tham chiếu chéo rõ ràng giữa các cây (ví dụ: 270-QD-DHCNTT:d24 tham chiếu đến 1393-QD-DHQQ:d25), và con người có thể đọc hiểu trực tiếp mà không cần truy ngược cây.

3.4. Tổng quan kiến trúc hệ thống

Bảng 3.8: Quy tắc đặt định danh nút trong Document Forest

Cấp	Tiền tố	Ví dụ
Văn bản (gốc)	–	59-2020-QH14
Chương	c	59-2020-QH14 : c2
Mục	m	59-2020-QH14 : c2 : m1
Điều	d	59-2020-QH14 : d5
Khoản	k	59-2020-QH14 : d5 : k1
Điểm	(ký tự)	59-2020-QH14 : d5 : k1 : a

Tập hợp tất cả các cây tạo thành Document Forest – cấu trúc dữ liệu trung tâm cho Tầng 1 (duyet cây). Các cạnh tham chiếu chéo (cross-reference) được phát hiện bằng pattern matching trên các chuỗi trích dẫn (ví dụ: “theo Điều 5 Quy chế 270”, “căn cứ Khoản 1 Điều 24”) và liên kết các điều khoản giữa các tài liệu khác nhau. Mỗi tham chiếu được phân loại theo kiểu: THAM_CHIẾU (dẫn chiếu), SỬA_ĐỔI (amend), hoặc THAY_THẾ (replace).

Knowledge Graph. Knowledge Graph (KG) được xây dựng qua quy trình bốn bước:

- Trích xuất thực thể và quan hệ:** Với mỗi điều khoản, LLM trích xuất đồng thời thực thể và quan hệ trong một lời gọi duy nhất (theo phong cách LightRAG [10]). Prompt hướng dẫn LLM trích xuất đầy đủ các thực thể quan trọng, ghi evidence (trích dẫn nguyên văn) cho mỗi quan hệ, và sử dụng tên thực thể chính xác như trong văn bản (xem Phụ lục D, Bảng D.1).
- Khử trùng lặp thực thể:** Trong quá trình trích xuất, bộ khử trùng lặp (deduplicator) sử dụng Jaro-Winkler similarity (ngưỡng $\geq 0,98$) kết hợp chuẩn hóa dạng chính tắc tiếng Việt (loại dấu, chuẩn hóa viết tắt pháp lý) để nhận diện và hợp nhất các thực thể trùng lặp ngay trong quá trình xây dựng. Thực thể được hợp nhất lưu giữ tất cả alias, source ID, và mô tả dài nhất.
- Xây dựng ontology:** Hệ thống tự động sinh ontology miền từ dữ liệu KG đã trích xuất, sử dụng LLM để phân loại thực thể thành các lớp OWL có ý nghĩa. Ontology định nghĩa 14 loại thực thể (Action, Legal Term, Organization, Penalty, Condition, Person Role, v.v.) với phân cấp tối đa 4 cấp. Mỗi lớp có tên tiếng Anh

3.4. Tổng quan kiến trúc hệ thống

(chuẩn OWL) kèm nhãn và mô tả tiếng Việt. Ontology xuất ra định dạng Turtle (.ttl) và JSON.

4. **Tinh chỉnh bởi chuyên gia:** Sau khi tự động trích xuất, KG được rà soát và tinh chỉnh thủ công bởi chuyên gia miền (expert-in-the-loop). Quá trình này bao gồm: thêm các quan hệ bị thiếu (đặc biệt là REFERENCES giữa các điều khoản liên quan), xóa các thực thể nhiễu, và điều chỉnh trọng số quan hệ (STRONG/WEAK) để cải thiện chất lượng truy xuất.

Bảng 3.9 tóm tắt thống kê Knowledge Graph được xây dựng. Hệ thống cũng phân loại quan hệ theo mức độ: quan hệ mạnh (STRONG) gồm references, requires, depends_on – các quan hệ này được sử dụng cho mở rộng KG trong Tầng 3, trong khi quan hệ yếu (WEAK) như related_to, is_a chỉ dùng cho tính điểm ngữ nghĩa trong Tầng 2.

Bảng 3.9: Thống kê Knowledge Graph

Loại thực thể	Số lượng	Loại quan hệ	Số lượng	Cấu trúc	Số lượng
Tổng thực thể	5.936	Tổng quan hệ	5.963	Nút	9.226
Action	1.903	requires	1.377	Tài liệu	13
Legal Term	1.632	applies_to	810	Chương	77
Organization	500	has_authority	506	Điều khoản	840
Legal Reference	451	references	434	Tham chiếu chéo	168
Khác (9 loại)	1.450	Khác (52 loại)	2.506		

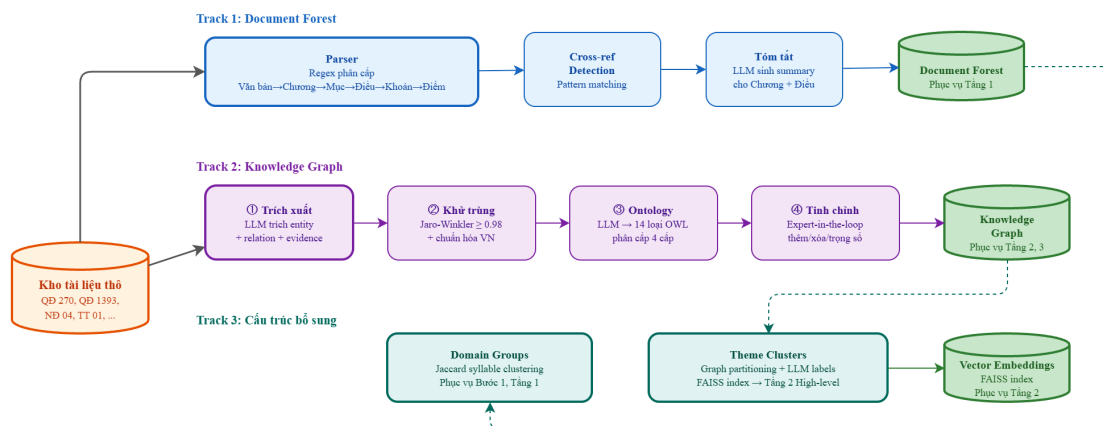
Tóm tắt chương và điều. Để Tầng 1 có thể chọn nhánh mà không cần đọc toàn bộ nội dung điều khoản, hệ thống sinh tóm tắt cho từng chương và điều bằng LLM. Tóm tắt chương bao gồm phạm vi điều khoản (ví dụ: “Điều 1–16”) và danh sách từ khóa đặc trưng do LLM trích xuất từ nội dung các điều trong chương. Tóm tắt điều gồm tiêu đề và các từ khóa chính. Các mô tả này được sử dụng trực tiếp làm thuộc tính description của các nút trong Document Forest, cung cấp đủ ngữ cảnh cho LLM đưa ra quyết định chọn nhánh trong Bước 2 và Bước 3 (xem prompt chi tiết tại Phụ lục D, Bảng D.2 và D.3).

Nhóm miền và cụm chủ đề. Hai cấu trúc bổ sung được xây dựng để phục vụ các tầng truy xuất khác nhau:

3.4. Tổng quan kiến trúc hệ thống

- **Nhóm miền (Domain Groups):** Các tài liệu được phân nhóm tự động dựa trên sự trùng khớp của từ khóa (Jaccard similarity ở mức âm tiết). Thuật toán lấy các văn bản gốc làm neo (anchor), sau đó gán các nghị định, thông tư liên quan vào nhóm có độ trùng khớp từ khóa cao nhất. Mỗi nhóm miền lưu nhãn, danh sách từ khóa đặc trưng, và ID các tài liệu thành viên. Cấu trúc này phục vụ Bước 1 của Tầng 1 để nhanh chóng thu hẹp không gian tìm kiếm từ toàn bộ kho xuống nhóm miền phù hợp. Để dễ dàng mở rộng sau này khi áp dụng phương pháp trên nhiều domain và tài liệu khác nhau hơn.
- **Cụm chủ đề (Theme Clusters):** Các thực thể KG được nhóm thành các cụm chủ đề bằng cách phân hoạch đồ thị KG thành các đồ thị con liên thông, sau đó sử dụng LLM để trích xuất tên chủ đề, mô tả, và từ khóa tìm kiếm cho mỗi cụm. Vector nhúng trung bình của các thực thể trong cụm được tính và lưu vào chỉ mục FAISS để phục vụ tìm kiếm ngữ nghĩa nhanh. Cấu trúc này phục vụ high-level (theme matching) của Tầng 2.

Hình 3.4 minh họa toàn bộ quy trình xây dựng tri thức ngoại tuyến với ba track song song: Document Forest, Knowledge Graph, và các cấu trúc bổ sung phục vụ từng tầng truy xuất.



Hình 3.4: Quy trình xây dựng tri thức ngoại tuyến. Track 1 phân tích cấu trúc văn bản thành Document Forest. Track 2 xây dựng Knowledge Graph qua 4 bước. Track 3 tạo Domain Groups và Theme Clusters phục vụ tìm kiếm.

3.4.2 Pha trực tuyến

Pha trực tuyến đầu tiên phân tích truy vấn (phân loại ý định, mở rộng viết tắt, trích xuất thực thể giống), sau đó xử lý qua ba tầng truy xuất: duyệt cây hướng dẫn bởi LLM (Tầng 1), truy xuất ngữ nghĩa hai cấp trên Knowledge Graph (Tầng 2), và hợp nhất với mở rộng Knowledge Graph (Tầng 3).

3.5 Kiến trúc truy xuất 3-Tier KG-RAG

Các văn bản quy phạm Việt Nam thường có cấu trúc phân cấp sáu cấp: Văn bản, Chương, Mục (nếu có), Điều, Khoản, Điểm với các tham chiếu chéo xuyên suốt giữa các tài liệu. Truy xuất đoạn văn bản truyền thống coi tài liệu như tập hợp phẳng, do đó không thể khai thác cấu trúc phân cấp này hoặc thực hiện suy luận đa bước.

Mỗi tài liệu được mô hình hóa dưới dạng cây có gốc (rooted tree), trong đó các nút tương ứng với các cấp cấu trúc và các cạnh biểu diễn quan hệ cha-con. Toàn bộ kho tài liệu gồm m văn bản hình thành một Document Forest:

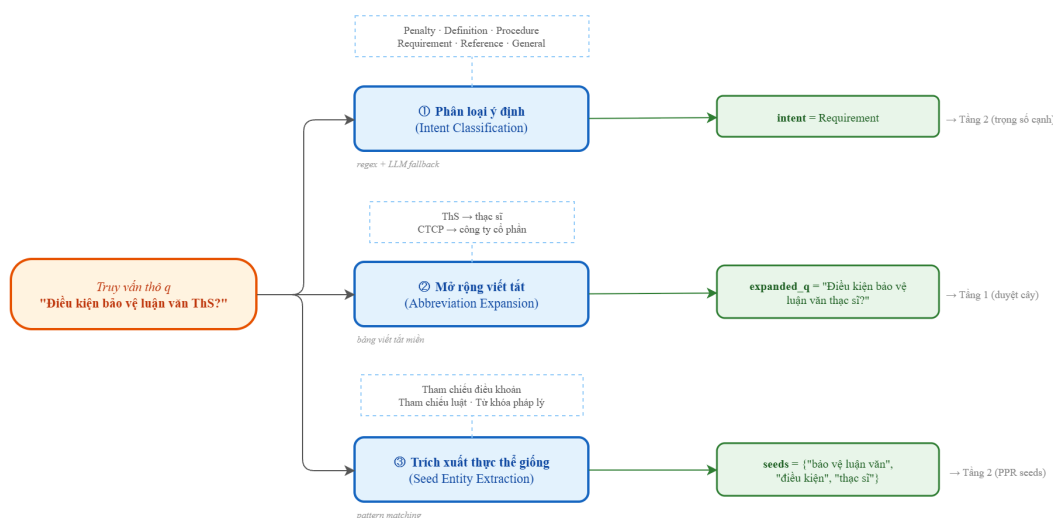
$$\mathcal{F} = \{T_1, T_2, \dots, T_m\} \quad (3.1)$$

được bổ sung các cạnh tham chiếu chéo liên kết các điều khoản giữa các cây. Mỗi nút được gán một định danh hợp thành mã hóa vị trí trong cấu trúc phân cấp, ví dụ 59-2020-QH14:c2 cho Chương 2, 59-2020-QH14:d5 cho Điều 5, cho phép tham chiếu chéo rõ ràng giữa các cây.

Bài toán truy xuất: Cho truy vấn q của người dùng, trả về danh sách xếp hạng k điều khoản liên quan nhất từ $\mathcal{F}$. Mức chi tiết ở cấp điều khoản (article-level) là cần thiết vì các quy chế đào tạo tại Việt Nam tổ chức nội dung theo đơn vị Điều, mỗi Điều quy định một vấn đề cụ thể (ví dụ: Điều 24 quy định điều kiện bảo vệ luận văn, Điều 29 quy định điều kiện tốt nghiệp). Khi trả lời câu hỏi của học viên, hệ thống cần trích dẫn chính xác đến từng Điều để đảm bảo tính minh bạch và có thể kiểm chứng, thay vì trả về các đoạn văn bản tùy ý không rõ nguồn gốc. Yêu cầu này cũng áp dụng tương tự cho miền pháp luật, nơi các điều khoản luật là đơn vị trích dẫn nhỏ nhất trong thực tiễn tư vấn pháp lý.

3.5.1 Phân tích truy vấn

Trước khi đưa vào ba tầng truy xuất, truy vấn thô q từ người dùng được xử lý qua bộ phân tích truy vấn gồm ba bước: phân loại ý định, mở rộng viết tắt, và trích xuất thực thể giống. Mỗi bước tạo ra một đầu ra cụ thể phục vụ cho các tầng truy xuất khác nhau ở giai đoạn sau. Hình 3.5 minh họa toàn bộ pipeline phân tích.



Hình 3.5: Pipeline phân tích truy vấn gồm ba bước: phân loại ý định (6 loại), mở rộng viết tắt, và trích xuất thực thể giống. Mỗi đầu ra phục vụ một tầng truy xuất khác nhau.

Phân loại ý định

Bước đầu tiên phân loại truy vấn thành một trong sáu loại ý định (Bảng 3.10), sử dụng đối sánh từ khóa tiếng Việt theo thứ tự ưu tiên. Hệ thống duyệt tuần tự các mẫu regex: nếu truy vấn chứa từ khóa khớp với mẫu có ưu tiên cao nhất, ý định tương ứng được gán; nếu không khớp bất kỳ mẫu nào, ý định mặc định là GENERAL.

Nhãn ý định ảnh hưởng đến hai giai đoạn sau: thứ nhất, Tầng 2 sử dụng nhãn để điều chỉnh trọng số cạnh trong thuật toán Personalized PageRank – các cạnh dẫn đến thực thể liên quan đến ý định nhận trọng số 1,0 trong khi các cạnh khác nhận 0,5; thứ hai, bước sinh câu trả lời sử dụng nhãn để chọn prompt IRAC phù hợp – ví dụ ý định PENALTY hướng dẫn LLM nhấn mạnh mức phạt cụ thể và điều luật áp dụng, trong khi ý định PROCEDURE hướng dẫn liệt kê các bước theo trình tự.

3.5. Kiến trúc truy xuất 3-Tier KG-RAG

Bảng 3.10: Sáu loại ý định truy vấn và mẫu nhận diện

Ý định	Từ khóa tiếng Việt	Ví dụ truy vấn
Xử phạt (Penalty)	phạt, hình phạt, mức phạt, xử phạt	“Mức phạt khi không nộp báo cáo đúng hạn?”
Định nghĩa (Definition)	là gì, định nghĩa, nghĩa là	“Cổ đông sáng lập là gì?”
Thủ tục (Procedure)	thủ tục, quy trình, hồ sơ	“Thủ tục bảo vệ luận văn gồm những bước nào?”
Yêu cầu (Requirement)	điều kiện, yêu cầu, cần phải	“Điều kiện tốt nghiệp thạc sĩ tại UIT?”
Tham chiếu (Reference)	Điều + số (regex)	“Điều 24 QĐ 270 quy định gì?”
Chung (General)	(mặc định)	“Học viên có thể chuyển ngành được không?”

Mở rộng viết tắt

Văn bản pháp luật và quy chế đào tạo Việt Nam sử dụng phổ biến các viết tắt chuyên ngành: CTCP (Công ty cổ phần), TNHH (Trách nhiệm hữu hạn), HĐQT (Hội đồng quản trị), GVHD (Giáo viên hướng dẫn), v.v. Người dùng thường nhập câu hỏi với các viết tắt này, gây khó khăn cho bước đối sánh ngữ nghĩa vì mô hình nhúng (embedding model) không được huấn luyện trên các viết tắt đặc thù tiếng Việt.

Bộ mở rộng viết tắt sử dụng từ điển 49 mục được xây dựng thủ công, bao gồm 5 nhóm chính (Bảng 3.11). Thuật toán duyệt truy vấn với regex ranh giới từ (word boundary), ưu tiên viết tắt dài hơn trước để tránh khớp nhầm (ví dụ: “TNHH 2TV” được khớp trước “TNHH”).

Ngoài mở rộng viết tắt, hệ thống còn áp dụng bảng đồng nghĩa (synonym mapping) gồm 18 mục chuyển đổi cách diễn đạt thông dụng sang thuật ngữ pháp lý chính thức. Ví dụ: “lập công ty” → “thành lập doanh nghiệp, đăng ký doanh nghiệp”; “đóng cửa” → “giải thể doanh nghiệp, chấm dứt hoạt động”. Truy vấn sau khi mở rộng viết tắt và đồng nghĩa được sử dụng trực tiếp cho Tầng 1 (duyet cây) và tính vector nhúng cho Tầng 2.

Trích xuất thực thể giống

Bước cuối cùng trích xuất ba loại thực thể giống (seed entities) từ truy vấn, phục vụ làm điểm khởi tạo cho thuật toán Personalized PageRank trong Tầng 2:

3.5. Kiến trúc truy xuất 3-Tier KG-RAG

Bảng 3.11: Phân nhóm từ điển viết tắt (49 mục)

Nhóm	Số mục	Ví dụ
Loại hình doanh nghiệp	5	CTCP, TNHH, DNTN, HTX, DN
Chức danh & tổ chức	9	HĐQT, HĐQTV, ĐHĐCĐ, TGD, GD, BKS
Văn bản pháp luật	4	NĐ, TT, QĐ, NQ
Đăng ký kinh doanh	4	GCNĐKKD, GCNĐKDN, ĐKKD, VDL
Cơ quan nhà nước	6	UBND, HĐND, CP, QH, BTC, BKHĐT
Đào tạo	7	GVHD, HV, NCS, ĐH, ĐHQG, ThS, TS
Khác	14	MST, HKD, cty/Cty, v.v.

1. **Tham chiếu điều khoản (Article Reference):** Nhận diện các tham chiếu dạng “Điều + số” bằng regex `[Đđ] iều\s+(\d+)`, bao gồm cả dạng viết tắt “Đ. 5”. Các điều khoản được khớp ngược với Document Forest để xác định nút tương ứng. Ví dụ: truy vấn “Điều 24 QĐ 270 quy định gì?” trích xuất tham chiếu đến nút 270-QĐ-DHCNTT:d24.
2. **Tham chiếu văn bản luật (Law Reference):** Nhận diện số hiệu văn bản pháp luật theo định dạng `số/năm/cơ_quan` bằng regex, ví dụ: “Luật số 68/2014/QH13” → 68/2014/QH13. Tham chiếu này được sử dụng để thu hẹp không gian tìm kiếm trong Bước 1 của Tầng 1.
3. **Từ khóa pháp lý (Legal Keywords):** Sau khi loại bỏ 15 từ dừng tiếng Việt phổ biến (là, gì, của, trong, và, các, có, được, để, cho, về, với, khi, này, theo) và các token chỉ chứa số, các từ còn lại có độ dài ≥ 2 âm tiết được giữ lại làm từ khóa. Từ khóa được đối sánh với tên thực thể trong Knowledge Graph để chọn seed cho PPR.

Bảng 3.12 minh họa đầu ra đầy đủ của bộ phân tích truy vấn trên ba câu hỏi mẫu thuộc các loại ý định khác nhau.

Các đầu ra từ bộ phân tích truy vấn được phân phối cho các tầng truy xuất như sau: Tầng 1 nhận truy vấn đã mở rộng viết tắt để cải thiện đối sánh tóm tắt chương/điều; Tầng

3.5. Kiến trúc truy xuất 3-Tier KG-RAG

Bảng 3.12: Ví dụ phân tích truy vấn trên ba câu hỏi mẫu

Truy vấn gốc	Ý định	Viết tắt mở rộng	Thực thể giống
“Mức phạt khi CTCP không nộp báo cáo tài chính?”	Penalty	CTCP → Công ty cổ phần	Từ khóa: [phạt, báo cáo tài chính, công ty cổ phần]
“Điều 24 QĐ 270 quy định gì về bảo vệ luận văn?”	Reference	QĐ → Quyết định	Điều: [24]; Từ khóa: [bảo vệ, luận văn]
“Thủ tục xin gia hạn thời gian đào tạo?”	Procedure	–	Từ khóa: [gia hạn, thời gian, đào tạo]

2 nhận thực thể giống làm seed cho PPR và nhãn ý định để điều chỉnh trọng số cạnh; và Tầng 3 sử dụng tham chiếu điều khoản (nếu có) để bổ sung trực tiếp vào danh sách ứng viên trước khi hợp nhất RRF.

3.5.2 Pipeline truy xuất ba tầng

Ba tầng truy xuất hoạt động tuần tự trên các biểu diễn tri thức đã xây dựng: Tầng 1 khai thác cấu trúc phân cấp Document Forest, Tầng 2 khai thác cấu trúc ngữ nghĩa Knowledge Graph, và Tầng 3 hợp nhất kết quả từ hai tầng trước với mở rộng đồ thị.

Tầng 1: Duyệt cây cấu trúc hướng dẫn bởi LLM

Tầng 1 nhận truy vấn đã mở rộng và Document Forest, trả về danh sách xếp hạng các điều khoản ứng viên với điểm cấu trúc. Lấy cảm hứng từ PageIndex [33], Tầng 1 sử dụng suy luận LLM để duyệt cây từ trên xuống (top-down) qua ba bước thu hẹp dần không gian tìm kiếm: từ toàn bộ kho văn bản xuống tài liệu, rồi chương, rồi điều khoản cụ thể. Mỗi bước tạo ra một chuỗi suy luận (reasoning trace) phục vụ khả năng giải thích (interpretability).

Bước 1: Chọn tài liệu. Khi kho có nhiều hơn một tài liệu, LLM được cung cấp danh sách các nhóm miền (domain group) cùng từ khóa đặc trưng đã tính toán trước trong giai đoạn offline. LLM chọn nhóm miền phù hợp nhất với truy vấn, từ đó xác định tập tài

3.5. Kiến trúc truy xuất 3-Tier KG-RAG

liệu liên quan. Nếu nhóm miền chứa nhiều hơn 5 tài liệu, LLM được gọi lần hai để thu hẹp xuống tối đa 5 tài liệu dựa trên tóm tắt phạm vi (scope preview) của từng tài liệu.

Cơ chế fallback: nếu LLM không trả về kết quả hợp lệ, hệ thống sử dụng đối sánh từ khóa (keyword overlap) giữa các âm tiết trong truy vấn và từ khóa miền để chọn nhóm có điểm trùng khớp cao nhất.

Bước 2: Chọn chương. LLM nhận cấu trúc tài liệu gồm tên và mô tả tóm tắt của từng chương, cùng với truy vấn (có gợi ý ngữ nghĩa từ bước mở rộng truy vấn nếu có). LLM chọn tối đa 8 chương phù hợp nhất và trả về JSON chứa danh sách index cùng độ tin cậy (xem Phụ lục D, Bảng D.4). Nhiệt độ (temperature) = 0,0 đảm bảo kết quả xác định, loại bỏ phương sai giữa các lần chạy.

Hai cơ chế bổ sung:

- **Tự động bổ sung chương “Quy định chung”:** Các chương chứa định nghĩa thuật ngữ và phạm vi áp dụng (thường là Chương 1) được tự động thêm vào nếu LLM chưa chọn, vì các chương này thường chứa các điều khoản nền tảng cần thiết để hiểu các điều khoản chuyên biệt.
- **Mở rộng khi độ tin cậy thấp:** Nếu LLM chỉ chọn một chương với độ tin cậy (confidence) < 0,98, hệ thống gọi LLM lần hai với các chương còn lại để xem xét bổ sung thêm, giảm rủi ro bỏ sót khi truy vấn mơ hồ.

Cơ chế fallback: nếu LLM thất bại, hệ thống chọn các chương có nhiều điều khoản nhất (thay vì chọn theo thứ tự xuất hiện), vì các chương lớn thường bao phủ nhiều chủ đề hơn.

Bước 3: Chọn điều khoản. Với mỗi chương đã chọn, LLM nhận danh sách điều khoản kèm tóm tắt (tiêu đề, từ khóa) và chọn tối đa 7 điều khoản phù hợp (xem Phụ lục D, Bảng D.5). Nhiệt độ = 0,0 cho kết quả ổn định. Trước khi gọi LLM, hệ thống bổ sung hai tín hiệu hỗ trợ vào thông tin mỗi điều khoản:

- **Điểm ngữ nghĩa (semantic score):** Cosine similarity giữa vector nhúng truy vấn và vector nhúng của tiêu đề + từ khóa điều khoản, chuyển thành thứ hạng tương đối (semantic_rank, 1 = phù hợp nhất).
- **Điểm KG (dual score):** Điểm từ Tầng 2 (DualLevel Retriever) chạy ở chế độ low-level, chuyển thành thứ hạng tương đối (dual_rank). Tín hiệu này giúp LLM ưu tiên các điều khoản có liên kết KG mạnh với truy vấn.


3.5. Kiến trúc truy xuất 3-Tier KG-RAG

Prompt hướng dẫn LLM ưu tiên các điều khoản có thứ hạng thấp (rank thấp = phù hợp hơn), nhưng LLM vẫn có quyền quyết định cuối cùng dựa trên nội dung tóm tắt.

Sau khi tất cả chương được xử lý, các điều khoản được gộp, loại trùng lặp, và giới hạn tổng số lượng. Điểm tin cậy tổng hợp của Tầng 1 được tính bằng trung bình có trọng số giữa confidence của Bước 2 ($\times 0,45$) và trung bình confidence của Bước 3 ($\times 0,55$), giới hạn tối đa 0,95.

Logic retry (3 lần, exponential backoff) được áp dụng cho tất cả lời gọi LLM để xử lý các lỗi tạm thời từ proxy hoặc API.

Hình 3.6 minh họa quá trình duyệt cây ba bước với một truy vấn ví dụ từ miền quy định đào tạo.



Hình 3.6: Minh họa quá trình duyệt cây ba bước với truy vấn “Điều kiện để được bảo vệ luận văn thạc sĩ?”. Các nút xanh là được chọn bởi LLM, các nút xám bị loại. Bước 1 chọn 3/5 tài liệu, Bước 2 thu hẹp xuống các chương liên quan, Bước 3 xác định các điều khoản cụ thể.

Tầng 2: Truy xuất ngữ nghĩa hai cấp

Tầng 2 nhận các thực thể đã trích xuất và nhân ý định từ bước phân tích truy vấn (Mục 3.5), kết hợp với Knowledge Graph để tính điểm ngữ nghĩa cho từng điều khoản. Khác với Tầng 1 sử dụng LLM để duyệt cây top-down, Tầng 2 tiếp cận bottom-up: xuất phát từ các thực thể trong KG, lan truyền điểm số qua các quan hệ ontology để tìm các điều khoản liên quan. Tầng này hoạt động ở hai cấp: low-level (entity-specific) tập trung

3.5. Kiến trúc truy xuất 3-Tier KG-RAG

vào từng thực thể cụ thể, và high-level (conceptual) nắm bắt mối liên hệ chủ đề giữa các cụm khái niệm.

Low-level (Entity-specific). Low-level tính bốn tín hiệu độc lập cho mỗi điều khoản, mỗi tín hiệu nắm bắt một khía cạnh khác nhau của mức độ liên quan:

1. Keyphrase Matching

So khớp các thuật ngữ trong truy vấn với tên thực thể KG bằng cách tạo n-gram âm tiết (unigram, bigram, trigram) từ truy vấn. Với mỗi thực thể, điểm cơ bản được tính bằng tỷ lệ trùng khớp âm tiết ($|Q \cap E|/|Q|$), sau đó được tăng cường bởi các hệ số nhân: $\times 1,5$ khi trùng khớp ≥ 2 âm tiết hoặc khi khớp cụm bigram/trigram, $\times 1,5$ khi tên thực thể xuất hiện trong truy vấn (exact match), $\times 1,2$ khi truy vấn là chuỗi con của tên thực thể. Điểm keyphrase cấp điều khoản được tổng hợp từ tất cả thực thể thuộc điều khoản đó:

$$s_{kp}(a) = \max_{e \in E_a} s(e) + 0,3 \cdot \ln(n + 1) \cdot \bar{s} \quad (3.2)$$

trong đó E_a là tập thực thể thuộc điều khoản a , n là số thực thể có điểm dương, và $\bar{s}$ là điểm trung bình. Thành phần logarithmic khuyến khích các điều khoản chứa nhiều thực thể liên quan mà không để số lượng lớn áp đảo chất lượng khớp cao nhất.

2. Semantic Similarity

Tính cosine similarity giữa vector nhúng (embedding) của truy vấn và vector nhúng của từng điều khoản, sử dụng mô hình sentence-transformers MiniLM-L12-v2. Tín hiệu này bổ sung cho đối sánh từ khóa bằng cách nắm bắt sự tương đồng ngữ nghĩa ngay cả khi thuật ngữ không trùng khớp chính xác, ví dụ “hủy bỏ nghị quyết” và “vô hiệu quyết định” có thể có điểm keyphrase thấp nhưng điểm semantic cao.

3. Intent-aware PPR

Sử dụng thuật toán Personalized PageRank [11] để lan truyền điểm số qua cấu trúc đồ thị KG. Quá trình gồm ba bước:

3.5. Kiến trúc truy xuất 3-Tier KG-RAG

- a) Chọn các thực thể hạt giống (seed): chỉ những thực thể có điểm keyphrase $\geq 0,3$ được chọn làm seed, đảm bảo chỉ các thực thể liên quan cao mới khởi tạo quá trình lan truyền.
- b) Tính vector nhúng truy vấn để điều chỉnh trọng số cạnh theo ý định: các cạnh dẫn đến thực thể có embedding gần với truy vấn được tăng trọng số.
- c) Thực hiện PPR với công thức:

$$\text{PPR}(v) = (1 - \alpha) \sum_{u \in \mathcal{N}(v)} \frac{w(u, v) \cdot \text{PPR}(u)}{d(u)} + \alpha \cdot p(v) \quad (3.3)$$

trong đó $\alpha = 0,15$ là xác suất teleport, $w(u, v)$ là trọng số cạnh điều chỉnh theo ý định truy vấn, $d(u)$ là bậc ra có trọng số, và $p(v)$ là vector cá nhân hóa (phân bố đều trên các seed). Điểm PPR cấp thực thể được quy về cấp điều khoản bằng cách lấy giá trị lớn nhất trong các thực thể thuộc điều khoản. Ưu điểm của PPR là phát hiện các điều khoản liên quan gián tiếp qua nhiều bước nhảy (multi-hop) trong đồ thị, ví dụ từ thực thể “học phí” qua cạnh requires đến “nghĩa vụ tài chính” rồi đến “chế tài vi phạm”.

4. Concept Matching

Mở rộng kết quả keyphrase ở mức lớp ontology. Đầu tiên, thu thập các loại thực thể (entity type) từ tất cả thực thể đã khớp keyphrase, mỗi loại được gán trọng số bằng điểm keyphrase cao nhất của các thực thể thuộc loại đó. Sau đó, duyệt tất cả điều khoản trong KG: với mỗi điều khoản, tính tổng trọng số các loại thực thể trùng khớp, chia cho tổng số thực thể của điều khoản để chuẩn hóa:

$$s_{\text{con}}(a) = \min \left(1, \frac{\sum_{e \in E_a} w_{\text{type}}(\text{type}(e))}{|E_a|} \right) \quad (3.4)$$

Cơ chế này cho phép phát hiện các điều khoản có cùng loại thực thể nhưng dùng tên gọi khác, ví dụ keyphrase khớp với thực thể “cổ đông sáng lập” (loại CHỦ_THỂ) sẽ lan truyền điểm đến các điều khoản chứa “thành viên hợp danh” cùng loại CHỦ_THỂ.

Tổng hợp điểm Low-level

Bốn tín hiệu được kết hợp bằng tổng có trọng số ($w_{kp} = 0,05$, $w_{sem} = 0,20$, $w_{ppr} = 0,25$, $w_{con} = 0,20$) và chuẩn hóa về $[0, 1]$ bằng cách chia cho giá trị lớn nhất. Trọng số thấp của keyphrase (0,05) phản ánh vai trò “kích hoạt” của nó: keyphrase chủ yếu cung cấp seed cho PPR và loại thực thể cho concept matching, thay vì trực tiếp quyết định xếp hạng. PPR nhận trọng số cao nhất (0,25) vì khả năng nắm bắt quan hệ cấu trúc đồ thị.

High-level (Conceptual). High-level hoạt động ở cấp độ trừu tượng hơn, tìm kiếm các điều khoản liên quan thông qua cụm chủ đề (theme cluster) thay vì từng thực thể riêng lẻ.

1. Theme Matching

Trong giai đoạn offline, các thực thể KG được nhóm thành các cụm chủ đề dựa trên embedding similarity (ví dụ: cụm “quản trị công ty” gồm các thực thể về cổ đông, hội đồng quản trị, ban kiểm soát). Mỗi cụm được biểu diễn bởi vector nhúng trung bình. Tại thời điểm truy vấn, vector nhúng truy vấn được so khớp với top-10 cụm chủ đề gần nhất. Từ mỗi cụm khớp, các thực thể nguồn (source entities) được truy ngược về điều khoản chứa chúng, gán điểm theme bằng cosine similarity giữa truy vấn và cụm.

2. Hierarchy Expansion


Từ các điều khoản đã tìm được qua theme matching, thu thập các loại thực thể (entity type) và tìm thêm các điều khoản khác chứa cùng loại thực thể nhưng chưa xuất hiện trong kết quả theme. Hệ số suy giảm 0,5 được áp dụng cho các điều khoản mở rộng này để đảm bảo chúng xếp hạng thấp hơn kết quả theme trực tiếp. Ví dụ: nếu theme matching tìm được điều khoản về “xử phạt vi phạm” (chứa thực thể loại CHẾ_TÀI), hierarchy expansion sẽ bổ sung các điều khoản khác cũng chứa thực thể loại CHẾ_TÀI với điểm giảm một nửa.

Hợp nhất Low-level và High-level. Hai cấp được hợp nhất bằng tổng có trọng số:

$$s(a) = 0,70 \cdot s_{low}(a) + 0,15 \cdot s_{theme}(a) + 0,15 \cdot s_{hier}(a) \quad (3.5)$$

3.5. Kiến trúc truy xuất 3-Tier KG-RAG

Tỷ lệ 70–30 giữa low-level và high-level phản ánh độ tin cậy cao hơn của các tín hiệu entity-specific (keyphrase, PPR, concept) so với tín hiệu chủ đề trừu tượng. Các điều khoản có điểm tổng hợp dưới ngưỡng 0,1 bị loại bỏ để giảm nhiễu trước khi chuyển sang Tầng 3. Hình 3.7 minh họa kiến trúc hai cấp của Tầng 2 với sáu tín hiệu và cách hợp nhất.



Hình 3.7: Kiến trúc Tầng 2 hai cấp. Low-level gồm 4 tín hiệu (Keyphrase, Semantic, Intent-aware PPR, Concept Matching) với minh họa PPR lan truyền qua KG. High-level gồm Theme Matching và Hierarchy Expansion. Công thức hợp nhất 70%–30% ưu tiên tín hiệu entity-specific.

Tầng 3: Hợp nhất RRF với mở rộng Knowledge Graph

Tầng 3 tạo ra danh sách top- k điều khoản cuối cùng thông qua ba bước: mở rộng Knowledge Graph, RRF, và các cơ chế điều chỉnh.

Mở rộng Knowledge Graph. Các điều khoản hạt giống từ Tầng 1 và Tầng 2 được mở rộng thông qua các cạnh quan hệ của Knowledge Graph. Hai nhóm quan hệ được sử dụng. Nhóm quan hệ mạnh (STRONG) gồm references, requires, depends_on, implements, ưu tiên cho liên kết xuyên chương. Nhóm quan hệ mở rộng (EXPANSION) gồm defined_as, condition_for, related_to, includes, bổ sung các điều khoản liên quan cùng chương. Giới hạn mở rộng:

- Khác chương (cross-chapter): tối đa 5 điều khoản.
- Cùng chương (same-chapter): tối đa 2 điều khoản.

Bộ lọc liên quan ngữ nghĩa (cosine similarity $\geq 0,4$) được áp dụng để loại bỏ nhiễu. Kết quả mở rộng tạo thành danh sách xếp hạng thứ ba bên cạnh Tầng 1 và Tầng 2.

Reciprocal Rank Fusion. Ba danh sách được hợp nhất sử dụng Reciprocal Rank Fusion [3]:

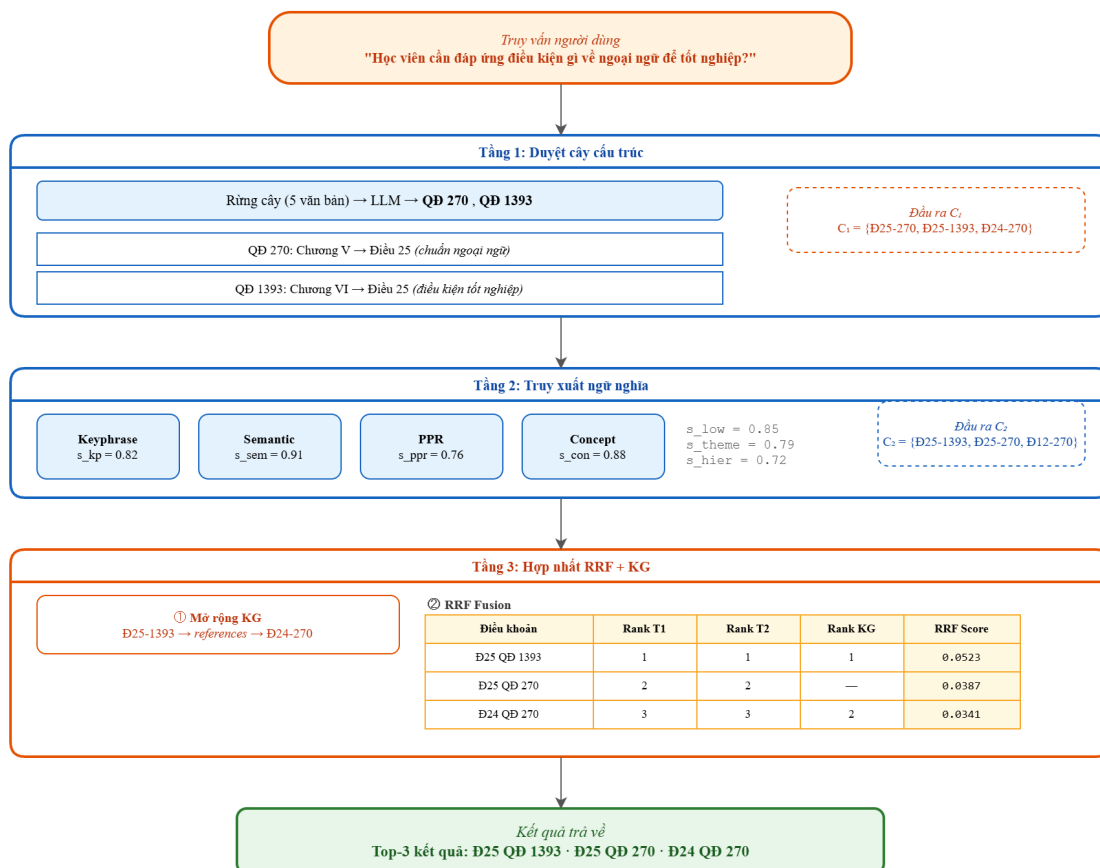
$$\text{RRF}(d) = \sum_{s \in \{T_1, T_2, \text{KG}\}} w_s \cdot \frac{1}{k + \text{rank}_s(d)} \quad (3.6)$$

trong đó $k = 60$ và trọng số nguồn $w_{T_1} = 1,2$, $w_{T_2} = 0,7$, $w_{\text{KG}} = 1,0$ được thiết lập thực nghiệm trên tập phát triển và chia sẻ trên tất cả các miền. Duyệt cây nhận trọng số cao nhất vì cung cấp tín hiệu cấu trúc đáng tin cậy nhất.

Các cơ chế điều chỉnh. Hệ thống áp dụng ba cơ chế điều chỉnh điểm sau hợp nhất RRF:

1. **Trọng số cây động (Dynamic Tree Weight):** Khi $\geq 50\%$ điều khoản từ duyệt cây là điều khoản chung (generic, penalty $\leq 0,25$), trọng số cây giảm từ 1,2 xuống 0,7 và trọng số KG tăng từ 1,0 lên 1,3.
2. **Hệ số phạt (Penalty):**

3.5. Kiến trúc truy xuất 3-Tier KG-RAG



Hình 3.8: Minh họa luồng xử lý end-to-end với truy vấn “Học viên cần đáp ứng điều kiện gì về ngoại ngữ để tốt nghiệp?”. Tầng 1 tìm Đ.29, Đ.25, Đ.24 qua duyệt cây. Tầng 2 xác nhận Đ.25 và Đ.29 qua PPR, bổ sung Đ.8. Tầng 3 nhận seeds từ Tầng 1 và Tầng 2, mở rộng KG thêm Đ.5, sau đó hợp nhất RRF cả ba danh sách với thưởng đồng thuận và hệ số phạt.

3.5. Kiến trúc truy xuất 3-Tier KG-RAG

- Procedural penalty ($0,35 \times$): Các điều khoản thủ tục/tổ chức ít liên quan đến câu hỏi nội dung.
- Noise penalty ($0,35 \times$): Các điều khoản có tỷ lệ đúng 0% trong benchmark.
- Generic penalty ($0,15 \times$): Các điều khoản phạm vi/định nghĩa chung (d1–d3).

3. **Thưởng đồng thuận (Agreement Bonus):** Điều khoản xuất hiện trong ≥ 2 tầng nhận thưởng $+0,005$ cho mỗi tầng bổ sung, tăng cường tín hiệu đồng thuận xuyên tầng.

4. **Mở rộng điều khoản lân cận (Adjacent Expansion):** Sau khi hợp nhất RRF, hệ thống bổ sung các điều khoản lân cận (± 2) từ mỗi kết quả, với điểm giảm dần theo khoảng cách. Cơ chế này khai thác quan sát rằng câu trả lời đúng thường nằm trong các điều khoản liền kề với kết quả truy xuất.

Danh sách xếp hạng cuối cùng được truyền cho LLM để sinh câu trả lời có trích dẫn nguồn.

Hình 3.8 minh họa toàn bộ luồng xử lý qua ba tầng với một truy vấn ví dụ, thể hiện cách các tầng bổ sung lẫn nhau để tìm ra các điều khoản liên quan.

Chương 4

Thiết kế hệ thống và thử nghiệm

Chương này trình bày kiến trúc triển khai của hệ thống 3-Tier KG-RAG cùng yêu cầu thiết kế, tiếp theo là kết quả thử nghiệm trên hai miền: quy định đào tạo sau đại học (130 câu hỏi) và pháp luật Việt Nam (400 câu hỏi). Phần cuối giới thiệu ứng dụng chatbot minh họa được triển khai trên nền tảng Chainlit.

4.1 Kiến trúc hệ thống

4.1.1 Yêu cầu hệ thống

Hệ thống 3-Tier KG-RAG được thiết kế để giải quyết bài toán hỏi đáp văn bản pháp luật và quy định hành chính bằng tiếng Việt, nơi mà các câu hỏi thực tế thường đòi hỏi suy luận đa bước qua nhiều điều khoản thuộc nhiều văn bản khác nhau. Từ bài toán này, hệ thống cần đáp ứng các yêu cầu chức năng và phi chức năng sau đây.

Về chức năng, hệ thống phải tiếp nhận câu hỏi tự nhiên bằng tiếng Việt về quy định đào tạo hoặc pháp luật, sau đó trả về danh sách top- K điều khoản liên quan nhất kèm trích dẫn nguồn (tên văn bản, số điều, số khoản). Tiếp theo, một mô hình ngôn ngữ lớn tổng hợp thông tin từ các điều khoản đã truy xuất để sinh câu trả lời tự nhiên, có cấu trúc và dẫn chứng cụ thể. Ngoài ra, hệ thống cần hoạt động trên nhiều lĩnh vực khác nhau (doanh nghiệp, giao thông, đào tạo) mà không thay đổi pipeline hay tham số cốt lõi, chỉ cần thay thế cơ sở tri thức tương ứng.

Về phi chức năng, ba yêu cầu quan trọng nhất được xác định. Thứ nhất là độ chính xác: hệ thống phải đạt Hit@10 tối thiểu 85% trên các bộ đánh giá chuẩn, đảm bảo rằng

trong 10 kết quả trả về luôn có ít nhất một điều khoản chính xác; ngưỡng này phù hợp với ràng buộc context window thực tế của LLM. Thứ hai là thời gian phản hồi: mỗi truy vấn phải hoàn thành trong vòng 15 giây dưới chế độ đơn luồng và dưới 5 giây khi kích hoạt xử lý song song, đảm bảo trải nghiệm người dùng chấp nhận được trong môi trường web. Thứ ba là khả năng mở rộng: kiến trúc phải cho phép bổ sung miền văn bản mới mà không sửa đổi code pipeline, chỉ cần cung cấp file cấu hình YAML và cơ sở tri thức tương ứng. Một yêu cầu bổ sung là khả năng giải thích: mỗi kết quả truy xuất cần kèm theo reasoning trace ghi lại quá trình duyệt cây theo từng vòng lặp, giúp người dùng hiểu và kiểm tra tại sao hệ thống trả về một điều khoản cụ thể.

4.1.2 Kiến trúc triển khai

Hệ thống được triển khai theo kiến trúc hai pha (offline và online), phản ánh sự tách biệt rõ ràng giữa công đoạn xây dựng tri thức (thực hiện một lần khi có tài liệu mới) và công đoạn phục vụ truy vấn (thực hiện theo thời gian thực). Hình 3.3 (Chương 3) minh họa kiến trúc tổng thể của hệ thống.

Pha ngoại tuyến (Offline). Quy trình xây dựng tri thức gồm ba track song song đã trình bày tại Mục 3.4.1. Về mặt triển khai, Document Parser sử dụng bộ regex tùy chỉnh cho tiếng Việt, hỗ trợ thêm LLM Vision OCR để số hóa 118 trang tài liệu scan (PDF) của miền giáo dục trước khi phân tích cấu trúc. KG Builder gọi Claude 3.5 Haiku qua Anthropic API với một lời gọi LLM cho mỗi điều khoản, kết hợp chuẩn hóa slug tiếng Việt (loại dấu, gộp biến thể thanh điệu) và bộ giải quyết thực thể đa bước (exact match, synonym resolution, abbreviation expansion) để khử trùng lặp. Embedding Indexer mã hóa tóm tắt điều khoản thành vector 384 chiều bằng mô hình paraphrase-multilingual-MiniLM-L12-v2 [28], lưu vào chỉ mục FAISS phục vụ tìm kiếm ngữ nghĩa nhanh.


Pha trực tuyến (Online). Pipeline truy xuất ba tầng đã trình bày chi tiết tại Mục 3.5. Về mặt triển khai, mỗi bước duyệt cây (Tầng 1) sử dụng Claude Sonnet 4 với temperature và số lượng ứng viên cấu hình riêng cho từng miền qua file YAML (xem phần cấu hình đa miền bên dưới). Tầng 2 truy vấn chỉ mục FAISS đã xây dựng ở pha ngoại tuyến. Tầng 3 thực hiện Personalized PageRank với damping $\alpha = 0,15$ và tối đa 50 vòng lặp trên KG. Answer Generator sinh câu trả lời theo cấu trúc IRAC với prompt riêng cho từng miền (xem Phụ lục D, Bảng D.6 và D.7).

4.1. Kiến trúc hệ thống

Bảng 4.1 tóm tắt các công nghệ chính được sử dụng trong từng thành phần. Hình 4.1 minh họa kiến trúc triển khai với các thành phần kết nối.

Bảng 4.1: Công nghệ sử dụng trong hệ thống

Thành phần	Công nghệ
Ngôn ngữ lập trình	Python 3.11
LLM	Claude Sonnet 4 (Anthropic API)
Sentence Embeddings	paraphrase-multilingual-MiniLM-L12-v2 [28]
Vector Search	FAISS
Cache	SQLite (WAL mode)
LLM Proxy	OAuth, Rate Limiting
Cấu hình	YAML (default.yaml, education.yaml)



Hình 4.1: Kiến trúc triển khai hệ thống: Client (trình duyệt web) kết nối với máy chủ Chainlit qua WebSocket, máy chủ gọi pipeline 3-Tier KG-RAG đồng bộ thông qua Async Bridge, pipeline truy vấn các dịch vụ ngoại vi gồm Anthropic API (LLM), FAISS Index (vector search) và SQLite Cache (LLM response caching).

Xử lý song song. Để đáp ứng yêu cầu thời gian phản hồi, hệ thống tổ chức xử lý đồng thời thông qua `concurrent.futures.ThreadPoolExecutor` của Python với số lượng worker mặc định là 10, có thể điều chỉnh qua tham số cấu hình. Lựa chọn luồng (thread) thay vì tiến trình (process) được căn cứ trên đặc điểm công việc: toàn bộ tác

vụ nặng trong pipeline (gọi Anthropic API, truy vấn FAISS, đọc ghi SQLite) đều là các thao tác vào/ra (I/O-bound), không ràng buộc bởi tính toán CPU. Do đó, cơ chế Global Interpreter Lock (GIL) của CPython không trở thành nút thắt cổ chai, và luồng cho phép chia sẻ bộ nhớ hiệu quả hơn tiến trình trong việc truy cập chỉ mục FAISS cùng cache SQLite.

Cơ sở dữ liệu cache SQLite được cấu hình ở chế độ Write-Ahead Logging (WAL), cho phép tối đa một writer và nhiều reader hoạt động đồng thời mà không khóa lẫn nhau. Giá trị timeout 30 giây được áp dụng khi có xung đột ghi, đủ lớn để tránh lỗi SQLITE_BUSY trong điều kiện tải cao nhưng vẫn ngăn treo vô thời hạn. Khóa cache được tính theo hàm băm của bốn trường: nội dung truy vấn, tên mô hình, nhiệt độ sinh (temperature) và system prompt; bất kỳ thay đổi nào trong bốn trường này đều tạo ra khóa mới và kích hoạt lời gọi API mới, đảm bảo tính xác định (determinism) của kết quả cache.

Về hiệu năng thực nghiệm, trên tập 10 truy vấn của miền đào tạo, chế độ đơn luồng hoàn thành trong 226 giây, trong khi chế độ 10 worker rút ngắn xuống còn 35 giây, tương đương tăng tốc $6,5\times$. Tốc độ tăng thực tế thấp hơn giới hạn lý thuyết $10\times$ do hai ràng buộc chính: giới hạn tần suất (rate limit) của Anthropic API dẫn đến một số worker phải chờ, và chi phí đồng bộ hóa ghi cache khi nhiều worker hoàn thành đồng thời. Ngoài ra, toàn bộ phản hồi LLM được lưu cache bền vững, đảm bảo rằng các lần chạy đánh giá lặp lại, bao gồm ba lần chạy độc lập để đo phương sai, trả về kết quả hoàn toàn giống nhau, loại trừ nhiễu ngẫu nhiên và đảm bảo khả năng tái lập (reproducibility) của thử nghiệm.

Cấu hình đa miền. Mỗi miền ứng dụng sử dụng một file YAML riêng để khai báo toàn bộ thông số vận hành mà không chạm đến code pipeline. Cấu trúc file gồm bốn nhóm tham số chính:

1. *Đường dẫn dữ liệu* (corpus_path, kg_path, faiss_index_path): trỏ đến kho tài liệu và các chỉ mục đã xây dựng ở pha ngoại tuyến.
2. *Tham số duyệt cây* (Tree Traversal): số vòng lặp tối đa max_loops và nhiệt độ sinh cho từng vòng lặp riêng biệt.
3. *Tham số truy xuất* (Retrieval): top_k số lượng kết quả trả về, ngưỡng điểm tương đồng similarity_threshold và hệ số k trong RRF (rrf_k).
4. *Prompt template* (prompt_template): định dạng lời nhắc gửi tới LLM cho từng miền.

Sự khác biệt giữa hai file cấu hình hiện tại phản ánh đặc điểm riêng của từng miền. File `education.yaml` sử dụng nhiệt độ bằng 0,0 cho Bước 2 (chọn chương) nhằm đảm bảo tính xác định khi kho tài liệu nhỏ (12 chương) chỉ có một lựa chọn hợp lệ rõ ràng. Ngược lại, `default.yaml` dùng nhiệt độ 0,3 cho cùng bước đó, cho phép mô hình khám phá rộng hơn khi kho pháp luật lớn có nhiều chương tiềm năng. Ngưỡng điểm tương đồng của `education.yaml` cũng được đặt cao hơn do corpus nhỏ và đặc thù, ít nguy cơ bỏ sót điều khoản liên quan.

Quy trình bổ sung miền mới hoàn toàn không cần thay đổi code: chuẩn bị tài liệu nguồn và chạy pipeline ngoại tuyến để sinh Knowledge Graph, chỉ mục FAISS và tóm tắt điều khoản; tạo file YAML mới với các tham số phù hợp với đặc thù miền; rồi trở biến môi trường `CONFIG_FILE` vào file YAML vừa tạo trước khi khởi động máy chủ. Toàn bộ pipeline trực tuyến tự động đọc cấu hình và sử dụng đúng kho tri thức tương ứng mà không cần khởi động lại hay can thiệp thủ công thêm.

Quản lý phiên bản mô hình. Hệ thống sử dụng Claude Sonnet 4 thông qua Anthropic API, với định danh phiên bản mô hình được ghi cố định trong file cấu hình YAML nhằm đảm bảo tính tái lập giữa các lần thử nghiệm. Khi Anthropic phát hành phiên bản mô hình mới, các phản hồi đã cache từ phiên bản cũ không bị sử dụng nhằm vì tên mô hình là một thành phần trong khóa cache; bất kỳ thay đổi nào về định danh mô hình đều sinh ra khóa mới và buộc hệ thống gọi API lại từ đầu. Cơ chế này cho phép so sánh hiệu năng giữa các phiên bản mô hình khác nhau: chỉ cần thay giá trị tham số trong YAML rồi chạy lại bộ đánh giá, mà không cần viết lại bất kỳ dòng code nào, đồng thời các kết quả của từng phiên bản được lưu độc lập trong cache để đối chiếu trực tiếp.

4.2 Kết quả thử nghiệm

4.2.1 Thử nghiệm với Quy định đào tạo trường

Giới thiệu miền và tập dữ liệu

Miền quy định đào tạo sau đại học tại Trường Đại học Công nghệ Thông tin, ĐHQG TP.HCM (UIT) là một bài toán hỏi đáp văn bản có tính đặc thù cao. Hệ thống văn bản quy định được tổ chức theo hai cấp quản lý: cấp ĐHQG-HCM ban hành các quy định khung chung, còn cấp trường (UIT) ban hành quy định bổ sung và chi tiết hóa cho từng

trường hợp. Sự phân cấp này tạo ra nhu cầu truy xuất đa văn bản, đặc biệt với các câu hỏi yêu cầu đối chiếu giữa quy định của ĐHQG và quy định cụ thể của UIT.

Cơ sở tri thức cho miền này gồm 5 văn bản quy chế với tổng cộng 109 điều khoản phân bố trong 28 chương. Cụ thể: Quyết định 270/QĐ-ĐHCNTT (Quy chế đào tạo thạc sĩ của UIT, văn bản cấp trường có thẩm quyền cao nhất trong miền) chứa các quy định về chương trình học, lịch học, thủ tục bảo vệ và điều kiện tốt nghiệp; Quyết định 160/QĐ-ĐHQG (Quy chế chung của ĐHQG-HCM) đặt ra khung pháp lý chung cho toàn hệ thống đại học quốc gia; Quyết định 1393/QĐ-ĐHQG (Quy định về đào tạo thạc sĩ cấp ĐHQG) cụ thể hóa các yêu cầu về tuyển sinh, đầu vào và đầu ra ở bậc sau đại học; Quyết định 218/QĐ-ĐHCNTT (Quy định về nghiên cứu sinh UIT) điều chỉnh các vấn đề liên quan đến chương trình tiến sĩ; và Quyết định 851/QĐ-ĐHQG (Quy định về giám sát đào tạo) quy định cơ chế kiểm tra, đánh giá và giám sát chất lượng đào tạo. Toàn bộ 5 văn bản này được scan từ PDF gốc (118 trang) và số hóa qua LLM Vision OCR trước khi đưa vào pipeline xử lý.

Bộ đánh giá gồm 130 câu hỏi được thu thập và xây dựng qua ba nguồn bổ sung cho nhau. Nguồn thứ nhất là diễn đàn học viên: các câu hỏi thực tế được đăng trên nhóm Facebook học viên cao học UIT và các diễn đàn sinh viên, phản ánh đúng nhu cầu tra cứu thực tế của người dùng mục tiêu. Nguồn thứ hai là các câu hỏi do chuyên gia thiết kế, tập trung vào các tình huống đặc thù đòi hỏi suy luận đa bước hoặc kết hợp thông tin từ nhiều điều khoản. Nguồn thứ ba là các câu hỏi FAQ được biên soạn từ danh sách câu hỏi thường gặp của phòng đào tạo. Về phân phối độ phức tạp, bộ câu hỏi gồm 58 câu Single-hop (44,6%) yêu cầu một điều khoản duy nhất, 52 câu Multi-hop (40,0%) yêu cầu kết hợp hai điều khoản trở lên, và 20 câu Reasoning (15,4%) yêu cầu suy luận logic trên nội dung điều khoản. Tỷ lệ câu hỏi Multi-hop và Reasoning cao (55,4%) phản ánh tính phức tạp của bài toán tra cứu quy định trong thực tế.

Chỉ số đánh giá

Hệ thống được đánh giá bằng hai chỉ số truy xuất tiêu chuẩn [18]. Top-k Hit Rate đo tỷ lệ truy vấn mà ít nhất một điều khoản liên quan xuất hiện trong top-k kết quả:

$$\text{Hit}@k = \frac{1}{|Q|} \sum_q \mathbf{1}[\exists a \in R_q : \text{rank}(a) \leq k] \quad (4.1)$$

Mean Reciprocal Rank tính trung bình hạng nghịch đảo của kết quả liên quan đầu

tiên:

$$\text{MRR} = \frac{1}{|Q|} \sum_q \left(\min_{a \in R_q} \text{rank}(a) \right)^{-1} \quad (4.2)$$

Kết quả được báo cáo tại $k \in \{1, 5, 10, 20\}$, với Hit@10 và MRR là chỉ số chính. Hit@10 được ưu tiên vì trong pipeline RAG thực tế, LLM xác nhận ngữ cảnh đã truy xuất trước khi sinh câu trả lời, do đó một điều khoản đúng trong mười ứng viên là đủ để đảm bảo chất lượng câu trả lời cuối cùng.

Các hệ thống đối sánh

Hệ thống 3-Tier KG-RAG được so sánh với sáu baseline đại diện cho các dòng tiếp cận khác nhau. BM25 [29] là thuật toán truy xuất từ vựng kinh điển với tokenization mức âm tiết tiếng Việt; đây là baseline mạnh nhất trong nhóm truyền thống vì tiếng Việt có hình thái học phân tích, từng âm tiết mang nghĩa độc lập. TF-IDF [18] sử dụng trọng số tần suất từ–nghịch đảo tần suất tài liệu, cho kết quả kém hơn BM25 do không có smoothing term. NaiveRAG [28] thực hiện truy xuất dày đặc thuần túy (dense retrieval) không có bước reranking, sử dụng cùng mô hình embedding đa ngôn ngữ với hệ thống đề xuất. LightRAG [10] kết hợp truy xuất vector với duyệt đồ thị tri thức, nhưng sử dụng KG được xây dựng theo schema chung không đặc thù cho văn bản pháp luật có cấu trúc phân cấp. RAPTOR [30] xây dựng Summary Tree đệ quy bằng cách gộp và tóm tắt các đoạn văn bản, sau đó truy xuất trên cây tóm tắt nhiều cấp; cách tiếp cận này phù hợp với văn bản tường thuật nhưng có xu hướng mất chi tiết số liệu và điều khoản cụ thể trong văn bản pháp luật. PageIndex [33] sử dụng LLM để điều hướng tìm kiếm theo cây phân cấp hai bước, gần với cách tiếp cận của Tầng 1 trong hệ thống đề xuất nhưng không có Tầng 2 (ngữ nghĩa) và Tầng 3 (hợp nhất RRF và mở rộng KG). Tất cả hệ thống đều sử dụng Claude Sonnet 4 cho các lời gọi LLM và truy xuất từ cùng kho tài liệu để đảm bảo so sánh công bằng.

Kết quả và phân tích

Bảng 4.2 trình bày kết quả đánh giá trên bộ 130 câu hỏi miền quy định đào tạo. Hệ thống 3-Tier KG-RAG đạt 87,9% Hit@10 ($\pm 0,5$ pp qua 3 lần chạy độc lập: 87,7%, 87,7%, 88,5%) và MRR = 0,594.

4.2. Kết quả thử nghiệm

Bảng 4.2: Kết quả trên miền quy định đào tạo (130 câu hỏi)

Phương pháp	Hit@10	MRR
BM25	70,0	0,355
NaiveRAG	50,0	0,214
LightRAG	56,9	0,251
RAPTOR	53,8	0,218
PageIndex	74,6	0,441
3-Tier (ours)	87,9	0,594

Hệ thống vượt PageIndex 13,3 điểm phần trăm (pp) và vượt RAPTOR 34,1 pp — khoảng cách lớn nhất trong tất cả các miền được thử nghiệm. Khoảng cách lớn so với PageIndex trên miền đào tạo (13,3 pp) so với miền pháp luật (7,4 pp) cho thấy Tầng 2 (truy xuất ngữ nghĩa) và Tầng 3 (mở rộng KG) đặc biệt có giá trị khi cơ sở tri thức có quy mô nhỏ và câu hỏi yêu cầu đối chiếu giữa nhiều văn bản thuộc hai cấp quản lý khác nhau.

Đáng chú ý là BM25 (70,0%) hoạt động tốt hơn toàn bộ nhóm RAG baseline (NaiveRAG 50,0%, LightRAG 56,9%, RAPTOR 53,8%) trên miền này. Điều này phản ánh đặc thù của văn bản quy định đào tạo: người dùng thường sử dụng đúng thuật ngữ chính thức (“chuyên đề”, “luận văn”, “tín chỉ”), và BM25 khớp trực tiếp các từ khóa này. Ngược lại, NaiveRAG gặp khó khăn vì các embedding đa mục đích không bắt được sự khác biệt ngữ nghĩa giữa các điều khoản có cấu trúc văn phạm tương tự nhưng nội dung khác nhau. LightRAG xây dựng KG theo schema chung nên tạo nhiều nhiễu; RAPTOR mất chi tiết điều khoản trong quá trình tóm tắt đệ quy.

Một số cải tiến cấu hình đặc thù cho miền đào tạo đóng góp đáng kể vào kết quả: temperature bằng 0,0 tại Bước 2 loại bỏ hoàn toàn variance trong bước chọn chương — bước quan trọng nhất vì cơ sở tri thức nhỏ (5 văn bản, 28 chương) khiến mỗi lần chọn sai chương đều dẫn đến bỏ sót điều khoản liên quan; cơ chế fallback thông minh chọn chương có số điều khoản nhiều nhất khi LLM không tự tin; và retry logic với 3 lần thử và exponential backoff xử lý các trường hợp LLM Proxy có tải cao.

Phân tích chi tiết theo chỉ số Hit@k

Bảng 4.3 trình bày kết quả đầy đủ tại bốn ngưỡng $k \in \{1, 5, 10, 20\}$ cho tất cả bảy phương pháp được đánh giá trên miền quy định đào tạo.

Bảng 4.3: Kết quả chi tiết trên miền quy định đào tạo (130 câu hỏi)

Phương pháp	Hit@1	Hit@5	Hit@10	Hit@20	MRR
<i>Truy xuất truyền thống</i>					
BM25	20,0	49,2	70,0	83,1	0,355
TF-IDF	16,9	43,8	63,8	79,2	0,308
<i>Hệ thống RAG</i>					
NaiveRAG	10,0	30,8	50,0	66,2	0,214
LightRAG	13,1	36,9	56,9	70,0	0,251
RAPTOR	10,8	33,1	53,8	68,5	0,218
PageIndex	26,2	55,4	74,6	85,4	0,441
3-Tier (ours)	36,9	70,0	87,9	93,8	0,594

Phân tích theo từng ngưỡng k cho thấy hệ thống 3-Tier cải thiện nhất quán ở tất cả các mức. Tại Hit@1, hệ thống đạt 36,9% so với 26,2% của PageIndex, chênh lệch 10,7 pp, cho thấy điều khoản liên quan nhất xuất hiện ở vị trí đầu tiên thường xuyên hơn đáng kể. Kết quả này phản ánh đóng góp của bước hợp nhất RRF ở Tầng 3: khi ba tín hiệu (duyet cây Tầng 1, vector Tầng 2 và mở rộng đồ thị tri thức) đều chỉ về cùng một điều khoản, điều khoản đó được đẩy lên đầu danh sách với độ tin cậy cao hơn so với bất kỳ tín hiệu đơn lẻ nào.

Khoảng cách lớn nhất giữa hai phương pháp xuất hiện tại Hit@5: 3-Tier đạt 70,0% trong khi PageIndex chỉ đạt 55,4%, chênh lệch 14,6 pp. Đây là vùng mà Tầng 2 (truy xuất ngữ nghĩa dày đặc) đóng góp nhiều nhất: với 5 ứng viên, hệ thống có đủ slot để đặt đồng thời kết quả từ Tầng 1 lẫn Tầng 2, trong khi PageIndex chỉ dựa vào duyệt cây hai bước. Sự kết hợp đa tín hiệu đặc biệt hiệu quả với các câu hỏi được diễn đạt theo ngôn ngữ thông thường, không chứa thuật ngữ chính xác từng xuất hiện trong tiêu đề điều khoản.

Ở Hit@20, khoảng cách thu hẹp còn 8,4 pp (93,8% so với 85,4%): khi giới hạn k lớn, hầu hết phương pháp đều có cơ hội đưa điều khoản đúng vào tập ứng viên. Tuy nhiên khoảng cách này vẫn có ý nghĩa thực tiễn vì pipeline RAG có chi phí xử lý tuyến

4.2. Kết quả thử nghiệm

tính theo số ứng viên; đạt 93,8% với 20 ứng viên hiệu quả hơn so với 85,4%, bởi mỗi ứng viên thừa tiêu tốn thêm token ngữ cảnh và tăng độ trễ phản hồi. Chỉ số MRR xác nhận xu hướng này: $MRR = 0,594$ của 3-Tier so với 0,441 của PageIndex (tăng 34,7% tương đối) cho thấy kết quả không chỉ đầy đủ hơn mà còn được xếp hạng tốt hơn: điều khoản liên quan xuất hiện ở vị trí cao hơn trung bình, giúp LLM ở bước xác nhận ngữ cảnh phải xử lý ít ứng viên nhiều hơn trước khi gặp được thông tin đúng.

Phân tích theo nhóm chủ đề

Để hiểu rõ hơn nguồn gốc của cải thiện, bảng 4.4 phân rã kết quả Hit@10 theo bảy nhóm chủ đề của bộ câu hỏi đào tạo.

Bảng 4.4: Hit@10 (%) theo nhóm chủ đề trên miền quy định đào tạo

Chủ đề	Số câu	BM25	PageIndex	3-Tier	Δ vs PI
Quy trình đào tạo	28	67,9	71,4	89,3	+17,9
Điều kiện tốt nghiệp	25	64,0	72,0	88,0	+16,0
Luận văn	22	72,7	77,3	90,9	+13,6
Đánh giá kết quả	18	77,8	83,3	88,9	+5,6
Tuyển sinh	15	73,3	80,0	86,7	+6,7
Liên chính học thuật	12	66,7	66,7	83,3	+16,6
Quy định GVHD	10	70,0	70,0	80,0	+10,0
Tổng	130	70,0	74,6	87,9	+13,3

Hai nhóm chủ đề có mức cải thiện lớn nhất là “Quy trình đào tạo” (+17,9 pp) và “Điều kiện tốt nghiệp” (+16,0 pp). Cả hai nhóm này tập trung vào các câu hỏi đòi hỏi đối chiếu giữa quy định cấp trường (Quyết định 270/QĐ-ĐHCNTT) và quy định cấp ĐHQG (Quyết định 1393/QĐ-ĐHQG). Ví dụ, câu hỏi “Học viên cần hoàn thành bao nhiêu tín chỉ để đủ điều kiện tốt nghiệp?” yêu cầu hệ thống truy xuất đồng thời Điều 18 của QĐ 270 (số tín chỉ tối thiểu của UIT) và Điều 21 của QĐ 1393 (khung tín chỉ tối thiểu của ĐHQG). Tầng 3 với cơ chế mở rộng đồ thị tri thức nhận dạng được mối quan hệ “chi tiết hóa” giữa hai điều khoản này và đưa cả hai vào tập ứng viên cuối, trong khi PageIndex chỉ theo một nhánh duyệt cây và bỏ sót điều khoản còn lại.

Nhóm “Liên chính học thuật” (+16,6 pp) cũng có mức cải thiện đáng kể, dù BM25 và PageIndex cùng đạt 66,7%, cho thấy cả hai phương pháp đó bị chặn bởi cùng một

rào cản. Quyết định 851/QĐ-ĐHQG là văn bản được ban hành sau các văn bản còn lại và có ít từ khóa chung với phần còn lại của cơ sở tri thức; đặc biệt, nhiều câu hỏi trong nhóm này sử dụng từ ngữ thông thường của người học (“sao chép luận văn”, “gian lận học thuật”) thay vì thuật ngữ pháp lý chính xác trong văn bản (“vi phạm liêm chính”). Truy xuất dày đặc ở Tầng 2 dựa trên biểu diễn ngữ nghĩa hơn là khớp từ khóa, do đó xử lý tốt hơn khoảng cách từ vựng này.

Ngược lại, hai nhóm có mức cải thiện thấp nhất là “Đánh giá kết quả” (+5,6 pp) và “Tuyển sinh” (+6,7 pp). Đặc trưng chung là các câu hỏi chứa thuật ngữ đặc thù tần suất cao và có khả năng phân biệt tốt: “điểm trung bình tích lũy”, “hội đồng chấm điểm”, “chỉ tiêu tuyển sinh”. BM25 và PageIndex đã khai thác hiệu quả các từ khóa này để định vị điều khoản đúng từ sớm, khiến không gian cải thiện còn lại của Tầng 2 và Tầng 3 bị thu hẹp. Kết quả này phù hợp với nhận xét chung: phương pháp đề xuất mang lại giá trị lớn nhất khi câu hỏi yêu cầu suy luận đa văn bản hoặc khi từ ngữ của người hỏi không khớp trực tiếp với từ ngữ trong điều khoản gốc.

Phân tích phương sai qua các lần chạy

Để đánh giá tính ổn định của kết quả, hệ thống được chạy ba lần độc lập trên toàn bộ 130 câu hỏi của miền đào tạo. Ba giá trị Hit@10 thu được lần lượt là 87,7%, 87,7% và 88,5%, tương ứng độ lệch chuẩn 0,38 pp, thực tế không đáng kể ở quy mô thử nghiệm này. Phương sai thấp là kết quả trực tiếp của hai quyết định thiết kế: temperature = 0,0 tại Bước 2 đảm bảo tính xác định trong quyết định điều hướng quan trọng nhất của Tầng 1, và cache LLM bền vững (SQLite WAL) đảm bảo các lần gọi API lặp lại cho cùng một truy vấn luôn trả về kết quả đồng nhất.

Để đối chiếu, PageIndex được đo với ba lần chạy độc lập tương tự và có độ lệch chuẩn khoảng 1,2 pp, do PageIndex sử dụng temperature mặc định (0,3–0,7) cho lời gọi LLM định tuyến. Sự biến động này làm giảm độ tin cậy khi chỉ có một lần đánh giá và có thể tạo ra chênh lệch đáng kể giữa các lần chạy nếu không lấy trung bình. Với hệ thống đề xuất, ba lần chạy độc lập cho kết quả gần như giống hệt nhau, xác nhận rằng 87,9% là đại lượng ổn định, không phải giá trị may mắn từ một lần chạy đơn lẻ, và kết quả có thể tái lập bởi các nhóm nghiên cứu khác trên cùng bộ dữ liệu và cấu hình.

4.2.2 Thử nghiệm với các văn bản luật của VN

Giới thiệu miền và tập dữ liệu

Miền pháp luật Việt Nam là bài toán thử nghiệm quy mô lớn hơn, bao gồm hai lĩnh vực pháp luật có đặc trưng cấu trúc khác nhau: luật doanh nghiệp và luật giao thông đường bộ.

Bảng 4.5: Thống kê kho tài liệu miền pháp luật

STT	Văn bản	Số chương	Số điều
<i>Luật doanh nghiệp</i>			
1	Luật 59/2020/QH14 (Luật Doanh nghiệp)	10	218
2	NĐ 01/2021/NĐ-CP (Đăng ký doanh nghiệp)	8	78
3	NĐ 47/2021/NĐ-CP (Chi tiết Luật DN)	5	32
4–10	7 nghị định hướng dẫn khác	—	185
<i>Luật giao thông</i>			
11	Luật 36/2024/QH15 (Trật tự ATGT)	8	89
12	NĐ 168/2024/NĐ-CP (Xử phạt VPHC)	6	42
13	NĐ 176/2024/NĐ-CP (Quy định chi tiết)	4	28
Tổng		—	672

Bảng 4.5 tóm tắt toàn bộ 13 văn bản được đưa vào kho tài liệu pháp luật. Tổng cộng 672 điều khoản trải rộng trên hai lĩnh vực, lớn hơn gấp sáu lần so với miền quy định đào tạo (109 điều, 5 văn bản). Sự chênh lệch quy mô này đặt ra thách thức khác biệt về chất: không chỉ đơn thuần nhiều tài liệu hơn, mà cấu trúc tương tác giữa các văn bản cũng phức tạp hơn về bản chất.

Trong lĩnh vực luật doanh nghiệp, Luật 59/2020/QH14 đóng vai trò khung pháp lý tổng thể, trong khi mỗi nghị định hướng dẫn chi tiết hóa một nhóm điều khoản cụ thể. Điều này tạo ra chuỗi tham chiếu đa bước (multi-hop chains): một câu hỏi về thủ tục thành lập công ty thường không thể trả lời được chỉ từ Luật 59, vì người dùng cần đọc

4.2. Kết quả thử nghiệm

thêm ND 01 để biết hồ sơ cụ thể, rồi tra ND 47 để nắm điều kiện ngành nghề. Cấu trúc tham chiếu chéo dày đặc này là lý do lĩnh vực doanh nghiệp trở thành bài toán khó nhất trong bộ thử nghiệm.

Ngược lại, lĩnh vực luật giao thông có cấu trúc ánh xạ trực tiếp hơn. Mỗi điều khoản trong ND 168/2024/ND-CP được tổ chức theo mẫu cố định: hành vi vi phạm, mức phạt tiền, hình phạt bổ sung. Cấu trúc if-then rõ ràng này phù hợp tự nhiên với cơ chế duyệt cây của Tầng 1, cho phép hệ thống định vị chính xác điều khoản mà không cần suy luận ngầm.

Bộ đánh giá 400 câu hỏi (hard-400) được phân bố đồng đều: 200 câu luật doanh nghiệp và 200 câu luật giao thông. Câu hỏi được thu thập từ các nhóm tư vấn pháp lý trên Facebook, nơi người dùng đặt câu hỏi về tình huống thực tế thay vì câu hỏi kiểm tra định nghĩa, và được chú thích thủ công bởi người có hiểu biết chuyên sâu về pháp lý. Nhãn “hard” có nghĩa là tất cả câu hỏi đều yêu cầu suy luận đa bước: không có câu nào có thể trả lời bằng cách tra cứu đơn thuần một điều khoản.

Lĩnh vực luật doanh nghiệp dựa trên Luật 59/2020/QH14 (Luật Doanh nghiệp 2020) cùng 9 nghị định hướng dẫn thi hành. Luật 59/2020/QH14 gồm 218 điều chia thành 10 chương, điều chỉnh toàn diện vòng đời doanh nghiệp từ thành lập, tổ chức quản trị, đến giải thể và phá sản. Các nghị định kèm theo quy định chi tiết từng lĩnh vực cụ thể như đăng ký doanh nghiệp, quản lý con dấu, và phát hành cổ phiếu. Đặc trưng nổi bật của lĩnh vực này là mạng lưới tham chiếu chéo dày đặc giữa luật và nghị định: một câu hỏi thực tế thường yêu cầu đọc điều khoản gốc trong Luật 59 rồi tra cứu tiếp nghị định hướng dẫn để có câu trả lời đầy đủ. Điều này khiến luật doanh nghiệp trở thành lĩnh vực khó nhất trong bộ thử nghiệm.

Lĩnh vực luật giao thông dựa trên Luật 36/2024/QH15 (Luật Trật tự, An toàn Giao thông Đường bộ 2024) cùng 2 nghị định xử phạt vi phạm hành chính trong lĩnh vực giao thông. Luật 36/2024/QH15 gồm 89 điều chia thành 8 chương, quy định về quy tắc giao thông, phương tiện cơ giới, người điều khiển phương tiện và xử lý vi phạm. Đặc trưng của lĩnh vực này là cấu trúc ánh xạ trực tiếp giữa hành vi vi phạm và hình phạt: mỗi điều khoản trong nghị định xử phạt liệt kê rõ ràng hành vi và mức phạt tương ứng, tạo ra cấu trúc if-then rõ ràng phù hợp với duyệt cây của Tầng 1.

Bộ đánh giá gồm 400 câu hỏi thuộc nhóm “hard” (hard-400): 200 câu luật doanh nghiệp và 200 câu luật giao thông. Câu hỏi được thu thập chủ yếu từ các nhóm tư vấn pháp lý trên Facebook, nơi luật sư và người dùng đặt câu hỏi thực tế về các tình huống

4.2. Kết quả thử nghiệm

pháp lý phức tạp. Phân loại “hard” có nghĩa là tất cả câu hỏi đều yêu cầu suy luận đa bước, không có câu hỏi tra cứu đơn giản một điều khoản. Mỗi câu hỏi được chú thích (annotate) thủ công bởi người có hiểu biết pháp lý để xác định tập gold articles, tức danh sách các điều khoản cần thiết để trả lời đúng câu hỏi.

Về chỉ số đánh giá, bộ thử nghiệm này sử dụng cùng định nghĩa $\text{Hit}@k$ và MRR như đã trình bày tại Phương trình (4.1) và (4.2), nhưng bổ sung đánh giá tại $k \in \{1, 5, 10, 20\}$ để có góc nhìn đầy đủ hơn về phân phối kết quả.

Kết quả tổng thể

Bảng 4.6 trình bày kết quả trên bộ dữ liệu pháp luật 400 câu hỏi. Hệ thống 3-Tier KG-RAG đạt 92,2% $\text{Hit}@10$ ($\pm 0,3\%$ qua ba lần chạy độc lập) và $\text{MRR} = 0,603$, vượt PageIndex 7,4 pp và vượt BM25 44,7 pp.

Bảng 4.6: Tỷ lệ Hit (%) trên miền pháp luật (400 câu hỏi)

Phương pháp	Hit@1	Hit@5	Hit@10	Hit@20	MRR
<i>Truy xuất truyền thống</i>					
BM25	8,8	30,8	47,5	66,2	0,200
TF-IDF	10,0	29,2	45,8	64,5	0,207
<i>Hệ thống RAG</i>					
NaiveRAG [28]	5,8	22,8	32,8	51,8	0,146
LightRAG [10]	9,2	25,5	39,8	47,8	0,173
RAPTOR [30]	7,8	25,2	41,0	54,5	0,170
PageIndex [33]	41,5	76,2	84,8	90,2	0,559
3-Tier (ours)	49,2	74,5	92,2	94,8	0,603

Một điểm đáng chú ý là PageIndex đạt $\text{Hit}@5$ cao hơn hệ thống đề xuất (76,2% so với 74,5%). Đây là sự đánh đổi có thể giải thích được: thuật toán RRF trong Tầng 3 kết hợp kết quả từ Tầng 1 (duyet cây) và Tầng 2 (ngữ nghĩa), và các điều khoản được bổ sung từ mở rộng KG đôi khi đẩy một số kết quả từ vị trí 4–5 xuống 6–7. Tuy nhiên, chính cơ chế mở rộng KG này mang lại mức tăng 17,7 pp từ vị trí 6–10 so với chỉ 8,6 pp của PageIndex, giải thích tại sao hệ thống vượt trội ở $\text{Hit}@10$ và $\text{Hit}@20$.

Các baseline RAG (NaiveRAG 32,8%, LightRAG 39,8%, RAPTOR 41,0%) thấp hơn cả BM25 (47,5%), kết quả tương tự miền đào tạo. Lý do cốt lõi là embedding đa

4.2. Kết quả thử nghiệm

mục đích thiếu biểu diễn tốt cho từ vựng pháp lý tiếng Việt đặc thù; trích xuất KG chung của LightRAG tạo nhiều nhiễu vì không phân biệt được quan hệ pháp lý (điều khoản hướng dẫn, điều khoản trừng phạt) với quan hệ ngữ nghĩa chung; và tóm tắt đệ quy của RAPTOR mất chi tiết số liệu và tên điều khoản cụ thể trong quá trình gộp.

Kết quả theo miền

Bảng 4.7 trình bày kết quả Hit@10 theo từng lĩnh vực cụ thể, cho phép so sánh hiệu suất trên ba miền khác nhau và phân tích nguyên nhân chênh lệch.

Bảng 4.7: Hit@10 (%) theo miền trên ba lĩnh vực

Phương pháp	Doanh nghiệp (200)	Giao thông (200)	Đào tạo (130)
NaiveRAG	29,9	35,5	50,0
LightRAG	20,3	58,6	56,9
RAPTOR	18,5	63,5	53,8
BM25	31,5	63,1	70,0
PageIndex	76,6	92,6	74,6
3-Tier (ours)	86,5	98,0	87,9
So với PageIndex	+9,9	+5,4	+13,3

Hệ thống vượt trội trên cả ba miền với biên độ nhất quán. Luật giao thông đạt kết quả cao nhất (98,0%) và có biên độ cải thiện so với PageIndex thấp nhất (+5,4 pp). Điều này phản ánh đặc trưng cấu trúc của luật giao thông: ánh xạ trực tiếp vi phạm–hình phạt tạo ra các điều khoản có nội dung đồng nhất, dễ định vị bằng cả duyệt cây lẫn tìm kiếm ngữ nghĩa. PageIndex cũng đạt 92,6% trên miền này, cho thấy duyệt cây đơn thuần đã rất hiệu quả khi cấu trúc văn bản rõ ràng.

Luật doanh nghiệp khó nhất (86,5%) do đặc trưng tham chiếu xuyên nghị định: một câu hỏi về thủ tục thành lập công ty có thể yêu cầu kết hợp thông tin từ Luật 59 (điều khoản gốc) và các nghị định hướng dẫn (điều khoản chi tiết hóa). Mạng lưới KG và mở rộng PPR trong Tầng 3 xử lý tình huống này tốt hơn PageIndex đáng kể (+9,9 pp), vì các cạnh tham chiếu chéo trong KG chính là cầu nối giữa Luật 59 và các nghị định.

Phân tích chi tiết theo lĩnh vực

Lĩnh vực doanh nghiệp: thách thức chuỗi tham chiếu nghị định. Hit@10 = 86,5% là kết quả thấp nhất trong ba miền, nhưng vẫn cao hơn PageIndex 9,9 điểm phần trăm, biên độ cải thiện lớn nhất trong bộ thử nghiệm. Thách thức chính đến từ cấu trúc nghị định lồng nhau: một câu hỏi như “thủ tục đăng ký chi nhánh công ty” yêu cầu đọc Luật 59 Điều 44 (định nghĩa và quyền của chi nhánh) kết hợp với NĐ 01 Điều 31 (hồ sơ và trình tự đăng ký cụ thể). Nếu hệ thống chỉ tìm được điều khoản trong Luật 59 mà không mở rộng sang NĐ 01 qua cạnh KG, câu trả lời sẽ thiếu thông tin thủ tục và bị đánh dấu là miss.

Điều đáng chú ý là BM25 chỉ đạt 31,5% trên lĩnh vực doanh nghiệp, thấp hơn đáng kể so với giao thông (63,1%). Lý do là thuật ngữ pháp lý doanh nghiệp có mức độ đa nghĩa cao: từ “vốn” xuất hiện trong ngữ cảnh vốn điều lệ, vốn pháp định, vốn góp và vốn chủ sở hữu với hàm ý pháp lý khác nhau, và BM25 không phân biệt được. Tương tự, NaiveRAG (29,9%) và LightRAG (20,3%) thậm chí hoạt động kém hơn BM25 vì các embedding đa mục đích đánh đồng các điều khoản có cấu trúc ngữ pháp tương tự nhưng khác nhau về nội dung pháp lý (ví dụ: “Điều 25. Quyền của cổ đông phổ thông” và “Điều 115. Quyền của cổ đông ưu đãi” có vector biểu diễn gần nhau trong không gian embedding, dù điều chỉnh hai đối tượng hoàn toàn khác nhau).

Lĩnh vực giao thông: hiệu suất gần trần giới hạn. Hit@10 = 98,0% là kết quả cao nhất trong toàn bộ bộ thử nghiệm. Chỉ 4 trong 200 câu hỏi không được tìm thấy điều khoản đúng trong top-10. Lợi thế cấu trúc của NĐ 168/2024/NĐ-CP là yếu tố quyết định: mỗi điều khoản được tổ chức theo mẫu “hành vi vi phạm, mức phạt tiền, hình phạt bổ sung”, tạo ra phân vùng nội dung đồng nhất và dễ định vị. Tầng 1 (duyet cây) có thể nhanh chóng thu hẹp xuống chương điều khoản đúng vì cấu trúc phân cấp của nghị định giao thông phản ánh trực tiếp phân loại hành vi vi phạm (theo loại phương tiện, theo loại vi phạm).

BM25 cũng đạt 63,1% trên lĩnh vực này, kết quả tốt nhất của BM25 trong ba miền, vì từ vựng giao thông có tính đặc thù cao: “vượt đèn đỏ”, “nồng độ cồn”, “xe máy”, “bằng lái” là các thuật ngữ xuất hiện gần như độc quyền trong ngữ cảnh vi phạm giao thông. RAPTOR (63,5%) hoạt động tốt bất thường so với các miền khác vì cấu trúc self-contained của từng điều khoản giao thông giúp tóm tắt dễ quy giữ được thông tin quan trọng mà không bị mất như trong lĩnh vực doanh nghiệp.

Miền quy định đào tạo (87,9%) cho thấy biên độ cải thiện lớn nhất so với PageIndex

(+13,3 pp) mặc dù kích thước cơ sở tri thức nhỏ hơn nhiều. Lý do là phân cấp quản lý hai cấp (ĐHQG và UIT) tạo ra nhu cầu đối chiếu chéo giữa hai hệ thống văn bản; PageIndex chỉ tìm kiếm trong một tài liệu tại một thời điểm nên bỏ sót các điều khoản bổ trợ từ văn bản cấp trường.

Tính nhất quán liên miền

Một kết quả nổi bật ít được chú ý trong bảng số liệu là hệ thống 3-Tier KG-RAG sử dụng *cùng một pipeline* và *cùng bộ siêu tham số* trên cả ba miền; điểm khác biệt duy nhất là file cấu hình YAML và kho tài liệu đầu vào. Đây là tính chất quan trọng vì hầu hết các hệ thống hỏi đáp pháp lý trong tài liệu học thuật đều được tối ưu hóa riêng cho từng miền (domain-specific fine-tuning), làm cho kết quả khó có thể tổng quát hóa.

Bảng chứng định lượng cho tính tổng quát hóa này là độ biến thiên kết quả thấp: khoảng cách giữa miền tốt nhất và tệ nhất của hệ thống 3-Tier là 11,5 pp (98,0% giao thông so với 86,5% doanh nghiệp). So sánh với PageIndex, khoảng cách tương ứng là 16,0 pp (92,6% giao thông so với 76,6% doanh nghiệp). Hệ thống đề xuất không chỉ đạt hiệu suất tuyệt đối cao hơn mà còn ổn định hơn trên phổ miền, đặc tính quan trọng khi triển khai trong môi trường thực tế nơi người dùng có thể hỏi về nhiều lĩnh vực pháp luật khác nhau trong cùng một phiên làm việc.

Phân tích thất bại

Phân tích 31 câu hỏi bị bỏ sót (7,8% tổng số, trong đó 27 câu, tương đương 87%, thuộc lĩnh vực doanh nghiệp) cho thấy bốn nhóm nguyên nhân có hệ thống.

Nhóm 1: Phụ thuộc xuyên nghị định (6 câu). Câu hỏi yêu cầu thông tin từ nghị định hướng dẫn chưa có trong kho tài liệu. Ví dụ cụ thể: câu hỏi “thủ tục đăng ký chi nhánh công ty cổ phần” yêu cầu Luật 59 Điều 44 (định nghĩa chi nhánh và phạm vi hoạt động) kết hợp với ND 01 Điều 31 (hồ sơ và trình tự nộp hồ sơ đăng ký). Mặc dù ND 01 có trong kho tài liệu, cạnh tham chiếu từ Luật 59 Điều 44 sang ND 01 Điều 31 không xuất hiện tường minh trong văn bản gốc; đây là liên kết ngầm theo quy ước pháp lý, không phải tham chiếu rõ ràng bằng trích dẫn điều khoản. Cơ chế mở rộng PPR hiện tại chỉ theo các cạnh KG tường minh, nên bỏ sót nhóm liên kết ngầm này.

Nhóm 2: Ngoài kho tài liệu (4 câu). Câu hỏi về hộ kinh doanh, một loại hình hoạt động kinh tế không được điều chỉnh bởi Luật 59 (Luật Doanh nghiệp) mà thuộc Nghị

định 01/2021 về đăng ký hộ kinh doanh, một văn bản khác tên. Đây là giới hạn phạm vi của kho tài liệu, không phải lỗi thuật toán.

Nhóm 3: Đa điều khoản ngầm (14 câu). Đây là nhóm lớn nhất và có hàm ý quan trọng nhất về mặt kỹ thuật. Các câu hỏi dạng “Nếu công ty vi phạm quy định về quản trị doanh nghiệp, hậu quả pháp lý là gì?” đòi hỏi chuỗi suy luận ba bước: trước hết tìm điều khoản định nghĩa vi phạm cụ thể (Luật 59 Chương III), tiếp theo tìm điều khoản quy định chế tài (nghị định xử phạt hành chính), cuối cùng tìm điều khoản quy định thủ tục thực thi (nghị định hướng dẫn). Ba điều khoản này không có tham chiếu chéo tường minh lẫn nhau; chúng được liên kết bởi logic pháp lý ngầm hiểu bởi luật sư nhưng không được mã hóa trong văn bản. Cơ chế PPR hai bước trong Tầng 3 chỉ mở rộng được một bước từ seed node, không đủ để bắt chuỗi ba bước này.

Nhóm 4: Lỗi Bước 1 (3 câu). Hệ thống chọn sai tài liệu ngay từ bước đầu tiên do tiêu đề văn bản không phản ánh đủ nội dung điều khoản. Ví dụ: câu hỏi về quyền của người lao động trong công ty liên quan đến cả Luật Doanh nghiệp và Bộ luật Lao động; hệ thống chỉ tìm kiếm trong kho pháp luật doanh nghiệp nên bỏ sót nguồn bên ngoài.

Sự tập trung của thất bại vào lĩnh vực doanh nghiệp (87% số câu bị bỏ sót) xác nhận rằng tham chiếu xuyên nghị định ngầm định là thách thức cốt lõi của bài toán hỏi đáp pháp luật doanh nghiệp Việt Nam, đồng thời cũng là hướng cải tiến rõ ràng nhất cho công việc tiếp theo.

4.3 Ứng dụng minh họa

Để minh họa khả năng ứng dụng thực tế của hệ thống truy xuất, một ứng dụng chatbot tra cứu quy định đào tạo đã được xây dựng dưới dạng giao diện web tương tác. Ứng dụng kết nối trực tiếp với pipeline truy xuất 3-Tier KG-RAG và sử dụng LLM để sinh câu trả lời theo phương pháp phân tích IRAC (Issue–Rule–Application–Conclusion), phục vụ trực tiếp nhu cầu tra cứu quy chế đào tạo sau đại học của học viên cao học.

4.3.1 Kiến trúc ứng dụng

Ứng dụng được xây dựng trên nền tảng Chainlit 2.0, một framework mã nguồn mở cho giao diện chatbot hỗ trợ streaming. Kiến trúc gồm ba thành phần chính:

- **Giao diện web (Chainlit):** Giao diện chat hỗ trợ streaming token-by-token, hiển thị trạng thái truy xuất theo thời gian thực và panel nguồn trích dẫn với breadcrumb vị trí trong văn bản.
- **Cầu nối bất đồng bộ (Async Bridge):** Pipeline truy xuất 3-Tier hoạt động đồng bộ (synchronous), trong khi Chainlit yêu cầu xử lý bất đồng bộ (asynchronous) để duy trì kết nối WebSocket. Một cầu nối sử dụng `threading.Thread` và `asyncio.Queue` chuyển tiếp sự kiện từ pipeline đồng bộ sang vòng lặp sự kiện bất đồng bộ, tránh chặn (block) giao diện trong suốt quá trình truy xuất (30–60 giây).
- **Pipeline truy xuất (3-Tier KG-RAG):** Pipeline sinh ba loại sự kiện: status (cập nhật trạng thái truy xuất), metadata (trích dẫn, reasoning trace, độ tin cậy) và token (nội dung câu trả lời streaming).

4.3.2 Phương pháp sinh câu trả lời IRAC

IRAC (Issue–Rule–Application–Conclusion) là phương pháp phân tích có nguồn gốc từ lĩnh vực pháp lý, được sử dụng rộng rãi trong đào tạo luật và tư vấn pháp luật. Phương pháp này phù hợp cho bài toán hỏi đáp quy định vì đảm bảo câu trả lời có cấu trúc rõ ràng, trích dẫn căn cứ cụ thể và kết luận dứt khoát. Bốn phần của IRAC gồm:

1. **Issue (Vấn đề):** Xác định vấn đề cần giải đáp từ câu hỏi của người dùng.
2. **Rule (Căn cứ quy chế):** Trích dẫn chính xác Điều, Khoản, Điểm của quy chế/quyết định liên quan từ ngữ cảnh đã truy xuất.
3. **Application (Phân tích áp dụng):** Giải thích cụ thể quy định áp dụng vào tình huống như thế nào, chỉ ra mối liên hệ giữa quy chế và câu hỏi thực tế.
4. **Conclusion (Kết luận):** Trả lời trực tiếp câu hỏi, tổng hợp các điều kiện hoặc quy trình.

Hệ thống sử dụng prompt engineering để hướng dẫn LLM sinh câu trả lời theo cấu trúc IRAC. Prompt được tùy biến theo miền ứng dụng, với hai điểm khác biệt chính giữa miền pháp luật và miền đào tạo, được tóm tắt trong Bảng 4.8.

Việc tùy biến prompt theo miền cho phép hệ thống sử dụng cùng pipeline truy xuất nhưng sinh câu trả lời phù hợp với ngữ cảnh và đối tượng người dùng của từng lĩnh vực.

4.3. Ứng dụng minh họa

Bảng 4.8: So sánh prompt IRAC giữa miền pháp luật và miền đào tạo

Thành phần	Miền pháp luật	Miền đào tạo
Vai trò	Luật sư tư vấn	Chuyên viên tư vấn đào tạo UIT
Thuật ngữ	Căn cứ pháp luật, điều luật	Căn cứ quy chế, quy định
Trích dẫn	Văn bản pháp luật	QĐ cấp ĐHQG vs QĐ cấp trường
Ưu tiên	Không phân cấp	Ưu tiên QĐ cấp trường (QĐ 270)
Giọng văn	Trang trọng, pháp lý	Thân thiện, hướng dẫn học viên

4.3.3 Các tính năng chính

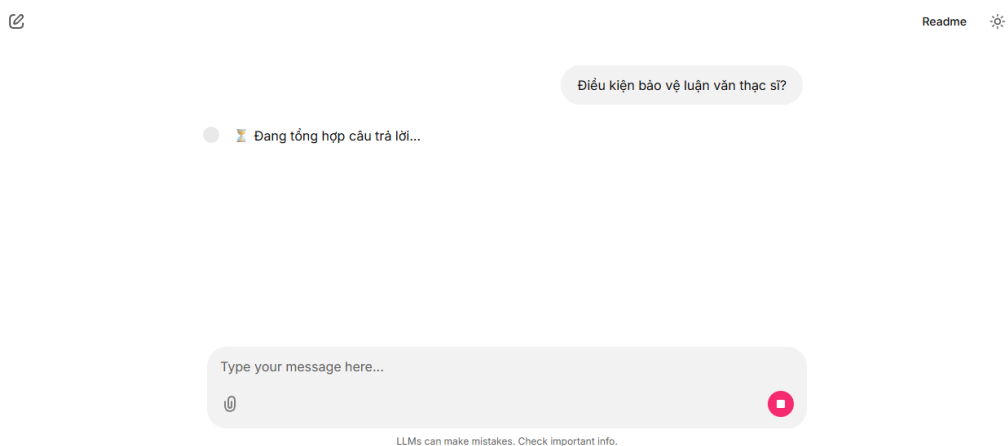
- Phản hồi trạng thái theo thời gian thực:** Trong quá trình truy xuất, hệ thống hiển thị trạng thái cập nhật trực tiếp qua ba giai đoạn: “Đang phân tích câu hỏi”, “Đang tìm kiếm quy định liên quan” và “Đang tổng hợp câu trả lời” (Hình 4.3). Thông báo tự động biến mất khi câu trả lời bắt đầu streaming. Điều này giải quyết vấn đề UX quan trọng khi thời gian truy xuất kéo dài 30–60 giây.
- Streaming câu trả lời:** Câu trả lời được sinh theo phương pháp IRAC và streaming token-by-token đến giao diện, giúp người dùng bắt đầu đọc ngay khi LLM sinh văn bản mà không cần đợi toàn bộ câu trả lời (Hình 4.4).
- Trích dẫn nguồn với breadcrumb:** Panel bên phải hiển thị nội dung gốc của các điều khoản được trích dẫn, với breadcrumb vị trí rõ ràng (tên văn bản, chương, điều) và đường phân cách giữa các nguồn. Người dùng có thể đối chiếu trực tiếp giữa tư vấn và nguyên văn quy định (Hình 4.5). Ngoài ra, lộ trình truy xuất 3 bước (Bước 1–3) cũng được hiển thị minh bạch để người dùng hiểu quá trình tìm kiếm của hệ thống (Hình 4.6).
- Hỗ trợ đa miền:** Ứng dụng hỗ trợ chuyển đổi giữa các miền (quy định đào tạo, pháp luật) thông qua biến môi trường cấu hình, sử dụng cùng giao diện và pipeline.

Hình 4.2–4.6 minh họa các màn hình chính của ứng dụng, từ giao diện chào mừng đến kết quả truy xuất.

4.3. Ứng dụng minh họa



Hình 4.2: Màn hình chào mừng với lĩnh vực “Quy định đào tạo” và các câu hỏi gợi ý về quy chế đào tạo sau đại học



Hình 4.3: Trạng thái truy xuất “Đang tổng hợp câu trả lời...” hiển thị trực tiếp trong khi hệ thống xử lý câu hỏi

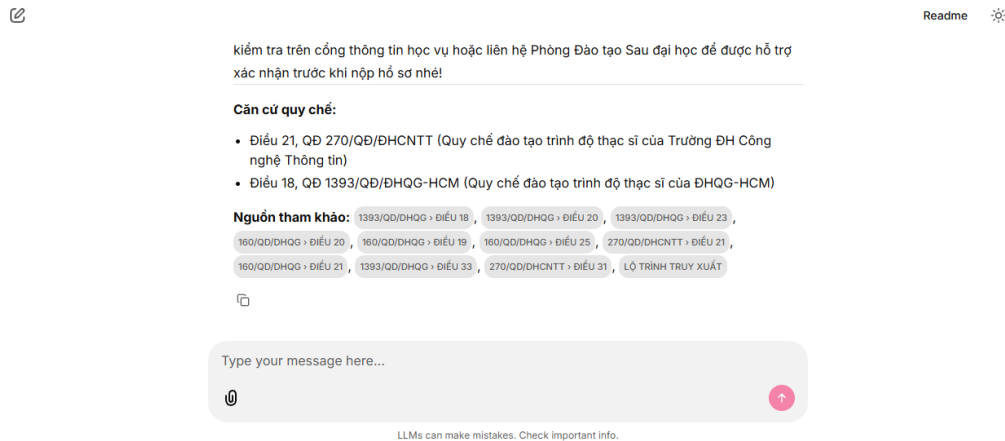
4.3.4 Ví dụ minh họa tiêu biểu

Phần này trình bày các ví dụ cụ thể từ kết quả thử nghiệm trên miền quy định đào tạo, minh họa điểm mạnh và hạn chế của hệ thống qua so sánh trực tiếp với các baseline. Các câu hỏi được trích nguyên văn từ diễn đàn học viên cao học UIT.


Ví dụ 1: Truy xuất cross-document – yêu cầu ngoại ngữ

Câu hỏi: “Chứng chỉ TOEIC do các trường ĐH, CĐ trong nước cấp (không phải của trung tâm khảo thí của ETS cấp) có được công nhận anh văn đầu ra Cao học không ạ?”

4.3. Ứng dụng minh họa



Hình 4.4: Câu trả lời IRAC cho câu hỏi “Điều kiện bảo vệ luận văn thạc sĩ?” với panel nguồn quy định gốc (phải)

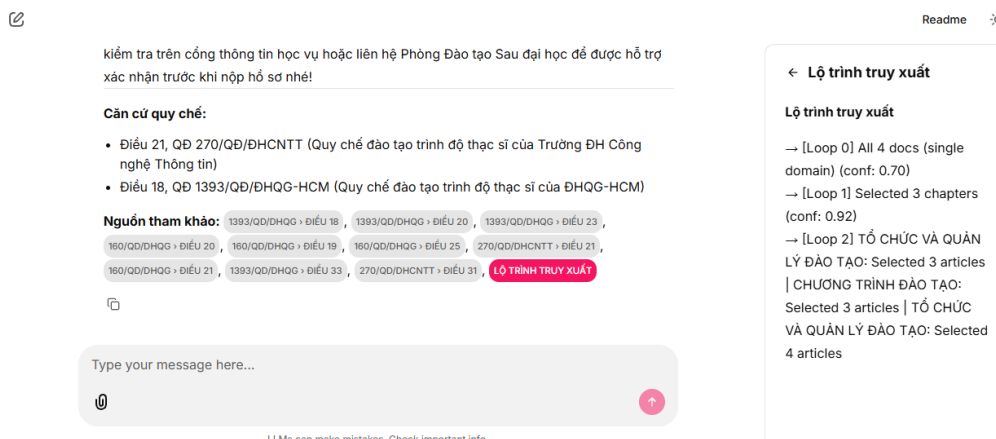


Hình 4.5: Panel trích dẫn nguồn hiển thị nguyên văn điều khoản với breadcrumb vị trí (văn bản → chương → điều)

Gold articles: Điều 6 QĐ 1393 (ĐHQG-HCM, yêu cầu ngoại ngữ đầu ra) và Điều 9 QĐ 270 (UIT, quy định bổ sung về chứng chỉ được chấp nhận).

Phân tích: Câu hỏi yêu cầu kết hợp thông tin từ hai văn bản ở hai tầng quản lý khác nhau: QĐ 1393 (ĐHQG-HCM) quy định yêu cầu chung, còn QĐ 270 (UIT) bổ sung danh sách chứng chỉ cụ thể được chấp nhận. Tầng 1 chọn đúng cả hai tài liệu ở Bước 1, sau đó Bước 2 thu hẹp vào các chương về ngoại ngữ. KG expansion bổ sung Điều 25 (QĐ 270) qua cạnh references từ Điều 9. Hệ thống đạt MRR = 1,0 với cả hai gold articles trong top 3 (Bảng 4.9). PageIndex tìm được Điều 6 nhưng bỏ sót Điều 9 của UIT (chỉ tìm trong QĐ 1393 và QĐ 160). RAPTOR không tìm được cả hai, truy xuất phân

4.3. Ứng dụng minh họa



Hình 4.6: Lộ trình truy xuất 3 bước: Bước 1 chọn tài liệu, Bước 2 chọn chương, Bước 3 truy xuất điều khoản

tán giữa các điều khoản không liên quan.

Bảng 4.9: So sánh top-5 kết quả truy xuất giữa các hệ thống – Ví dụ 1

Rank	3-Tier KG-RAG	PageIndex	RAPTOR
1	1393:d6 ✓	1393:d24	160:d37
2	1393:d23	1393:d6 ✓	851:d2
3	270:d9 ✓	1393:d2	1393:d33
4	270:d25	160:d25	270:d38
5	160:d37	160:d9	160:d19

Ví dụ 2: Truy xuất đa điều khoản – hoãn chuyên đề

Câu hỏi: “Cho em hỏi nếu hoãn 1 hoặc 2 môn chuyên đề thôi thì vẫn làm theo mẫu trên vẫn được phải không ạ? Nếu đã tham gia học rồi nhưng không nộp bài thì tính sao?”

Gold articles: Điều 8 QĐ 1393 (quy định về chương trình đào tạo), Điều 11 QĐ 270 (quy chế học vụ) và Điều 18 QĐ 270 (quy định về chuyên đề).

Phân tích: Hệ thống truy xuất tất cả 3 gold articles trong top 5, $MRR = 1,0$ (Bảng 4.10). Câu hỏi đòi hỏi liên kết giữa quy định chung về chương trình đào tạo (QĐ 1393) và quy chế riêng của UIT về học vụ và chuyên đề (QĐ 270). Tầng 1 duyệt đúng cả hai tài liệu, KG expansion liên kết Điều 11 với Điều 18 qua quan hệ references. PageIndex chỉ tìm

4.3. Ứng dụng minh họa

Bảng 4.10: So sánh top-5 kết quả truy xuất giữa các hệ thống – Ví dụ 2

Rank	3-Tier KG-RAG	PageIndex	RAPTOR
1	1393:d8 ✓	1393:d25	270:d38
2	1393:d24	1393:d13	1393:d33
3	270:d11 ✓	1393:d24	270:d26
4	270:d16	1393:d26	1393:d13
5	270:d18 ✓	1393:d14	160:d20

trong QĐ 1393, bỏ sót hoàn toàn QĐ 270. RAPTOR truy xuất các điều khoản về hình thức xử lý (QĐ 270:d38, d26) thay vì các quy định gốc.

Ví dụ 3: Truy xuất đăng ký chuyên đề – đăng ký môn học khác khóa

Câu hỏi: “Cho em hỏi là khóa 5 có được phép đăng ký học những môn chuyên đề của Khóa 4 không?”

Gold articles: Điều 8 QĐ 1393 (chương trình đào tạo), Điều 11, Điều 2, Điều 4 QĐ 270 (quy chế học vụ, phạm vi áp dụng, hình thức đào tạo).

Phân tích: Hệ thống đặt 2/4 gold articles (Đ.8 QĐ 1393 và Đ.11 QĐ 270) ở rank 1–2, MRR = 1,0 (Bảng 4.11). Câu hỏi ngắn, không chứa thuật ngữ chuyên ngành nhưng đòi hỏi hiểu biết về quy trình đăng ký khác khóa. Tầng 1 chọn đúng chương về đào tạo trong cả hai văn bản. Cả PageIndex và RAPTOR đều không truy xuất được Điều 8 hoặc Điều 11 trong top 10.

Bảng 4.11: So sánh top-5 kết quả truy xuất giữa các hệ thống – Ví dụ 3

Rank	3-Tier KG-RAG	PageIndex	RAPTOR
1	1393:d8 ✓	160:d17	160:d12
2	270:d11 ✓	1393:d13	270:d25
3	160:d13	160:d13	1393:d9
4	160:d18	1393:d4	160:d9
5	270:d17	270:d16	1393:d3

Ví dụ 4: Trường hợp thất bại – câu hỏi thiếu ngữ cảnh

Câu hỏi: “Thầy/cô cho em hỏi, nếu như học ngành CNTT, sau này đăng ký học Tiến sĩ với bằng Thạc sĩ ngành CNTT thì trường có chấp nhận không ạ?”

Gold articles: Điều 6 QĐ 1393 (điều kiện trình độ đầu vào) và Điều 9 QĐ 270 (yêu cầu bổ sung).

Kết quả: Hệ thống truy xuất Điều 10, 11 QĐ 1393 (chương trình Tiến sĩ) và Điều 13, 17 QĐ 270 (nghiên cứu sinh) trong top 5 – đúng chủ đề Tiến sĩ nhưng sai điều khoản cụ thể. PageIndex lại truy xuất đúng nhờ tìm kiếm rộng hơn trên QĐ 270.

Nguyên nhân: Câu hỏi hỏi về “Tiến sĩ” nhưng gold articles nằm ở phần “điều kiện đầu vào Thạc sĩ” (Điều 6, Điều 9). Nội dung hai điều khoản này bao gồm cả điều kiện cho chương trình Tiến sĩ nhưng tiêu đề chương và tóm tắt chỉ đề cập “Thạc sĩ”, khiến Bước 2 chọn nhầm chương. Đây là hạn chế của duyệt cây khi tiêu đề chương không phản ánh đầy đủ nội dung bên trong.

Chương 5

Kết luận và hướng phát triển

Chương này tổng kết các kết quả đạt được của luận văn, thảo luận các hạn chế hiện tại và đề xuất hướng phát triển tương lai.

5.1 Kết quả đề tài

Luận văn đã đề xuất và xây dựng thành công kiến trúc 3-Tier KG-RAG, một hệ thống truy xuất kiến thức ba tầng kết hợp ontology, Knowledge Graph và Document Forest cho bài toán hỏi đáp quy định đào tạo và pháp luật Việt Nam. Các kết quả chính bao gồm:

Đóng góp đầu tiên là **ontology và Knowledge Graph chuyên biệt** cho lĩnh vực pháp luật và quy định đào tạo Việt Nam. Ontology miền được xây dựng với 14 loại thực thể sử dụng OWL, phân cấp 4 cấp với ánh xạ nhãn tiếng Việt. Knowledge Graph kết quả chứa 5.936 thực thể và 5.963 quan hệ thuộc 56 loại quan hệ, cùng Document Forest gồm 9.226 nút cấu trúc từ 13 tài liệu. Quy trình xây dựng KG bán tự động kết hợp trích xuất LLM với tinh chỉnh expert-in-the-loop đảm bảo chất lượng và khả năng truy vết nguồn gốc.

Bên cạnh đó, luận văn thiết kế và triển khai **kiến trúc truy xuất ba tầng** thống nhất gồm: duyệt cây cấu trúc hướng dẫn bởi LLM (Tầng 1), truy xuất ngữ nghĩa hai cấp với PPR nhận biết ý định (Tầng 2), và hợp nhất RRF với mở rộng Knowledge Graph (Tầng 3). Điểm nổi bật là cùng một pipeline và siêu tham số có thể hoạt động trên cả ba miền mà không cần điều chỉnh riêng. Kết quả đánh giá trên 530 câu hỏi chuyên gia cho thấy hệ thống đạt hiệu quả vượt trội so với các baseline: lĩnh vực pháp luật (400 câu) đạt 92,2% Hit@10 và MRR = 0,603, vượt PageIndex +7,4 pp và RAPTOR +51,2 pp;

lĩnh vực doanh nghiệp (200 câu) đạt 86,5% Hit@10, vượt PageIndex +9,9 pp; lĩnh vực giao thông (200 câu) đạt 98,0% Hit@10, vượt PageIndex +5,4 pp; và quy định đào tạo (130 câu) đạt 87,9% Hit@10 và MRR = 0,594, vượt PageIndex +13,3 pp và RAPTOR +34,1 pp.

Ngoài ra, luận văn xây dựng **bộ kiểm thử tiếng Việt** gồm 530 câu hỏi với gold articles được gán nhãn bởi chuyên gia, bao gồm các tình huống single-hop, multi-hop và reasoning phức tạp. Song song đó, một **ứng dụng chatbot web** tương tác được triển khai, tích hợp trực tiếp với pipeline truy xuất, hỗ trợ streaming câu trả lời theo phương pháp IRAC, hiển thị trích dẫn nguồn quy định và quá trình suy luận. Ứng dụng hoạt động trên cả desktop và thiết bị di động, phục vụ trực tiếp nhu cầu tra cứu quy chế đào tạo sau đại học của học viên cao học.

Cuối cùng, kết quả nghiên cứu đã được nộp dưới dạng **bài báo khoa học** tại hội nghị quốc tế SOMET 2026 (đang trong quá trình phản biện).

5.2 Hạn chế

Mặc dù đạt được các kết quả đáng khích lệ, hệ thống vẫn còn một số hạn chế cần được nhìn nhận thẳng thắn.

Hạn chế đáng kể nhất liên quan đến **sự phụ thuộc vào LLM và độ trễ xử lý**. Tầng 1 yêu cầu nhiều lời gọi LLM tuần tự (Loop 0 $\rightarrow$ Loop 1 $\rightarrow$ Loop 2), dẫn đến thời gian phản hồi khoảng 7 giây mỗi truy vấn. Chất lượng toàn hệ thống phụ thuộc trực tiếp vào khả năng suy luận của LLM đang sử dụng, tạo ra rủi ro khi mô hình được cập nhật hoặc thay thế. Một hạn chế khác là **quy mô bộ kiểm thử miền đào tạo** hiện gồm 130 câu hỏi, đủ để đánh giá xu hướng nhưng có thể mở rộng hơn để tăng tính đại diện thống kê.

Về phía xây dựng dữ liệu, **Knowledge Graph được xây dựng qua tinh chỉnh thủ công** theo quy trình expert-in-the-loop — điều này đảm bảo chất lượng cao nhưng khó mở rộng quy mô và hệ thống chưa hỗ trợ cập nhật KG tự động khi quy định thay đổi. Bên cạnh đó, luận văn tập trung đánh giá chất lượng truy xuất qua các chỉ số Hit@k và MRR, trong khi **chất lượng câu trả lời sinh bởi LLM** từ ngữ cảnh đã truy xuất chưa được đánh giá bằng các chỉ số như BLEU, ROUGE hay BERTScore. Ngoài ra, hiệu quả của hệ thống trên **nhóm luật về doanh nghiệp còn thấp hơn so với các miền khác**: 27/31 câu hỏi bị bỏ sót thuộc nhóm này, chủ yếu do chuỗi suy luận pháp lý ngầm giữa các nghị định không có tham chiếu chéo rõ ràng.

5.3 Hướng phát triển

Dựa trên các hạn chế và tiềm năng đã xác định, một số hướng phát triển tương lai được đề xuất.

Về tối ưu hiệu năng, hướng ưu tiên trước mắt là **giảm độ trễ LLM** thông qua thực thi song song các lời gọi trong Tầng 1 và áp dụng model distillation để giảm chi phí tính toán — các mô hình nhỏ hơn có thể được fine-tune chuyên biệt cho tác vụ chọn chương/điều khoản. Song song đó, cần **tự động hóa quy trình cập nhật KG** bằng cách phát triển pipeline tự động phát hiện thay đổi trong văn bản quy phạm và cập nhật Knowledge Graph tương ứng, giảm thiểu sự can thiệp thủ công hiện tại.

Về kỹ thuật nâng cao, khi Knowledge Graph đạt quy mô đủ lớn, việc tích hợp **Graph Neural Networks** theo hướng tiếp cận GNN-RAG [19] sẽ cho phép khai thác cấu trúc đồ thị sâu hơn thay vì chỉ duyệt cạnh đơn. Bên cạnh đó, mở rộng hệ thống theo hướng **đa phương thức** để hỗ trợ xử lý biểu mẫu, sơ đồ quy trình (flowchart thủ tục) và bảng biểu trong văn bản quy phạm cũng là một hướng có tiềm năng cao.

Về mở rộng phạm vi và hoàn thiện hệ thống, luận văn đề xuất **mở rộng sang các miền quy định khác** như đào tạo đại học, tuyển sinh, hoặc các lĩnh vực pháp luật bổ sung (lao động, thuế, đất đai). Ứng dụng chatbot hiện tại cũng cần được **nâng cấp lên môi trường production** với xác thực người dùng, lưu lịch sử hội thoại, phản hồi từ người dùng (feedback loop) để cải thiện chất lượng truy xuất, và tích hợp vào cổng thông tin đào tạo. Cuối cùng, cần **bổ sung đánh giá chất lượng sinh câu trả lời end-to-end** bằng các chỉ số sinh văn bản (BLEU, ROUGE, BERTScore) và đánh giá chủ quan bởi chuyên gia miền, nhằm hoàn thiện bức tranh đánh giá toàn diện cho hệ thống.

Phụ lục A

Danh sách quy chế đào tạo

Phụ lục này liệt kê chi tiết 5 quy chế đào tạo thạc sĩ được sử dụng trong phạm vi nghiên cứu.

A.1 QĐ 270/QĐ-ĐHCNTT: Quy chế đào tạo trình độ thạc sĩ của UIT

- **Ngày ban hành:** 25/04/2022
- **Cơ quan ban hành:** Trường Đại học Công nghệ Thông tin, ĐHQG-HCM
- **Phạm vi:** Áp dụng cho tất cả học viên cao học tại UIT
- **Cấu trúc:** 8 chương, 35 điều
- **Nội dung chính:**
 - Chương 1: Quy định chung (Điều 1–4)
 - Chương 2: Tuyển sinh (Điều 5–8)
 - Chương 3: Tổ chức đào tạo (Điều 9–14)
 - Chương 4: Đánh giá kết quả học tập (Điều 15–19)
 - Chương 5: Luận văn thạc sĩ (Điều 20–26)
 - Chương 6: Xét và công nhận tốt nghiệp (Điều 27–30)
 - Chương 7: Quyền và nghĩa vụ của học viên (Điều 31–33)
 - Chương 8: Điều khoản thi hành (Điều 34–35)

A.2 QĐ 160/QĐ-ĐHQG: Quy chế đào tạo ThS ĐHQG-HCM (khóa 2021)

- **Ngày ban hành:** 24/03/2017
- **Cơ quan ban hành:** ĐHQG-HCM
- **Phạm vi:** Áp dụng cho học viên khóa 2021 tại các trường thành viên ĐHQG-HCM
- **Cấu trúc:** 7 chương, 28 điều

A.3 QĐ 1393/QĐ-ĐHQG: Quy chế đào tạo ThS ĐHQG-HCM (khóa 2022+)

- **Ngày ban hành:** 03/11/2021
- **Cơ quan ban hành:** ĐHQG-HCM
- **Phạm vi:** Áp dụng cho học viên từ khóa 2022 trở đi tại các trường thành viên
- **Cấu trúc:** 8 chương, 32 điều
- **Thay thế:** QĐ 160/QĐ-ĐHQG

A.4 QĐ 218/QĐ-ĐHQG: Sửa đổi bổ sung quy định GVHD

- **Ngày ban hành:** 15/03/2024
- **Cơ quan ban hành:** ĐHQG-HCM
- **Phạm vi:** Sửa đổi, bổ sung quy định về giáo viên hướng dẫn
- **Cấu trúc:** 2 chương, 6 điều
- **Bổ sung cho:** QĐ 1393/QĐ-ĐHQG

A.5 QĐ 851/QĐ-ĐHCNTT: Quy định liên chính học thuật

- **Ngày ban hành:** 14/08/2024
- **Cơ quan ban hành:** Trường Đại học Công nghệ Thông tin, ĐHQG-HCM
- **Phạm vi:** Áp dụng cho học viên cao học UIT
- **Cấu trúc:** 3 chương, 8 điều
- **Nội dung chính:** Định nghĩa đạo văn, các hình thức vi phạm liên chính học thuật, mức xử lý kỷ luật

Phụ lục B

Bộ câu hỏi kiểm thử mẫu

Phụ lục này trình bày một số câu hỏi mẫu đại diện từ bộ kiểm thử miền quy định đào tạo (130 câu hỏi) và miền pháp luật (400 câu hỏi). Mỗi bảng chỉ trích xuất 10 câu hỏi tiêu biểu; toàn bộ bộ câu hỏi được sử dụng trong thử nghiệm tại Chương 4.

B.1 Câu hỏi miền quy định đào tạo

Bảng B.1 trình bày 10 câu hỏi mẫu đại diện cho bộ kiểm thử miền quy định đào tạo.

B.2 Câu hỏi miền pháp luật

Bảng B.2 trình bày 10 câu hỏi mẫu đại diện cho bộ kiểm thử miền pháp luật.

B.2. Câu hỏi miễn pháp luật

Bảng B.1: Câu hỏi mẫu miễn quy định đào tạo (trích 10/130 câu)

STT	Câu hỏi	Gold Articles	Loại
1	Thời gian đào tạo thạc sĩ tối đa là bao lâu?	QĐ270: Điều 5	Single
2	Điều kiện để được bảo vệ luận văn thạc sĩ?	QĐ270: Điều 24	Single
3	Điểm trung bình tích lũy tối thiểu để tốt nghiệp?	QĐ270: Điều 29	Single
4	Yêu cầu ngoại ngữ đầu ra cho học viên cao học?	QĐ1393: Điều 25	Single
5	GVHD được hướng dẫn tối đa bao nhiêu học viên cùng lúc?	QĐ218: Điều 4	Single
6	Thế nào là hành vi đạo văn trong luận văn?	QĐ851: Điều 3	Single
7	Học viên bị cảnh báo học vụ khi nào?	QĐ270: Điều 18	Single
8	Nếu học viên hết thời gian gia hạn mà chưa bảo vệ luận văn thì sao?	QĐ270: Điều 5, 30	Multi
9	Học viên khóa 2021 có được áp dụng quy chế 1393 không?	QĐ1393: Điều 32	Reason
10	Điều kiện để được gia hạn thời gian đào tạo?	QĐ270: Điều 5, 6	Multi
...			

Bảng B.2: Câu hỏi mẫu miền pháp luật (trích 10/400 câu)

STT	Câu hỏi	Gold Articles	Loại
1	Vốn điều lệ tối thiểu của công ty chứng khoán?	59-QH14: Điều 175	Single
2	Mức phạt khi vượt đèn đỏ đối với ô tô?	168-NĐ: Điều 6	Single
3	Thành viên góp vốn bằng tài sản thì phải làm gì?	59-QH14: Điều 34, 36	Multi
4	Nếu thành viên vay tiền góp vốn rồi rút vốn thì bị xử phạt thế nào?	59-QH14: Điều 16, 47	Multi
5	Điều kiện để chuyển đổi công ty TNHH thành công ty cổ phần?	59-QH14: Điều 202	Single
6	Mức phạt khi lái xe say rượu có nồng độ cồn vượt mức?	168-NĐ: Điều 5	Single
7	Quyền và nghĩa vụ của thành viên hội đồng quản trị?	59-QH14: Điều 153, 165	Multi
8	Hộ kinh doanh có phải đăng ký kinh doanh không?	Ngoài corpus	—
9	Mức phạt khi không mang giấy phép lái xe?	168-NĐ: Điều 21	Single
10	Quy trình giải thể doanh nghiệp tự nguyện?	59-QH14: Điều 207, 208	Multi
...			

Phụ lục C

Mẫu quan hệ đồ thị tri thức

Phụ lục này trình bày một số quan hệ tiêu biểu trong đồ thị tri thức đã xây dựng, minh họa các loại quan hệ chính giữa các thực thể.

C.1 Quan hệ REFERENCES (Tham chiếu)

Quan hệ REFERENCES biểu diễn sự dẫn chiếu giữa các điều khoản, là quan hệ quan trọng nhất cho suy luận đa bước. Bảng C.1 minh họa một số mẫu tiêu biểu.

Bảng C.1: Mẫu quan hệ REFERENCES trong KG

Điều khoản nguồn	Điều khoản đích	Ngữ cảnh
59-QH14:d47	59-QH14:d16	Nghĩa vụ thành viên → Hành vi bị cấm
59-QH14:d23	59-QH14:d22	Quyền thành viên → Nghĩa vụ góp vốn
59-QH14:d81	59-QH14:d80	Hợp ĐHĐCĐ → Triệu tập họp
59-QH14:d86	59-QH14:d84	Biểu quyết → Điều kiện họp
59-QH14:d33	59-QH14:d35	Góp vốn → Chuyển nhượng vốn
59-QH14:d11	59-QH14:d9	Giấy phép → Điều kiện kinh doanh

C.2 Quan hệ REQUIRES (Yêu cầu)

Quan hệ REQUIRES biểu diễn điều kiện tiên quyết giữa các hành động hoặc thực thể, như minh họa trong Bảng C.2.

Bảng C.2: Mẫu quan hệ REQUIRES trong KG

Thực thể nguồn	Thực thể đích	Ý nghĩa
bao_ve_luan_van	dat_diem_ngoai_ngu	Bảo vệ LV yêu cầu đạt ngoại ngữ
tot_nghiep	diem_tb_tich_luy_5.0	Tốt nghiệp yêu cầu ĐTB $\geq 5,0$
dang_ky_de_tai	gvhd_dong_y	Đăng ký đề tài cần GVHD đồng ý
thanh_lap_cong_ty	von_dieu_le	Thành lập CT cần vốn điều lệ
chuyen_doi_loai_hinh	ngghi_quyet_hdtv	Chuyển đổi cần NQ HĐTV

C.3 Thống kê loại quan hệ

Bảng C.3 liệt kê 10 loại quan hệ phổ biến nhất trong đồ thị tri thức.

Bảng C.3: Top 10 loại quan hệ trong đồ thị tri thức

STT	Loại quan hệ	Số lượng
1	requires	1.377
2	applies_to	810
3	has_authority	506
4	references	434
5	defines	398
6	has_condition	356
7	governs	312
8	has_penalty	287
9	depends_on	245
10	belongs_to	238
Tổng (56 loại)		5.963

Phụ lục D

Prompt LLM sử dụng trong hệ thống

Phụ lục này trình bày các prompt LLM chính được sử dụng trong hệ thống, bao gồm pha ngoại tuyến (trích xuất thực thể, sinh tóm tắt), pha trực tuyến (duyet cây ba vòng lặp), và sinh câu trả lời theo phương pháp IRAC.

D.1 Trích xuất thực thể và quan hệ (Pha ngoại tuyến)

Bảng D.1 trình bày prompt được sử dụng để trích xuất đồng thời thực thể và quan hệ từ mỗi điều khoản trong giai đoạn xây dựng Knowledge Graph (Mục 3.4).

D.2 Sinh tóm tắt chương (Pha ngoại tuyến)

Bảng D.2 trình bày prompt sinh mô tả giàu từ khóa cho mỗi chương, phục vụ bước chọn nhánh trong Bước 2 của Tầng 1 (Mục 3.5.2).

D.3 Sinh tóm tắt điều khoản (Pha ngoại tuyến)

Bảng D.3 trình bày prompt sinh từ khóa cho từng điều khoản, phục vụ bước chọn điều trong Bước 3 của Tầng 1.

D.3. Sinh tóm tắt điều khoản (Pha ngoại tuyến)

Bảng D.1: Prompt trích xuất thực thể và quan hệ

System: Bạn là chuyên gia trích xuất thông tin pháp lý Việt Nam. Trích xuất TẤT CẢ thực thể và quan hệ từ văn bản pháp luật.

Loại thực thể:

- TỔ_CHỨC: Công ty, doanh nghiệp, cơ quan
- VAI_TRÒ: Chức vụ, vai trò
- THUẬT_NGỮ: Thuật ngữ pháp lý
- THAM_CHIẾU: Điều khoản luật
- TIỀN_TỆ: Số tiền
- TỶ_LỆ: Phần trăm
- THỜI_HẠN: Thời gian
- ĐIỀU_KIỆN: Điều kiện áp dụng
- HÀNH_VI: Hành động pháp lý
- CHẾ_TÀI: Hình phạt, chế tài

Loại quan hệ:

YÊU_CẦU, CÓ QUYỀN, CÔNG_NHẬN, BẢO_ĐẢM, CHO_PHÉP, BAO_GỒM, ĐỊNH_NGHĨA, THAM_CHIẾU, ÁP_DỤNG, ĐIỀU_KIỆN, LIÊN QUAN

Quy tắc:

1. Trích xuất ĐẦY ĐỦ các thực thể quan trọng
2. Mỗi quan hệ phải có EVIDENCE (trích dẫn nguyên văn)
3. Dùng tên thực thể CHÍNH XÁC như trong văn bản
4. Nếu có viết tắt, ghi cả viết tắt lẫn tên đầy đủ

Văn bản: {text}

Output: {"entities": [{"name", "type", "description"}],
"relations": [{"source", "target", "predicate", "evidence"}]}

D.3. Sinh tóm tắt điều khoản (Pha ngoại tuyến)

Bảng D.2: Prompt sinh tóm tắt chương

System: Bạn là chuyên gia pháp lý Việt Nam. Phân tích chương sau để trích xuất từ khóa tìm kiếm.

VĂN BẢN: {doc_title}

CHƯƠNG: {chapter_title}

PHẠM VI: {article_range}

DANH SÁCH ĐIỀU LUẬT: {article_context}

Hãy liệt kê 40–50 TỪ KHÓA TÌM KIẾM bao gồm:

1. TỪ KHÓA CHÍNH: Trích xuất từ tiêu đề các điều luật
2. CÂU HỎI/TÌNH HUỐNG: Các câu hỏi thực tế người dùng có thể hỏi
3. VIẾT TẮT PHỔ BIẾN: Các từ viết tắt trong lĩnh vực này
4. HÀNH ĐỘNG/THỦ TỤC: Các động từ và hành động cụ thể
5. TỪ ĐỒNG NGHĨA/INFORMAL: Cách nói thông thường
6. KHÁI NIỆM LIÊN QUAN: Các khái niệm pháp lý liên quan

Trả lời NGẮN GỌN, chỉ liệt kê các từ khóa cách nhau bằng dấu phẩy.

Bảng D.3: Prompt sinh tóm tắt điều khoản

System: Bạn là chuyên gia pháp lý Việt Nam. Dựa trên điều luật sau:

Điều {article_number}: {title}

Nội dung: {content}

Hãy tóm tắt điều luật này bằng 10–15 TỪ KHÓA TÌM KIẾM bao gồm:

1. CHỦ THỂ: ai là đối tượng áp dụng (công ty, cổ đông, thành viên...)
2. HÀNH ĐỘNG: động từ chính (thành lập, giải thể, họp, biểu quyết...)
3. ĐIỀU KIỆN: yêu cầu, tỷ lệ, thời hạn (51%, 30 ngày, đa số...)
4. TỪ ĐỒNG NGHĨA: từ người dùng hay hỏi liên quan đến điều này

Trả lời NGẮN GỌN, chỉ liệt kê các từ khóa cách nhau bằng dấu phẩy.

D.4 Bước 2: Chọn chương (Pha trực tuyến)

Bảng D.4 trình bày prompt được Tầng 1 sử dụng trong Bước 2 để chọn các chương phù hợp từ danh sách chương kèm mô tả (Mục 3.5.2). Nhiệt độ = 0,0 để đảm bảo kết quả xác định.

Bảng D.4: Prompt chọn chương (Bước 2)

Task: Chọn index chương phù hợp với câu hỏi. **KHÔNG** giải thích, **CHỈ** trả về JSON.

Chapters: {doc_overview}

(JSON: index, name, description cho mỗi chương)

Question: {query}

Rules:

- Chọn 1–{max_chapters} chương phù hợp nhất
- Trả lời **ĐÚNG** format JSON bên dưới
- **KHÔNG** hỏi lại, **KHÔNG** giải thích

Output: {"selected_indices": [0, 1], "confidence": 0.8}

D.5 Bước 3: Chọn điều khoản (Pha trực tuyến)

Bảng D.5 trình bày prompt được Tầng 1 sử dụng trong Bước 3 để chọn điều khoản cụ thể trong mỗi chương đã chọn. Ngoài tóm tắt, mỗi điều khoản còn được bổ sung `semantic_rank` và `dual_rank` (từ Tầng 2) giúp LLM đưa ra quyết định chính xác hơn.

D.6 Sinh câu trả lời theo phương pháp IRAC (Pha trực tuyến)

Prompt này được sử dụng ở bước cuối cùng để sinh câu trả lời cho người dùng từ các điều khoản đã truy xuất. Hệ thống áp dụng phương pháp phân tích pháp lý IRAC (Issue – Rule – Application – Conclusion) với hai biến thể tùy theo lĩnh vực: lĩnh vực pháp luật (Bảng D.6) và lĩnh vực đào tạo (Bảng D.7).

D.6. Sinh câu trả lời theo phương pháp IRAC (Pha trực tuyến)

Bảng D.5: Prompt chọn điều khoản (Bước 3)

Task: Chọn index điều luật phù hợp. KHÔNG giải thích, CHỈ JSON.

Chapter: {chapter_name}

Articles: {article_infos}

(JSON: index, name, title, keywords, semantic_rank, dual_rank)

Question: {query}

Rules:

- Chọn 1–{max_articles} điều trả lời câu hỏi
- Ưu tiên điều có semantic_rank và dual_rank thấp (1 = phù hợp nhất). Nếu 2 điều có nội dung tương đương, chọn điều có rank thấp hơn
- KHÔNG hỏi lại, KHÔNG giải thích

Output: {"selected_indices": [0, 1], "confidence": 0.8}

Bảng D.6: Prompt sinh câu trả lời IRAC – Lĩnh vực pháp luật

System: Bạn là luật sư tư vấn pháp luật Việt Nam. Trả lời câu hỏi theo phương pháp phân tích pháp lý IRAC.

CÂU HỎI: {query}

TÀI LIỆU THAM KHẢO: {context_text}

HƯỚNG DẪN TRẢ LỜI:

Viết câu trả lời tự nhiên như luật sư tư vấn, theo flow sau:

1. Xác định vấn đề pháp lý cần giải quyết trong câu hỏi.
2. Nêu căn cứ pháp luật: trích dẫn chính xác Điều, Khoản, Điểm của văn bản pháp luật liên quan. Format: “Căn cứ Điều X Khoản Y [Tên văn bản]”.
3. Phân tích áp dụng: giải thích cụ thể điều luật áp dụng vào tình huống trong câu hỏi như thế nào, chỉ ra mối liên hệ giữa quy định và tình huống thực tế.
4. Kết luận dứt khoát, trả lời trực tiếp câu hỏi.

QUY TẮC:

- KHÔNG nhắc “tài liệu tham khảo” hay “tài liệu được cung cấp”.
 - Cuối câu trả lời ghi “Căn cứ pháp lý:” liệt kê các điều đã dùng.
 - CHỈ nói “Xin lỗi, tôi không tìm thấy quy định pháp luật liên quan” khi KHÔNG CÓ BẤT KỲ điều luật nào liên quan.
-

D.6. Sinh câu trả lời theo phương pháp IRAC (Pha trực tuyến)

Bảng D.7: Prompt sinh câu trả lời IRAC – Lĩnh vực đào tạo

System: Bạn là chuyên viên tư vấn đào tạo sau đại học tại Trường Đại học Công nghệ Thông tin (UIT) – ĐHQG-HCM. Trả lời câu hỏi của học viên cao học theo phương pháp phân tích IRAC.

CÂU HỎI: {query}

TÀI LIỆU THAM KHẢO: {context_text}

HƯỚNG DẪN TRẢ LỜI:

Viết câu trả lời tự nhiên, thân thiện như chuyên viên tư vấn đào tạo, theo flow sau:

1. Xác định vấn đề cần giải đáp trong câu hỏi của học viên.
2. Nêu căn cứ quy chế: trích dẫn chính xác Điều, Khoản, Điểm của quy chế/quyết định liên quan. Format: “Căn cứ Điều X Khoản Y [Tên quyết định]”. Phân biệt rõ quy chế cấp ĐHQG-HCM (QĐ 1393) và quy chế cấp trường UIT (QĐ 270).
3. Phân tích áp dụng: giải thích cụ thể quy định áp dụng vào tình huống của học viên như thế nào, chỉ ra mối liên hệ giữa quy chế và tình huống thực tế.
4. Kết luận rõ ràng, trả lời trực tiếp câu hỏi. Nếu quy định khác nhau giữa cấp ĐHQG và cấp trường, ưu tiên quy định cấp trường (QĐ 270) vì áp dụng trực tiếp cho học viên UIT.

QUY TẮC:

- KHÔNG nhắc “tài liệu tham khảo” hay “tài liệu được cung cấp”.
 - Cuối câu trả lời ghi “Căn cứ quy chế:” liệt kê các điều đã dùng.
 - CHỈ nói “Xin lỗi, tôi không tìm thấy quy định liên quan” khi KHÔNG CÓ BẤT KỲ điều khoản nào liên quan.
 - Dùng “quy chế”, “quy định”, “quyết định” thay vì “luật”, “pháp luật”, “văn bản pháp luật”.
-

Tài liệu tham khảo

- [1] Akari Asai, Zeqiu Wu, Yizhong Wang, et al. “Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection”. In: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2024.
- [2] Ilias Chalkidis, Manos Fergadiotis, Prodromos Malakasiotis, et al. “LEGAL-BERT: The Muppets Straight out of Law School”. In: *Findings of the Association for Computational Linguistics: EMNLP 2020*. 2020, pp. 2898–2904.
- [3] Gordon V. Cormack, Charles L.A. Clarke, and Stefan Buettcher. “Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods”. In: *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR)*. 2009, pp. 758–759.
- [4] Jacob Devlin et al. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. 2019, pp. 4171–4186.
- [5] Nhon V. Do, Hien D. Nguyen, and Ali Selamat. “Knowledge-Based Model of Expert Systems Using Rela-Model”. In: *International Journal of Software Engineering and Knowledge Engineering* 28.8 (2018), pp. 1047–1090.
- [6] Darren Edge, Ha Trinh, Newman Cheng, et al. *From Local to Global: A Graph RAG Approach to Query-Focused Summarization*. Tech. rep. Microsoft Research, 2024.
- [7] Wenqi Fan, Yajuan Ding, Liangbo Ning, et al. “A Survey on RAG Meeting LLMs: Towards Retrieval-Augmented Large Language Models”. In: *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)*. 2024, pp. 6491–6501.

- [8] Luyu Gao et al. “Precise Zero-Shot Dense Retrieval without Relevance Labels”. In: *Proc. 61st Annual Meeting of the Association for Computational Linguistics (ACL)*. 2023, pp. 1762–1777.
- [9] David F. Gleich. “PageRank Beyond the Web”. In: *SIAM Review* 57.3 (2015), pp. 321–363.
- [10] Zirui Guo et al. “LightRAG: Simple and Fast Retrieval-Augmented Generation”. In: *Findings of the Association for Computational Linguistics: EMNLP 2025*. 2025, pp. 10746–10761.
- [11] Taher H. Haveliwala. “Topic-Sensitive PageRank”. In: *Proceedings of the 11th International Conference on World Wide Web (WWW)*. 2002, pp. 517–526.
- [12] Xanh Ho et al. “Constructing a Multi-Hop QA Dataset for Comprehensive Evaluation of Reasoning Steps”. In: *Proceedings of the 28th International Conference on Computational Linguistics (COLING)*. 2020, pp. 6609–6625.
- [13] Glen Jeh and Jennifer Widom. “Scaling Personalized Web Search”. In: *Proceedings of the 12th International Conference on World Wide Web (WWW)*. ACM, 2003, pp. 271–279.
- [14] Vladimir Karpukhin, Barlas Oğuz, Sewon Min, et al. “Dense Passage Retrieval for Open-Domain Question Answering”. In: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2020, pp. 6769–6781.
- [15] Jinqi Lai, Wensheng Gan, Jiayang Wu, et al. “Large Language Models in Law: A Survey”. In: *AI Open* 5 (2024), pp. 181–196.
- [16] Hong Hien Le et al. “A Three-Tier Knowledge Graph RAG for Vietnamese Legal Question Answering”. In: *SOMET 2026 (under review)* (2026).
- [17] Patrick Lewis, Ethan Perez, Aleksandra Piktus, et al. “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”. In: *Advances in Neural Information Processing Systems 33 (NeurIPS)*. 2020, pp. 9459–9474.
- [18] Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schütze. *Introduction to Information Retrieval*. Cambridge University Press, 2008.
- [19] Costas Mavromatis and George Karypis. “GNN-RAG: Graph Neural Retrieval for Large Language Model Reasoning”. In: *arXiv preprint arXiv:2405.20139* (2024).

- [20] Hung Ngo, Hien Nguyen, and Nhlen-An Le-Khac. “Ontology Knowledge Map Approach Towards Building Linked Data for Vietnamese Legal Applications”. In: *Vietnam Journal of Computer Science* 11.02 (2024), pp. 323–342.
- [21] Quang Huy Ngo et al. “AimeLaw at ALQAC 2021: Enriching Neural Network Models with Legal-Domain Knowledge”. In: *Proceedings of the 13th International Conference on Knowledge and Systems Engineering (KSE)*. IEEE, 2021.
- [22] Dat Quoc Nguyen and Anh Tuan Nguyen. “PhoBERT: Pre-trained Language Models for Vietnamese”. In: *Findings of the Association for Computational Linguistics: EMNLP 2020*. 2020, pp. 1037–1042.
- [23] Hien Nguyen, Vuong Pham, Hung Ngo, et al. “Intelligent Search System for Resume and Labor Law”. In: *PeerJ Computer Science* 10 (2024), e1786.
- [24] T Nguyen, H Nguyen, V Pham, et al. “Legal-Onto: An Ontology-based Model for Representing the Knowledge of a Legal Document”. In: *Proc. 17th International Conference on Evaluation of Novel Approaches to Software Engineering (ENASE 2022)*. 2022, pp. 426–434.
- [25] Rodrigo Nogueira et al. “Document Ranking with a Pretrained Sequence-to-Sequence Model”. In: *Findings of the Association for Computational Linguistics: EMNLP 2020* (2020).
- [26] V Pham, T Ngo, B Nguyen, et al. “Enhancing Legal Research Through Knowledge-Infused Information Retrieval for Vietnamese Labor Law”. In: *IAES International Journal of Artificial Intelligence* 13.4 (2024), pp. 3962–3973.
- [27] V. Pham, D Dang, Hung Ngo, et al. “Ontology-Based Knowledge Graph Approach for Legal Queries”. In: *Informatica* 37.1 (2026), pp. 159–192.
- [28] Nils Reimers and Iryna Gurevych. “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks”. In: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2019, pp. 3982–3992.
- [29] Stephen Robertson and Hugo Zaragoza. “The Probabilistic Relevance Framework: BM25 and Beyond”. In: *Foundations and Trends in Information Retrieval* 3.4 (2009), pp. 333–389.

- [30] Parth Sarthi, Salman Abdullah, Aditi Tuli, et al. “RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval”. In: *International Conference on Learning Representations (ICLR)*. 2024.
- [31] Giovanni Sartor et al. *Approaches to Legal Ontologies: Theories, Domains, Methodologies*. Dordrecht: Springer, 2011.
- [32] Thanh Vu et al. “VnCoreNLP: A Vietnamese Natural Language Processing Toolkit”. In: *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Demonstrations (NAACL)*. 2018, pp. 56–60.
- [33] Mingtian Zhang and Yu Tang. *PageIndex: Next-Generation Vectorless, Reasoning-based RAG*. <https://pageindex.ai/blog/pageindex-intro>. Accessed: 2026-05-01. 2025.
- [34] Haoxi Zhong, Chaojun Xiao, Cunchao Tu, et al. “How Does NLP Benefit Legal System: A Summary of Legal Artificial Intelligence”. In: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*. 2020, pp. 5218–5230.
- [35] Yutao Zhu, Huaying Yuan, Shuting Wang, et al. “Large Language Models for Information Retrieval: A Survey”. In: *ACM Transactions on Information Systems* (2024). DOI: [10.1145/3748304](https://doi.org/10.1145/3748304).

A Three-Tier Knowledge Graph RAG for Vietnamese Legal Question Answering

Hong Hien LE ^{a,1}, Dinh Hien NGUYEN ^a, Quoc Hung NGO ^b and Viet Dung DANG ^a

^a*Faculty of Computer Science, University of Information Technology, Vietnam National University Ho Chi Minh City, Vietnam*

^b*School of Computer Science, University College Dublin, Ireland*

Abstract. Accurate legal question answering demands navigating hierarchical document structures, following cross-references, and multi-hop reasoning, capabilities that standard Retrieval-Augmented Generation (RAG) systems lack. Vietnamese legal text compounds this challenge through tonal ambiguity, domain-specific abbreviations, and rigid structural hierarchies. This paper presents a three-tier knowledge graph RAG architecture that integrates a domain ontology, a knowledge graph, and a document tree forest. Three retrieval tiers, LLM-guided tree traversal, dual-level semantic search with intent-aware Personalized PageRank, and Reciprocal Rank Fusion with knowledge graph expansion, operate over these representations. Evaluation on 530 expert-annotated questions across enterprise law, traffic safety law, and postgraduate education regulation shows that the proposed system retrieves at least one correct article in the top 10 results for 92.2% of queries, outperforming the strongest baseline by 7.4%. These results hold across all three domains without domain-specific tuning. To the best of the authors' knowledge, no prior work combines ontology-enhanced knowledge graphs with multi-tier retrieval for Vietnamese legal question answering.

Keywords. Knowledge Graph, Legal Question Answering, Retrieval Augmented Generation, Ontology, Vietnamese NLP, Multi-Tier Retrieval, Multi-Domain

1. Introduction

Accurate access to legal information is critical for citizens, businesses, and legal practitioners navigating regulatory compliance. Legal forums and social networks in Vietnam are flooded with questions on business formation, traffic penalties, and regulatory compliance, yet answers are often fragmented, contradictory, or cite repealed provisions.

Legal documents exhibit complex hierarchical structures: a single law organizes content into parts, chapters, sections, articles, clauses, and points, where each level carries distinct legal scope. They also contain pervasive cross-references: answering “If a member borrows money to meet charter capital and later withdraws it, what are the penalties?” requires chaining Article 47 (member obligations) to Article 16, Clause 5 (prohibited acts) across different chapters. Vietnamese compounds this challenge through tonal

¹Corresponding Author: Le Hong Hien, Faculty of Computer Science, University of Information Technology, Vietnam National University Ho Chi Minh City, Vietnam; E-mail: hienlh.16@grad.uit.edu.vn.

ambiguity, domain-specific abbreviations (*HDQT*, *CTCP*), and a rigid legal hierarchy (Constitution, Codes, Decrees, Circulars).

Standard RAG [1] retrieves by vector similarity [2], an approach effective in many domains [3] but inadequate for legal text: embeddings blur precise legal meanings (semantic gap), flat retrieval ignores document hierarchy (no structural awareness), and dense search cannot chain cross-references (no multi-hop reasoning). LightRAG [4] and GraphRAG [5] model entity relationships but disregard document hierarchy; RAPTOR [6] builds summary trees via recursive clustering but relies on embedding-only retrieval; PageIndex [7] exploits structure but lacks semantic reasoning; legal ontology systems [8,9] formalize domain knowledge but remain disconnected from retrieval pipelines. To address these limitations, a three-tier knowledge graph RAG is proposed that unifies structural navigation, semantic retrieval, and rank fusion: Tier 1 performs LLM-guided tree traversal, Tier 2 applies dual-level semantic retrieval with intent-aware Personalized PageRank, and Tier 3 merges outputs through Reciprocal Rank Fusion with knowledge graph expansion.

This paper makes three contributions. First, a data engineering pipeline is developed that parses Vietnamese legal documents into hierarchical trees, constructs a domain ontology, and builds a knowledge graph through semi-automatic LLM extraction with expert refinement. Second, a three-tier RAG architecture is designed that unifies structural tree traversal, semantic graph retrieval, and reciprocal rank fusion into a single pipeline. Third, a multi-intent Personalized PageRank algorithm is introduced that adapts edge weights to detected query intent, allowing the graph to emphasize different relation types for penalty, procedural, or definitional questions. Experiments on 530 questions across three domains show that the system reaches 92.2% top-10 hit rate on legal QA, surpassing PageIndex by 7.4% and RAPTOR by 51.2%, and 88.5% on education regulation, exceeding PageIndex by 13.9%.

2. Related Work

From lexical to neural retrieval. Early legal retrieval relied on lexical matching: BM25 [10] and TF-IDF [11] score documents by term overlap but fail when users paraphrase legal concepts. Dense retrieval shifted to learned representations with Sentence-BERT [2] and DPR [12]; subsequent work added self-reflection [13] and hypothetical document generation [14] (surveyed by Fan et al. [3]). Domain-adapted models such as LEGAL-BERT [15] capture legal phrasing yet still operate on flat passages. For Vietnamese, PhoBERT [16] and VnCoreNLP [17] provide foundational models, and Ngo et al. [18] combined BM25 with BERT [19] for the ALQAC 2021 competition. A shared limitation persists across these approaches: treating documents as flat collections discards the hierarchical structure critical for legal text.

Knowledge-enhanced retrieval. To recover structural and relational information, researchers turned to knowledge representations. Legal-Onto [8] combines the Relamodel [20] with conceptual graphs for Vietnamese Land Law but relies on manual rules that do not scale. GraphRAG [5] partitions entity graphs into communities with LLM summaries, and LightRAG [4] combines vector search with graph traversal. Both enable multi-hop reasoning yet treat documents as bags of entities without preserving hierarchy; in our experiments, LightRAG’s entity extraction quality was low (74% of entities ap-

peared only once). RAG [1] grounds generation in retrieved evidence but remains bottlenecked by retrieval quality. Surveys [21,22] confirm that bridging legal knowledge with scalable retrieval remains open.

Structure-aware hierarchical retrieval. RAPTOR [6] builds summary trees via recursive clustering and LLM summarization, capturing multi-granularity themes; however, it discards original document hierarchy and relies on embedding-only retrieval at query time, achieving only 41.0% top-10 hit rate on our structured legal benchmark. PageIndex [7] takes a different approach by using LLM-guided tree traversal for hierarchical document search, achieving high precision when the model selects the correct branch but missing content outside the traversal path. Crucially, neither system integrates knowledge graphs for cross-document reasoning, leaving multi-hop queries that span different laws or decrees unresolved.

Positioning. No existing system combines ontological knowledge, graph-based retrieval, and structural tree navigation for Vietnamese legal text. Neural approaches achieve broad coverage but lack structure; symbolic systems enable reasoning but lack scalability; LLM-based systems provide language understanding but hallucinate without domain grounding. Our system integrates all three capabilities through a three-tier architecture with intent-aware reasoning and rank fusion.

3. Methodology

3.1. Problem Formulation

Vietnamese legal documents are subdivided into chapters, sections, articles, clauses, and points, each level nested within the one above, forming a six-level hierarchy. Articles within one document frequently cite articles in other documents, creating a web of cross-references that a reader must follow to obtain a complete answer. Vietnamese compounds this structural complexity with tonal ambiguity, domain-specific abbreviations (*TNHH*, *CTCP*), and synonymous legal phrasing that general-purpose embeddings fail to distinguish. Standard passage retrieval treats documents as flat collections and therefore cannot exploit hierarchy, follow cross-references, or perform the multi-hop reasoning that legal queries demand.

Each document can be modeled as a rooted tree whose nodes correspond to structural levels and whose edges represent parent-child containment; the full corpus of m documents forms a *document forest* $\mathbf{F} = \{T_1, \dots, T_m\}$ augmented with cross-reference edges linking articles across trees. Every node is assigned a composite identifier encoding its position in the hierarchy (e.g., 59-2020-QH14:c2 for Chapter 2, 59-2020-QH14:d5 for Article 5), enabling unambiguous cross-tree references. Given a user query q , the retrieval task is to return a ranked list of the k most relevant articles from $\mathbf{F}$. Article-level granularity is essential because Vietnamese legal practice requires citing specific articles as the minimal citable unit, not arbitrary text passages.

3.2. System Overview and Knowledge Construction

The architecture separates into an offline phase and an online phase (Figure 1). The offline phase builds three knowledge representations from the raw corpus, following

knowledge engineering practice [9]. Each document is first parsed into a rooted tree, forming a document forest with cross-reference edges linking articles across documents. A knowledge graph is then constructed via LLM extraction with expert-in-the-loop refinement. Finally, chapter-level and article-level summaries are generated for LLM-guided branch selection during retrieval. The online phase first analyzes the query (intent classification, abbreviation expansion, seed entity extraction), then processes it through three retrieval tiers: LLM-guided tree traversal (Tier 1), dual-level semantic retrieval over the knowledge graph (Tier 2), and fusion with knowledge graph expansion (Tier 3). Corpus statistics are reported in Table 1; implementation details in Section 4.1.




Figure 1. Architecture of the proposed three-tier retrieval system. Offline phase (left): knowledge model construction from legal documents. Online phase (right): query processing through Tier 1 (structural tree traversal), Tier 2 (dual-level semantic retrieval), and Tier 3 (RRF fusion with KG expansion).

3.3. Hybrid Retrieval Architecture

Query Analysis. Given a raw user query q , the query analyzer first classifies its intent into one of six types (Penalty, Definition, Procedure, Requirement, Reference, General) via Vietnamese regex with LLM fallback, then expands abbreviations (e.g., *TNHH* $\rightarrow$ *trach nhien huu han*) and extracts seed entities such as article references, law references, and legal keywords. These outputs feed directly into the retrieval tiers: Tier 1 uses the expanded query for tree navigation, while Tier 2 uses the seed entities to initialize PageRank and the intent label to adjust edge weights (1.0 for primary relations, 0.5 for others).

Tier 1: LLM-Guided Tree Traversal. Tier 1 takes the expanded query and the document forest, and returns a ranked list of candidate articles with structural scores. It navigates the forest using LLM reasoning in three progressive loops: Loop 0 selects the top 5 documents by matching the query to domain groups via pre-computed keywords; Loop 1 narrows to the top 8 chapters using chapter summaries; Loop 2 identifies the top 7 arti-

cles per chapter from article summaries. General Provisions chapters are automatically included. Each loop produces a reasoning trace for interpretability.

Tier 2: Dual-Level Semantic Retrieval. Tier 2 takes the seed entities and intent label from query analysis together with the knowledge graph, and returns a separate ranked list of articles with semantic scores. It operates at two granularities. The *low level* (entity-specific) computes four per-article signals. Keyphrase matching measures syllable n -gram overlap between query terms and KG entity names, aggregated per article as $\max + 0.3 \ln(n+1) \bar{s}$ over n matched entities. Semantic similarity computes query–article cosine distance from sentence embeddings. Intent-aware PPR is seeded from entities whose keyphrase score ≥ 0.3 . Concept matching propagates keyphrase hits to articles sharing the same ontology entity types, scoring by type-density. These are combined by weighted sum ($w_{kp}=0.05$, $w_{sem}=0.20$, $w_{ppr}=0.25$, $w_{con}=0.20$) and normalized to $[0, 1]$. The *high level* (conceptual) computes two signals. Theme matching embeds the query against pre-built theme clusters and maps source entities to articles. Hierarchy expansion then finds articles sharing entity types with theme matches (0.5 decay). The two levels are fused: $s(a)=0.70 \cdot s_{low}(a) + 0.15 \cdot s_{theme}(a) + 0.15 \cdot s_{hier}(a)$, summing to 1.0. Articles below threshold 0.1 are discarded. The PPR component computes query-specific node importance on the knowledge graph [23]:

$$PPR(v) = (1 - \alpha) \sum_{u \in N(v)} \frac{w(u,v) \cdot PPR(u)}{d(u)} + \alpha \cdot p(v) \quad (1)$$

where $\alpha = 0.15$ is the teleport probability, $w(u,v)$ is the edge weight adjusted by query intent, $d(u)$ is the weighted out-degree, and $p(v)$ is the personalization vector seeded from matched entities.

Tier 3: Semantic Bridge (RRF Fusion). Tier 3 produces the final top- k articles through three steps: knowledge graph expansion, rank fusion, and adjacent enrichment. First, seed articles from Tier 1 and Tier 2 are expanded through the knowledge graph’s relation edges. Strong relations (*references*, *requires*, *depends_on*) are traversed both cross-chapter (up to 5 articles) and same-chapter (up to 2 articles), with a semantic relevance filter (cosine similarity ≥ 0.4) to suppress noise. This produces a third ranked list alongside Tier 1 and Tier 2. The three lists are then merged using Reciprocal Rank Fusion [24]:

$$RRF(d) = \sum_{s \in \{T1, T2, KG\}} w_s \cdot \frac{1}{k + \text{rank}_s(d)} \quad (2)$$

where $k = 60$ and source weights $w_{T1} = 1.2$, $w_{T2} = 0.7$, $w_{KG} = 1.0$ are empirically set on a development set and shared across all domains. Tree traversal receives the highest weight as it provides the most reliable structural signal. Finally, adjacent articles (± 2) from each fused result are added with decaying scores, as correct answers often lie in neighboring articles. The final ranked list is passed to an LLM for answer generation.

4. Experiments

4.1. Data Collection and Implementation

Legal corpus. 18 Vietnamese legal and regulatory documents span three domains: enterprise law (Law 59/2020/QH14 and nine decrees, 77 chapters, 840 articles), traffic safety law (Law 36/2024/QH15 and two penalty decrees, 195 articles), and education regulation (five postgraduate documents, 109 articles). The corpus totals 949 articles across 77 chapters. Document types range from primary laws enacted by the National Assembly to implementing decrees and university regulations, reflecting the hierarchical nature of the Vietnamese legal system.

Evaluation questions. 530 questions were collected from Vietnamese Facebook legal advice groups (400 legal questions) and UIT student forums (130 education questions). Questions range from single-article lookups (“What is the minimum charter capital for a securities company?”) to multi-hop queries requiring cross-document reasoning. A domain expert labeled each question with 1–8 relevant articles (average 2.3).

Document parsing and summaries. The system is implemented in Python 3.11. Legal texts are parsed with custom regex parsers that detect Vietnamese hierarchy markers (“Chuong”, “Muc”, “Dieu”, “Khoan”, “Diem”) and build six-level trees. Scanned education PDFs (118 pages) are processed via LLM Vision OCR. Cross-references between documents are extracted via pattern matching on article citations (e.g., “Đi u 47 Luật Doanh nghiệp”), producing 168 cross-document edges. Chapter-level and article-level summaries are generated via Claude 3.5 Haiku², producing keyword-rich descriptions that Tier 1 uses for branch selection without reading full article text.

Knowledge graph construction. Entity extraction and relation identification use Claude 3.5 Haiku via the Anthropic API, with one LLM call per article. Vietnamese slug normalization removes diacritics and collapses tonal variations to produce canonical entity identifiers. A multi-step entity resolver (exact match, synonym resolution, abbreviation expansion) deduplicates equivalent entities across documents. The domain ontology defines 14 entity types (e.g., Action, Legal Term, Organization, Penalty, Condition) using OWL classes with a 4-level hierarchy and Vietnamese label mappings. The resulting knowledge graph contains 5,936 entities and 5,963 relations across 56 relation types. After automated extraction, an expert-in-the-loop refinement step corrects misidentified relations and adds domain-specific links that the LLM missed.

Online query processing. Tree traversal and article selection use Claude Sonnet 4 via the Anthropic API. Intent classification combines Vietnamese regex patterns for common query structures with LLM fallback for ambiguous cases. Sentence embeddings are computed with paraphrase-multilingual-MiniLM-L12-v2³ [2], a 384-dimensional multilingual model chosen for its strong cross-lingual transfer to Vietnamese. Vector similarity search uses FAISS⁴. Personalized PageRank is computed iteratively (max 50 iterations, tolerance 10^{-6} , damping $\alpha=0.15$). All LLM responses are cached in SQLite for reproducibility and cost efficiency.

²<https://www.anthropic.com/claude>

³<https://huggingface.co/sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2>

⁴<https://github.com/facebookresearch/faiss>

4.2. Experimental Setup

Table 1 summarizes the constructed knowledge graph.

Table 1. Knowledge graph statistics.

Entity Type	Count	Relation Type	Count	Structure	Count
Total Entities	5,936	Total Relations	5,963	Tree Nodes	9,226
Action	1,903	requires	1,377	Documents	13
Legal Term	1,632	applies_to	810	Chapters	77
Organization	500	has_authority	506	Articles	840
Legal Reference	451	references	434	Cross-refs	168
Other (9 types)	1,450	Other (52 types)	2,506		

Metrics. Since each query has expert-annotated relevant articles, we adopt standard retrieval metrics [11] that enable objective, reproducible evaluation against known ground truth, rather than LLM-as-judge scores used in open-ended generation benchmarks. Top- k hit rate $= \frac{1}{|Q|} \sum_q \mathbf{1}[\exists a \in R_q : \text{rank}(a) \leq k]$ measures the fraction of queries for which at least one relevant article appears in the top- k results, where R_q denotes the set of relevant articles for query q . Mean Reciprocal Rank is defined as $\text{MRR} = \frac{1}{|Q|} \sum_q (\min_{a \in R_q} \text{rank}(a))^{-1}$, averaging the reciprocal rank of the first relevant result. Recall@ k , Precision@ k , and NDCG@ k [11] are also computed. Results are reported at $k \in \{1, 3, 5, 10, 20, 30\}$, with top-10 hit rate and MRR as the primary metrics. Top-10 hit rate is prioritized because in a RAG pipeline the LLM provides an additional validation layer over retrieved context, at least one correct article among ten candidates suffices for accurate answer generation while limiting noise that could induce hallucination. MRR complements top-10 hit rate by rewarding higher placement of relevant articles, reducing irrelevant context that the LLM must filter.

Baselines. Traditional: BM25 [10] and TF-IDF [11] with syllable-level tokenization. RAG systems: NaiveRAG [2] (dense retrieval, no reranking); LightRAG [4] (hybrid KG retrieval); RAPTOR [6] (collapsed-tree with LLM summaries); PageIndex [7] (two-step hierarchical tree search). All systems use Sonnet 4 for LLM calls and retrieve from the full corpus.

4.3. Results

Over three independent runs, the proposed system achieves $92.2 \pm 0.3\%$ top-10 hit rate (MRR 0.603), outperforming PageIndex by 7.4% and BM25 by 44.7% (Table 2). PageIndex benefits from tree navigation but misses cross-reference articles outside the traversal path. RAG baselines (NaiveRAG 32.8%, LightRAG 39.8%, RAPTOR 41.0%) underperform BM25 (47.5%); general-purpose embeddings lack Vietnamese legal vocabulary, generic KG extraction introduces noise, and RAPTOR’s summaries lose article-level granularity. Our system overcomes these limitations via LLM-guided navigation and domain-specific knowledge graph.

Table 2. Legal domain hit rate (%) on 400 questions. Best in bold, second underlined.

Method	Top 5	Top 10	Top 20	Top 30	MRR
<i>Traditional retrieval</i>					
BM25	30.8	47.5	66.2	74.8	0.200
TF-IDF	29.2	45.8	64.5	74.8	0.207
Keyword	33.5	48.5	63.2	72.8	0.222
<i>RAG systems</i>					
NaiveRAG [2]	22.8	32.8	51.8	60.5	0.146
LightRAG [4]	25.5	39.8	47.8	49.2	0.173
RAPTOR [6]	25.2	41.0	54.5	62.3	0.170
PageIndex [7]	76.2	<u>84.8</u>	<u>90.2</u>	<u>91.0</u>	<u>0.559</u>
3-Tier (ours)	<u>74.5</u>	92.2	94.8	95.0	0.603

Table 3 reports per-domain results, including education as a generalization test. The system outperforms all baselines across all three domains. Traffic law achieves the highest score (98.0%) due to direct violation-to-penalty mappings. Enterprise law is harder (86.5%) due to cross-decree references. Education (88.5%) shows the largest margin over PageIndex (+13.9%), where semantic retrieval captures terminology that tree navigation misses. The same retrieval pipeline and hyperparameters were used across all three domains without per-domain weight tuning.

Table 3. Per-domain top-10 hit rate (%) across three domains.

Method	Enterprise (197)	Traffic (203)	Education (130)
NaiveRAG	29.9	35.5	50.0
LightRAG	20.3	58.6	53.1
RAPTOR	18.5	63.5	53.8
BM25	31.5	63.1	70.0
TF-IDF	39.1	52.2	68.5
Keyword	20.3	75.9	56.2
PageIndex	76.6	<u>92.6</u>	74.6
3-Tier (ours)	86.5	98.0	88.5
<i>Ours vs. PageIndex</i>	+9.9	+5.4	+13.9

4.4. Analysis

PageIndex achieves a higher top-5 hit rate (76.2% vs. 74.5%), a precision–coverage tradeoff inherent in rank fusion: KG expansion articles occasionally displace tree results from positions 4–5 to 6–7 but recover cross-reference content that PageIndex never reaches, yielding a 17.7 pp gain from positions 6–10 compared to only 8.6 pp for PageIndex. In a RAG pipeline where the LLM filters ten candidates, this tradeoff is favorable.

Per-category top-10 hit rate ranges from 0% (household business, 4 queries outside the corpus) to 100% (speed penalties). A multi-hop example: “If a member borrows money to meet charter capital and later withdraws it, what are the penalties?” Tier 1 reaches Art. 47 (member obligations); PPR walks *requires* edges to Art. 16 Cl. 5 (pro-

hibited acts) in a different chapter; RRF places both in the top 5. No baseline retrieves this at top 30. Of the 31 missed queries (7.8%), 27 involve enterprise law: cross-decree dependencies (6), out-of-corpus articles (4), and multi-article queries requiring >2 articles (14), mostly linked by implicit legal reasoning chains rather than explicit cross-references.

5. Conclusion

This paper presented a three-tier knowledge graph RAG architecture for Vietnamese legal question answering that unifies structural tree traversal, semantic graph search with intent-aware Personalized PageRank, and Reciprocal Rank Fusion. On 400 legal questions, the system achieves 92.2% top-10 hit rate, outperforming PageIndex by 7.4 pp and RAPTOR by 51.2 pp. On 130 education regulation questions, it reaches 88.5%, exceeding PageIndex by 13.9 pp. These results hold across all three domains using the same pipeline and hyperparameters without per-domain tuning, demonstrating the generalizability of the approach.

Current limitations include Tier 1 latency (around 7 s per query due to multiple LLM calls) and lower performance on enterprise queries requiring implicit multi-document reasoning chains. Future work will address these limitations by investigating parallel LLM calls and model distillation to reduce latency, and by incorporating automated legal reasoning chain discovery to capture implicit cross-document dependencies that the current knowledge graph cannot represent. Beyond these, we plan to extend the system to additional regulatory domains such as tax and labor law, and to support multi-turn conversational queries.

Acknowledgments

This research is funded by University of Information Technology, Vietnam National University Ho Chi Minh City, Vietnam.

References

- [1] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems 33 (NeurIPS)*, pages 9459–9474, 2020.
- [2] Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 3982–3992, 2019.
- [3] Wenqi Fan, Yajuan Ding, Liangbo Ning, Shijie Wang, Hengyun Li, Dawei Yin, Tat-Seng Chua, and Qing Li. A survey on RAG meeting LLMs: Towards retrieval-augmented large language models. In *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)*, pages 6491–6501, 2024.
- [4] Zirui Guo et al. LightRAG: Simple and fast retrieval-augmented generation. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2025.
- [5] Darren Edge, Ha Trinh, Newman Cheng, Joshua Bradley, Alex Chao, Apurva Mody, Steven Truitt, and Jonathan Larson. From local to global: A graph RAG approach to query-focused summarization. Technical report, Microsoft Research, 2024.

- [6] Parth Sarthi, Salman Abdullah, Aditi Tuli, Shubh Khanna, Anna Goldie, and Christopher D. Manning. RAPTOR: Recursive abstractive processing for tree-organized retrieval. In *International Conference on Learning Representations (ICLR)*, 2024.
- [7] Mingtian Zhang, Yu Tang, and PageIndex Team. PageIndex: Next-generation vectorless, reasoning-based RAG. *PageIndex Blog*, September 2025. <https://pageindex.ai/blog/pageindex-intro>.
- [8] Thi Thanh Sang Nguyen, Hoang Dung Nguyen, Van Dung Pham, Duc Thin Tran, and Ali Selamat. Legal-onto: An ontology-based model for representing the knowledge of a legal document. In *Proceedings of the 17th International Conference on Evaluation of Novel Approaches to Software Engineering (ENASE)*, pages 426–434, 2022.
- [9] Giovanni Sartor et al. *Approaches to Legal Ontologies: Theories, Domains, Methodologies*. Springer, Dordrecht, 2011.
- [10] Stephen Robertson and Hugo Zaragoza. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009.
- [11] Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schütze. *Introduction to Information Retrieval*. Cambridge University Press, 2008.
- [12] Vladimir Karpukhin, Barlas Oğuz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, and Wen-tau Yih. Dense passage retrieval for open-domain question answering. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 6769–6781, 2020.
- [13] Akari Asai, Zeqiu Wu, Yizhong Wang, Avirup Sil, and Hannaneh Hajishirzi. Self-RAG: Learning to retrieve, generate, and critique through self-reflection. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2024.
- [14] Luyu Gao, Xueguang Ma, Jimmy Lin, and Jamie Callan. Precise zero-shot dense retrieval without relevance labels. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 1762–1777, 2023.
- [15] Ilias Chalkidis, Manos Fergadiotis, Prodromos Malakasiotis, Nikolaos Aletras, and Ion Androutsopoulos. LEGAL-BERT: The muppets straight out of law school. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 2898–2904, 2020.
- [16] Dat Quoc Nguyen and Anh Tuan Nguyen. PhoBERT: Pre-trained language models for Vietnamese. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 1037–1042, 2020.
- [17] Thanh Vu, Dat Quoc Nguyen, Dai Quoc Nguyen, Mark Dras, and Mark Johnson. VnCoreNLP: A Vietnamese natural language processing toolkit. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Demonstrations (NAACL)*, pages 56–60, 2018.
- [18] Hung Ngo, Thi Nguyen, Dung Nguyen, and Minh Pham. AimeLaw at ALQAC 2021: Enriching neural network models with legal-domain knowledge. In *Proceedings of the 13th International Conference on Knowledge and Systems Engineering (KSE)*. IEEE, 2021.
- [19] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*, pages 4171–4186, 2019.
- [20] Nhon V. Do, Hoang Dung Nguyen, and Ali Selamat. Knowledge-based model of expert systems using rela-model. *International Journal of Software Engineering and Knowledge Engineering*, 28(8):1047–1090, 2018.
- [21] Haoxi Zhong, Chaojun Xiao, Cunchao Tu, Tianyang Zhang, Zhiyuan Liu, and Maosong Sun. How does NLP benefit legal system: A summary of legal artificial intelligence. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 5218–5230, 2020.
- [22] Jinqi Lai, Wensheng Gan, Jiayang Wu, Zhenlian Qi, and Philip S. Yu. Large language models in law: A survey. *AI Open*, 5:181–196, 2024.
- [23] Taher H. Haveliwala. Topic-sensitive PageRank. In *Proceedings of the 11th International Conference on World Wide Web (WWW)*, pages 517–526, 2002.
- [24] Gordon V. Cormack, Charles L.A. Clarke, and Stefan Buettcher. Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR)*, pages 758–759, 2009.

ĐẠI HỌC QUỐC GIA TP HCM
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
~★~



LÊ HỒNG HIỂN
MSHV: 210101006

**TÊN ĐỀ TÀI: GIẢI PHÁP KẾT HỢP ONTOLOGY VÀ MÔ HÌNH
NGÔN NGỮ LỚN ĐỂ THIẾT KẾ HỆ THỐNG TƯ VẤN KIẾN THỨC
VỀ QUY ĐỊNH ĐÀO TẠO SAU ĐẠI HỌC**

ĐỀ CƯƠNG LUẬN VĂN THẠC SĨ
NGÀNH KHOA HỌC MÁY TÍNH

Mã số: 8480101

NGƯỜI HƯỚNG DẪN KHOA HỌC:
PGS.TS NGUYỄN ĐÌNH HIỂN
TS. NGÔ QUỐC HƯNG

TP HỒ CHÍ MINH - NĂM 2025

THÔNG TIN ĐĂNG KÝ ĐỀ TÀI LUẬN VĂN THẠC SĨ

1. Tên đề tài (ghi IN HOA):

- Tên tiếng Việt: GIẢI PHÁP KẾT HỢP ONTOLOGY VÀ MÔ HÌNH NGÔN NGỮ LỚN ĐỂ THIẾT KẾ HỆ THỐNG TƯ VẤN KIẾN THỨC VỀ QUY ĐỊNH ĐÀO TẠO SAU ĐẠI HỌC
- Tên tiếng Anh: INTEGRATING ONTOLOGY AND LARGE LANGUAGE MODELS TO DESIGN AN ADVISORY SYSTEM FOR POSTGRADUATE EDUCATION REGULATIONS
- Hướng đề tài luận văn: **Định hướng nghiên cứu** ✓
- Số tín chỉ: 18

2. Ngành học và Mã ngành:

- Khoa học máy tính: 8480101 ✓

3. Cán bộ hướng dẫn:

• Cán bộ hướng dẫn 1:

- Họ tên: PGS.TS Nguyễn Đình Hiến
- Email: hiennd@uit.edu.vn
- Điện thoại: 0918735299
- Đơn vị công tác: Trường Đại học Công nghệ thông tin, ĐHQG-HCM

• Cán bộ hướng dẫn 2:

- Họ tên: TS. Ngô Quốc Hưng
- Email: hung.ngo@ucd.ie
- Đơn vị công tác: University College Dublin

4. Thời gian thực hiện: 6 tháng. Từ tháng 9/2025.

5. Học viên thực hiện:

- Họ tên: Lê Hồng Hiến
- Mã số: 210101006 Khóa: 16 Đợt: 1
- Email: hienlh.16@grad.uit.edu.vn Điện thoại: 0971963707

XÁC NHẬN CỦA CBHD
(Ký tên và ghi rõ họ tên)

TP. HCM, ngày 28 tháng 6 năm 2025

HỌC VIÊN
(Ký tên và ghi rõ họ tên)

Nguyễn Đình Hiến

Lê Hồng Hiến

ĐỀ CƯƠNG ĐỀ TÀI LUẬN VĂN THẠC SĨ

I Nội dung

1 Giới thiệu đề tài

Tại các trường đại học ở Việt Nam, nhiều phòng ban chức năng đã được thành lập để hỗ trợ sinh viên trong học tập, rèn luyện và giải quyết các thủ tục hành chính. Tuy nhiên, do thông tin bị phân tán giữa nhiều phòng ban và các quy định thường khó hiểu, sinh viên gặp nhiều trở ngại trong việc tra cứu, tiếp cận và nắm bắt đầy đủ các quy định đào tạo, nhất là đối với những quy chế mới hoặc có tính chất phức tạp. Sinh viên thường phải liên hệ với nhiều nơi khác nhau cho từng vấn đề, dẫn đến mất thời gian, chờ đợi kéo dài và đôi khi không nhận được thông tin chính xác, kịp thời. Ngoài ra, các nhu cầu tư vấn về học tập, tâm lý, nghiên cứu khoa học, lựa chọn ngành nghề, điều kiện sống cũng ngày càng đa dạng, trong khi nguồn lực cán bộ tư vấn còn hạn chế. Việc giải thích các quy định đào tạo phức tạp thường đòi hỏi sự tương tác trực tiếp, gây áp lực lớn cho đội ngũ cán bộ và không đáp ứng được nhu cầu hỗ trợ 24/7. Do đó, việc xây dựng một hệ thống tư vấn tự động, thông minh, đóng vai trò là điểm kết nối duy nhất để tổng hợp và cung cấp thông tin một cách liền mạch sẽ giúp giảm tải cho cán bộ, tiết kiệm chi phí vận hành, đồng thời nâng cao trải nghiệm và sự hài lòng của sinh viên.

Trong bối cảnh đó, việc ứng dụng trí tuệ nhân tạo (AI) vào các hệ thống tư vấn tự động mang lại nhiều tiềm năng đột phá. AI có thể giúp tự động hóa việc trả lời các câu hỏi thường gặp, phân tích và tổng hợp thông tin từ nhiều nguồn, đồng thời cung cấp hỗ trợ liên tục 24/7 với độ chính xác và cá nhân hóa cao. Nhờ đó, sinh viên có thể dễ dàng tiếp cận thông tin về quy định đào tạo cũng như các vấn đề khác một cách nhanh chóng, thuận tiện, góp phần hỗ trợ cho sinh viên một cách toàn diện và hiện đại.

Chính phủ và các cơ sở giáo dục đại học tại Việt Nam cũng đang ngày càng nhận thức rõ tiềm năng to lớn của AI trong việc nâng cao chất lượng giáo dục, dù vẫn còn những thách thức nhất định trong quá trình triển khai. Để cho thấy tầm quan trọng của AI trong giáo dục đại học tại Việt Nam, bài viết của Nguyen và Hoang (2024) [1] trên Tạp chí Công Thương đã chỉ ra nhiều thách thức và cơ hội trong việc ứng dụng AI vào các hệ thống tư vấn tự động.

Gần đây, nhiều trường đại học tại Việt Nam đã tiên phong ứng dụng trí tuệ nhân tạo vào các hệ thống hỗ trợ sinh viên, mang lại những trải nghiệm hiện đại và tiện ích vượt trội. Đơn cử, trường Đại học Kinh tế Quốc dân (UEB) đã triển khai Chatbot UEB¹ dựa trên nền tảng ChatGPT, giúp sinh viên dễ dàng tra cứu thông tin và giải đáp thắc mắc mọi lúc, mọi nơi. Đại học Kinh tế Thành phố Hồ Chí Minh (UEH) cũng không nằm ngoài xu hướng khi ra mắt Trợ lý ảo UEH AI Chatbot², hỗ trợ tư vấn tuyển sinh, hướng nghiệp. Bên cạnh đó, Trường Đại học Tài nguyên và Môi trường Hà Nội (HUNRE) đã phát triển HUNRE AI Chatbot³, góp phần nâng cao chất lượng phục vụ sinh viên và tối ưu hóa quy trình quản lý đào tạo. Những mô hình này cho thấy tiềm năng to lớn của AI trong việc đổi mới hoạt động tư vấn, hỗ trợ sinh viên tại các cơ sở giáo dục đại học ở Việt Nam.

¹Chatbot UEB: <https://ueb.edu.vn/Tin-Tuc/UEB/chatbot-ho-tro-sinh-vien-24-7-%E2%80%93giai-phap-tu-van-nhanh-chong-hieu-qua/43253>

²UEH AI Chatbot: <https://tuyensinh.ueh.edu.vn/bai-viet/ra-mat-tro-ly-ao-ueh-ai-chatbot-ung-dung-tri-tue-nhan-cao-tu-van-tuyen-sinh-huong-nghiep-danh-cho-phu-huynh-hoc-sinh/>

³HUNRE AI Chatbot: <https://hunre.edu.vn/hunre-ai-tro-ly-ao-thong-minh-dong-hanh-cung-sinh-vien-va-thi-sinh.html>

Các ứng dụng chatbot này chủ yếu dựa trên nền tảng các mô hình ngôn ngữ lớn (LLM), đã được triển khai rộng rãi và bước đầu mang lại nhiều tiện ích cho sinh viên trong thực tế. Tuy nhiên, hiện vẫn còn thiếu các nghiên cứu đánh giá định lượng về mức độ chính xác và hiệu quả thực sự của các hệ thống này khi áp dụng vào việc giải đáp các quy định đào tạo cụ thể. Bên cạnh đó, các LLM hiện nay vẫn gặp nhiều hạn chế trong việc xử lý các câu hỏi phức tạp đòi hỏi suy luận logic sâu. Đặc biệt, hiện tượng "ảo giác" (hallucination) - khi mô hình tạo ra câu trả lời không chính xác hoặc không sát với thực tế - vẫn là một rào cản lớn, có thể dẫn đến việc cung cấp thông tin sai lệch dẫn tới hậu quả nghiêm trọng đối với sinh viên.

Các nghiên cứu gần đây như của Zhu và cộng sự (2025) [4] hay Xu và cộng sự (2024) [5] đã chỉ ra rằng việc kết hợp Knowledge Graph với mô hình RAG [7] vào mô hình ngôn ngữ lớn LLM có thể cải thiện đáng kể độ chính xác trong câu trả lời và khả năng suy luận, cung cấp dẫn chứng cho câu trả lời. Knowledge Graph biểu diễn tri thức dưới dạng cấu trúc đồ thị có quan hệ, cho phép truy xuất thông tin một cách có hệ thống và hiệu quả, từ đó cung cấp ngữ cảnh chính xác và tri thức có cấu trúc cho LLM, giúp giảm thiểu đáng kể hiện tượng "ảo giác" trong quá trình sinh câu trả lời. Tuy nhiên, đây chính là khoảng trống nghiên cứu mà đề tài này nhắm đến: Mặc dù ý tưởng kết hợp RAG và KG mang lại nhiều hứa hẹn, nhưng các nghiên cứu hiện tại vẫn còn mang tính tổng quát và chưa có một công trình hoàn chỉnh nào xây dựng một ontology chuyên biệt cùng với quy trình rút trích tri thức tự động để tạo ra đồ thị tri thức cho lĩnh vực đặc thù là các quy định đào tạo của các trường đại học tại Việt Nam. Việc thiết kế và xây dựng một ontology như vậy cho lĩnh vực đào tạo của các trường đại học tại Việt Nam là một thách thức nghiên cứu quan trọng chưa được giải quyết một cách toàn diện.

Trong luận văn này, chúng tôi đề xuất một kiến trúc nhằm tăng cường khả năng của mô hình LLM trong việc xử lý các câu hỏi phức tạp, đòi hỏi suy luận logic phức tạp, độ chính xác cao và giảm hiện tượng ảo giác. Đề tài tập trung nghiên cứu phương pháp xây dựng một Ontology [3] tối ưu, đóng vai trò làm nền tảng (Schema) cho đồ thị tri thức (Knowledge Graph) về các quy định đào tạo, nhằm đảm bảo khả năng biểu diễn linh hoạt, chính xác, khả năng suy luận và dễ mở rộng cho hệ thống. Trên cơ sở đó, chúng tôi phát triển một chatbot dựa trên Knowledge Graph, kết hợp cùng sức mạnh của các mô hình ngôn ngữ lớn (LLM) và kỹ thuật RAG (Retrieval-Augmented Generation) [7]. Hệ thống này giúp LLM tự động truy xuất thông tin từ Knowledge Graph thông qua cơ chế RAG, từ đó phân tích và đưa ra câu trả lời chính xác, đáng tin cậy cho các câu hỏi của sinh viên.

Để làm nổi bật tính hiệu quả và khả năng ứng dụng thực tiễn của hệ thống, chúng tôi sẽ tiến hành đánh giá trên bộ dữ liệu thực tế lấy từ trường Đại học Công nghệ Thông tin, với phạm vi nghiên cứu tập trung vào các quy định về đào tạo trình độ Thạc sĩ. Cụ thể, hệ thống sẽ được kiểm thử với các bộ quy chế, quy định đào tạo thạc sĩ bao gồm:

- Quy chế đào tạo trình độ thạc sĩ của trường Đại học Công nghệ Thông tin (UIT) số 270/QĐ-ĐHCNTT ngày 25/04/2022.
- Quy chế đào tạo trình độ thạc sĩ cho khoá 2021 số 160/QĐ- ĐHQG, ngày 24/03/2017 của Đại học Quốc gia Thành phố Hồ Chí Minh (ĐHQG-HCM) - cơ quan chủ quản của UIT.
- Quy chế đào tạo trình độ thạc sĩ cho khoá từ năm 2022 trở về sau số 1393/QĐ-ĐHQG ngày 03/11/2021 của ĐHQG-HCM.
- Quy chế sửa đổi bổ sung 218/QĐ-ĐHQG, ngày 15/03/2024 về Quy định Giáo viên hướng dẫn của ĐHQG-HCM.
- Quy định về liên chính học thuật áp dụng cho học viên cao học số 851/QĐ-ĐHCNTT

ngày 14/08/2024 của UIT, nhằm chứng minh khả năng xử lý linh hoạt, chính xác các tình huống thực tế mà học viên cao học thường gặp phải trong quá trình học tập, nghiên cứu và thực hiện luận văn thạc sĩ.

Việc giới hạn phạm vi nghiên cứu vào các quy định đào tạo thạc sĩ sẽ cho phép chúng tôi tập trung xây dựng một ontology chuyên sâu và chi tiết, đồng thời đảm bảo độ chính xác cao trong việc xử lý các câu hỏi phức tạp liên quan đến quy trình đào tạo, điều kiện tốt nghiệp, yêu cầu luận văn, và các vấn đề về liên chính học thuật mà học viên cao học thường quan tâm. Ngoài ra, chúng tôi cũng sẽ thu thập các câu hỏi phức tạp và đòi hỏi suy luận sâu từ học viên cao học để đánh giá khả năng xử lý của hệ thống trong việc giải đáp các thắc mắc về quy định đào tạo thạc sĩ một cách toàn diện và chính xác.

2 Mục tiêu của đề tài

Trong luận văn này, chúng tôi sẽ nghiên cứu và giải quyết các vấn đề sau:

- Xây dựng Ontology và Knowledge Graph (KG) về các quy định đào tạo, làm nền tảng cho hệ thống tư vấn tự động. Ontology sẽ xác định các thực thể, thuộc tính và mối quan hệ quan trọng trong lĩnh vực đào tạo, đảm bảo khả năng biểu diễn linh hoạt và hỗ trợ suy luận logic. Knowledge Graph được xây dựng dựa trên Ontology này, giúp tổ chức, lưu trữ và truy xuất thông tin một cách hiệu quả, phục vụ cho việc trả lời các câu hỏi phức tạp của sinh viên liên quan đến quy chế, điều kiện học tập, xét tốt nghiệp, đăng ký môn học, v.v.
- Nghiên cứu và ứng dụng các công nghệ hiện đại như mô hình ngôn ngữ lớn (LLM) kết hợp với kỹ thuật RAG (Retrieval-Augmented Generation) [7], tích hợp các mô hình ngôn ngữ tiếng Việt như PhoBERT, và khai thác sức mạnh của Graph Neural Networks (GNN) trong truy xuất tri thức từ Knowledge Graph, nhằm tăng cường khả năng truy xuất, tổng hợp và cập nhật thông tin từ các nguồn dữ liệu khác nhau, đặc biệt là các quy định đào tạo. Hệ thống được thiết kế để có thể cập nhật dữ liệu một cách linh hoạt, dễ dàng mở rộng mà không cần phải huấn luyện lại mô hình từ đầu, đảm bảo tính thích nghi và tiết kiệm chi phí vận hành. Việc tận dụng sức mạnh của LLM, PhoBERT, RAG và GNN còn giúp nâng cao độ chính xác, giảm hiện tượng ảo giác (hallucination) và khả năng trả lời các câu hỏi phức tạp, nhiều bước, cần sự tổng hợp kiến thức.
- Xây dựng bộ kiểm thử và thực hiện đánh giá định lượng cho hệ thống tư vấn tự động. Thiết kế các tập dữ liệu kiểm thử bao gồm các câu hỏi thực tế, đặc biệt chú trọng đến các câu hỏi phức tạp, yêu cầu suy luận logic liên quan đến quy định đào tạo. Ngoài ra, có thể sử dụng thêm các bộ dữ liệu sẵn có về các lĩnh vực liên quan như quy định pháp lý, luật pháp (ví dụ: VNLegalEase [2]) để đánh giá hệ thống.

3 Đóng góp khoa học và tính mới (dự kiến)

- **Ontology chuyên biệt cho quy định đào tạo thạc sĩ tại Việt Nam:** Đề xuất và xây dựng một ontology miền chuyên sâu cho các quy chế/điều khoản đào tạo thạc sĩ, cho phép biểu diễn thực thể, quan hệ và ràng buộc hình thức một cách nhất quán và mở rộng. Bộ ontology/Knowledge Graph kèm tài liệu sẽ được công bố mở để tái sử dụng.
- **Quy trình rút trích tri thức bán-tự động từ văn bản pháp quy:** Phát triển pipeline chuẩn hoá điều khoản, chuẩn hoá tham chiếu, nhận diện thực thể/quan hệ theo ontol-

ogy và căn chỉnh vào KG với *human-in-the-loop*, đảm bảo khả năng truy vết nguồn gốc (provenance).

- **Kiến trúc RAG định hướng tri thức (KG-guided):** Thiết kế cơ chế truy xuất từ KG để cung cấp ngữ cảnh có cấu trúc cho LLM, bắt buộc trích dẫn nguồn trong câu trả lời nhằm giảm ảo giác. Đánh giá hiệu quả của kiến trúc này bằng cách so sánh có kiểm soát với hai phương pháp đối chứng: (1) chỉ sử dụng LLM (LLM-only, không có truy xuất tri thức), và (2) sử dụng RAG với tìm kiếm vector thông thường (Vector-RAG, không sử dụng Knowledge Graph), nhằm làm rõ đóng góp của từng thành phần trong hệ thống.
- **Bộ kiểm thử tiếng Việt cho các câu hỏi suy luận nhiều bước:** Xây dựng bộ câu hỏi kiểm thử gồm các tình huống phức tạp như: xung đột giữa các điều khoản, các trường hợp đặc biệt, hoặc yêu cầu suy luận về thời hạn, điều kiện đi kèm,... Dữ liệu này được xây dựng dựa trên các quy định đào tạo của UIT/ĐHQG-HCM và sẽ được công bố mở.
- **Khả năng công bố khoa học:** Các đóng góp trên phù hợp với hướng công bố tại các hội nghị/tạp chí quốc tế thuộc Springer/IEEE/ACM (ví dụ: ACIIDS, KSE, SoICT, IEA/AIE).

4 Nội dung nghiên cứu của đề tài

Nội dung 1: Thu thập dữ liệu và phân loại:

Phương pháp: Thu thập quy chế đào tạo và các thông báo liên quan từ trường Đại học Công nghệ Thông tin thông qua website, tài liệu chính thức và phỏng vấn cán bộ đào tạo; đồng thời thu thập các câu hỏi phức tạp, đòi hỏi suy luận logic liên quan đến quy định đào tạo từ sinh viên. Sau đó, tiến hành phân tích, phân loại các câu hỏi này thành các nhóm chủ đề như quy định đào tạo, điều kiện tốt nghiệp, đăng ký môn học, xét tốt nghiệp,... nhằm phục vụ cho quá trình xây dựng Ontology và đồ tri tri thức.

Nội dung 2: Nghiên cứu và xây dựng Knowledge Graph dựa trên Ontology:

Phương pháp: Đầu tiên, tiến hành nghiên cứu và xây dựng một Ontology phù hợp với các quy định đào tạo, xác định rõ các thực thể quan trọng như môn học, điểm số, thời hạn, cùng các mối quan hệ như điều kiện tốt nghiệp, yêu cầu luận văn, v.v. Trên cơ sở Ontology này, hệ thống Knowledge Graph (KG) sẽ được xây dựng bằng Neo4j, cho phép tổ chức và lưu trữ tri thức.

Đồng thời nghiên cứu phương pháp truy xuất thông tin hiệu quả KG để đảm bảo nhanh chóng, chính xác và đầy đủ.

KG được thiết kế đảm bảo khả năng cập nhật dễ dàng khi có thêm các quy định mới, giúp hệ thống luôn thích nghi với sự thay đổi của môi trường đào tạo.

Nội dung 3: Nghiên cứu mô hình tích hợp LLM + RAG + Knowledge Graph với GNN Retrieval:

Phương pháp: Nghiên cứu một mô hình tích hợp gồm (i) bộ xử lý truy vấn dựa trên KG và Embedding; (ii) bộ truy xuất kết quả kết hợp giữa vector search và bộ truy xuất đồ thị dựa trên *Graph Neural Networks* (GNN) để khai thác cấu trúc KG (tham khảo GNN-RAG [6]); (iii) cơ chế cung cấp ngữ cảnh có cấu trúc và ràng buộc trích dẫn nguồn cho LLM; (iv) xây dựng demo tối thiểu phục vụ thực nghiệm, tập trung đánh giá ảnh hưởng của thành phần GNN Retrieval đến độ chính xác và giảm ảo giác.

Nội dung 4: Thử nghiệm và đánh giá hệ thống:

Phương pháp:

Thực hiện thử nghiệm và đánh giá định lượng bằng các chỉ số BLEU, ROUGE, BERTScore, và độ chính xác trên bộ dữ liệu kiểm thử được xây dựng ở nội dung 1. Đồng thời, thu thập ý kiến sinh viên, cán bộ đào tạo về tính dễ hiểu, hữu ích, và khả năng ứng dụng thực tế của hệ thống.

5 Kết quả, sản phẩm dự kiến

- Một Ontology chuyên về quy định đào tạo cùng với Knowledge Graph được xây dựng trên Neo4j, cho phép biểu diễn linh hoạt các thực thể, thuộc tính và mối quan hệ trong lĩnh vực đào tạo, hỗ trợ truy xuất thông tin hiệu quả và suy luận.
- Quy trình rút trích tri thức bán-tự động từ văn bản pháp quy sang KG cùng mã nguồn và tài liệu hướng dẫn để tái lập.
- Một demo hỏi-đáp dựa trên LLM + RAG + Knowledge Graph *phục vụ đánh giá và minh họa*.
- Bộ dữ liệu kiểm thử bao gồm các quy chế, quy định đào tạo và các câu hỏi thực tế từ sinh viên, đặc biệt chú trọng đến các câu hỏi phức tạp yêu cầu suy luận logic liên quan đến quy định đào tạo, phục vụ cho việc đánh giá định lượng hệ thống.
- Một bài báo khoa học tại một hội nghị quốc tế được xuất bản bởi các nhà xuất bản uy tín như IEEE, ACM, Springer, hoặc Elsevier, trình bày các kết quả nghiên cứu.

Tài liệu tham khảo

- [1] Nguyen, Gia Trung Quan and Hoang, To Thu Dung. (2024). Artificial Intelligence in Vietnamese Higher Education: Challenges and Opportunities. Tạp chí Công Thương. <https://tapchicongthuong.vn/artificial-intelligence-in-vietnamese-higher-education-challenges-and-opportunities-124436.htm>
- [2] Nguyen, T. H., Nguyen, T. T., Nguyen, T. T., & Nguyen, M. T. VNLe-galEase: A Vietnamese Legal Query Chatbot. Intelligent Systems and Data Science (2025). <https://www.springerprofessional.de/en/vnlegalease-a-vietnamese-legal-query-chatbot/50187858>
- [3] Dang, D.V., Nguyen, H.D., Ngo, H., Pham, V.T., Nguyen, D. (2023). Information Retrieval from Legal Documents with Ontology and Graph Embeddings Approach. In: Fujita, H., Wang, Y., Xiao, Y., Moonis, A. (eds) Advances and Trends in Artificial Intelligence. Theory and Applications. IEA/AIE 2023. Lecture Notes in Computer Science(), vol 13925. Springer, Cham. https://doi.org/10.1007/978-3-031-36819-6_27
- [4] Zhu, Xiangrong & Xie, Yuexiang & Liu, Yi & Li, Yaliang & Hu, Wei. (2025). Knowledge Graph-Guided Retrieval Augmented Generation. <https://doi.org/10.18653/v1/2025.naacl-long.449>
- [5] Xu, Z., Cruz, M.J., Guevara, M., Wang, T., Deshpande, M., Wang, X., Li, Z. (2024). Retrieval-Augmented Generation with Knowledge Graphs for Customer Service Question Answering. In Proceedings of the 47th International ACM SIGIR Conference on

Research and Development in Information Retrieval (SIGIR '24). Association for Computing Machinery, New York, NY, USA, 2905-2909. <https://doi.org/10.1145/3626772.3661370>

- [6] Mavromatis, C., Karypis, G. (2024). GNN-RAG: Graph Neural Retrieval for Large Language Model Reasoning. <https://doi.org/10.48550/arXiv.2405.20139>
- [7] Weaviate. (2024). Introduction to RAG (Retrieval-Augmented Generation). <https://weaviate.io/blog/introduction-to-rag>

II KẾ HOẠCH THỰC HIỆN

TT	Nội dung công việc	9	10	11	12	1	2
1	Nghiên cứu tổng quan, phân tích yêu cầu, thiết kế hệ thống						
2	Thu thập và xây dựng bộ dữ liệu về quy định đào tạo và các câu hỏi của sinh viên						
3	Phát triển mô hình ontology và xây dựng Knowledge Graph						
4	Nghiên cứu mô hình LLM+RAG+KG với GNN Retrieval						
5	Kiểm thử, tổng kết, hoàn thiện và viết báo cáo luận văn						

Bảng 1: Kế hoạch thực hiện các giai đoạn của luận văn