

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC MÁY TÍNH

LÊ HỒNG HIỂN

LUẬN VĂN THẠC SĨ

GIẢI PHÁP KẾT HỢP ONTOLOGY VÀ
MÔ HÌNH NGÔN NGỮ LỚN ĐỂ THIẾT
KẾ HỆ THỐNG TƯ VẤN KIẾN THỨC
VỀ QUY ĐỊNH ĐÀO TẠO SAU ĐẠI HỌC

INTEGRATING ONTOLOGY AND
LARGE LANGUAGE MODELS TO
DESIGN AN ADVISORY SYSTEM FOR
POSTGRADUATE EDUCATION
REGULATIONS

THẠC SĨ NGÀNH KHOA HỌC MÁY TÍNH

TP. HỒ CHÍ MINH, NĂM 2026

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC MÁY TÍNH

LÊ HỒNG HIỂN - 210101006

LUẬN VĂN THẠC SĨ

GIẢI PHÁP KẾT HỢP ONTOLOGY VÀ
MÔ HÌNH NGÔN NGỮ LỚN ĐỂ THIẾT
KẾ HỆ THỐNG TƯ VẤN KIẾN THỨC
VỀ QUY ĐỊNH ĐÀO TẠO SAU ĐẠI HỌC

INTEGRATING ONTOLOGY AND
LARGE LANGUAGE MODELS TO
DESIGN AN ADVISORY SYSTEM FOR
POSTGRADUATE EDUCATION
REGULATIONS

THẠC SĨ NGÀNH KHOA HỌC MÁY TÍNH

GIẢNG VIÊN HƯỚNG DẪN
PGS. TS. NGUYỄN ĐÌNH HIỂN
TS. NGÔ QUỐC HÙNG

TP. HỒ CHÍ MINH, NĂM 2026

Thông tin hội đồng chấm luận văn thạc sĩ

Hội đồng chấm luận văn thạc sĩ, thành lập theo Quyết định số.../QĐ-ĐHCNTT ngày ... tháng ... năm 2026 của Hiệu trưởng Trường Đại học Công nghệ Thông tin.

- | | |
|--------|-------------|
| 1. ... | Chủ tịch |
| 2. ... | Phản biện 1 |
| 3. ... | Phản biện 2 |
| 4. ... | Ủy viên |
| 5. ... | Thư ký |

Lời cam đoan

Tôi xin cam đoan đây là công trình nghiên cứu của riêng tôi, được thực hiện dưới sự hướng dẫn khoa học của PGS. TS. Nguyễn Đình Hiến và TS. Ngô Quốc Hưng. Các số liệu, kết quả nêu trong luận văn là trung thực và chưa từng được ai công bố trong bất kỳ công trình nào khác.

Tôi xin chịu trách nhiệm về nghiên cứu của mình.

Thành phố Hồ Chí Minh, ngày 04 tháng 05 năm 2026

Người thực hiện

Lê Hồng Hiến

Lời cảm ơn

Xin chân thành cảm ơn quý thầy cô trong trường Đại học Công Nghệ Thông Tin, ĐHQG-HCM đã tận tình dạy bảo cho em nhiều kiến thức bổ ích trong suốt thời gian học tập tại trường, cũng như tạo điều kiện cho em thực hiện đề tài này. Kính chúc quý thầy cô luôn dồi dào sức khỏe và thành công trong cuộc sống.

Đặc biệt, em xin bày tỏ lòng biết ơn chân thành đến PGS. TS. Nguyễn Đình Hiến, người thầy đã tận tâm, nhiệt tình hướng dẫn và chỉ bảo cho em trong suốt quá trình thực hiện đề tài. Em cũng xin gửi lời cảm ơn đến TS. Ngô Quốc Hưng (University College Dublin), người đồng hướng dẫn đã hỗ trợ về mặt học thuật quốc tế và đóng góp nhiều góp ý về phương pháp nghiên cứu.

Tôi cũng xin gửi lời cảm ơn đến ThS. Đặng Việt Dũng đã hỗ trợ và giúp đỡ tôi trong quá trình nghiên cứu.

Tôi cũng không quên gửi lời cảm ơn đến tác giả của các báo cáo nghiên cứu khoa học mà tôi đã tham khảo và tìm hiểu cho đề tài.

Luận văn đã hoàn thành với một số kết quả nhất định tuy nhiên vẫn không tránh khỏi thiếu sót. Kính mong sự cảm thông và đóng góp ý kiến từ quý thầy cô và các bạn.

Một lần nữa tôi xin chân thành cảm ơn!

Thành phố Hồ Chí Minh, ngày 04 tháng 05 năm 2026

Người thực hiện

Lê Hồng Hiến

Mục lục

Thông tin hội đồng chấm luận văn thạc sĩ	i
Lời cam đoan	iii
Lời cảm ơn	v
Mục lục	vi
Danh sách hình vẽ	x
Danh sách bảng	xii
Danh mục từ tạm dịch	xv
1 Tổng quan	1
1.1 Giới thiệu đề tài	1
1.1.1 Bối cảnh và động lực nghiên cứu	1
1.1.2 Hiện trạng các hệ thống chatbot giáo dục tại Việt Nam	2
1.1.3 Thách thức trong truy xuất thông tin văn bản quy phạm	2
1.2 Các nghiên cứu liên quan	3
1.2.1 Từ truy xuất từ vựng đến truy xuất neural	3
1.2.2 Truy xuất tăng cường tri thức	3
1.2.3 Truy xuất phân cấp nhận biết cấu trúc	4
1.2.4 Định vị nghiên cứu	4
1.3 Mục tiêu và phạm vi nghiên cứu	4
1.3.1 Mục tiêu nghiên cứu	4

1.3.2	Đối tượng	5
1.3.3	Phạm vi nghiên cứu	6
1.4	Bố cục luận văn	6
2	Thu thập kiến thức về quy định đào tạo	9
2.1	Giới thiệu về hệ thống quy chế đào tạo thạc sĩ	9
2.1.1	Tổng quan hệ thống quy chế đào tạo sau đại học tại Việt Nam .	9
2.1.2	Cấu trúc văn bản quy phạm	10
2.1.3	Các quy chế trong phạm vi nghiên cứu	11
2.2	Thu thập kiến thức trong văn bản quy chế	12
2.2.1	Quy trình thu thập và số hóa	12
2.2.2	Các khái niệm chính trong quy chế đào tạo	12
2.2.3	Các quan hệ giữa các khái niệm	13
2.2.4	Phân loại chủ đề	13
2.3	Thu thập câu hỏi kiểm thử	13
2.3.1	Nguồn thu thập	13
2.3.2	Phân loại câu hỏi	14
2.3.3	Thống kê bộ câu hỏi	15
3	Thiết kế giải thuật	17
3.1	Phát biểu bài toán	17
3.2	Tổng quan kiến trúc hệ thống	18
3.2.1	Pha ngoại tuyến	19
3.2.2	Pha trực tuyến	22
3.3	Phân tích truy vấn	22
3.4	Tầng 1: Duyệt cây cấu trúc hướng dẫn bởi LLM	23
3.5	Tầng 2: Truy xuất ngữ nghĩa hai cấp	25
3.5.1	Low-level (Entity-specific)	26
3.5.2	High-level (Conceptual)	28
3.5.3	Hợp nhất Low-level và High-level	28
3.6	Tầng 3: Hợp nhất RRF với mở rộng Knowledge Graph	30
3.6.1	Mở rộng Knowledge Graph	30
3.6.2	Reciprocal Rank Fusion	30
3.6.3	Các cơ chế điều chỉnh	30

4	Thiết kế hệ thống và thử nghiệm	33
4.1	Yêu cầu hệ thống	33
4.1.1	Yêu cầu chức năng	33
4.1.2	Yêu cầu phi chức năng	33
4.2	Kiến trúc hệ thống	34
4.2.1	Tổng quan kiến trúc triển khai	34
4.2.2	Công nghệ sử dụng	34
4.2.3	Chi tiết triển khai	34
4.3	Kết quả thử nghiệm	36
4.3.1	Các chỉ số đánh giá	36
4.3.2	Các hệ thống đối sánh	36
4.3.3	Case Study 1: Pháp luật Việt Nam	37
4.3.4	Case Study 2: Quy định đào tạo	38
4.3.5	Ablation Study	39
4.3.6	Phân tích lỗi	39
4.4	Ứng dụng minh họa	40
4.4.1	Kiến trúc ứng dụng	40
4.4.2	Phương pháp sinh câu trả lời IRAC	41
4.4.3	Các tính năng chính	41
4.4.4	Ví dụ minh họa tiêu biểu	42
5	Kết luận và hướng phát triển	49
5.1	Kết quả đề tài	49
5.2	Hạn chế	50
5.3	Hướng phát triển	51
A	Danh sách quy chế đào tạo	53
A.1	QĐ 270/QĐ-ĐHCNTT: Quy chế đào tạo trình độ thạc sĩ của UIT	53
A.2	QĐ 160/QĐ-ĐHQG: Quy chế đào tạo ThS ĐHQG-HCM (khóa 2021)	54
A.3	QĐ 1393/QĐ-ĐHQG: Quy chế đào tạo ThS ĐHQG-HCM (khóa 2022+)	54
A.4	QĐ 218/QĐ-ĐHQG: Sửa đổi bổ sung quy định GVHD	54
A.5	QĐ 851/QĐ-ĐHCNTT: Quy định liên chính học thuật	55
B	Bộ câu hỏi kiểm thử mẫu	57

B.1	Câu hỏi miền quy định đào tạo	57
B.2	Câu hỏi miền pháp luật	57
C	Mẫu quan hệ đồ thị tri thức	61
C.1	Quan hệ REFERENCES (Tham chiếu)	61
C.2	Quan hệ REQUIRES (Yêu cầu)	62
C.3	Thống kê loại quan hệ	62
D	Prompt LLM sử dụng trong hệ thống	65
D.1	Trích xuất thực thể và quan hệ (Pha ngoại tuyến)	65
D.2	Sinh tóm tắt chương (Pha ngoại tuyến)	65
D.3	Sinh tóm tắt điều khoản (Pha ngoại tuyến)	65
D.4	Loop 1 — Chọn chương (Pha trực tuyến)	68
D.5	Loop 2 — Chọn điều khoản (Pha trực tuyến)	68
D.6	Sinh câu trả lời theo phương pháp IRAC (Pha trực tuyến)	68
	Tài liệu tham khảo	71

Danh sách hình vẽ

2.1	Cấu trúc Document Tree của QĐ 270/QĐ-ĐHCNTT theo cấu trúc phân cấp 6 cấp: Văn bản → Chương → Mục → Điều → Khoản → Điểm (cấp Mục không áp dụng cho văn bản này). Mũi tên nét đứt đỏ thể hiện các tham chiếu chéo giữa các điều khoản và giữa các văn bản.	10
2.2	Đồ thị con minh họa các thực thể và quan hệ xung quanh chủ đề “bảo vệ luận văn thạc sĩ”. Các nút được phân loại theo ontology (Action, Condition, Organization, Person, Legal Reference) và các cạnh thể hiện các loại quan hệ (requires, leads_to, regulates, references).	14
3.1	Kiến trúc hệ thống truy xuất ba tầng. Pha ngoại tuyến (trái): xây dựng mô hình tri thức từ văn bản quy phạm. Pha trực tuyến (phải): xử lý truy vấn qua Tầng 1 (duyet cây cấu trúc), Tầng 2 (truy xuất ngữ nghĩa hai cấp), và Tầng 3 (hợp nhất RRF với mở rộng KG).	18
3.2	Quy trình xây dựng tri thức ngoại tuyến. Track 1 phân tích cấu trúc văn bản thành Document Forest. Track 2 xây dựng Knowledge Graph qua 4 bước. Track 3 tạo Domain Groups và Theme Clusters phục vụ tìm kiếm. .	22
3.3	Pipeline phân tích truy vấn gồm ba bước: phân loại ý định (6 loại), mở rộng viết tắt, và trích xuất thực thể giống. Mỗi đầu ra phục vụ một tầng truy xuất khác nhau.	23
3.4	Minh họa quá trình duyệt cây ba vòng lặp với truy vấn “Điều kiện để được bảo vệ luận văn thạc sĩ?”. Các nút xanh là được chọn bởi LLM, các nút xám bị loại. Loop 0 chọn 3/5 tài liệu, Loop 1 thu hẹp xuống các chương liên quan, Loop 2 xác định các điều khoản cụ thể.	25

3.5	Kiến trúc Tầng 2 hai cấp. Low-level gồm 4 tín hiệu (Keyphrase, Semantic, Intent-aware PPR, Concept Matching) với minh họa PPR lan truyền qua KG. High-level gồm Theme Matching và Hierarchy Expansion. Công thức hợp nhất 70%–30% ưu tiên tín hiệu entity-specific.	29
3.6	Minh họa luồng xử lý end-to-end với truy vấn “Học viên cần đáp ứng điều kiện gì về ngoại ngữ để tốt nghiệp?”. Tầng 1 tìm Đ.29, Đ.25, Đ.24 qua duyệt cây. Tầng 2 xác nhận Đ.25 và Đ.29 qua PPR, bổ sung Đ.8. Tầng 3 nhận seeds từ Tầng 1 và Tầng 2, mở rộng KG thêm Đ.5, sau đó hợp nhất RRF cả ba danh sách với thưởng đồng thuận và hệ số phạt.	31
4.1	Màn hình chào mừng với lĩnh vực “Quy định đào tạo” và các câu hỏi gợi ý về quy chế đào tạo sau đại học	42
4.2	Trạng thái truy xuất “Đang tổng hợp câu trả lời...” hiển thị trực tiếp trong khi hệ thống xử lý câu hỏi	43
4.3	Câu trả lời IRAC cho câu hỏi “Điều kiện bảo vệ luận văn thạc sĩ?” với panel nguồn quy định gốc (phải)	43
4.4	Panel trích dẫn nguồn hiển thị nguyên văn điều khoản với breadcrumb vị trí (văn bản → chương → điều)	44
4.5	Lộ trình truy xuất 3 vòng lặp: Loop 0 chọn tài liệu, Loop 1 chọn chương, Loop 2 truy xuất điều khoản	44

Danh sách bảng

1.1	So sánh các hệ thống liên quan	5
2.1	Danh sách các quy chế đào tạo trong phạm vi nghiên cứu	11
2.2	Phân loại chủ đề trong quy chế đào tạo thạc sĩ	15
2.3	Thống kê bộ câu hỏi kiểm thử miền quy định đào tạo	16
2.4	Ví dụ câu hỏi mẫu từ bộ kiểm thử	16
3.1	Quy tắc đặt định danh nút trong Document Forest	19
3.2	Thống kê Knowledge Graph	21
4.1	Công nghệ sử dụng trong hệ thống	35
4.2	Tỷ lệ Hit (%) trên miền pháp luật (400 câu hỏi)	37
4.3	Hit@10 (%) theo miền trên ba lĩnh vực	38
4.4	Kết quả trên miền quy định đào tạo (130 câu hỏi)	38
4.5	Kết quả ablation study (Hit@10 %, trung bình 3 lần chạy)	39
4.6	So sánh prompt IRAC giữa miền pháp luật và miền đào tạo	41
4.7	So sánh top-5 kết quả truy xuất giữa các hệ thống – Ví dụ 1	45
4.8	So sánh top-5 kết quả truy xuất giữa các hệ thống – Ví dụ 2	45
4.9	So sánh top-5 kết quả truy xuất giữa các hệ thống – Ví dụ 3	46
B.1	Câu hỏi mẫu miền quy định đào tạo	58
B.2	Câu hỏi mẫu miền pháp luật	59
C.1	Mẫu quan hệ REFERENCES trong KG	61
C.2	Mẫu quan hệ REQUIRES trong KG	62
C.3	Top 10 loại quan hệ trong đồ thị tri thức	63
D.1	Prompt trích xuất thực thể và quan hệ	66

D.2	Prompt sinh tóm tắt chương	67
D.3	Prompt sinh tóm tắt điều khoản	67
D.4	Prompt chọn chương (Loop 1)	68
D.5	Prompt chọn điều khoản (Loop 2)	69
D.6	Prompt sinh câu trả lời IRAC — Lĩnh vực pháp luật	69
D.7	Prompt sinh câu trả lời IRAC — Lĩnh vực đào tạo	70

Danh mục từ tạm dịch

Tiếng Anh	Tiếng Việt
Knowledge Graph	Đồ thị tri thức
Ontology	Bản thể học
Retrieval-Augmented Generation	Sinh văn bản tăng cường truy xuất
Large Language Model	Mô hình ngôn ngữ lớn
Tree Traversal	Duyệt cây
Semantic Retrieval	Truy xuất ngữ nghĩa
Reciprocal Rank Fusion	Reciprocal Rank Fusion (RRF)
Personalized PageRank	PageRank cá nhân hóa
Document Forest	Rừng cây tài liệu
Cross-reference	Tham chiếu chéo
Embedding	Biểu diễn nhúng
Hallucination	Ảo giác
Query Intent	Ý định truy vấn
Hit Rate	Tỷ lệ trúng
Mean Reciprocal Rank	Hạng nghịch đảo trung bình
Ablation Study	Nghiên cứu loại bỏ thành phần
Summary Tree	Cây tóm tắt
Document Tree	Cây tài liệu
Multi-hop Reasoning	Suy luận đa bước
Knowledge Graph Expansion	Mở rộng đồ thị tri thức

Chương 1

Tổng quan

Chương này trình bày tổng quan về đề tài nghiên cứu, bao gồm giới thiệu bối cảnh và động lực nghiên cứu, tổng quan các công trình liên quan, mục tiêu và phạm vi nghiên cứu, cũng như bố cục của luận văn.

1.1 Giới thiệu đề tài

1.1.1 Bối cảnh và động lực nghiên cứu

Tại các trường đại học ở Việt Nam, nhiều phòng ban chức năng đã được thành lập để hỗ trợ sinh viên trong học tập, rèn luyện và giải quyết các thủ tục hành chính. Tuy nhiên, do thông tin bị phân tán giữa nhiều phòng ban và các quy định thường khó hiểu, sinh viên gặp nhiều trở ngại trong việc tra cứu, tiếp cận và nắm bắt đầy đủ các quy định đào tạo, nhất là đối với những quy chế mới hoặc có tính chất phức tạp. Sinh viên thường phải liên hệ với nhiều nơi khác nhau cho từng vấn đề, dẫn đến mất thời gian, chờ đợi kéo dài và đôi khi không nhận được thông tin chính xác, kịp thời.

Ngoài ra, các nhu cầu tư vấn về học tập, nghiên cứu khoa học, lựa chọn ngành nghề, điều kiện tốt nghiệp cũng ngày càng đa dạng, trong khi nguồn lực cán bộ tư vấn còn hạn chế. Việc giải thích các quy định đào tạo phức tạp thường đòi hỏi sự tương tác trực tiếp, gây áp lực lớn cho đội ngũ cán bộ và không đáp ứng được nhu cầu hỗ trợ 24/7. Do đó, việc xây dựng một hệ thống tư vấn tự động, thông minh sẽ giúp giảm tải cho cán bộ, tiết kiệm chi phí vận hành, đồng thời nâng cao trải nghiệm và sự hài lòng của sinh viên.

1.1.2 Hiện trạng các hệ thống chatbot giáo dục tại Việt Nam

Gần đây, nhiều trường đại học tại Việt Nam đã tiên phong ứng dụng trí tuệ nhân tạo vào các hệ thống hỗ trợ sinh viên:

- **Chatbot UEB** (Đại học Kinh tế Quốc dân): triển khai dựa trên nền tảng ChatGPT, giúp sinh viên tra cứu thông tin và giải đáp thắc mắc mọi lúc, mọi nơi.
- **UEH AI Chatbot** (Đại học Kinh tế TP.HCM): hỗ trợ tư vấn tuyển sinh, hướng nghiệp cho phụ huynh và học sinh.
- **HUNRE AI Chatbot** (Đại học Tài nguyên và Môi trường Hà Nội): góp phần nâng cao chất lượng phục vụ sinh viên và tối ưu hóa quy trình quản lý đào tạo.

Các ứng dụng chatbot này chủ yếu dựa trên mô hình ngôn ngữ lớn (LLM), đã được triển khai rộng rãi và bước đầu mang lại nhiều tiện ích cho sinh viên. Tuy nhiên, hiện vẫn còn thiếu các nghiên cứu đánh giá định lượng về mức độ chính xác và hiệu quả thực sự của các hệ thống này. Bên cạnh đó, các LLM hiện nay vẫn gặp nhiều hạn chế trong việc xử lý các câu hỏi phức tạp đòi hỏi suy luận logic sâu. Đặc biệt, hiện tượng “ảo giác” (hallucination), tức khi mô hình tạo ra câu trả lời không chính xác hoặc không sát với thực tế, vẫn là một rào cản lớn, có thể dẫn đến việc cung cấp thông tin sai lệch với hậu quả nghiêm trọng đối với sinh viên.

1.1.3 Thách thức trong truy xuất thông tin văn bản quy phạm

Các văn bản quy chế đào tạo tại Việt Nam có cấu trúc phân cấp phức tạp: một quy chế tổ chức nội dung theo các cấp Chương, Điều, Khoản và Điểm, mỗi cấp mang phạm vi quy định riêng biệt. Ngoài ra, các văn bản còn chứa nhiều tham chiếu chéo (cross-reference): để trả lời câu hỏi “*Học viên cao học cần đáp ứng điều kiện gì để được bảo vệ luận văn?*” cần kết nối Điều 24 (điều kiện bảo vệ) trong QĐ 270 của UIT với Điều 25 (yêu cầu ngoại ngữ) trong QĐ 1393 của ĐHQG-HCM, vốn là hai văn bản khác nhau ở hai tầng quản lý.

Tiếng Việt còn tạo thêm thách thức qua sự đa nghĩa thanh điệu, các viết tắt chuyên ngành (GVHD, ThS, NCS, ĐHQG) và hệ thống phân cấp văn bản quy phạm đa tầng (Bộ GD&ĐT, ĐHQG-HCM, trường thành viên). Các phương pháp truy xuất thông tin truyền thống dựa trên vector similarity [20] hiệu quả trong nhiều lĩnh vực [7] nhưng không đủ

cho văn bản quy phạm có cấu trúc: embedding mờ đi ý nghĩa chính xác của thuật ngữ chuyên ngành (*semantic gap*), truy xuất phẳng bỏ qua cấu trúc phân cấp tài liệu, và tìm kiếm dày đặc không thể kết nối các tham chiếu chéo giữa các quy chế. Các thách thức tương tự cũng xuất hiện trong lĩnh vực pháp luật Việt Nam, nơi hệ thống được mở rộng đánh giá (Chương 4).

1.2 Các nghiên cứu liên quan

1.2.1 Truy xuất từ vựng đến truy xuất neural

Truy xuất thông tin pháp lý ban đầu dựa vào đối sánh từ vựng: BM25 [21] và TF-IDF [15] xếp hạng tài liệu theo mức độ trùng khớp thuật ngữ, nhưng thất bại khi người dùng diễn đạt lại các khái niệm pháp lý bằng ngôn ngữ tự nhiên. Truy xuất dày đặc (dense retrieval) chuyển sang các biểu diễn học được với Sentence-BERT [20] và DPR [11]; các công trình tiếp theo bổ sung cơ chế tự phản ánh [1] và sinh tài liệu giả thuyết [8] (được tổng quan bởi Fan và cộng sự [7]). Các mô hình chuyên biệt miền như LEGAL-BERT [2] nắm bắt ngôn ngữ pháp lý nhưng vẫn hoạt động trên các đoạn văn bản phẳng.

Đối với tiếng Việt, PhoBERT [18] và VnCoreNLP [24] cung cấp các mô hình nền tảng, và Ngo cùng cộng sự [17] đã kết hợp BM25 với BERT [4] cho cuộc thi ALQAC 2021. Một hạn chế chung xuyên suốt các phương pháp này: việc coi tài liệu như tập hợp phẳng đã loại bỏ cấu trúc phân cấp quan trọng cho văn bản pháp lý.

1.2.2 Truy xuất tăng cường tri thức

Để phục hồi thông tin có cấu trúc và quan hệ, các nhà nghiên cứu đã chuyển sang các mô hình biểu diễn tri thức. Legal-Onto [19] kết hợp mô hình Rela [5] với đồ thị khái niệm cho Luật Đất đai Việt Nam nhưng dựa vào luật thủ công, không có khả năng mở rộng. GraphRAG [6] phân vùng đồ thị thực thể thành các cộng đồng với tóm tắt LLM, và LightRAG [9] kết hợp tìm kiếm vector với duyệt đồ thị. Cả hai cho phép suy luận đa bước nhưng coi tài liệu như tập hợp thực thể mà không bảo toàn cấu trúc phân cấp; trong thử nghiệm của chúng tôi, chất lượng trích xuất thực thể của LightRAG khá thấp (74% thực thể chỉ xuất hiện một lần).

RAG [14] nền tảng hóa việc sinh văn bản dựa trên bằng chứng truy xuất nhưng vẫn bị giới hạn bởi chất lượng truy xuất. Các khảo sát [26, 12] xác nhận rằng việc kết nối tri thức pháp lý với truy xuất có khả năng mở rộng vẫn là một vấn đề mở.

1.2.3 Truy xuất phân cấp nhận biết cấu trúc

RAPTOR [22] xây dựng Summary Tree qua phân cụm đệ quy và tóm tắt LLM, nắm bắt chủ đề đa mức chi tiết; tuy nhiên, nó loại bỏ cấu trúc phân cấp gốc của tài liệu và chỉ dựa vào truy xuất embedding tại thời điểm truy vấn, chỉ đạt 41,0% tỷ lệ Hit@10 trên bộ đánh giá pháp lý có cấu trúc của chúng tôi.

PageIndex [25] duyệt qua cây theo hướng dẫn bởi LLM để tìm kiếm tài liệu đã phân cấp, đạt độ chính xác cao khi mô hình chọn đúng nhánh nhưng bỏ sót nội dung ngoài đường duyệt. Đặc biệt, cả hai hệ thống đều không tích hợp Knowledge Graph cho suy luận liên tài liệu; các truy vấn đa bước xuyên các luật hoặc nghị định khác nhau chưa được giải quyết.

1.2.4 Định vị nghiên cứu

Chưa có hệ thống nào kết hợp tri thức ontology, truy xuất dựa trên đồ thị và duyệt cây cấu trúc cho văn bản pháp lý Việt Nam. Hệ thống được đề xuất trong luận văn này tích hợp cả ba khả năng thông qua kiến trúc ba tầng với suy luận nhận biết ý định và tổng hợp, xếp hạng. Bảng 1.1 tóm tắt so sánh các phương pháp liên quan.

1.3 Mục tiêu và phạm vi nghiên cứu

1.3.1 Mục tiêu nghiên cứu

Luận văn này nghiên cứu và giải quyết các vấn đề sau:

1. **Xây dựng Knowledge Graph và Ontology cho văn bản quy phạm:** Xây dựng pipeline trích xuất tri thức bán tự động sử dụng LLM để trích xuất thực thể và quan hệ từ văn bản quy phạm, kết hợp tinh chỉnh bởi chuyên gia (expert-in-the-loop) để tạo KG. Từ KG đã xây dựng, suy luận (infer) ontology chuyên biệt theo chuẩn OWL, xác định hệ thống phân cấp các loại thực thể (chủ thể, điều kiện,

1.3. Mục tiêu và phạm vi nghiên cứu

Bảng 1.1: So sánh các hệ thống liên quan

Hệ thống	Cấu trúc	KG	Ngữ nghĩa	Đa tài liệu
BM25/TF-IDF	—	—	—	✓
NaiveRAG	—	—	✓	✓
LightRAG [9]	—	✓	✓	✓
RAPTOR [22]	Summary Tree	—	✓	✓
PageIndex [25]	Document Tree	—	—	✓
Legal-Onto [19]	—	✓	—	—
3-Tier (ours)	Document Tree	✓	✓	✓

thời hạn, mức phạt, ...) và quan hệ (references, requires, depends_on, ...), phục vụ cho cơ chế Concept Matching trong truy xuất ngữ nghĩa.

2. **Đề xuất kiến trúc truy xuất 3-Tier KG-RAG:** Thiết kế kiến trúc truy xuất ba tầng kết hợp duyệt cây cấu trúc hướng dẫn bởi LLM (Tầng 1), truy xuất ngữ nghĩa hai cấp dựa trên KG và embedding (Tầng 2), và hợp nhất Reciprocal Rank Fusion với mở rộng Knowledge Graph (Tầng 3). Kiến trúc này tận dụng đồng thời cấu trúc phân cấp của văn bản quy phạm, quan hệ ngữ nghĩa trong đồ thị tri thức và tín hiệu tương đồng vector để truy xuất chính xác các điều khoản liên quan.
3. **Xây dựng bộ đánh giá và so sánh định lượng:** Thiết kế các bộ benchmark tiếng Việt gồm các câu hỏi phức tạp yêu cầu suy luận đa bước, tham chiếu chéo giữa các văn bản. Đánh giá hệ thống bằng các chỉ số Hit@k và MRR, so sánh với các phương pháp tiên tiến (PageIndex, RAPTOR, LightRAG), và phân tích ablation để đo lường đóng góp của từng thành phần.

1.3.2 Đối tượng

Đề tài này nghiên cứu việc tổ chức và truy xuất thông tin từ các văn bản quy phạm có cấu trúc phân cấp để xây dựng một hệ thống hỏi đáp tự động dựa trên đồ thị tri thức và mô hình ngôn ngữ lớn. Hệ thống hướng đến đối tượng là học viên cao học, sinh viên sau đại học tại UIT và các trường thuộc ĐHQG-HCM có nhu cầu tra cứu các quy định

đào tạo, cũng như cán bộ phòng đào tạo cần hỗ trợ giải đáp thắc mắc cho học viên. Hệ thống cũng có thể mở rộng ra cho người dùng có nhu cầu muốn tra cứu thông tin pháp luật.

1.3.3 Phạm vi nghiên cứu

Hệ thống được kiểm thử trên 5 bộ quy chế, quy định đào tạo thạc sĩ:

1. Quy chế đào tạo trình độ thạc sĩ của UIT số 270/QĐ-ĐHCNTT ngày 25/04/2022.
2. Quy chế đào tạo trình độ thạc sĩ cho khóa 2021 số 160/QĐ-ĐHQG ngày 24/03/2017 của ĐHQG-HCM.
3. Quy chế đào tạo trình độ thạc sĩ cho khóa từ năm 2022 số 1393/QĐ-ĐHQG ngày 03/11/2021 của ĐHQG-HCM.
4. Quy chế sửa đổi bổ sung số 218/QĐ-ĐHQG ngày 15/03/2024 của ĐHQG-HCM.
5. Quy định về liên chính học thuật số 851/QĐ-ĐHCNTT ngày 14/08/2024 của UIT.

Ngoài ra, hệ thống còn được đánh giá trên bộ dữ liệu pháp luật Việt Nam gồm 12 văn bản thuộc lĩnh vực luật doanh nghiệp và luật giao thông để chứng minh tính tổng quát của phương pháp.

1.4 Bố cục luận văn

Phần còn lại của luận văn được tổ chức như sau:

- **Chương 2:** Thu thập kiến thức về quy định đào tạo: trình bày tổng quan hệ thống quy chế đào tạo thạc sĩ, quy trình thu thập và tổ chức kiến thức từ văn bản quy phạm, cũng như xây dựng bộ câu hỏi kiểm thử.
- **Chương 3:** Thiết kế giải thuật: trình bày chi tiết kiến trúc 3-Tier KG-RAG bao gồm phân tích truy vấn, duyệt cây cấu trúc, truy xuất ngữ nghĩa hai cấp và hợp nhất RRF với mở rộng Knowledge Graph.

- **Chương 4:** Thiết kế hệ thống và thử nghiệm: trình bày yêu cầu hệ thống, kiến trúc triển khai, và kết quả thử nghiệm trên hai nghiên cứu trường hợp (case study) cùng phân tích ablation.
- **Chương 5:** Kết luận và hướng phát triển: tổng kết các kết quả đạt được, thảo luận hạn chế và đề xuất hướng phát triển tương lai.

Chương 2

Thu thập kiến thức về quy định đào tạo

Chương này trình bày tổng quan về hệ thống quy chế đào tạo thạc sĩ tại UIT và ĐHQG-HCM, quy trình thu thập và tổ chức kiến thức từ các văn bản quy phạm, cũng như việc xây dựng bộ câu hỏi kiểm thử phục vụ đánh giá hệ thống. Nội dung chương này tuân theo phương pháp thu thập kiến thức theo miền (domain knowledge acquisition) cho hệ thống truy xuất thông tin.

2.1 Giới thiệu về hệ thống quy chế đào tạo thạc sĩ

2.1.1 Tổng quan hệ thống quy chế đào tạo sau đại học tại Việt Nam

Hệ thống giáo dục sau đại học tại Việt Nam được quản lý bởi nhiều tầng văn bản quy phạm pháp luật, từ cấp quốc gia đến cấp trường. Tại cấp quốc gia, Luật Giáo dục và Luật Giáo dục Đại học đặt ra khung pháp lý chung. Bộ Giáo dục và Đào tạo ban hành các quy chế đào tạo trình độ thạc sĩ, tiến sĩ áp dụng trên toàn quốc. Tại cấp cơ sở, các đại học quốc gia và trường đại học ban hành quy chế riêng phù hợp với đặc thù đào tạo.

Đối với UIT, một trường thành viên của ĐHQG-HCM, hệ thống quy chế đào tạo thạc sĩ bao gồm hai tầng chính:

- **Tầng ĐHQG-HCM:** Các quy chế khung do ĐHQG-HCM ban hành, áp dụng cho tất cả các trường thành viên (QĐ 160, QĐ 1393, QĐ 218).

2.1. Giới thiệu về hệ thống quy chế đào tạo thạc sĩ

- **Tầng trường:** Các quy chế, quy định cụ thể hóa do UIT ban hành (QĐ 270, QĐ 851), bổ sung và chi tiết hóa các quy định của ĐHQG-HCM.


2.1.2 Cấu trúc văn bản quy phạm

Các văn bản quy chế đào tạo tuân theo cấu trúc phân cấp chuẩn của văn bản quy phạm pháp luật Việt Nam:

Văn bản → Chương → Mục → Điều → Khoản → Điểm

Mỗi cấp mang phạm vi pháp lý riêng biệt. Một Văn bản thường bao gồm nhiều Chương, mỗi Chương có thể chứa các Mục gom nhóm các Điều theo chủ đề. Mỗi Điều quy định về một vấn đề cụ thể và được chia thành các Khoản (đánh số 1, 2, 3...) và Điểm (đánh số a, b, c...). Đây chính là đơn vị trích dẫn nhỏ nhất (minimal citable unit) trong thực tiễn pháp lý Việt Nam. Trong thực tế, không phải văn bản nào cũng có đủ cả 6 cấp; ví dụ các quy chế đào tạo thường không có cấp Mục.

Hình 2.1 minh họa cấu trúc Document Tree của QĐ 270/QĐ-ĐHCNTT với các cấp phân cấp và tham chiếu chéo.



Hình 2.1: Cấu trúc Document Tree của QĐ 270/QĐ-ĐHCNTT theo cấu trúc phân cấp 6 cấp: Văn bản → Chương → Mục → Điều → Khoản → Điểm (cấp Mục không áp dụng cho văn bản này). Mũi tên nét đứt đỏ thể hiện các tham chiếu chéo giữa các điều khoản và giữa các văn bản.

2.1. Giới thiệu về hệ thống quy chế đào tạo thạc sĩ

2.1.3 Các quy chế trong phạm vi nghiên cứu

Bảng 2.1 liệt kê 5 quy chế được sử dụng trong luận văn.

Bảng 2.1: Danh sách các quy chế đào tạo trong phạm vi nghiên cứu

STT	Tên quy chế	Số QĐ	Số chương	Số điều
1	Quy chế ĐT trình độ ThS của UIT	270/QĐ-ĐHCNTT	8	35
2	Quy chế ĐT trình độ ThS của ĐHQG-HCM (khóa 2021)	160/QĐ-ĐHQG	7	28
3	Quy chế ĐT trình độ ThS của ĐHQG-HCM (khóa 2022+)	1393/QĐ-ĐHQG	8	32
4	Quy chế sửa đổi bổ sung về GVHD	218/QĐ-ĐHQG	2	6
5	Quy định liên chính học thuật	851/QĐ-ĐHCNTT	3	8
Tổng cộng			28	109

QĐ 270/QĐ-ĐHCNTT (25/04/2022) là quy chế đào tạo trình độ thạc sĩ chính của UIT, gồm 8 chương và 35 điều, quy định toàn bộ quy trình từ tuyển sinh, tổ chức đào tạo, đánh giá kết quả học tập, thực hiện luận văn đến xét tốt nghiệp. Đây là văn bản được học viên cao học UIT tham chiếu nhiều nhất.

QĐ 160/QĐ-ĐHQG (24/03/2017) là quy chế khung của ĐHQG-HCM áp dụng cho khóa 2021, gồm 7 chương và 28 điều, quy định các nguyên tắc chung về đào tạo thạc sĩ tại các trường thành viên.

QĐ 1393/QĐ-ĐHQG (03/11/2021) là quy chế mới thay thế QĐ 160, áp dụng cho khóa từ 2022 trở đi, gồm 8 chương và 32 điều với nhiều thay đổi quan trọng về thời gian đào tạo, điều kiện tốt nghiệp và yêu cầu luận văn.

QĐ 218/QĐ-ĐHQG (15/03/2024) sửa đổi, bổ sung một số điều về quy định giáo viên hướng dẫn trong quy chế đào tạo của ĐHQG-HCM.

QĐ 851/QĐ-ĐHCNTT (14/08/2024) quy định về liên chính học thuật áp dụng cho học viên cao học UIT, gồm 3 chương và 8 điều, bao gồm các quy định về đạo văn, gian lận và xử lý vi phạm.

2.2 Thu thập kiến thức trong văn bản quy chế

2.2.1 Quy trình thu thập và số hóa

Quá trình thu thập kiến thức từ các văn bản được thực hiện theo các bước sau:

1. **Thu thập văn bản gốc:** Tải các quyết định từ website chính thức của UIT và ĐHQG-HCM. Các văn bản ở dạng PDF scan (118 trang) được số hóa bằng LLM Vision OCR.
2. **Phân tích cấu trúc:** Sử dụng bộ phân tích cú pháp (parser) tùy chỉnh với regex nhận diện các dấu hiệu phân cấp tiếng Việt (“Chương”, “Mục”, “Điều”, “Khoản”, “Điểm”) để xây dựng cây cấu trúc phân cấp.
3. **Trích xuất tham chiếu chéo:** Nhận diện các tham chiếu giữa các điều khoản bằng pattern matching trên chuỗi trích dẫn (ví dụ: “Điều 5 Quy chế 270”).
4. **Tạo tóm tắt:** Sinh tóm tắt chương và điều bằng LLM (Claude 3.5 Haiku), tạo mô tả gồm nhiều từ khóa phục vụ cho bước chọn nhánh trong Tầng 1.

2.2.2 Các khái niệm chính trong quy chế đào tạo

Qua phân tích nội dung 5 quy chế, các khái niệm chính được xác định bao gồm:

- **Chương trình đào tạo:** khung chương trình, môn học bắt buộc, môn học tự chọn, số tín chỉ tối thiểu.
- **Tín chỉ và môn học:** định nghĩa tín chỉ, phân loại môn học, điều kiện tiên quyết, đăng ký môn học.
- **Đánh giá kết quả học tập:** thang điểm 10, thang điểm 4, thang điểm chữ (A, B+, B, C+, C, D+, D, F), quy đổi giữa các thang điểm.
- **Thời hạn đào tạo:** thời gian đào tạo chuẩn, thời gian tối đa, gia hạn, bảo lưu kết quả học tập.
- **Luận văn thạc sĩ:** đề cương luận văn, hội đồng xét duyệt đề cương, giáo viên hướng dẫn, hội đồng bảo vệ luận văn, điều kiện bảo vệ.

- **Điều kiện tốt nghiệp:** điểm trung bình tích lũy, yêu cầu ngoại ngữ, yêu cầu bài báo khoa học, xét tốt nghiệp.
- **Liên chính học thuật:** định nghĩa đạo văn, các hình thức vi phạm, mức xử lý kỷ luật.

2.2.3 Các quan hệ giữa các khái niệm

Các mối quan hệ quan trọng được xác định từ văn bản quy chế:

- **Tiên quyết** (MonHoc $\rightarrow$ MonHoc): Một môn học yêu cầu hoàn thành môn khác trước khi đăng ký.
- **Thuộc** (DieuKhoan $\rightarrow$ VanBan): Một điều khoản thuộc về một văn bản quy chế cụ thể.
- **Tham chiếu** (DieuKhoan $\rightarrow$ DieuKhoan): Một điều khoản dẫn chiếu đến điều khoản khác trong cùng hoặc khác văn bản.
- **Thay thế/Bổ sung** (VanBan $\rightarrow$ VanBan): Một văn bản thay thế hoặc bổ sung cho văn bản khác (ví dụ: QĐ 1393 thay thế QĐ 160; QĐ 218 bổ sung QĐ 1393).
- **Yêu cầu** (DieuKien $\rightarrow$ HanhDong): Một điều kiện phải được đáp ứng trước khi thực hiện một hành động (ví dụ: đạt điểm ngoại ngữ trước khi bảo vệ luận văn).

Hình 2.2 minh họa một đồ thị con trích xuất từ Knowledge Graph miền đào tạo, thể hiện các thực thể và quan hệ xung quanh chủ đề bảo vệ luận văn thạc sĩ.

2.2.4 Phân loại chủ đề

Bảng 2.2 trình bày các nhóm chủ đề chính được phân loại từ nội dung quy chế.

2.3 Thu thập câu hỏi kiểm thử

2.3.1 Nguồn thu thập

Bộ câu hỏi kiểm thử cho miền quy định đào tạo gồm 130 câu hỏi, được thu thập từ các diễn đàn và nhóm trao đổi trực tuyến của học viên cao học tại UIT. Các câu hỏi bao

2.3. Thu thập câu hỏi kiểm thử



Hình 2.2: Đồ thị con minh họa các thực thể và quan hệ xung quanh chủ đề “bảo vệ luận văn thạc sĩ”. Các nút được phân loại theo ontology (Action, Condition, Organization, Person, Legal Reference) và các cạnh thể hiện các loại quan hệ (requires, leads_to, regulates, references).

gồm từ tra cứu đơn giản (“Thời gian đào tạo thạc sĩ tối đa là bao lâu?”) đến các truy vấn đa bước yêu cầu suy luận liên văn bản (“Học viên khóa 2021 có được áp dụng quy chế mới không?”). Chuyên gia miền gán nhãn mỗi câu hỏi với 1–5 điều khoản liên quan (gold articles) để phục vụ đánh giá định lượng.

Ngoài ra, hệ thống còn được đánh giá trên bộ 400 câu hỏi pháp luật thu thập từ các nhóm tư vấn pháp lý trên Facebook, thuộc hai lĩnh vực luật doanh nghiệp (200 câu) và luật giao thông (200 câu), nhằm chứng minh tính tổng quát của phương pháp.

2.3.2 Phân loại câu hỏi

Bộ câu hỏi được phân loại theo mức độ phức tạp:

2.3. Thu thập câu hỏi kiểm thử

Bảng 2.2: Phân loại chủ đề trong quy chế đào tạo thạc sĩ

STT	Chủ đề	Nội dung
1	Quy trình đào tạo	Đăng ký môn học, lịch học, thời khóa biểu, nghỉ phép
2	Điều kiện tốt nghiệp	Điểm TB tích lũy, ngoại ngữ, bài báo, luận văn
3	Luận văn	Đề cương, GVHD, hội đồng, bảo vệ, chỉnh sửa
4	Đánh giá kết quả	Thang điểm, quy đổi, cảnh báo học vụ, buộc thôi học
5	Tuyển sinh	Điều kiện dự tuyển, hồ sơ, xét tuyển
6	Liên chính học thuật	Đạo văn, gian lận, xử lý vi phạm
7	Quy định GVHD	Tiêu chuẩn, số lượng, trách nhiệm

- **Single-hop:** Câu hỏi chỉ cần tra cứu một điều khoản duy nhất. Ví dụ: “Thời gian đào tạo thạc sĩ tối đa là bao lâu?”
- **Multi-hop:** Câu hỏi cần kết hợp thông tin từ nhiều điều khoản hoặc nhiều văn bản. Ví dụ: “Nếu học viên khóa 2021 muốn chuyển sang quy chế mới thì cần đáp ứng điều kiện gì?”
- **Reasoning:** Câu hỏi đòi hỏi suy luận logic dựa trên các quy định. Ví dụ: “Học viên đã hết thời gian gia hạn nhưng chưa bảo vệ luận văn thì có thể làm gì?”

2.3.3 Thống kê bộ câu hỏi

Bảng 2.3 trình bày thống kê phân bố câu hỏi theo chủ đề.

Bảng 2.4 trình bày một số ví dụ câu hỏi mẫu từ bộ kiểm thử.

Chi tiết kết quả đánh giá trên cả hai bộ dữ liệu được trình bày trong Chương 4.

2.3. Thu thập câu hỏi kiểm thử

Bảng 2.3: Thống kê bộ câu hỏi kiểm thử miền quy định đào tạo

Chủ đề	Số câu hỏi	Tỷ lệ
Quy trình đào tạo	28	21,5%
Điều kiện tốt nghiệp	25	19,2%
Luận văn	22	16,9%
Đánh giá kết quả	18	13,8%
Tuyển sinh	15	11,5%
Liên chính học thuật	12	9,2%
Quy định GVHD	10	7,7%
Tổng	130	100%

Bảng 2.4: Ví dụ câu hỏi mẫu từ bộ kiểm thử

STT	Câu hỏi	Điều khoản
1	Thời gian đào tạo thạc sĩ tối đa là bao lâu?	QĐ270: Điều 5
2	Điều kiện để được bảo vệ luận văn thạc sĩ?	QĐ270: Điều 24
3	Điểm trung bình tích lũy tối thiểu để tốt nghiệp?	QĐ270: Điều 29
4	Yêu cầu ngoại ngữ đầu ra cho học viên cao học?	QĐ1393: Điều 25
5	Tiêu chuẩn để được làm GVHD luận văn thạc sĩ?	QĐ218: Điều 3
6	Thế nào là hành vi đạo văn trong luận văn?	QĐ851: Điều 3
7	Học viên bị cảnh báo học vụ khi nào?	QĐ270: Điều 18
8	Học viên khóa 2021 có được áp dụng quy chế mới không?	QĐ1393: Điều 32
9	Số tín chỉ tối thiểu cho chương trình ThS nghiên cứu?	QĐ270: Điều 8
10	GVHD được hướng dẫn tối đa bao nhiêu học viên?	QĐ218: Điều 4

Chương 3

Thiết kế giải thuật

Chương này trình bày chi tiết kiến trúc giải thuật 3-Tier KG-RAG được đề xuất, bao gồm phát biểu bài toán, tổng quan kiến trúc hệ thống, và ba tầng truy xuất: duyệt cây cấu trúc hướng dẫn bởi LLM, truy xuất ngữ nghĩa hai cấp, và Reciprocal Rank Fusion với mở rộng Knowledge Graph. Nội dung chương dựa trên bài báo khoa học đã nộp tại hội nghị SOMET 2026 [13].

3.1 Phát biểu bài toán

Các văn bản quy phạm Việt Nam thường có cấu trúc phân cấp sáu cấp: Văn bản, Chương, Mục (nếu có), Điều, Khoản, Điểm với các tham chiếu chéo xuyên suốt giữa các tài liệu. Truy xuất đoạn văn bản truyền thống coi tài liệu như tập hợp phẳng, do đó không thể khai thác cấu trúc phân cấp này hoặc thực hiện suy luận đa bước.

Mỗi tài liệu được mô hình hóa dưới dạng cây có gốc (rooted tree), trong đó các nút tương ứng với các cấp cấu trúc và các cạnh biểu diễn quan hệ cha-con. Toàn bộ kho tài liệu gồm m văn bản hình thành một Document Forest:

$$\mathcal{F} = \{T_1, T_2, \dots, T_m\} \quad (3.1)$$


được bổ sung các cạnh tham chiếu chéo liên kết các điều khoản giữa các cây. Mỗi nút được gán một định danh hợp thành mã hóa vị trí trong cấu trúc phân cấp, ví dụ 59-2020-QH14: c2 cho Chương 2, 59-2020-QH14: d5 cho Điều 5, cho phép tham chiếu chéo rõ ràng giữa các cây.

3.2. Tổng quan kiến trúc hệ thống

Bài toán truy xuất: Cho truy vấn q của người dùng, trả về danh sách xếp hạng k điều khoản liên quan nhất từ $\mathcal{F}$. Mức chi tiết ở cấp điều khoản (article-level) là cần thiết vì các quy chế đào tạo tại Việt Nam tổ chức nội dung theo đơn vị Điều, mỗi Điều quy định một vấn đề cụ thể (ví dụ: Điều 24 quy định điều kiện bảo vệ luận văn, Điều 29 quy định điều kiện tốt nghiệp). Khi trả lời câu hỏi của học viên, hệ thống cần trích dẫn chính xác đến từng Điều để đảm bảo tính minh bạch và có thể kiểm chứng, thay vì trả về các đoạn văn bản tùy ý không rõ nguồn gốc. Yêu cầu này cũng áp dụng tương tự cho miền pháp luật, nơi các điều khoản luật là đơn vị trích dẫn nhỏ nhất trong thực tiễn tư vấn pháp lý.

3.2 Tổng quan kiến trúc hệ thống

Kiến trúc hệ thống được chia thành hai pha: pha ngoại tuyến (offline phase) và pha trực tuyến (online phase), như minh họa trong Hình 3.1.



Hình 3.1: Kiến trúc hệ thống truy xuất ba tầng. Pha ngoại tuyến (trái): xây dựng mô hình tri thức từ văn bản quy phạm. Pha trực tuyến (phải): xử lý truy vấn qua Tầng 1 (duyet cây cấu trúc), Tầng 2 (truy xuất ngữ nghĩa hai cấp), và Tầng 3 (hợp nhất RRF với mở rộng KG).

3.2.1 Pha ngoại tuyến

Pha ngoại tuyến xây dựng bốn bộ biểu diễn tri thức từ kho tài liệu thô, tuân theo phương pháp kỹ thuật tri thức [23]. Các biểu diễn này phục vụ cho từng tầng truy xuất khác nhau trong pha trực tuyến.

Document Forest. Mỗi văn bản quy phạm được phân tích thành cây có gốc theo cấu trúc phân cấp 6 cấp: Văn bản → Chương → Mục → Điều → Khoản → Điểm. Bộ phân tích cú pháp (parser) sử dụng regex nhận diện các dấu hiệu phân cấp tiếng Việt (“Chương I”, “Điều 5”, “Khoản 1”, “Điểm a”) để xây dựng cây cấu trúc. Mỗi nút trong cây lưu trữ: mã định danh (node_id), loại nút (node_type), tên, nội dung văn bản, và metadata (số hiệu, ngày ban hành, cơ quan ban hành).

Mỗi nút được gán một định danh hợp thành (composite ID) mã hóa vị trí trong cấu trúc phân cấp theo quy tắc {số_hiệu_văn_bản}:{tiền_tổ}{số}. Bảng 3.1 trình bày quy tắc đặt tiền tố cho từng cấp. Ví dụ, Điều 5 của Luật Doanh nghiệp 2020 có định danh 59-2020-QH14:d5, Chương 3 của Quy chế 1393 có định danh 1393-QD-DHQQ:c3. Sơ đồ này cho phép: tra cứu nút trong thời gian $O(1)$ qua bảng băm, tham chiếu chéo rõ ràng giữa các cây (ví dụ: 270-QD-DHCNTT:d24 tham chiếu đến 1393-QD-DHQQ:d25), và con người có thể đọc hiểu trực tiếp mà không cần truy ngược cây.

Bảng 3.1: Quy tắc đặt định danh nút trong Document Forest

Cấp	Tiền tố	Ví dụ
Văn bản (gốc)	–	59-2020-QH14
Chương	c	59-2020-QH14:c2
Mục	s	59-2020-QH14:c2s1
Điều	d	59-2020-QH14:d5
Khoản	k	59-2020-QH14:d5k1
Điểm	p	59-2020-QH14:d5k1pa

Tập hợp tất cả các cây tạo thành Document Forest – cấu trúc dữ liệu trung tâm cho Tầng 1 (duyet cây). Các cạnh tham chiếu chéo (cross-reference) được phát hiện bằng pattern matching trên các chuỗi trích dẫn (ví dụ: “theo Điều 5 Quy chế 270”, “căn cứ Khoản 1 Điều 24”) và liên kết các điều khoản giữa các tài liệu khác nhau. Mỗi tham chiếu được phân loại theo kiểu: THAM_CHIẾU (dẫn chiếu), SỬA_ĐỔI (amend), hoặc THAY_THẾ (replace).

3.2. Tổng quan kiến trúc hệ thống

Knowledge Graph. Knowledge Graph (KG) được xây dựng qua quy trình bốn bước:

1. **Trích xuất thực thể và quan hệ:** Với mỗi điều khoản, LLM trích xuất đồng thời thực thể và quan hệ trong một lời gọi duy nhất (theo phong cách LightRAG [9]). Prompt hướng dẫn LLM trích xuất đầy đủ các thực thể quan trọng, ghi evidence (trích dẫn nguyên văn) cho mỗi quan hệ, và sử dụng tên thực thể chính xác như trong văn bản (xem Phụ lục D, Bảng D.1).
2. **Khử trùng lặp thực thể:** Trong quá trình trích xuất, bộ khử trùng lặp (deduplicator) sử dụng Jaro-Winkler similarity (ngưỡng $\geq 0,98$) kết hợp chuẩn hóa dạng chính tắc tiếng Việt (loại dấu, chuẩn hóa viết tắt pháp lý) để nhận diện và hợp nhất các thực thể trùng lặp ngay trong quá trình xây dựng. Thực thể được hợp nhất lưu giữ tất cả alias, source ID, và mô tả dài nhất.
3. **Xây dựng ontology:** Hệ thống tự động sinh ontology miền từ dữ liệu KG đã trích xuất, sử dụng LLM để phân loại thực thể thành các lớp OWL có ý nghĩa. Ontology định nghĩa 14 loại thực thể (Action, Legal Term, Organization, Penalty, Condition, Person Role, v.v.) với phân cấp tối đa 4 cấp. Mỗi lớp có tên tiếng Anh (chuẩn OWL) kèm nhãn và mô tả tiếng Việt. Ontology xuất ra định dạng Turtle (.ttl) và JSON.
4. **Tinh chỉnh bởi chuyên gia:** Sau khi tự động trích xuất, KG được rà soát và tinh chỉnh thủ công bởi chuyên gia miền (expert-in-the-loop). Quá trình này bao gồm: thêm các quan hệ bị thiếu (đặc biệt là REFERENCES giữa các điều khoản liên quan), xóa các thực thể nhiễu, và điều chỉnh trọng số quan hệ (STRONG/WEAK) để cải thiện chất lượng truy xuất.

Bảng 3.2 tóm tắt thống kê Knowledge Graph được xây dựng. Hệ thống cũng phân loại quan hệ theo mức độ: quan hệ mạnh (STRONG) gồm references, requires, depends_on – các quan hệ này được sử dụng cho mở rộng KG trong Tầng 3, trong khi quan hệ yếu (WEAK) như related_to, is_a chỉ dùng cho tính điểm ngữ nghĩa trong Tầng 2.

Tóm tắt chương và điều. Để Tầng 1 có thể chọn nhánh mà không cần đọc toàn bộ nội dung điều khoản, hệ thống sinh tóm tắt cho từng chương và điều bằng LLM. Tóm tắt chương bao gồm phạm vi điều khoản (ví dụ: “Điều 1–16”) và danh sách từ khóa đặc trưng do LLM trích xuất từ nội dung các điều trong chương. Tóm tắt điều gồm tiêu đề và

3.2. Tổng quan kiến trúc hệ thống

Bảng 3.2: Thống kê Knowledge Graph

Loại thực thể	Số lượng	Loại quan hệ	Số lượng	Cấu trúc	Số lượng
Tổng thực thể	5.936	Tổng quan hệ	5.963	Nút	9.226
Action	1.903	requires	1.377	Tài liệu	13
Legal Term	1.632	applies_to	810	Chương	77
Organization	500	has_authority	506	Điều khoản	840
Legal Reference	451	references	434	Tham chiếu chéo	168
Khác (9 loại)	1.450	Khác (52 loại)	2.506		


các từ khóa chính. Các mô tả này được sử dụng trực tiếp làm thuộc tính description của các nút trong Document Forest, cung cấp đủ ngữ cảnh cho LLM đưa ra quyết định chọn nhánh trong Loop 1 và Loop 2 (xem prompt chi tiết tại Phụ lục D, Bảng D.2 và D.3).

Nhóm miền và cụm chủ đề. Hai cấu trúc bổ sung được xây dựng để phục vụ các tầng truy xuất khác nhau:

- **Nhóm miền (Domain Groups):** Các tài liệu được phân nhóm tự động dựa trên sự trùng khớp của từ khóa (Jaccard similarity ở mức âm tiết). Thuật toán lấy các văn bản gốc làm neo (anchor), sau đó gán các nghị định, thông tư liên quan vào nhóm có độ trùng khớp từ khóa cao nhất. Mỗi nhóm miền lưu nhãn, danh sách từ khóa đặc trưng, và ID các tài liệu thành viên. Cấu trúc này phục vụ Loop 0 của Tầng 1 để nhanh chóng thu hẹp không gian tìm kiếm từ toàn bộ kho xuống nhóm miền phù hợp. Để dễ dàng mở rộng sau này khi áp dụng phương pháp trên nhiều domain và tài liệu khác nhau hơn.
- **Cụm chủ đề (Theme Clusters):** Các thực thể KG được nhóm thành các cụm chủ đề bằng cách phân hoạch đồ thị KG thành các đồ thị con liên thông, sau đó sử dụng LLM để trích xuất tên chủ đề, mô tả, và từ khóa tìm kiếm cho mỗi cụm. Vector nhúng trung bình của các thực thể trong cụm được tính và lưu vào chỉ mục FAISS để phục vụ tìm kiếm ngữ nghĩa nhanh. Cấu trúc này phục vụ high-level (theme matching) của Tầng 2.

Hình 3.2 minh họa toàn bộ quy trình xây dựng tri thức ngoại tuyến với ba track song song: Document Forest, Knowledge Graph, và các cấu trúc bổ sung phục vụ từng tầng

truy xuất.



Hình 3.2: Quy trình xây dựng tri thức ngoại tuyến. Track 1 phân tích cấu trúc văn bản thành Document Forest. Track 2 xây dựng Knowledge Graph qua 4 bước. Track 3 tạo Domain Groups và Theme Clusters phục vụ tìm kiếm.

3.2.2 Pha trực tuyến

Pha trực tuyến đầu tiên phân tích truy vấn (phân loại ý định, mở rộng viết tắt, trích xuất thực thể giống), sau đó xử lý qua ba tầng truy xuất: duyệt cây hướng dẫn bởi LLM (Tầng 1), truy xuất ngữ nghĩa hai cấp trên Knowledge Graph (Tầng 2), và hợp nhất với mở rộng Knowledge Graph (Tầng 3).

3.3 Phân tích truy vấn


Với truy vấn thô q từ người dùng, bộ phân tích truy vấn thực hiện ba bước:

- 1. Phân loại ý định (Intent Classification):** Phân loại truy vấn thành một trong sáu loại ý định gồm Xử phạt (Penalty), Định nghĩa (Definition), Thủ tục (Procedure), Yêu cầu (Requirement), Tham chiếu (Reference), Chung (General), thông qua regex tiếng Việt với LLM fallback.
- 2. Mở rộng viết tắt (Abbreviation Expansion):** Mở rộng các viết tắt chuyên ngành, ví dụ: TNHH → trách nhiệm hữu hạn, CTCP → công ty cổ phần.

3.4. Tầng 1: Duyệt cây cấu trúc hướng dẫn bởi LLM

3. **Trích xuất thực thể giống (Seed Entity Extraction):** Trích xuất các tham chiếu điều khoản, tham chiếu luật và từ khóa pháp lý.

Các đầu ra này được đưa trực tiếp vào các tầng truy xuất: Tầng 1 sử dụng truy vấn đã mở rộng cho duyệt cây, Tầng 2 sử dụng thực thể giống để khởi tạo PageRank và nhãn ý định để điều chỉnh trọng số cạnh (1,0 cho quan hệ chính, 0,5 cho quan hệ khác). Hình 3.3 minh họa ba bước phân tích với ví dụ cụ thể.



Hình 3.3: Pipeline phân tích truy vấn gồm ba bước: phân loại ý định (6 loại), mở rộng viết tắt, và trích xuất thực thể giống. Mỗi đầu ra phục vụ một tầng truy xuất khác nhau.

3.4 Tầng 1: Duyệt cây cấu trúc hướng dẫn bởi LLM

Tầng 1 nhận truy vấn đã mở rộng và Document Forest, trả về danh sách xếp hạng các điều khoản ứng viên với điểm cấu trúc. Lấy cảm hứng từ PageIndex [25], Tầng 1 sử dụng suy luận LLM để duyệt cây từ trên xuống (top-down) qua ba vòng lặp thu hẹp dần không gian tìm kiếm: từ toàn bộ kho văn bản xuống tài liệu, rồi chương, rồi điều khoản cụ thể. Mỗi vòng lặp tạo ra một chuỗi suy luận (reasoning trace) phục vụ khả năng giải thích (interpretability).

Vòng lặp 0: Chọn tài liệu. Khi kho có nhiều hơn một tài liệu, LLM được cung cấp danh sách các nhóm miền (domain group) cùng từ khóa đặc trưng đã tính toán trước trong giai đoạn offline. LLM chọn nhóm miền phù hợp nhất với truy vấn, từ đó xác định tập tài liệu liên quan. Nếu nhóm miền chứa nhiều hơn 5 tài liệu, LLM được gọi lần hai

3.4. Tầng 1: Duyệt cây cấu trúc hướng dẫn bởi LLM

để thu hẹp xuống tối đa 5 tài liệu dựa trên tóm tắt phạm vi (scope preview) của từng tài liệu.

Cơ chế fallback: nếu LLM không trả về kết quả hợp lệ, hệ thống sử dụng đối sánh từ khóa (keyword overlap) giữa các âm tiết trong truy vấn và từ khóa miền để chọn nhóm có điểm trùng khớp cao nhất.

Vòng lặp 1: Chọn chương. LLM nhận cấu trúc tài liệu gồm tên và mô tả tóm tắt của từng chương, cùng với truy vấn (có gợi ý ngữ nghĩa từ bước mở rộng truy vấn nếu có). LLM chọn tối đa 8 chương phù hợp nhất và trả về JSON chứa danh sách index cùng độ tin cậy (xem Phụ lục D, Bảng D.4). Nhiệt độ (temperature) = 0,0 đảm bảo kết quả xác định, loại bỏ phương sai giữa các lần chạy.

Hai cơ chế bổ sung:

- **Tự động bổ sung chương “Quy định chung”:** Các chương chứa định nghĩa thuật ngữ và phạm vi áp dụng (thường là Chương 1) được tự động thêm vào nếu LLM chưa chọn, vì các chương này thường chứa các điều khoản nền tảng cần thiết để hiểu các điều khoản chuyên biệt.
- **Mở rộng khi độ tin cậy thấp:** Nếu LLM chỉ chọn một chương với độ tin cậy (confidence) < 0,98, hệ thống gọi LLM lần hai với các chương còn lại để xem xét bổ sung thêm, giảm rủi ro bỏ sót khi truy vấn mơ hồ.

Cơ chế fallback: nếu LLM thất bại, hệ thống chọn các chương có nhiều điều khoản nhất (thay vì chọn theo thứ tự xuất hiện), vì các chương lớn thường bao phủ nhiều chủ đề hơn.

Vòng lặp 2: Chọn điều khoản. Với mỗi chương đã chọn, LLM nhận danh sách điều khoản kèm tóm tắt (tiêu đề, từ khóa) và chọn tối đa 7 điều khoản phù hợp (xem Phụ lục D, Bảng D.5). Nhiệt độ = 0,0 cho kết quả ổn định. Trước khi gọi LLM, hệ thống bổ sung hai tín hiệu hỗ trợ vào thông tin mỗi điều khoản:

- **Điểm ngữ nghĩa (semantic score):** Cosine similarity giữa vector nhúng truy vấn và vector nhúng của tiêu đề + từ khóa điều khoản, chuyển thành thứ hạng tương đối (semantic_rank, 1 = phù hợp nhất).
- **Điểm KG (dual score):** Điểm từ Tầng 2 (DualLevel Retriever) chạy ở chế độ low-level, chuyển thành thứ hạng tương đối (dual_rank). Tín hiệu này giúp LLM ưu tiên các điều khoản có liên kết KG mạnh với truy vấn.


3.5. Tầng 2: Truy xuất ngữ nghĩa hai cấp

Prompt hướng dẫn LLM ưu tiên các điều khoản có thứ hạng thấp (rank thấp = phù hợp hơn), nhưng LLM vẫn có quyền quyết định cuối cùng dựa trên nội dung tóm tắt.

Sau khi tất cả chương được xử lý, các điều khoản được gộp, loại trùng lặp, và giới hạn tổng số lượng. Điểm tin cậy tổng hợp của Tầng 1 được tính bằng trung bình có trọng số giữa confidence của Loop 1 ($\times 0,45$) và trung bình confidence của Loop 2 ($\times 0,55$), giới hạn tối đa 0,95.

Logic retry (3 lần, exponential backoff) được áp dụng cho tất cả lời gọi LLM để xử lý các lỗi tạm thời từ proxy hoặc API.

Hình 3.4 minh họa quá trình duyệt cây ba vòng lặp với một truy vấn ví dụ từ miền quy định đào tạo.



Hình 3.4: Minh họa quá trình duyệt cây ba vòng lặp với truy vấn “Điều kiện để được bảo vệ luận văn thạc sĩ?”. Các nút xanh là được chọn bởi LLM, các nút xám bị loại. Loop 0 chọn 3/5 tài liệu, Loop 1 thu hẹp xuống các chương liên quan, Loop 2 xác định các điều khoản cụ thể.

3.5 Tầng 2: Truy xuất ngữ nghĩa hai cấp

Tầng 2 nhận các thực thể đã trích xuất và nhân ý định từ bước phân tích truy vấn (Mục 3.3), kết hợp với Knowledge Graph để tính điểm ngữ nghĩa cho từng điều khoản. Khác với Tầng 1 sử dụng LLM để duyệt cây top-down, Tầng 2 tiếp cận bottom-up: xuất phát từ các thực thể trong KG, lan truyền điểm số qua các quan hệ ontology để tìm các điều khoản liên quan. Tầng này hoạt động ở hai cấp: low-level (entity-specific) tập trung

3.5. Tầng 2: Truy xuất ngữ nghĩa hai cấp

vào từng thực thể cụ thể, và high-level (conceptual) nắm bắt mối liên hệ chủ đề giữa các cụm khái niệm.

3.5.1 Low-level (Entity-specific)

Low-level tính bốn tín hiệu độc lập cho mỗi điều khoản, mỗi tín hiệu nắm bắt một khía cạnh khác nhau của mức độ liên quan:

1. Keyphrase Matching

So khớp các thuật ngữ trong truy vấn với tên thực thể KG bằng cách tạo n-gram âm tiết (unigram, bigram, trigram) từ truy vấn. Với mỗi thực thể, điểm cơ bản được tính bằng tỷ lệ trùng khớp âm tiết ($|Q \cap E|/|Q|$), sau đó được tăng cường bởi các hệ số nhân: $\times 1,5$ khi trùng khớp ≥ 2 âm tiết hoặc khi khớp cụm bigram/trigram, $\times 1,5$ khi tên thực thể xuất hiện trong truy vấn (exact match), $\times 1,2$ khi truy vấn là chuỗi con của tên thực thể. Điểm keyphrase cấp điều khoản được tổng hợp từ tất cả thực thể thuộc điều khoản đó:

$$s_{kp}(a) = \max_{e \in E_a} s(e) + 0,3 \cdot \ln(n + 1) \cdot \bar{s} \quad (3.2)$$

trong đó E_a là tập thực thể thuộc điều khoản a , n là số thực thể có điểm dương, và $\bar{s}$ là điểm trung bình. Thành phần logarithmic khuyến khích các điều khoản chứa nhiều thực thể liên quan mà không để số lượng lớn áp đảo chất lượng khớp cao nhất.

2. Semantic Similarity

Tính cosine similarity giữa vector nhúng (embedding) của truy vấn và vector nhúng của từng điều khoản, sử dụng mô hình sentence-transformers MiniLM-L12-v2. Tín hiệu này bổ sung cho đối sánh từ khóa bằng cách nắm bắt sự tương đồng ngữ nghĩa ngay cả khi thuật ngữ không trùng khớp chính xác, ví dụ “hủy bỏ nghị quyết” và “vô hiệu quyết định” có thể có điểm keyphrase thấp nhưng điểm semantic cao.

3. Intent-aware PPR

Sử dụng thuật toán Personalized PageRank [10] để lan truyền điểm số qua cấu trúc đồ thị KG. Quá trình gồm ba bước:

3.5. Tầng 2: Truy xuất ngữ nghĩa hai cấp

- a) Chọn các thực thể hạt giống (seed): chỉ những thực thể có điểm keyphrase $\geq 0,3$ được chọn làm seed, đảm bảo chỉ các thực thể liên quan cao mới khởi tạo quá trình lan truyền.
- b) Tính vector nhúng truy vấn để điều chỉnh trọng số cạnh theo ý định: các cạnh dẫn đến thực thể có embedding gần với truy vấn được tăng trọng số.
- c) Thực hiện PPR với công thức:

$$\text{PPR}(v) = (1 - \alpha) \sum_{u \in \mathcal{N}(v)} \frac{w(u, v) \cdot \text{PPR}(u)}{d(u)} + \alpha \cdot p(v) \quad (3.3)$$

trong đó $\alpha = 0,15$ là xác suất teleport, $w(u, v)$ là trọng số cạnh điều chỉnh theo ý định truy vấn, $d(u)$ là bậc ra có trọng số, và $p(v)$ là vector cá nhân hóa (phân bố đều trên các seed). Điểm PPR cấp thực thể được quy về cấp điều khoản bằng cách lấy giá trị lớn nhất trong các thực thể thuộc điều khoản. Ưu điểm của PPR là phát hiện các điều khoản liên quan gián tiếp qua nhiều bước nhảy (multi-hop) trong đồ thị, ví dụ từ thực thể “học phí” qua cạnh requires đến “nghĩa vụ tài chính” rồi đến “chế tài vi phạm”.

4. Concept Matching

Mở rộng kết quả keyphrase ở mức lớp ontology. Đầu tiên, thu thập các loại thực thể (entity type) từ tất cả thực thể đã khớp keyphrase, mỗi loại được gán trọng số bằng điểm keyphrase cao nhất của các thực thể thuộc loại đó. Sau đó, duyệt tất cả điều khoản trong KG: với mỗi điều khoản, tính tổng trọng số các loại thực thể trùng khớp, chia cho tổng số thực thể của điều khoản để chuẩn hóa:

$$s_{\text{con}}(a) = \min \left(1, \frac{\sum_{e \in E_a} w_{\text{type}}(\text{type}(e))}{|E_a|} \right) \quad (3.4)$$

Cơ chế này cho phép phát hiện các điều khoản có cùng loại thực thể nhưng dùng tên gọi khác, ví dụ keyphrase khớp với thực thể “cổ đông sáng lập” (loại CHỦ_THỂ) sẽ lan truyền điểm đến các điều khoản chứa “thành viên hợp danh” cùng loại CHỦ_THỂ.

Tổng hợp điểm Low-level

Bốn tín hiệu được kết hợp bằng tổng có trọng số ($w_{kp} = 0,05$, $w_{sem} = 0,20$, $w_{ppr} = 0,25$, $w_{con} = 0,20$) và chuẩn hóa về $[0, 1]$ bằng cách chia cho giá trị lớn nhất. Trọng số thấp của keyphrase (0,05) phản ánh vai trò “kích hoạt” của nó: keyphrase chủ yếu cung cấp seed cho PPR và loại thực thể cho concept matching, thay vì trực tiếp quyết định xếp hạng. PPR nhận trọng số cao nhất (0,25) vì khả năng nắm bắt quan hệ cấu trúc đồ thị.

3.5.2 High-level (Conceptual)

High-level hoạt động ở cấp độ trừu tượng hơn, tìm kiếm các điều khoản liên quan thông qua cụm chủ đề (theme cluster) thay vì từng thực thể riêng lẻ.

1. Theme Matching

Trong giai đoạn offline, các thực thể KG được nhóm thành các cụm chủ đề dựa trên embedding similarity (ví dụ: cụm “quản trị công ty” gồm các thực thể về cổ đông, hội đồng quản trị, ban kiểm soát). Mỗi cụm được biểu diễn bởi vector nhúng trung bình. Tại thời điểm truy vấn, vector nhúng truy vấn được so khớp với top-10 cụm chủ đề gần nhất. Từ mỗi cụm khớp, các thực thể nguồn (source entities) được truy ngược về điều khoản chứa chúng, gán điểm theme bằng cosine similarity giữa truy vấn và cụm.

2. Hierarchy Expansion

Từ các điều khoản đã tìm được qua theme matching, thu thập các loại thực thể (entity type) và tìm thêm các điều khoản khác chứa cùng loại thực thể nhưng chưa xuất hiện trong kết quả theme. Hệ số suy giảm 0,5 được áp dụng cho các điều khoản mở rộng này để đảm bảo chúng xếp hạng thấp hơn kết quả theme trực tiếp. Ví dụ: nếu theme matching tìm được điều khoản về “xử phạt vi phạm” (chứa thực thể loại CHẾ_TÀI), hierarchy expansion sẽ bổ sung các điều khoản khác cũng chứa thực thể loại CHẾ_TÀI với điểm giảm một nửa.


3.5.3 Hợp nhất Low-level và High-level

Hai cấp được hợp nhất bằng tổng có trọng số:

3.5. Tầng 2: Truy xuất ngữ nghĩa hai cấp

$$s(a) = 0,70 \cdot s_{\text{low}}(a) + 0,15 \cdot s_{\text{theme}}(a) + 0,15 \cdot s_{\text{hier}}(a) \quad (3.5)$$

Tỷ lệ 70–30 giữa low-level và high-level phản ánh độ tin cậy cao hơn của các tín hiệu entity-specific (keyphrase, PPR, concept) so với tín hiệu chủ đề trừu tượng. Các điều khoản có điểm tổng hợp dưới ngưỡng 0,1 bị loại bỏ để giảm nhiễu trước khi chuyển sang Tầng 3. Hình 3.5 minh họa kiến trúc hai cấp của Tầng 2 với sáu tín hiệu và cách hợp nhất.



Hình 3.5: Kiến trúc Tầng 2 hai cấp. Low-level gồm 4 tín hiệu (Keyphrase, Semantic, Intent-aware PPR, Concept Matching) với minh họa PPR lan truyền qua KG. High-level gồm Theme Matching và Hierarchy Expansion. Công thức hợp nhất 70%–30% ưu tiên tín hiệu entity-specific.

3.6 Tầng 3: Hợp nhất RRF với mở rộng Knowledge Graph

Tầng 3 tạo ra danh sách top- k điều khoản cuối cùng thông qua ba bước: mở rộng Knowledge Graph, RRF, và các cơ chế điều chỉnh.

3.6.1 Mở rộng Knowledge Graph

Các điều khoản hạt giống từ Tầng 1 và Tầng 2 được mở rộng thông qua các cạnh quan hệ của Knowledge Graph. Các quan hệ mạnh (STRONG), bao gồm references, requires, depends_on, được duyệt theo hai hướng:

- Khác chương (cross-chapter): tối đa 5 điều khoản.
- Cùng chương (same-chapter): tối đa 2 điều khoản.

Bộ lọc liên quan ngữ nghĩa (cosine similarity $\geq 0,4$) được áp dụng để loại bỏ nhiễu. Kết quả mở rộng tạo thành danh sách xếp hạng thứ ba bên cạnh Tầng 1 và Tầng 2.

3.6.2 Reciprocal Rank Fusion

Ba danh sách được hợp nhất sử dụng Reciprocal Rank Fusion [3]:

$$\text{RRF}(d) = \sum_{s \in \{T_1, T_2, \text{KG}\}} w_s \cdot \frac{1}{k + \text{rank}_s(d)} \quad (3.6)$$


trong đó $k = 60$ và trọng số nguồn $w_{T_1} = 1,2$, $w_{T_2} = 0,7$, $w_{\text{KG}} = 1,0$ được thiết lập thực nghiệm trên tập phát triển và chia sẻ trên tất cả các miền. Duyệt cây nhận trọng số cao nhất vì cung cấp tín hiệu cấu trúc đáng tin cậy nhất.

3.6.3 Các cơ chế điều chỉnh

Hệ thống áp dụng ba cơ chế điều chỉnh điểm sau hợp nhất RRF:

1. **Trọng số cây động (Dynamic Tree Weight):** Khi $\geq 50\%$ điều khoản từ duyệt cây là điều khoản chung (generic, penalty $\leq 0,25$), trọng số cây giảm từ 1,2 xuống 0,7 và trọng số KG tăng từ 1,0 lên 1,3.

3.6. Tầng 3: Hợp nhất RRF với mở rộng Knowledge Graph



Hình 3.6: Minh họa luồng xử lý end-to-end với truy vấn “Học viên cần đáp ứng điều kiện gì về ngoại ngữ để tốt nghiệp?”. Tầng 1 tìm Đ.29, Đ.25, Đ.24 qua duyệt cây. Tầng 2 xác nhận Đ.25 và Đ.29 qua PPR, bổ sung Đ.8. Tầng 3 nhận seeds từ Tầng 1 và Tầng 2, mở rộng KG thêm Đ.5, sau đó hợp nhất RRF cả ba danh sách với thưởng đồng thuận và hệ số phạt.

3.6. Tầng 3: Hợp nhất RRF với mở rộng Knowledge Graph

2. Hệ số phạt (Penalty):

- Procedural penalty ($0,35\times$): Các điều khoản thủ tục/tổ chức ít liên quan đến câu hỏi nội dung.
- Noise penalty ($0,2\times$): Các điều khoản có tỷ lệ đúng 0% trong benchmark.
- Generic penalty ($0,15\times$): Các điều khoản phạm vi/định nghĩa chung (d1–d3).

3. Thưởng đồng thuận (Agreement Bonus): Điều khoản xuất hiện trong ≥ 2 tầng nhận thưởng $+0,005$ cho mỗi tầng bổ sung, tăng cường tín hiệu đồng thuận xuyên tầng.

Danh sách xếp hạng cuối cùng được truyền cho LLM để sinh câu trả lời có trích dẫn nguồn.

Hình 3.6 minh họa toàn bộ luồng xử lý qua ba tầng với một truy vấn ví dụ, thể hiện cách các tầng bổ sung lẫn nhau để tìm ra các điều khoản liên quan.

Chương 4

Thiết kế hệ thống và thử nghiệm

Chương này trình bày yêu cầu hệ thống, kiến trúc triển khai, và kết quả thử nghiệm trên hai nghiên cứu trường hợp: pháp luật Việt Nam (400 câu hỏi) và quy định đào tạo (130 câu hỏi), cùng phân tích ablation đánh giá đóng góp của từng thành phần.

4.1 Yêu cầu hệ thống

4.1.1 Yêu cầu chức năng

1. **Tiếp nhận truy vấn:** Người dùng nhập câu hỏi bằng tiếng Việt về quy định đào tạo hoặc pháp luật.
2. **Truy xuất điều khoản:** Hệ thống trả về danh sách top-K điều khoản liên quan nhất, kèm trích dẫn nguồn (tên văn bản, số điều).
3. **Sinh câu trả lời:** LLM tổng hợp thông tin từ các điều khoản đã truy xuất thành câu trả lời tự nhiên.
4. **Hỗ trợ đa miền:** Hệ thống hoạt động trên nhiều lĩnh vực (doanh nghiệp, giao thông, đào tạo) với cùng pipeline và tham số.

4.1.2 Yêu cầu phi chức năng

1. **Độ chính xác:** $\text{Hit}@10 \geq 85\%$ trên các bộ đánh giá.
2. **Thời gian phản hồi:** Dưới 15 giây cho mỗi truy vấn.

3. **Khả năng mở rộng:** Hỗ trợ thêm miền mới mà không cần thay đổi kiến trúc core.
4. **Khả năng giải thích:** Mỗi kết quả kèm reasoning trace từ quá trình duyệt cây.

4.2 Kiến trúc hệ thống

4.2.1 Tổng quan kiến trúc triển khai

Hệ thống được triển khai theo kiến trúc hai pha (offline–online) với các thành phần chính:

- **Pha ngoại tuyến (Offline):**
 - Document Parser: phân tích văn bản thành cây cấu trúc
 - KG Builder: xây dựng Knowledge Graph qua LLM + expert review
 - Summary Generator: sinh tóm tắt chương và điều
 - Embedding Indexer: tạo chỉ mục vector cho tìm kiếm ngữ nghĩa
- **Pha trực tuyến (Online):**
 - Query Analyzer: phân loại ý định, mở rộng viết tắt, trích xuất thực thể
 - Tree Traversal Retriever: duyệt cây 3 vòng lặp (Tầng 1)
 - Dual-Level Retriever: truy xuất ngữ nghĩa hai cấp (Tầng 2)
 - Semantic Bridge RRF Merger: hợp nhất RRF + mở rộng KG (Tầng 3)
 - Answer Generator: sinh câu trả lời từ LLM

4.2.2 Công nghệ sử dụng

Bảng 4.1 liệt kê các công nghệ chính được sử dụng.

4.2.3 Chi tiết triển khai

Document parsing. Văn bản pháp luật được phân tích bằng bộ regex tùy chỉnh nhận diện các dấu hiệu phân cấp tiếng Việt (“Phần”, “Chương”, “Mục”, “Điều”, “Khoản”, “Điểm”) và xây dựng cây cấu trúc 6 cấp. Các văn bản scan (PDF) của miền giáo dục

Bảng 4.1: Công nghệ sử dụng trong hệ thống

Thành phần	Công nghệ
Ngôn ngữ lập trình	Python 3.11
LLM	Claude Sonnet 4 (Anthropic API)
Sentence Embeddings	paraphrase-multilingual-MiniLM-L12-v2 [20]
Vector Search	FAISS
Cache	SQLite (WAL mode)
LLM Proxy	OAuth, Rate Limiting
Cấu hình	YAML (default.yaml, education.yaml)

(118 trang) được số hóa qua LLM Vision OCR. Tham chiếu chéo được trích xuất qua pattern matching trên chuỗi trích dẫn điều khoản, tạo ra 168 cạnh liên tài liệu.

Knowledge graph. Trích xuất thực thể và nhận diện quan hệ sử dụng Claude 3.5 Haiku qua Anthropic API, với một lời gọi LLM cho mỗi điều khoản. Chuẩn hóa slug tiếng Việt loại bỏ dấu và gộp biến thể thành điệu thành định danh thực thể chuẩn. Bộ giải quyết thực thể đa bước (exact match, synonym resolution, abbreviation expansion) khử trùng lặp các thực thể tương đương. Sau trích xuất tự động, bước tinh chỉnh expert-in-the-loop sửa các quan hệ nhận diện sai và bổ sung liên kết chuyên ngành mà LLM bỏ sót.

Online query processing. Duyệt cây và chọn điều khoản sử dụng Claude Sonnet 4. Sentence embeddings được tính bằng paraphrase-multilingual-MiniLM-L12-v2 [20], mô hình đa ngôn ngữ 384 chiều. PPR được tính lặp (tối đa 50 vòng, tolerance 10^{-6} , damping $\alpha = 0,15$). Tất cả phản hồi LLM được cache trong SQLite để đảm bảo tái lập và tiết kiệm chi phí.

Parallel execution. Hệ thống hỗ trợ thực thi song song với 10 worker đồng thời, đạt tăng tốc $6,5\times$ ($226s \rightarrow 35s$ cho 10 truy vấn). SQLite cache sử dụng WAL mode + timeout 30s cho truy cập đồng thời an toàn.

4.3 Kết quả thử nghiệm

4.3.1 Các chỉ số đánh giá

Hệ thống được đánh giá bằng hai chỉ số truy xuất tiêu chuẩn [15]:

Top-k Hit Rate đo tỷ lệ truy vấn mà ít nhất một điều khoản liên quan xuất hiện trong top-k kết quả:

$$\text{Hit}@k = \frac{1}{|Q|} \sum_q \mathbf{1}[\exists a \in R_q : \text{rank}(a) \leq k] \quad (4.1)$$

Mean Reciprocal Rank trung bình hạng nghịch đảo của kết quả liên quan đầu tiên:

$$\text{MRR} = \frac{1}{|Q|} \sum_q \left(\min_{a \in R_q} \text{rank}(a) \right)^{-1} \quad (4.2)$$

Kết quả được báo cáo tại $k \in \{1, 5, 10, 20\}$, với Hit@10 và MRR là chỉ số chính. Hit@10 được ưu tiên vì trong pipeline RAG, LLM xác nhận ngữ cảnh đã truy xuất, nên một điều khoản đúng trong mười ứng viên là đủ.

4.3.2 Các hệ thống đối sánh

- **BM25** [21]: Truy xuất từ vựng với tokenization mức âm tiết.
- **TF-IDF** [15]: Truy xuất dựa trên tần suất từ–nghịch đảo tần suất tài liệu.
- **NaiveRAG** [20]: Truy xuất dày đặc, không reranking.
- **LightRAG** [9]: Truy xuất hybrid KG (vector + duyệt đồ thị).
- **RAPTOR** [22]: Summary Tree đệ quy với truy xuất embedding.
- **PageIndex** [25]: Tìm kiếm cây phân cấp hai bước hướng dẫn bởi LLM.

Tất cả hệ thống sử dụng Sonnet 4 cho các lời gọi LLM và truy xuất từ cùng kho tài liệu.

4.3.3 Case Study 1: Pháp luật Việt Nam

Dữ liệu. Bộ dữ liệu pháp luật gồm 400 câu hỏi khó (hard-400) thuộc hai lĩnh vực: luật doanh nghiệp (200 câu, chủ yếu từ Luật 59/2020/QH14 và 9 nghị định) và luật giao thông (200 câu, từ Luật 36/2024/QH15 và 2 nghị định xử phạt). Câu hỏi được thu thập từ các nhóm tư vấn pháp lý trên Facebook, với mức độ khó cao đòi hỏi suy luận đa bước.

Kết quả. Bảng 4.2 trình bày kết quả trên bộ dữ liệu pháp luật 400 câu hỏi.

Bảng 4.2: Tỷ lệ Hit (%) trên miền pháp luật (400 câu hỏi)

Phương pháp	Hit@1	Hit@5	Hit@10	Hit@20	MRR
<i>Truy xuất truyền thống</i>					
BM25	8,8	30,8	47,5	66,2	0,200
TF-IDF	10,0	29,2	45,8	64,5	0,207
<i>Hệ thống RAG</i>					
NaiveRAG [20]	5,8	22,8	32,8	51,8	0,146
LightRAG [9]	9,2	25,5	39,8	47,8	0,173
RAPTOR [22]	7,8	25,2	41,0	54,5	0,170
PageIndex [25]	41,5	76,2	84,8	90,2	0,559
3-Tier (ours)	49,2	74,5	92,2	94,8	0,603

Hệ thống đề xuất đạt 92,2% Hit@10 ($\pm 0,3\%$) và MRR = 0,603 qua ba lần chạy độc lập, vượt PageIndex 7,4 điểm phần trăm (pp) và BM25 44,7 pp. PageIndex đạt Hit@5 cao hơn (76,2% so với 74,5%). Đây là sự đánh đổi giữa độ chính xác và độ phủ vốn có trong RRF: các điều khoản từ mở rộng KG đôi khi đẩy kết quả cây từ vị trí 4–5 xuống 6–7, nhưng phục hồi nội dung tham chiếu chéo mà PageIndex không bao giờ đạt tới, tạo ra mức tăng 17,7 pp từ vị trí 6–10 so với chỉ 8,6 pp của PageIndex.

Các baseline RAG (NaiveRAG 32,8%, LightRAG 39,8%, RAPTOR 41,0%) thấp hơn cả BM25 (47,5%): embeddings đa mục đích thiếu từ vựng pháp lý tiếng Việt, trích xuất KG chung tạo nhiễu, và tóm tắt RAPTOR mất chi tiết mức điều khoản.

Kết quả theo miền. Bảng 4.3 trình bày kết quả Hit@10 theo từng miền.

Hệ thống vượt trội trên cả ba miền. Luật giao thông đạt cao nhất (98,0%) nhờ ánh xạ trực tiếp vi phạm–hình phạt. Luật doanh nghiệp khó hơn (86,5%) do tham chiếu xuyên nghị định. Quy định đào tạo (87,9%) cho thấy biên độ lớn nhất so với PageIndex (+13,3

4.3. Kết quả thử nghiệm

Bảng 4.3: Hit@10 (%) theo miền trên ba lĩnh vực

Phương pháp	Doanh nghiệp (200)	Giao thông (200)	Đào tạo (130)
NaiveRAG	29,9	35,5	50,0
LightRAG	20,3	58,6	56,9
RAPTOR	18,5	63,5	53,8
BM25	31,5	63,1	70,0
PageIndex	76,6	92,6	74,6
3-Tier (ours)	86,5	98,0	87,9
So với PageIndex	+9,9	+5,4	+13,3

pp), nhờ truy xuất ngữ nghĩa bổ sung các thuật ngữ mà duyệt cây bỏ sót. Cùng pipeline và siêu tham số được sử dụng trên cả ba miền mà không điều chỉnh riêng.

4.3.4 Case Study 2: Quy định đào tạo

Dữ liệu. Bộ dữ liệu quy định đào tạo gồm 130 câu hỏi, 5 văn bản quy chế (109 điều khoản). Cấu hình hệ thống sử dụng file `config/education.yaml` với LLM proxy hỗ trợ OAuth và rate limiting.

Kết quả chi tiết. Hệ thống đạt 87,9% Hit@10 ($\pm 0,5$ pp qua 3 lần chạy: 87,7%, 87,7%, 88,5%) và MRR = 0,594. So sánh với các hệ thống đối sánh:

Bảng 4.4: Kết quả trên miền quy định đào tạo (130 câu hỏi)

Phương pháp	Hit@10	MRR
BM25	70,0	0,355
NaiveRAG	50,0	0,214
LightRAG	56,9	0,251
RAPTOR	53,8	0,218
PageIndex	74,6	0,441
3-Tier (ours)	87,9	0,594

Hệ thống vượt PageIndex 13,3 pp và RAPTOR 34,1 pp trên miền đào tạo. BM25 (70,0%) hoạt động tốt hơn các RAG baseline nhờ trùng khớp thuật ngữ tiếng Việt ở mức âm tiết, nhưng không đủ cho các câu hỏi multi-hop. Các cải tiến quan trọng cho miền

đào tạo bao gồm: temperature = 0,0 cho Loop 1 (loại bỏ variance), fallback thông minh chọn chương có nhiều điều khoản nhất, và retry logic (3 lần, exponential backoff).

4.3.5 Ablation Study

Để đánh giá đóng góp của từng thành phần, thử nghiệm ablation được thực hiện trên bộ hard-200 (150 doanh nghiệp + 50 giao thông). Bảng 4.5 trình bày kết quả.

Bảng 4.5: Kết quả ablation study (Hit@10 %, trung bình 3 lần chạy)

Cấu hình	Hit@10	Δ
Full (3-Tier + RRF)	88,0	—
Tree only (Tầng 1)	64,8	−23,2
Dual only (Tầng 2)	33,0	−55,0
Simple merge (không RRF)	72,8	−15,2
Tree + KG + expand (không Tầng 2)	73,0	−15,0

Phân tích:

- **RRF là thành phần quan trọng nhất:** Hợp nhất RRF đóng góp +23,2 pp so với chỉ dùng duyệt cây, và +15,2 pp so với simple merge. Không có RRF, mở rộng KG và Tầng 2 gần như không đóng góp.
- **Duyệt cây là backbone:** Tầng 1 alone (64,8%) vượt xa Tầng 2 alone (33,0%), xác nhận rằng tín hiệu cấu trúc đáng tin cậy hơn tín hiệu ngữ nghĩa cho văn bản pháp lý có cấu trúc.
- **Tầng 2 bổ trợ qua RRF:** Dual-Level alone yếu (33,0%), nhưng khi kết hợp qua RRF đóng góp +15,0 pp so với Tree+KG, cho thấy giá trị bổ trợ thông qua RRF.
- **Variance thấp:** Tất cả cấu hình có variance $\pm 0,2$ – $0,5$ pp qua 3 lần chạy, xác nhận tính ổn định.

4.3.6 Phân tích lỗi

Trong 31 câu hỏi bị bỏ sót (7,8%), 27 thuộc lĩnh vực doanh nghiệp:

- **Phụ thuộc xuyên nghị định (6 câu):** Câu hỏi yêu cầu kết hợp thông tin từ luật chính và nghị định hướng dẫn.
- **Ngoài kho tài liệu (4 câu):** Câu hỏi về hộ kinh doanh, nằm ngoài phạm vi kho tài liệu.
- **Đa điều khoản (14 câu):** Câu hỏi yêu cầu >2 điều khoản, chủ yếu liên kết bằng chuỗi suy luận pháp lý ngầm thay vì tham chiếu chéo rõ ràng.
- **Lỗi Loop 0 (3 câu):** Chọn sai tài liệu ở bước đầu tiên.

4.4 Ứng dụng minh họa

Để minh họa khả năng ứng dụng thực tế của hệ thống truy xuất, một ứng dụng chatbot tra cứu quy định đào tạo đã được xây dựng dưới dạng giao diện web tương tác. Ứng dụng kết nối trực tiếp với pipeline truy xuất 3-Tier KG-RAG và sử dụng LLM để sinh câu trả lời theo phương pháp phân tích IRAC (Issue–Rule–Application–Conclusion), phục vụ trực tiếp nhu cầu tra cứu quy chế đào tạo sau đại học của học viên cao học.

4.4.1 Kiến trúc ứng dụng

Ứng dụng được xây dựng trên nền tảng Chainlit 2.0, một framework mã nguồn mở cho giao diện chatbot hỗ trợ streaming. Kiến trúc gồm ba thành phần chính:

- **Giao diện web (Chainlit):** Giao diện chat hỗ trợ streaming token-by-token, hiển thị trạng thái truy xuất theo thời gian thực và panel nguồn trích dẫn với breadcrumb vị trí trong văn bản.
- **Cầu nối bất đồng bộ (Async Bridge):** Pipeline truy xuất 3-Tier hoạt động đồng bộ (synchronous), trong khi Chainlit yêu cầu xử lý bất đồng bộ (asynchronous) để duy trì kết nối WebSocket. Một cầu nối sử dụng `threading.Thread` và `asyncio.Queue` chuyển tiếp sự kiện từ pipeline đồng bộ sang vòng lặp sự kiện bất đồng bộ, tránh chặn (block) giao diện trong suốt quá trình truy xuất (30–60 giây).
- **Pipeline truy xuất (3-Tier KG-RAG):** Pipeline sinh ba loại sự kiện: status (cập nhật trạng thái truy xuất), metadata (trích dẫn, reasoning trace, độ tin cậy) và token (nội dung câu trả lời streaming).

4.4.2 Phương pháp sinh câu trả lời IRAC

IRAC (Issue–Rule–Application–Conclusion) là phương pháp phân tích có nguồn gốc từ lĩnh vực pháp lý, được sử dụng rộng rãi trong đào tạo luật và tư vấn pháp luật. Phương pháp này phù hợp cho bài toán hỏi đáp quy định vì đảm bảo câu trả lời có cấu trúc rõ ràng, trích dẫn căn cứ cụ thể và kết luận dứt khoát. Bốn phần của IRAC gồm:

- 1. **Issue (Vấn đề):** Xác định vấn đề cần giải đáp từ câu hỏi của người dùng.
- 2. **Rule (Căn cứ quy chế):** Trích dẫn chính xác Điều, Khoản, Điểm của quy chế/quyết định liên quan từ ngữ cảnh đã truy xuất.
- 3. **Application (Phân tích áp dụng):** Giải thích cụ thể quy định áp dụng vào tình huống như thế nào, chỉ ra mối liên hệ giữa quy chế và câu hỏi thực tế.
- 4. **Conclusion (Kết luận):** Trả lời trực tiếp câu hỏi, tổng hợp các điều kiện hoặc quy trình.

Hệ thống sử dụng prompt engineering để hướng dẫn LLM sinh câu trả lời theo cấu trúc IRAC. Prompt được tùy biến theo miền ứng dụng, với hai điểm khác biệt chính giữa miền pháp luật và miền đào tạo:

Bảng 4.6: So sánh prompt IRAC giữa miền pháp luật và miền đào tạo

Thành phần	Miền pháp luật	Miền đào tạo
Vai trò	Luật sư tư vấn	Chuyên viên tư vấn đào tạo UIT
Thuật ngữ	Căn cứ pháp luật, điều luật	Căn cứ quy chế, quy định
Trích dẫn	Văn bản pháp luật	QĐ cấp ĐHQG vs QĐ cấp trường
Ưu tiên	Không phân cấp	Ưu tiên QĐ cấp trường (QĐ 270)
Giọng văn	Trang trọng, pháp lý	Thân thiện, hướng dẫn học viên

Việc tùy biến prompt theo miền cho phép hệ thống sử dụng cùng pipeline truy xuất nhưng sinh câu trả lời phù hợp với ngữ cảnh và đối tượng người dùng của từng lĩnh vực.


4.4.3 Các tính năng chính

- 1. **Phản hồi trạng thái theo thời gian thực:** Trong quá trình truy xuất, hệ thống hiển thị trạng thái cập nhật trực tiếp qua ba giai đoạn: “Đang phân tích câu hỏi”,

4.4. Ứng dụng minh họa

“Đang tìm kiếm quy định liên quan” và “Đang tổng hợp câu trả lời” (Hình 4.2). Thông báo tự động biến mất khi câu trả lời bắt đầu streaming. Điều này giải quyết vấn đề UX quan trọng khi thời gian truy xuất kéo dài 30–60 giây.

2. **Streaming câu trả lời:** Câu trả lời được sinh theo phương pháp IRAC và streaming token-by-token đến giao diện, giúp người dùng bắt đầu đọc ngay khi LLM sinh văn bản mà không cần đợi toàn bộ câu trả lời (Hình 4.3).
3. **Trích dẫn nguồn với breadcrumb:** Panel bên phải hiển thị nội dung gốc của các điều khoản được trích dẫn, với breadcrumb vị trí rõ ràng (tên văn bản, chương, điều) và đường phân cách giữa các nguồn. Người dùng có thể đối chiếu trực tiếp giữa tư vấn và nguyên văn quy định (Hình 4.4). Ngoài ra, lộ trình truy xuất 3 vòng lặp (Loop 0–2) cũng được hiển thị minh bạch để người dùng hiểu quá trình tìm kiếm của hệ thống (Hình 4.5).
4. **Hỗ trợ đa miền:** Ứng dụng hỗ trợ chuyển đổi giữa các miền (quy định đào tạo, pháp luật) thông qua biến môi trường cấu hình, sử dụng cùng giao diện và pipeline.




Hình 4.1: Màn hình chào mừng với lĩnh vực “Quy định đào tạo” và các câu hỏi gợi ý về quy chế đào tạo sau đại học


4.4.4 Ví dụ minh họa tiêu biểu

Phần này trình bày các ví dụ cụ thể từ kết quả thử nghiệm trên miền quy định đào tạo, minh họa điểm mạnh và hạn chế của hệ thống qua so sánh trực tiếp với các baseline.

4.4. Ứng dụng minh họa



Hình 4.2: Trạng thái truy xuất “Đang tổng hợp câu trả lời...” hiển thị trực tiếp trong khi hệ thống xử lý câu hỏi



Hình 4.3: Câu trả lời IRAC cho câu hỏi “Điều kiện bảo vệ luận văn thạc sĩ?” với panel nguồn quy định gốc (phải)

Các câu hỏi được trích nguyên văn từ diễn đàn học viên cao học UIT.


Ví dụ 1: Truy xuất cross-document – yêu cầu ngoại ngữ

Câu hỏi: “Chứng chỉ TOEIC do các trường ĐH, CĐ trong nước cấp (không phải của trung tâm khảo thí của ETS cấp) có được công nhận anh văn đầu ra Cao học không ạ?”


Gold articles: Điều 6 QĐ 1393 (ĐHQG-HCM, yêu cầu ngoại ngữ đầu ra) và Điều 9 QĐ 270 (UIT, quy định bổ sung về chứng chỉ được chấp nhận).

Phân tích: Câu hỏi yêu cầu kết hợp thông tin từ hai văn bản ở hai tầng quản lý khác nhau: QĐ 1393 (ĐHQG-HCM) quy định yêu cầu chung, còn QĐ 270 (UIT) bổ sung

4.4. Ứng dụng minh họa



Hình 4.4: Panel trích dẫn nguồn hiển thị nguyên văn điều khoản với breadcrumb vị trí (văn bản → chương → điều)



Hình 4.5: Lộ trình truy xuất 3 vòng lặp: Loop 0 chọn tài liệu, Loop 1 chọn chương, Loop 2 truy xuất điều khoản

danh sách chứng chỉ cụ thể được chấp nhận. Tầng 1 chọn đúng cả hai tài liệu ở Loop 0, sau đó Loop 1 thu hẹp vào các chương về ngoại ngữ. KG expansion bổ sung Điều 25 (QĐ 270) qua cạnh references từ Điều 9. Hệ thống đạt $MRR = 1,0$ với cả hai gold articles trong top 3. PageIndex tìm được Điều 6 nhưng bỏ sót Điều 9 của UIT (chỉ tìm trong QĐ 1393 và QĐ 160). RAPTOR không tìm được cả hai, truy xuất phân tán giữa các điều khoản không liên quan.

4.4. Ứng dụng minh họa

Bảng 4.7: So sánh top-5 kết quả truy xuất giữa các hệ thống – Ví dụ 1

Rank	3-Tier KG-RAG	PageIndex	RAPTOR
1	1393:d6 ✓	1393:d24	160:d37
2	1393:d23	1393:d6 ✓	851:d2
3	270:d9 ✓	1393:d2	1393:d33
4	270:d25	160:d25	270:d38
5	160:d37	160:d9	160:d19

Ví dụ 2: Truy xuất đa điều khoản – hoãn chuyên đề

Câu hỏi: “Cho em hỏi nếu hoãn 1 hoặc 2 môn chuyên đề thôi thì vẫn làm theo mẫu trên vẫn được phải không ạ? Nếu đã tham gia học rồi nhưng không nộp bài thì tính sao?”

Gold articles: Điều 8 QĐ 1393 (quy định về chương trình đào tạo), Điều 11 QĐ 270 (quy chế học vụ) và Điều 18 QĐ 270 (quy định về chuyên đề).

Bảng 4.8: So sánh top-5 kết quả truy xuất giữa các hệ thống – Ví dụ 2

Rank	3-Tier KG-RAG	PageIndex	RAPTOR
1	1393:d8 ✓	1393:d25	270:d38
2	1393:d24	1393:d13	1393:d33
3	270:d11 ✓	1393:d24	270:d26
4	270:d16	1393:d26	1393:d13
5	270:d18 ✓	1393:d14	160:d20

Phân tích: Hệ thống truy xuất tất cả 3 gold articles trong top 5, MRR = 1,0. Câu hỏi đòi hỏi liên kết giữa quy định chung về chương trình đào tạo (QĐ 1393) và quy chế riêng của UIT về học vụ và chuyên đề (QĐ 270). Tầng 1 duyệt đúng cả hai tài liệu, KG expansion liên kết Điều 11 với Điều 18 qua quan hệ references. PageIndex chỉ tìm trong QĐ 1393, bỏ sót hoàn toàn QĐ 270. RAPTOR truy xuất các điều khoản về hình thức xử lý (QĐ 270:d38, d26) thay vì các quy định gốc.

Ví dụ 3: Truy xuất đăng ký chuyên đề – đăng ký môn học khác khóa

Câu hỏi: “Cho em hỏi là khóa 5 có được phép đăng ký học những môn chuyên đề của Khóa 4 không?”

Gold articles: Điều 8 QĐ 1393 (chương trình đào tạo), Điều 11, Điều 2, Điều 4 QĐ 270 (quy chế học vụ, phạm vi áp dụng, hình thức đào tạo).

Phân tích: Hệ thống đặt 2/4 gold articles (Đ.8 QĐ 1393 và Đ.11 QĐ 270) ở rank 1–2, MRR = 1,0. Câu hỏi ngắn, không chứa thuật ngữ chuyên ngành nhưng đòi hỏi hiểu biết về quy trình đăng ký khác khóa. Tầng 1 chọn đúng chương về đào tạo trong cả hai văn bản. Cả PageIndex và RAPTOR đều không truy xuất được Điều 8 hoặc Điều 11 trong top 10.

Bảng 4.9: So sánh top-5 kết quả truy xuất giữa các hệ thống – Ví dụ 3

Rank	3-Tier KG-RAG	PageIndex	RAPTOR
1	1393:d8 ✓	160:d17	160:d12
2	270:d11 ✓	1393:d13	270:d25
3	160:d13	160:d13	1393:d9
4	160:d18	1393:d4	160:d9
5	270:d17	270:d16	1393:d3

Ví dụ 4: Trường hợp thất bại – câu hỏi thiếu ngữ cảnh

Câu hỏi: “Thầy/cô cho em hỏi, nếu như học ngành CNTT, sau này đăng ký học Tiến sĩ với bằng Thạc sĩ ngành CNTT thì trường có chấp nhận không ạ?”

Gold articles: Điều 6 QĐ 1393 (điều kiện trình độ đầu vào) và Điều 9 QĐ 270 (yêu cầu bổ sung).

Kết quả: Hệ thống truy xuất Điều 10, 11 QĐ 1393 (chương trình Tiến sĩ) và Điều 13, 17 QĐ 270 (nghiên cứu sinh) trong top 5 – đúng chủ đề Tiến sĩ nhưng sai điều khoản cụ thể. PageIndex lại truy xuất đúng nhờ tìm kiếm rộng hơn trên QĐ 270.

Nguyên nhân: Câu hỏi hỏi về “Tiến sĩ” nhưng gold articles nằm ở phần “điều kiện đầu vào Thạc sĩ” (Điều 6, Điều 9). Nội dung hai điều khoản này bao gồm cả điều kiện cho chương trình Tiến sĩ nhưng tiêu đề chương và tóm tắt chỉ đề cập “Thạc sĩ”, khiến

4.4. Ứng dụng minh họa

Loop 1 chọn nhầm chương. Đây là hạn chế của duyệt cây khi tiêu đề chương không phản ánh đầy đủ nội dung bên trong.

Chương 5

Kết luận và hướng phát triển

Chương này tổng kết các kết quả đạt được của luận văn, thảo luận các hạn chế hiện tại và đề xuất hướng phát triển tương lai.

5.1 Kết quả đề tài

Luận văn đã đề xuất và xây dựng thành công kiến trúc 3-Tier KG-RAG, một hệ thống truy xuất kiến thức ba tầng kết hợp ontology, Knowledge Graph và Document Forest cho bài toán hỏi đáp quy định đào tạo và pháp luật Việt Nam. Các kết quả chính bao gồm:

- 1. Ontology và Knowledge Graph chuyên biệt:** Xây dựng ontology miền với 14 loại thực thể sử dụng OWL, phân cấp 4 cấp với ánh xạ nhãn tiếng Việt. Knowledge Graph kết quả chứa 5.936 thực thể và 5.963 quan hệ thuộc 56 loại quan hệ, cùng Document Forest gồm 9.226 nút cấu trúc từ 13 tài liệu. Quy trình xây dựng KG bán tự động kết hợp trích xuất LLM với tinh chỉnh expert-in-the-loop đảm bảo chất lượng và khả năng truy vết nguồn gốc.
- 2. Kiến trúc truy xuất ba tầng:** Thiết kế và triển khai pipeline truy xuất thống nhất gồm ba tầng: duyệt cây cấu trúc hướng dẫn bởi LLM (Tầng 1), truy xuất ngữ nghĩa hai cấp với PPR nhận biết ý định (Tầng 2), và hợp nhất RRF với mở rộng Knowledge Graph (Tầng 3). Cùng pipeline và siêu tham số hoạt động trên cả ba miền mà không cần điều chỉnh riêng.
- 3. Kết quả đánh giá vượt trội:** Trên 530 câu hỏi chuyên gia thuộc ba lĩnh vực:

- Pháp luật (400 câu): 92,2% Hit@10, MRR = 0,603, vượt PageIndex +7,4 pp và RAPTOR +51,2 pp.
 - Doanh nghiệp (200 câu): 86,5% Hit@10, vượt PageIndex +9,9 pp.
 - Giao thông (200 câu): 98,0% Hit@10, vượt PageIndex +5,4 pp.
 - Quy định đào tạo (130 câu): 87,9% Hit@10, MRR = 0,594, vượt PageIndex +13,3 pp và RAPTOR +34,1 pp.
4. **Bộ kiểm thử tiếng Việt:** Xây dựng bộ câu hỏi kiểm thử gồm 530 câu hỏi với gold articles được gán nhãn bởi chuyên gia, bao gồm các tình huống single-hop, multi-hop và reasoning phức tạp.
 5. **Ứng dụng chatbot minh họa:** Xây dựng ứng dụng chatbot web tương tác tích hợp trực tiếp với pipeline truy xuất, hỗ trợ streaming câu trả lời theo phương pháp IRAC, hiển thị trích dẫn nguồn quy định và quá trình suy luận. Ứng dụng hoạt động trên cả desktop và thiết bị di động, phục vụ trực tiếp nhu cầu tra cứu quy chế đào tạo sau đại học của học viên cao học.
 6. **Bài báo khoa học:** Kết quả nghiên cứu đã được nộp dưới dạng bài báo tại hội nghị quốc tế SOMET 2026 (đang trong quá trình phản biện).

5.2 Hạn chế

Mặc dù đạt được các kết quả đáng khích lệ, hệ thống vẫn còn một số hạn chế:

1. **Phụ thuộc LLM và độ trễ:** Tầng 1 yêu cầu nhiều lời gọi LLM tuần tự (Loop 0 → Loop 1 → Loop 2), dẫn đến thời gian phản hồi khoảng 7 giây mỗi truy vấn. Chất lượng hệ thống phụ thuộc trực tiếp vào khả năng suy luận của LLM sử dụng, tạo ra rủi ro khi LLM cập nhật hoặc thay đổi.
2. **Quy mô bộ kiểm thử miền đào tạo:** Bộ kiểm thử miền đào tạo gồm 130 câu hỏi, đủ để đánh giá xu hướng nhưng có thể mở rộng để tăng tính đại diện thống kê.
3. **KG xây dựng thủ công:** Bước tinh chỉnh expert-in-the-loop đảm bảo chất lượng nhưng khó mở rộng quy mô. Hệ thống chưa hỗ trợ cập nhật KG tự động khi quy định thay đổi.

4. **Chưa đánh giá chất lượng sinh câu trả lời:** Luận văn tập trung đánh giá chất lượng truy xuất (Hit@k, MRR). Chất lượng câu trả lời sinh bởi LLM từ ngữ cảnh đã truy xuất chưa được đánh giá bằng các chỉ số như BLEU, ROUGE hay BERTScore.
5. **Hiệu quả trên nhóm luật về doanh nghiệp thấp hơn:** 27/31 câu hỏi bị bỏ sót thuộc nhóm luật về doanh nghiệp, chủ yếu do chuỗi suy luận pháp lý ngầm giữa các nghị định không có tham chiếu chéo rõ ràng.

5.3 Hướng phát triển

Dựa trên các hạn chế và tiềm năng đã xác định, các hướng phát triển tương lai bao gồm:

1. **Giảm độ trễ LLM:** Nghiên cứu thực thi song song các lời gọi LLM trong Tầng 1 và model distillation để giảm chi phí tính toán. Các mô hình nhỏ hơn có thể được fine-tune cho tác vụ chọn chương/điều khoản cụ thể.
2. **Cập nhật KG tự động:** Phát triển pipeline tự động phát hiện thay đổi trong văn bản quy phạm và cập nhật Knowledge Graph tương ứng, giảm thiểu sự can thiệp thủ công.
3. **GNN-RAG:** Khi Knowledge Graph đủ lớn, nghiên cứu tích hợp Graph Neural Networks [16] cho truy xuất trên KG, khai thác cấu trúc đồ thị sâu hơn thay vì chỉ duyệt cạnh đơn.
4. **Đa phương thức:** Mở rộng hệ thống hỗ trợ xử lý biểu mẫu, sơ đồ quy trình (flowchart thủ tục) và bảng biểu trong văn bản quy phạm.
5. **Mở rộng miền:** Áp dụng hệ thống cho các miền quy định khác như đào tạo đại học, tuyển sinh, hoặc các lĩnh vực pháp luật bổ sung (lao động, thuế, đất đai).
6. **Triển khai production:** Nâng cấp ứng dụng chatbot hiện tại thành hệ thống production với xác thực người dùng, lưu lịch sử hội thoại, phản hồi từ người dùng (feedback loop) để cải thiện chất lượng truy xuất, và tích hợp vào cổng thông tin đào tạo.

7. **Đánh giá chất lượng sinh câu trả lời:** Bổ sung đánh giá end-to-end bằng các chỉ số sinh văn bản (BLEU, ROUGE, BERTScore) và đánh giá chủ quan bởi chuyên gia miền.

Phụ lục A

Danh sách quy chế đào tạo

Phụ lục này liệt kê chi tiết 5 quy chế đào tạo thạc sĩ được sử dụng trong phạm vi nghiên cứu.

A.1 QĐ 270/QĐ-ĐHCNTT: Quy chế đào tạo trình độ thạc sĩ của UIT

- **Ngày ban hành:** 25/04/2022
- **Cơ quan ban hành:** Trường Đại học Công nghệ Thông tin, ĐHQG-HCM
- **Phạm vi:** Áp dụng cho tất cả học viên cao học tại UIT
- **Cấu trúc:** 8 chương, 35 điều
- **Nội dung chính:**
 - Chương 1: Quy định chung (Điều 1–4)
 - Chương 2: Tuyển sinh (Điều 5–8)
 - Chương 3: Tổ chức đào tạo (Điều 9–14)
 - Chương 4: Đánh giá kết quả học tập (Điều 15–19)
 - Chương 5: Luận văn thạc sĩ (Điều 20–26)
 - Chương 6: Xét và công nhận tốt nghiệp (Điều 27–30)
 - Chương 7: Quyền và nghĩa vụ của học viên (Điều 31–33)
 - Chương 8: Điều khoản thi hành (Điều 34–35)

A.2 QĐ 160/QĐ-ĐHQG: Quy chế đào tạo ThS ĐHQG-HCM (khóa 2021)

- **Ngày ban hành:** 24/03/2017
- **Cơ quan ban hành:** ĐHQG-HCM
- **Phạm vi:** Áp dụng cho học viên khóa 2021 tại các trường thành viên ĐHQG-HCM
- **Cấu trúc:** 7 chương, 28 điều

A.3 QĐ 1393/QĐ-ĐHQG: Quy chế đào tạo ThS ĐHQG-HCM (khóa 2022+)

- **Ngày ban hành:** 03/11/2021
- **Cơ quan ban hành:** ĐHQG-HCM
- **Phạm vi:** Áp dụng cho học viên từ khóa 2022 trở đi tại các trường thành viên
- **Cấu trúc:** 8 chương, 32 điều
- **Thay thế:** QĐ 160/QĐ-ĐHQG

A.4 QĐ 218/QĐ-ĐHQG: Sửa đổi bổ sung quy định GVHD

- **Ngày ban hành:** 15/03/2024
- **Cơ quan ban hành:** ĐHQG-HCM
- **Phạm vi:** Sửa đổi, bổ sung quy định về giáo viên hướng dẫn
- **Cấu trúc:** 2 chương, 6 điều
- **Bổ sung cho:** QĐ 1393/QĐ-ĐHQG

A.5 QĐ 851/QĐ-ĐHCNTT: Quy định liên chính học thuật

- **Ngày ban hành:** 14/08/2024
- **Cơ quan ban hành:** Trường Đại học Công nghệ Thông tin, ĐHQG-HCM
- **Phạm vi:** Áp dụng cho học viên cao học UIT
- **Cấu trúc:** 3 chương, 8 điều
- **Nội dung chính:** Định nghĩa đạo văn, các hình thức vi phạm liên chính học thuật, mức xử lý kỷ luật

Phụ lục B

Bộ câu hỏi kiểm thử mẫu

Phụ lục này trình bày 20 câu hỏi mẫu từ bộ kiểm thử miền quy định đào tạo (130 câu hỏi) và miền pháp luật (400 câu hỏi).

B.1 Câu hỏi miền quy định đào tạo

B.2 Câu hỏi miền pháp luật

Bảng B.1: Câu hỏi mẫu miền quy định đào tạo

STT Câu hỏi	Gold Articles	Loại
1 Thời gian đào tạo thạc sĩ tối đa là bao lâu?	QĐ270: Điều 5	Single
2 Điều kiện để được bảo vệ luận văn thạc sĩ?	QĐ270: Điều 24	Single
3 Điểm trung bình tích lũy tối thiểu để tốt nghiệp?	QĐ270: Điều 29	Single
4 Yêu cầu ngoại ngữ đầu ra cho học viên cao học?	QĐ1393: Điều 25	Single
5 GVHD được hướng dẫn tối đa bao nhiêu học viên cùng lúc?	QĐ218: Điều 4	Single
6 Thế nào là hành vi đạo văn trong luận văn?	QĐ851: Điều 3	Single
7 Học viên bị cảnh báo học vụ khi nào?	QĐ270: Điều 18	Single
8 Nếu học viên hết thời gian gia hạn mà chưa bảo vệ luận văn thì sao?	QĐ270: Điều 5, 30	Multi
9 Học viên khóa 2021 có được áp dụng quy chế 1393 không?	QĐ1393: Điều 32	Reason
10 Điều kiện để được gia hạn thời gian đào tạo?	QĐ270: Điều 5, 6	Multi

Bảng B.2: Câu hỏi mẫu miền pháp luật

STT	Câu hỏi	Gold Articles	Loại
1	Vốn điều lệ tối thiểu của công ty chứng khoán?	59-QH14: Điều 175	Single
2	Mức phạt khi vượt đèn đỏ đối với ô tô?	168-NĐ: Điều 6	Single
3	Thành viên góp vốn bằng tài sản thì phải làm gì?	59-QH14: Điều 34, 36	Multi
4	Nếu thành viên vay tiền góp vốn rồi rút vốn thì bị xử phạt thế nào?	59-QH14: Điều 16, 47	Multi
5	Điều kiện để chuyển đổi công ty TNHH thành công ty cổ phần?	59-QH14: Điều 202	Single
6	Mức phạt khi lái xe say rượu có nồng độ cồn vượt mức?	168-NĐ: Điều 5	Single
7	Quyền và nghĩa vụ của thành viên hội đồng quản trị?	59-QH14: Điều 153, 165	Multi
8	Hộ kinh doanh có phải đăng ký kinh doanh không?	Ngoài corpus	–
9	Mức phạt khi không mang giấy phép lái xe?	168-NĐ: Điều 21	Single
10	Quy trình giải thể doanh nghiệp tự nguyện?	59-QH14: Điều 207, 208	Multi

Phụ lục C

Mẫu quan hệ đồ thị tri thức

Phụ lục này trình bày một số quan hệ tiêu biểu trong đồ thị tri thức đã xây dựng, minh họa các loại quan hệ chính giữa các thực thể.

C.1 Quan hệ REFERENCES (Tham chiếu)

Quan hệ REFERENCES biểu diễn sự dẫn chiếu giữa các điều khoản, là quan hệ quan trọng nhất cho suy luận đa bước.

Bảng C.1: Mẫu quan hệ REFERENCES trong KG

Điều khoản nguồn	Điều khoản đích	Ngữ cảnh
59-QH14:d47	59-QH14:d16	Nghĩa vụ thành viên → Hành vi bị cấm
59-QH14:d23	59-QH14:d22	Quyền thành viên → Nghĩa vụ góp vốn
59-QH14:d81	59-QH14:d80	Hợp ĐHĐCĐ → Triệu tập họp
59-QH14:d86	59-QH14:d84	Biểu quyết → Điều kiện họp
59-QH14:d33	59-QH14:d35	Góp vốn → Chuyển nhượng vốn
59-QH14:d11	59-QH14:d9	Giấy phép → Điều kiện kinh doanh

C.2 Quan hệ REQUIRES (Yêu cầu)

Quan hệ REQUIRES biểu diễn điều kiện tiên quyết giữa các hành động hoặc thực thể.

Bảng C.2: Mẫu quan hệ REQUIRES trong KG

Thực thể nguồn	Thực thể đích	Ý nghĩa
bao_ve_luan_van	dat_diem_ngoai_ngu	Bảo vệ LV yêu cầu đạt ngoại ngữ
tot_nghiep	diem_tb_tich_luy_5.0	Tốt nghiệp yêu cầu ĐTB $\geq 5,0$
dang_ky_de_tai	gvhd_dong_y	Đăng ký đề tài cần GVHD đồng ý
thanh_lap_cong_ty	von_dieu_le	Thành lập CT cần vốn điều lệ
chuyen_doi_loai_hinh	nghi_quyet_hdtv	Chuyển đổi cần NQ HĐTV

C.3 Thống kê loại quan hệ

Bảng C.3: Top 10 loại quan hệ trong đồ thị tri thức

STT	Loại quan hệ	Số lượng
1	requires	1.377
2	applies_to	810
3	has_authority	506
4	references	434
5	defines	398
6	has_condition	356
7	governs	312
8	has_penalty	287
9	depends_on	245
10	belongs_to	238
Tổng (56 loại)		5.963

Phụ lục D

Prompt LLM sử dụng trong hệ thống

Phụ lục này trình bày các prompt LLM chính được sử dụng trong hệ thống, bao gồm pha ngoại tuyến (trích xuất thực thể, sinh tóm tắt), pha trực tuyến (duyet cây ba vòng lặp), và sinh câu trả lời theo phương pháp IRAC.

D.1 Trích xuất thực thể và quan hệ (Pha ngoại tuyến)

Prompt này được sử dụng để trích xuất đồng thời thực thể và quan hệ từ mỗi điều khoản trong giai đoạn xây dựng Knowledge Graph (Mục 3.2).

D.2 Sinh tóm tắt chương (Pha ngoại tuyến)

Prompt này được sử dụng để sinh mô tả giàu từ khóa cho mỗi chương, phục vụ bước chọn nhánh trong Loop 1 của Tầng 1 (Mục 3.4).

D.3 Sinh tóm tắt điều khoản (Pha ngoại tuyến)

Prompt này sinh từ khóa cho từng điều khoản, phục vụ bước chọn điều trong Loop 2 của Tầng 1.

D.3. Sinh tóm tắt điều khoản (Pha ngoại tuyến)

Bảng D.1: Prompt trích xuất thực thể và quan hệ

System: Bạn là chuyên gia trích xuất thông tin pháp lý Việt Nam. Trích xuất TẤT CẢ thực thể và quan hệ từ văn bản pháp luật.

Loại thực thể:

- TỔ_CHỨC: Công ty, doanh nghiệp, cơ quan
- VAI_TRÒ: Chức vụ, vai trò
- THUẬT_NGỮ: Thuật ngữ pháp lý
- THAM_CHIẾU: Điều khoản luật
- TIỀN_TỆ: Số tiền
- TỶ_LỆ: Phần trăm
- THỜI_HẠN: Thời gian
- ĐIỀU_KIỆN: Điều kiện áp dụng
- HÀNH_VI: Hành động pháp lý
- CHẾ_TÀI: Hình phạt, chế tài

Loại quan hệ:

YÊU_CẦU, CÓ QUYỀN, CÔNG_NHẬN, BẢO_ĐẢM, CHO_PHÉP, BAO_GỒM, ĐỊNH_NGHĨA, THAM_CHIẾU, ÁP_DỤNG, ĐIỀU_KIỆN, LIÊN QUAN

Quy tắc:

1. Trích xuất ĐẦY ĐỦ các thực thể quan trọng
2. Mỗi quan hệ phải có EVIDENCE (trích dẫn nguyên văn)
3. Dùng tên thực thể CHÍNH XÁC như trong văn bản
4. Nếu có viết tắt, ghi cả viết tắt lẫn tên đầy đủ

Văn bản: {text}

Output: {"entities": [{"name", "type", "description"}],
"relations": [{"source", "target", "predicate", "evidence"}]}

D.3. Sinh tóm tắt điều khoản (Pha ngoại tuyến)

Bảng D.2: Prompt sinh tóm tắt chương

System: Bạn là chuyên gia pháp lý Việt Nam. Phân tích chương sau để trích xuất từ khóa tìm kiếm.

VĂN BẢN: {doc_title}

CHƯƠNG: {chapter_title}

PHẠM VI: {article_range}

DANH SÁCH ĐIỀU LUẬT: {article_context}

Hãy liệt kê 40–50 TỪ KHÓA TÌM KIẾM bao gồm:

1. TỪ KHÓA CHÍNH: Trích xuất từ tiêu đề các điều luật
2. CÂU HỎI/TÌNH HUỐNG: Các câu hỏi thực tế người dùng có thể hỏi
3. VIẾT TẮT PHỔ BIẾN: Các từ viết tắt trong lĩnh vực này
4. HÀNH ĐỘNG/THỦ TỤC: Các động từ và hành động cụ thể
5. TỪ ĐỒNG NGHĨA/INFORMAL: Cách nói thông thường
6. KHÁI NIỆM LIÊN QUAN: Các khái niệm pháp lý liên quan

Trả lời NGẮN GỌN, chỉ liệt kê các từ khóa cách nhau bằng dấu phẩy.

Bảng D.3: Prompt sinh tóm tắt điều khoản

System: Bạn là chuyên gia pháp lý Việt Nam. Dựa trên điều luật sau:

Điều {article_number}: {title}

Nội dung: {content}

Hãy tóm tắt điều luật này bằng 10–15 TỪ KHÓA TÌM KIẾM bao gồm:

1. CHỦ THỂ: ai là đối tượng áp dụng (công ty, cổ đông, thành viên...)
2. HÀNH ĐỘNG: động từ chính (thành lập, giải thể, họp, biểu quyết...)
3. ĐIỀU KIỆN: yêu cầu, tỷ lệ, thời hạn (51%, 30 ngày, đa số...)
4. TỪ ĐỒNG NGHĨA: từ người dùng hay hỏi liên quan đến điều này

Trả lời NGẮN GỌN, chỉ liệt kê các từ khóa cách nhau bằng dấu phẩy.

D.4 Loop 1 — Chọn chương (Pha trực tuyến)

Prompt này được Tầng 1 sử dụng trong Loop 1 để chọn các chương phù hợp từ danh sách chương kèm mô tả (Mục 3.4). Nhiệt độ = 0,0 để đảm bảo kết quả xác định.

Bảng D.4: Prompt chọn chương (Loop 1)

Task: Chọn index chương phù hợp với câu hỏi. **KHÔNG** giải thích, **CHỈ** trả về JSON.

Chapters: {doc_overview}

(JSON: index, name, description cho mỗi chương)

Question: {query}

Rules:

- Chọn 1–{max_chapters} chương phù hợp nhất
- Trả lời **ĐÚNG** format JSON bên dưới
- **KHÔNG** hỏi lại, **KHÔNG** giải thích

Output: {"selected_indices": [0, 1], "confidence": 0.8}

D.5 Loop 2 — Chọn điều khoản (Pha trực tuyến)

Prompt này được Tầng 1 sử dụng trong Loop 2 để chọn điều khoản cụ thể trong mỗi chương đã chọn. Ngoài tóm tắt, mỗi điều khoản còn được bổ sung `semantic_rank` và `dual_rank` (từ Tầng 2) giúp LLM đưa ra quyết định chính xác hơn.

D.6 Sinh câu trả lời theo phương pháp IRAC (Pha trực tuyến)

Prompt này được sử dụng ở bước cuối cùng để sinh câu trả lời cho người dùng từ các điều khoản đã truy xuất. Hệ thống áp dụng phương pháp phân tích pháp lý IRAC (Issue – Rule – Application – Conclusion) với hai biến thể tùy theo lĩnh vực.

D.6. Sinh câu trả lời theo phương pháp IRAC (Pha trực tuyến)

Bảng D.5: Prompt chọn điều khoản (Loop 2)

Task: Chọn index điều luật phù hợp. KHÔNG giải thích, CHỈ JSON.

Chapter: {chapter_name}

Articles: {article_infos}

(JSON: index, name, title, keywords, semantic_rank, dual_rank)

Question: {query}

Rules:

- Chọn 1–{max_articles} điều trả lời câu hỏi
- Ưu tiên điều có semantic_rank và dual_rank thấp (1 = phù hợp nhất). Nếu 2 điều có nội dung tương đương, chọn điều có rank thấp hơn
- KHÔNG hỏi lại, KHÔNG giải thích

Output: {"selected_indices": [0, 1], "confidence": 0.8}

Bảng D.6: Prompt sinh câu trả lời IRAC — Lĩnh vực pháp luật

System: Bạn là luật sư tư vấn pháp luật Việt Nam. Trả lời câu hỏi theo phương pháp phân tích pháp lý IRAC.

CÂU HỎI: {query}

TÀI LIỆU THAM KHẢO: {context_text}

HƯỚNG DẪN TRẢ LỜI:

Viết câu trả lời tự nhiên như luật sư tư vấn, theo flow sau:

1. Xác định vấn đề pháp lý cần giải quyết trong câu hỏi.
2. Nêu căn cứ pháp luật: trích dẫn chính xác Điều, Khoản, Điểm của văn bản pháp luật liên quan. Format: “Căn cứ Điều X Khoản Y [Tên văn bản]”.
3. Phân tích áp dụng: giải thích cụ thể điều luật áp dụng vào tình huống trong câu hỏi như thế nào, chỉ ra mối liên hệ giữa quy định và tình huống thực tế.
4. Kết luận dứt khoát, trả lời trực tiếp câu hỏi.

QUY TẮC:

- KHÔNG nhắc “tài liệu tham khảo” hay “tài liệu được cung cấp”.
 - Cuối câu trả lời ghi “Căn cứ pháp lý:” liệt kê các điều đã dùng.
 - CHỈ nói “Xin lỗi, tôi không tìm thấy quy định pháp luật liên quan” khi KHÔNG CÓ BẤT KỲ điều luật nào liên quan.
-

D.6. Sinh câu trả lời theo phương pháp IRAC (Pha trực tuyến)

Bảng D.7: Prompt sinh câu trả lời IRAC — Lĩnh vực đào tạo

System: Bạn là chuyên viên tư vấn đào tạo sau đại học tại Trường Đại học Công nghệ Thông tin (UIT) – ĐHQG-HCM. Trả lời câu hỏi của học viên cao học theo phương pháp phân tích IRAC.

CÂU HỎI: {query}

TÀI LIỆU THAM KHẢO: {context_text}

HƯỚNG DẪN TRẢ LỜI:

Viết câu trả lời tự nhiên, thân thiện như chuyên viên tư vấn đào tạo, theo flow sau:

1. Xác định vấn đề cần giải đáp trong câu hỏi của học viên.
2. Nêu căn cứ quy chế: trích dẫn chính xác Điều, Khoản, Điểm của quy chế/quyết định liên quan. Format: “Căn cứ Điều X Khoản Y [Tên quyết định]”. Phân biệt rõ quy chế cấp ĐHQG-HCM (QĐ 1393) và quy chế cấp trường UIT (QĐ 270).
3. Phân tích áp dụng: giải thích cụ thể quy định áp dụng vào tình huống của học viên như thế nào, chỉ ra mối liên hệ giữa quy chế và tình huống thực tế.
4. Kết luận rõ ràng, trả lời trực tiếp câu hỏi. Nếu quy định khác nhau giữa cấp ĐHQG và cấp trường, ưu tiên quy định cấp trường (QĐ 270) vì áp dụng trực tiếp cho học viên UIT.

QUY TẮC:

- KHÔNG nhắc “tài liệu tham khảo” hay “tài liệu được cung cấp”.
 - Cuối câu trả lời ghi “Căn cứ quy chế:” liệt kê các điều đã dùng.
 - CHỈ nói “Xin lỗi, tôi không tìm thấy quy định liên quan” khi KHÔNG CÓ BẤT KỲ điều khoản nào liên quan.
 - Dùng “quy chế”, “quy định”, “quyết định” thay vì “luật”, “pháp luật”, “văn bản pháp luật”.
-

Tài liệu tham khảo

- [1] Akari Asai et al. “Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection”. In: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2024.
- [2] Ilias Chalkidis et al. “LEGAL-BERT: The Muppets Straight out of Law School”. In: *Findings of the Association for Computational Linguistics: EMNLP 2020*. 2020, pp. 2898–2904.
- [3] Gordon V. Cormack, Charles L.A. Clarke, and Stefan Buettcher. “Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods”. In: *Proceedings of the 32nd International ACM SIGIR Conference (SIGIR)*. 2009, pp. 758–759.
- [4] Jacob Devlin et al. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. 2019, pp. 4171–4186.
- [5] Nhon V. Do, Hien D. Nguyen, and Ali Selamat. “Knowledge-Based Model of Expert Systems Using Rela-Model”. In: *International Journal of Software Engineering and Knowledge Engineering* 28.8 (2018), pp. 1047–1090.
- [6] Darren Edge et al. *From Local to Global: A Graph RAG Approach to Query-Focused Summarization*. Tech. rep. Microsoft Research, 2024.
- [7] Wenqi Fan et al. “A Survey on RAG Meeting LLMs: Towards Retrieval-Augmented Large Language Models”. In: *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)*. 2024, pp. 6491–6501.

- [8] Luyu Gao et al. “Precise Zero-Shot Dense Retrieval without Relevance Labels”. In: *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL)*. 2023, pp. 1762–1777.
- [9] Zirui Guo et al. “LightRAG: Simple and Fast Retrieval-Augmented Generation”. In: *Findings of the Association for Computational Linguistics: EMNLP 2025*. 2025, pp. 10746–10761.
- [10] Taher H. Haveliwala. “Topic-Sensitive PageRank”. In: *Proceedings of the 11th International Conference on World Wide Web (WWW)*. 2002, pp. 517–526.
- [11] Vladimir Karpukhin et al. “Dense Passage Retrieval for Open-Domain Question Answering”. In: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2020, pp. 6769–6781.
- [12] Jinqi Lai et al. “Large Language Models in Law: A Survey”. In: *AI Open* 5 (2024), pp. 181–196.
- [13] Hong Hien Le et al. “A Three-Tier Knowledge Graph RAG for Vietnamese Legal Question Answering”. In: *SOMET 2026 (under review)* (2026).
- [14] Patrick Lewis et al. “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”. In: *Advances in Neural Information Processing Systems 33 (NeurIPS)*. 2020, pp. 9459–9474.
- [15] Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schütze. *Introduction to Information Retrieval*. Cambridge University Press, 2008.
- [16] Costas Mavromatis and George Karypis. “GNN-RAG: Graph Neural Retrieval for Large Language Model Reasoning”. In: *arXiv preprint arXiv:2405.20139* (2024).
- [17] Quang Huy Ngo et al. “AimeLaw at ALQAC 2021: Enriching Neural Network Models with Legal-Domain Knowledge”. In: *Proceedings of the 13th International Conference on Knowledge and Systems Engineering (KSE)*. IEEE, 2021.
- [18] Dat Quoc Nguyen and Anh Tuan Nguyen. “PhoBERT: Pre-trained Language Models for Vietnamese”. In: *Findings of the Association for Computational Linguistics: EMNLP 2020*. 2020, pp. 1037–1042.

- [19] Thinh H. Nguyen et al. “Legal-Onto: An Ontology-based Model for Representing the Knowledge of a Legal Document”. In: *Proceedings of the 17th International Conference on Evaluation of Novel Approaches to Software Engineering (ENASE)*. 2022, pp. 426–434.
- [20] Nils Reimers and Iryna Gurevych. “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks”. In: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2019, pp. 3982–3992.
- [21] Stephen Robertson and Hugo Zaragoza. “The Probabilistic Relevance Framework: BM25 and Beyond”. In: *Foundations and Trends in Information Retrieval* 3.4 (2009), pp. 333–389.
- [22] Parth Sarthi et al. “RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval”. In: *International Conference on Learning Representations (ICLR)*. 2024.
- [23] Giovanni Sartor et al. *Approaches to Legal Ontologies: Theories, Domains, Methodologies*. Dordrecht: Springer, 2011.
- [24] Thanh Vu et al. “VnCoreNLP: A Vietnamese Natural Language Processing Toolkit”. In: *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Demonstrations (NAACL)*. 2018, pp. 56–60.
- [25] Mingtian Zhang, Yu Tang, and PageIndex Team. *PageIndex: Next-Generation Vectorless, Reasoning-based RAG*. PageIndex Blog. <https://pageindex.ai/blog/pageindex-intro>. Sept. 2025.
- [26] Haoxi Zhong et al. “How Does NLP Benefit Legal System: A Summary of Legal Artificial Intelligence”. In: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*. 2020, pp. 5218–5230.